


Estatística Básica

com suporte computacional 



```
# Estatísticas básicas
x <- dados$variavel
n <- length(x)
media <- mean(x)
mediana <- median(x)
desvio <- sd(x)
variancia <- var(x)
q <- quantile(x, c(.25,.5,.75))
resumo <- data.frame(n, media,
  mediana, desvio)
```

```
# Resumo dos dados
resumo
summary(x)
fivenum(x)
range(x)
IQR(x)
sd(x)
var(x)
```

```
# Histograma
hist(x, probability = TRUE,
  col = "#4C78A8",
  border = "white",
  main = "Histograma",
  xlab = "x")
abline(v = mean(x),
  col = "#F58518",
  lwd = 2, lty = 2)
```

```
# Boxplot
boxplot(x, horizontal = TRUE,
  col = "#7287B2",
  main = "Boxplot",
  xlab = "x")
abline(v = median(x),
  col = "#E45756",
  lwd = 2, lty = 2)
```

Francisco Louzada
Paulo Henrique Ferreira
Pedro Luiz Ramos

Primeira edição

Dados Internacionais de Catalogação na Publicação (CIP)
(Câmara Brasileira do Livro, SP, Brasil)

Louzada, Francisco

Estatística básica com suporte computacional
[livro eletrônico] / Francisco Louzada, Paulo
Henrique Ferreira, Pedro Luiz Ramos. -- São Carlos,
SP :

Ed. dos Autores, 2026.

PDF

Requisitos do sistema: Adobe Acrobat Reader

Modo de acesso: World Wide Web

ISBN 978-65-02-13968-4

1. Estatística 2. Estatística matemática
3. Probabilidades 4. Software I. Ferreira, Paulo
Henrique. II. Ramos, Pedro Luiz. III. Título.

26-365070.0

CDD-519.5

Índices para catálogo sistemático:

1. Estatística : Matemática 519.5

Camila Aparecida Rodrigues - Bibliotecária CRB -
SP-010133/O

Prefácio

Primeira edição

A ciência estatística, ou simplesmente estatística, tem provocado enorme impacto em praticamente todas as áreas do conhecimento, dentre as quais podemos citar desde áreas básicas como a física, a química e a biologia, às mais tecnológicas, como as engenharias, passando pela agronomia, astronomia, criminologia, demografia, saúde e psicologia. Consequentemente, todos os setores de atividades, primário, secundário e terciário, têm se beneficiado dos avanços desta ciência, inclusive a administração pública. E se mostra evidente que nenhuma ciência tenha interagido tanto com as demais em suas atividades quanto a ciência estatística, sendo o ensino desta ciência, atualmente, obrigatório em praticamente quase todos os cursos de graduação das mais diversas áreas, com pouquíssimas exceções. Neste contexto, este livro apresenta uma introdução aos principais elementos de estatística básica de uma perspectiva prática e interativa.

A motivação para escrever este material tem como base nossa percepção de que, do melhor do nosso conhecimento, poucos livros de estatística básica em português mostram a aplicação dos procedimentos teóricos apresentados em um *software* livre com códigos disponíveis para o leitor, o que facilita, em muito, a aplicação direta e o aprendizado das metodologias e técnicas estatísticas.

Assim, no presente livro, os procedimentos teóricos apresentados são viabilizados a qualquer usuário ou analista por meio de um *software* livre e gratuito. Ao longo dos capítulos são apresentadas as teorias envolvidas e os procedimentos de análises, bem como os resultados obtidos por meio desses procedimentos. Além disso, são apresentados os códigos, construídos no *software* livre e gratuito R, os quais podem ser utilizados para se aplicar de forma rápida o ferramental estatístico aprendido em conjuntos de dados que o usuário deseja analisar. Desta forma, usuários que possuem pouco ou nenhum conhecimento em programação e/ou não possuem um *software* estatístico comercial se beneficiarão do livro e terão plenas condições de fazer uso de um recurso computacional livre e gratuito para analisar estatisticamente seus dados.

O material contido no livro foi projetado para ser ministrado em um curso de estatística básica de um semestre em cursos de graduação, principalmente em Administração, Ciências Biomédicas e Engenharias, ou em cursos de pós-graduação de áreas afins em que existe a necessidade de um curso introdutório sobre o tema. Temos também experiências que demonstram que o material pode ser seguido em forma de autoestudo, dado que a estrutura do livro permeia da apresentação da teoria envolvida à sua aplicação prática, com a utilização de um *software* livre.

O livro é composto por oito capítulos. No Capítulo 1 são apresentadas várias motivações para a utilização de procedimentos estatísticos. No Capítulo 2 são apresentados elementos de probabilidade básica. No Capítulo 3 são apresentados procedimentos de sumarização de dados. No Capítulo 4 são apresentadas as distribuições

de algumas estatísticas. No Capítulo 5 são discutidos procedimentos inferenciais e testes de hipóteses. No Capítulo 6 são apresentados testes de hipóteses para dois grupos. No Capítulo 7 são discutidos procedimentos de análise de variância. Por fim, no Capítulo 8 são apresentados alguns tópicos básicos em análise de regressão.

Agradecemos a Adriano K. Suzuki, Estela M. Bereta, Marcelo de Paula e Mari Roman, que participaram de uma versão embrionária do material na ocasião, como parte das atividades da disciplina Tópicos Avançados em Estatística do Programa de Pós-Graduação em Estatística da Universidade Federal de São Carlos (PPGEs-UFSCar), ministrada pelo primeiro autor. Agradecemos também a Taciana K. Oliveira, que revisou o material, testando e adequando os comandos no *software* R, e a Gleici S. C. Perdoná, José Galvão Leite, Lilia C. C. da Costa e Mario de Castro, que, em um momento inicial, tiveram contato com o material e apresentaram críticas, sugestões e comentários construtivos. A todos, nossa gratidão.

O material foi desenvolvido inicialmente dentro do laboratório Centro de Estudos do Risco (CER) da Universidade de São Paulo e Universidade Federal de São Carlos (USP/UFSCar), e posteriormente, junto ao Centro de Ciências Matemáticas Aplicadas à Indústria (CeMEAI) da USP e ao CER da Universidade Federal da Bahia.

A ciência estatística é uma disciplina em constante desenvolvimento e tópicos avançados não são tratados no livro, o que gera a oportunidade para a pesquisa e preparação futura de material sobre o assunto. Assim, seremos gratos a sugestões e críticas que possam contribuir para novos desenvolvimentos e dirimir quaisquer problemas envolvendo o presente material.

Finalmente, agradecemos a todos os alunos que passaram pelo teste de ler este material e que nos passaram as suas percepções sobre o mesmo.

São Carlos, 28 de maio de 2026.

Francisco Louzada
Paulo Henrique Ferreira
Pedro Luiz Ramos

Sobre os autores

Francisco Louzada é professor de Estatística no Instituto de Ciências Matemáticas e de Computação da Universidade de São Paulo (ICMC-USP), em São Carlos. É doutor em Estatística pela University of Oxford e atua em ensino, pesquisa e aplicações de Estatística e Ciência de Dados.

Paulo Henrique Ferreira é professor do Departamento de Estatística da Universidade Federal da Bahia (DEst-UFBA), onde atua em ensino, pesquisa e orientação nas áreas de análise de sobrevivência e confiabilidade, controle estatístico de processos (CEP) e aprendizado de máquina. É doutor em Estatística pela Universidade Federal de São Carlos (UFSCar) e realizou estágio de pós-doutorado no Instituto de Ciências Matemáticas e de Computação da Universidade de São Paulo (ICMC-USP).

Pedro Luiz Ramos é professor assistente do Departamento de Estatística da Pontifícia Universidad Católica de Chile, onde atua em ensino, pesquisa e orientação nas áreas de análise de sobrevivência, inferência Bayesiana, confiabilidade, teoria de distribuições e controle estatístico de processos. É doutor em Estatística pela Universidade de São Paulo e realizou estágio de pós-doutorado na mesma instituição entre 2018 e 2021. Possui ampla produção científica em periódicos internacionais e colabora ativamente em pesquisas envolvendo modelagem estatística aplicada e métodos inferenciais.

Sumário

1	Ideias básicas, motivações e aplicações	1
1.1	Introdução	1
1.2	Alguns exemplos de aplicação	4
1.2.1	Ecologia: estimação de tamanho e variedade populacional . . .	4
1.2.2	Medicina: estudo da AIDS	6
1.2.3	Política: pesquisa de intenção de voto numa eleição	7
1.2.4	Pesquisa de mercado: lançamento de um novo produto	9
1.2.5	Controle de qualidade: defeito em parafusos	9
1.3	Introdução ao <i>software</i> R	10
2	Elementos de probabilidade	12
2.1	Introdução	12
2.2	Conceitos básicos	13
2.3	Probabilidade: definições	20
2.4	Probabilidade condicional e independência	24
2.5	Variáveis aleatórias	29
2.6	Curva Normal de probabilidade	38
2.6.1	Características da curva Normal	41
2.6.2	Distribuição Normal reduzida ou padronizada	41
2.7	Considerações finais	46
2.8	Exercícios propostos	46
3	Sumarização de dados	49
3.1	Introdução	49
3.2	Representação gráfica	50
3.2.1	Representação gráfica: dados categóricos	50
3.2.2	Representação gráfica: dados quantitativos	54
3.3	Medidas de posição central	60
3.3.1	Somatório	60
3.3.2	Média aritmética	62
3.3.3	Moda	65
3.3.4	Mediana	67

3.3.5	Relações empíricas entre média, moda, mediana e as distribuições de dados	69
3.4	Medidas de dispersão	71
3.4.1	Amplitude	71
3.4.2	Desvio médio	72
3.4.3	Variância	74
3.4.4	Desvio-padrão	75
3.4.5	Coeficiente de variação	77
3.5	Dados agrupados em classes	79
3.6	Apresentação tabular	80
3.6.1	Distribuição de frequência	80
3.6.2	Construção de uma distribuição de frequência	80
3.6.3	Medidas de posição ou tendência central	87
3.6.4	Medidas de dispersão	92
3.6.5	Medidas separatrizes	94
3.7	Considerações finais	103
3.8	Exercícios propostos	104
4	Distribuições de estatísticas	107
4.1	Introdução	107
4.2	Conceitos básicos	108
4.3	Amostragem	110
4.4	Número de amostras em população finita	111
4.5	Erro-padrão da média	113
4.5.1	Fator de correção para populações finitas	113
4.6	Distribuição de amostragem	115
4.6.1	População não Normal	116
4.6.2	População Normal	118
4.6.3	Duas populações Normais	120
4.7	Considerações finais	121
4.8	Exercícios propostos	121
5	Intervalos de confiança e testes de hipóteses para uma população	123
5.1	Introdução	123
5.2	Probabilidade de cobertura	124
5.3	Média populacional	126
5.3.1	Intervalo de confiança com desvio-padrão conhecido	127
5.3.2	Intervalo de confiança com desvio-padrão desconhecido	129
5.3.3	Testes de hipóteses	131
5.3.4	Tipos de hipótese - unilaterais e bilateral	132
5.4	Proporção populacional	139
5.4.1	Intervalo de confiança	139

5.4.2	Teste de hipóteses	142
5.5	Variância populacional	146
5.5.1	Intervalo de confiança	146
5.5.2	Teste de hipóteses	148
5.6	Relação entre teste de hipóteses e intervalo de confiança	150
5.7	Tipos de erros	151
5.8	P-valor	153
5.9	Considerações finais	153
5.10	Exercícios propostos	154
6	Testes de hipóteses para duas populações	156
6.1	Introdução	156
6.2	Comparação entre duas variâncias	156
6.3	Comparação de duas médias	162
6.3.1	Dados pareados	162
6.3.2	Dados não pareados	171
6.4	Considerações finais	181
6.5	Exercícios propostos	181
7	Análise de variância	183
7.1	Introdução	183
7.2	Exemplos e discussões	184
7.2.1	Notações	186
7.3	Análise de variância com um fator fixo	188
7.3.1	Modelo estatístico	188
7.3.2	Suposições do modelo	188
7.3.3	Hipóteses	188
7.3.4	Tabela ANOVA	189
7.3.5	Regra de decisão	189
7.3.6	Interpretação dos elementos da ANOVA	190
7.3.7	Intervalo de confiança para a média de cada tratamento	190
7.4	Análise de variância com dois fatores fixos	197
7.4.1	Notações	198
7.4.2	Modelo estatístico	199
7.4.3	Suposições do modelo	199
7.4.4	Hipóteses	200
7.4.5	Tabela ANOVA	200
7.4.6	Interpretação dos elementos da ANOVA	201
7.4.7	Regra de decisão	202
7.5	Considerações finais	205
7.6	Exercícios propostos	205

8	Tópicos básicos em análise de regressão	210
8.1	Introdução	210
8.2	Relação entre as variáveis	210
8.2.1	Coeficiente de correlação linear	213
8.2.2	Teste de hipóteses	215
8.3	O modelo estatístico	217
8.4	Estimação dos parâmetros	220
8.4.1	Suposições do modelo	221
8.4.2	Mínimos Quadrados	222
8.5	Qualidade do ajuste	227
8.5.1	Coeficiente de determinação	229
8.6	Distribuição amostral dos estimadores	230
8.6.1	Teste de hipóteses	231
8.6.2	Intervalos de confiança	232
8.7	Adequação do modelo de regressão linear simples	232
8.8	Considerações finais	242
8.9	Exercícios propostos	242
	Referências bibliográficas	245
	Tabelas	250
	Respostas dos exercícios propostos	259

Capítulo 1

Ideias básicas, motivações e aplicações

Resumo do capítulo: *Neste capítulo, apresentamos de forma introdutória alguns conceitos básicos em Estatística, que serão fundamentais para os próximos capítulos.*

Objetivo: *Proporcionar ao leitor uma visão holística e abrangente da ciência estatística, apresentando exemplos de aplicações em algumas áreas do conhecimento.*

1.1 Introdução

De forma geral, a Ciência Estatística, ou simplesmente Estatística, se constitui em uma coleção de técnicas e métodos responsáveis pela extração de conhecimento a partir de informações contidas em um conjunto de dados, envolvendo, dentre outros, o planejamento de um determinado experimento a ser realizado, a coleta qualificada dos dados, a inferência, o processamento, a manipulação e a análise.

A palavra **estatística** deriva da palavra em latim *status*, traduzida como o “estado do Estado”, uma vez que as coletas de dados na Antiguidade eram constituídas fundamentalmente de levantamentos promovidos pelo Estado. Em particular, na Roma Antiga, tais levantamentos tinham por objetivo o registro de todos os indivíduos de determinada classe social, tal como o inventário de suas propriedades, a fim de determinar como e quem deveria ser taxado e/ou convocado para servir ao exército romano. Esses levantamentos amplos eram denominados **censos**, sendo promovidos por um magistrado conhecido como “censor” (do latim *censore*), cargo esse criado em 443 a.C. Subsequentemente, o cargo passou a abranger outras funções, como a fiscalização da conduta moral dos cidadãos (daí decorrendo, igualmente, a palavra “censura”) (Bearzoti & Filho, 2000).

Com o desenvolvimento do **método científico**, a partir do século XVI, a Estatística viria a desempenhar um papel fundamental na ciência, por propiciar um

tratamento formal de dados experimentais. Inicialmente, no século XVI, ela era vista pelos ingleses, por exemplo, como uma ciência política, designada para descrever as características de um determinado estado ou país, tais como área, população, recursos naturais e riquezas (Yule & Kendall, 1950; Laurenti *et al.*, 1985; Szwarcwald & Castilho, 1992).

Em 1662, o inglês John Graunt publicou informes estatísticos sobre nascimentos e mortes em Londres (Rothman, 1996). A partir daí, teve início o desenvolvimento da Probabilidade e Estatística, principalmente a partir do século XVII, com o estudo das grandes epidemias que assolavam a humanidade, dando margem ao desenvolvimento da demografia. Nos séculos seguintes, um número cada vez maior de áreas foi se incorporando ao conjunto das que faziam uso da Estatística (Botter *et al.*, 1996).

Com a consolidação gradual da **probabilidade**, a partir do século XVII, tornou-se possível usar informações coletadas em **amostras** para inferir características de uma **população**. Neste contexto, população é o conjunto completo de unidades sobre o qual se deseja produzir conhecimento, enquanto a amostra corresponde à parte desse conjunto efetivamente observada. Essa ideia reduziu a dependência de censos, nos quais todos os elementos precisam ser avaliados, e permitiu estudar populações de forma mais econômica e operacionalmente viável (Bearzoti & Filho, 2000).

A partir de 1925, os trabalhos de Ronald Aylmer Fisher deram novo impulso à Estatística como base metodológica da pesquisa científica. O papel do estatístico passou a incluir, de modo sistemático, o planejamento experimental, a análise dos dados produzidos e a comunicação dos resultados para apoiar decisões. Antes disso, contribuições como as de Carl Friedrich Gauss e de William Seally Gosset, publicadas sob o pseudônimo de “Student”, já haviam sido fundamentais para esse desenvolvimento (Ferreira, 1996).

Em 1936, George Horace Gallup inaugurou a prática da pesquisa de intenção de voto, segundo a qual uma amostra representativa da população (considerando diferentes níveis de escolaridade, idade e renda) era entrevistada. Tal prática conquistou grande popularidade a partir daquele ano, visto que as previsões da pesquisa se confirmaram nas urnas (Bearzoti & Filho, 2000).

No Brasil, a Estatística tem sua história ligada ao Instituto Brasileiro de Geografia e Estatística (IBGE), fundado ainda nos tempos do Brasil Império (Ara & Louzada, 2012). Segundo os autores, Araujo (1993) e Dantas (2002) apontam que o primeiro curso de “Inferência Estatística” foi ministrado em 1947, com base no livro “Mathematical Methods of Statistics” de Harald Cramer. Contudo, apenas em 1953 duas escolas iniciaram o ensino da Estatística no Brasil: a Escola Nacional de Ciências Estatísticas (ENCE), criada pelo IBGE, e a Escola Superior de Estatística

da Bahia (ESEB), fundada e mantida pela Fundação Visconde de Cairu (IBGE, 1987; Silva, 1989).

Nas últimas décadas, com a grande revolução da Informática, tem-se observado um avanço significativo das áreas de Probabilidade e Estatística, com o desenvolvimento de linguagens de programação mais poderosas, deixando à disposição do pesquisador diversas ferramentas alternativas para auxiliar no seu trabalho (Botter *et al.*, 1996).

Neste contexto, a Estatística tem causado um enorme impacto em praticamente todas as áreas do conhecimento, dentre as quais podemos citar desde áreas básicas, como a biologia, química e física, até áreas mais tecnológicas, como as engenharias, astronomia, agronomia, ecologia, demografia, criminologia, psicologia e saúde. Por conseguinte, todos os setores de atividades - primário, secundário e terciário - têm se beneficiado dos progressos desta ciência, inclusive a administração pública (Ara & Louzada, 2012). E hoje em dia, grande parte das decisões tomadas na quase totalidade das áreas de atividade humana moderna são suportadas por evidências, tendo suas bases na Estatística.

Para fins de estudo, é comum organizar a Estatística em dois grandes blocos: **Estatística Descritiva** e **Inferência Estatística**. A primeira reúne ferramentas para organizar, apresentar e resumir dados por meio de tabelas, gráficos e medidas numéricas. A segunda utiliza modelos probabilísticos para tirar conclusões sobre uma população com base nas informações observadas em uma amostra representativa (Tavares, 2014).

Algumas aplicações da Estatística em áreas específicas são:

- Agronomia: comparação da eficácia de diferentes insumos agrícolas, determinação de sementes mais resistentes a uma determinada praga;
- Astronomia: estudos vinculados a medição de corpos celestes, como suas distâncias, tamanhos, massas e densidades;
- Demografia: estudo sobre fenômenos populacionais, sociais ou ambientais;
- Ecologia: estimação de tamanho populacional ou estudo da dinâmica de populações animais e vegetais;
- Economia: previsão da inflação ou rendimento da bolsa de valores ao longo do tempo;
- Finanças: estudo do comportamento do uso de cartões de crédito, detecção de cartões de crédito roubados, identificação de clientes fiéis;

- Indústria: controle da qualidade de um item, estudo do tempo de garantia/vida útil de um produto;
- Marketing e Comércio: identificação de compras de um determinado cliente, associações entre itens comprados e as características cadastrais dos clientes;
- Medicina: estudo do tempo de vida de pacientes com certa doença, comparação da eficácia de tratamentos, identificação de terapias mais eficientes, determinação de padrões em sequências de DNA;
- Meio Ambiente: determinação de riscos relacionados a usinas nucleares, determinação do impacto ambiental de instalações de fábricas em uma certa região, estudo da difusão de poluentes;
- Meteorologia: previsão de chuvas, ventos ou temperaturas;
- Política: pesquisa de intenção de voto numa eleição (municipal, estadual ou federal) ou pesquisa sobre a popularidade de determinado candidato político;
- Seguros e Planos de Saúde: predição de clientes que comprariam novos tipos de apólices ou planos de saúde, identificação de clientes de sinistros fraudulentos, identificação de clientes inadimplentes.

1.2 Alguns exemplos de aplicação

Nesta seção apresentamos alguns exemplos que requerem a aplicação de metodologia estatística.

1.2.1 Ecologia: estimação de tamanho e variedade populacional

Para recuperar áreas devastadas pelo desmatamento e ocupação pelo gado, foi criado um projeto de reflorestamento que visa semear sementes de três plantas nativas na área devastada. Porém, por ser um projeto piloto, requer-se o monitoramento do desenvolvimento das plantas para verificar o êxito do projeto e adotar medidas de melhoria, caso necessário. A equipe precisa de estimativas em relação às questões:

1. Quantas espécies se desenvolveram?
2. Quantas mudas de cada espécie nasceram?
3. Como está o desenvolvimento das plantas que nasceram?

Para responder a essas indagações, os pesquisadores planejam realizar uma amostragem para obter dados que possam ajudá-los a avaliar a situação. Algumas particularidades precisam ser respondidas no planejamento.

Como será a coleta de dados:

Conhecendo a região na qual as sementes foram semeadas e a forma como foram semeadas, eles acreditam que em áreas de 3 metros $\times$ 3 metros terão uma estimativa de quantas plantas de cada espécie se desenvolveram. Desta forma, a unidade amostral adotada serão quadrados de 9 metros².

Pela extensão da área, eles decidem que serão consideradas 53 unidades amostrais. Para não ter influência do pesquisador e preservar a aleatoriedade necessária, tais unidades serão demarcadas previamente em mapa e depois localizadas em solo, com auxílio de GPS (do inglês *Global Positioning System*).

Quais variáveis irão amostrar:

Para responder às duas primeiras questões, basta fazer a distinção das espécies que se desenvolveram e efetuar a contagem das mesmas. Já para responder à terceira questão, outras variáveis precisam ser observadas. Dentre as tantas possíveis variáveis, concluíram que as seguintes informações já seriam suficientes para caracterizar o desenvolvimento das plantas:

- Altura média das plantas;
- Número médio de ramos desenvolvidos;
- Coloração mais comum e em quantas plantas ocorreu;
- Existência de doença.

Para determinar a altura média das plantas, optou-se por fazer de 0 a 5 medições em cada área (menos de 5 apenas quando não se tem 5 na área), de acordo com a disponibilidade de plantas, e posteriormente obtém-se o valor médio das mesmas.

A escala de cores das folhas para cada espécie já é conhecida, e com base nela, observa-se qual a cor que mais ocorre para a espécie e em quantas plantas ela ocorreu.

Algumas espécies possuem a característica de ramificação logo no início de sua vida. Para essas espécies serão consideradas de 0 a 5 plantas por área (menos de 5 somente quando não se tem 5 na área) e conta-se o número de ramos de cada uma, para posteriormente obter-se a média.

A existência de doenças apenas será indicada por 0 ou 1, em que 0 indica ausência de doença e 1 indica presença de doença, não levando em consideração quais doenças e quantas aparecem.

Após feito o planejamento, é preciso obter os dados e disponibilizá-los para análises. Na Tabela 1.1 a seguir, apresentamos alguns dos resultados.

Os resultados serão convertidos para a área total, visto que os valores apresentados na Tabela 1.1 referem-se a áreas de 9 metros².

Tabela 1.1: Dados de reflorestamento em área devastada do cerrado brasileiro.

Espécies	Variáveis	Unidades amostrais										
		1	2	3	4	5	6	7	8	9	...	53
Araticum-do-cerrado	Qtde	0	4	2	0	2	0	0	2	0	...	0
	Altura	-	23,50	19,45	-	34,60	-	-	25,10	-	...	-
	Ramos	-	2,50	3,00	-	3,00	-	-	2,50	-	...	-
	Cor	-	1	2	-	2	-	-	2	-	...	-
	Doença	-	0	0	-	1	-	-	1	-	...	-
Pequi	Qtde	3	0	1	2	1	0	4	0	0	...	2
	Altura	12,45	-	16,05	15,35	17,90	-	15,30	-	-	...	13,70
	Ramos	2,67	-	3,00	2,50	4,00	-	3,50	-	-	...	3,00
	Cor	2	-	1	1	1	-	1	-	-	...	2
	Doença	1	-	0	0	0	-	0	-	-	...	1
Copaíba	Qtde	0	0	2	3	2	0	0	1	1	...	2
	Altura	-	-	14,76	15,60	27,90	-	-	15,70	17,90	...	19,50
	Ramos	-	-	1,50	2,67	2,00	-	-	3,00	2,00	...	3,00
	Cor	-	-	2	1	1	-	-	1	1	...	1
	Doença	-	-	0	0	0	-	-	1	0	...	0

Fonte: Dados fictícios.

1.2.2 Medicina: estudo da AIDS

O estudo da epidemia da Síndrome da Imunodeficiência Adquirida (AIDS) é uma área de intensa pesquisa. A maioria dos trabalhos nessa área tem como principal objetivo, avaliar o tempo de vida de pacientes que se submetem a determinado tratamento. Um estudo foi desenvolvido pela professora Denise Utsch Gonçalves do Departamento de Oftalmologia e Otorrinolaringologia da Faculdade de Medicina da Universidade Federal de Minas Gerais, e teve como interesse a ocorrência de manifestações otorrinolaringológicas em pacientes HIV positivos. O interesse primordial do estudo é verificar a hipótese de que a infecção pelo vírus da imunodeficiência humana (HIV) aumenta o risco de ocorrência de sinusite.

Nesse estudo foram utilizadas informações de 91 pacientes HIV positivos e 21 HIV negativos. Esses indivíduos foram acompanhados durante 24 meses, e sua classificação seguiu critérios especificados pelo *Centers of Disease Control - CDC, 1987*, sendo classificados como:

- HIV soronegativo - não possuem o vírus HIV;
- HIV soropositivo assintomático - possuem o vírus mas não desenvolveram o quadro clínico da AIDS;
- ARC - apresentam baixa imunidade e outros indicadores clínicos que antecedem o quadro clínico da AIDS;
- AIDS - já desenvolveram infecções oportunistas que definem a AIDS.

A cada consulta trimestral, a classificação do paciente foi reavaliada.

Outro objetivo do estudo era identificar os grupos de risco para a sinusite. Os principais fatores de risco incluídos estão listados na Tabela 1.2.

Tabela 1.2: Covariáveis medidas no estudo de ocorrência de sinusite.

Idade	Medida em anos
Sexo	0 - Masculino 1 - Feminino
Grupo de risco	1 - Paciente HIV soronegativo 2 - Paciente HIV soropositivo assintomático 3 - Paciente com ARC 4 - Paciente com AIDS
Atividade sexual	1 - Homossexual 2 - Bissexual 3 - Heterossexual
Uso de drogas injetáveis	1 - Sim 2 - Não
Uso de cocaína por aspiração	1 - Sim 2 - Não

Fonte: Colosimo e Giolo (2006).

Foram observados o tempo de permanência do indivíduo em cada grupo e as covariáveis acima. Na Tabela 1.3 estão apresentados os dados observados para 9 dos 112 pacientes. Para dados completos, vide Colosimo e Giolo (2006).

Tabela 1.3: Dados de pacientes com sinusite em relação ao vírus da AIDS.

pac	id	sex	grp	ti	tf	ac	cd4	cd8	ats	ud
1	31	0	4	0,0	0,0	2	NA	NA	3	2
2	22	1	2	0,0	378,0	2	132,0	715,0	3	2
3	32	0	4	0,0	84,0	2	75,0	315,0	3	2
4	36	0	2	0,0	109,0	2	NA	NA	3	2
5	34	0	2	0,0	134,0	NA	NA	NA	NA	NA
23	NA	0	2	0,0	471,5	2	NA	NA	1	2
23	NA	0	4	471,5	507,0	2	NA	NA	1	2
24	34	1	3	0,0	141,5	2	5,0	200,0	3	2
24	34	1	4	141,5	244,5	2	5,0	200,0	3	2
25	31	0	4	0,0	49,0	2	NA	NA	1	1
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
112	24	0	2	0,0	226,0	NA	NA	NA	NA	NA

pac = paciente; id = idade (anos); sex = sexo, grp = grupo de risco; ti = tempo inicial; tf = tempo final no grupo; ac = aspira cocaína; cd4 = contagem de CD4; cd8 = contagem de CD8; ats = atividade sexual; ud = uso de drogas injetáveis; e NA = valor não observado.

Fonte: Colosimo e Giolo (2006).

1.2.3 Política: pesquisa de intenção de voto numa eleição

Sempre que o país está em campanha política, os órgãos de pesquisa trabalham na tentativa de prever os resultados das eleições vindouras. Em âmbito nacional, as pesquisas geralmente são realizadas em algumas capitais com um certo número de eleitores. Este número de eleitores consultados está relacionado com o número de eleitores que o país possui e o percentual de erro admitido para a pesquisa.

Porém, ao realizar uma pesquisa entre os candidatos A, B e C à presidência da República, os órgãos de pesquisa podem estar interessados em caracterizar o perfil do eleitor de cada candidato. Desta forma, não apenas será solicitado ao eleitor entrevistado em qual candidato ele votará, mas também serão coletadas do mesmo, algumas informações que o descreverão.

Na pesquisa de intenção de voto, pode ser solicitado que o entrevistado manifeste sua intenção ou então que escolha uma entre as possíveis.

Com anseio de caracterizar o eleitor de cada candidato, determinou-se que devem ser coletadas informações quanto ao grau escolar, sexo, nível socioeconômico, região e idade (vide Tabela 1.4).

Tabela 1.4: Covariáveis consideradas na pesquisa de intenção de voto.

Idade	Medida em anos
Estado	Nome do estado em que reside
Sexo	1 - Masculino
	2 - Feminino
Grau escolar	1 - Primeiro grau incompleto
	2 - Primeiro grau completo
	3 - Ensino médio incompleto
	4 - Ensino médio completo
	5 - Superior incompleto
	6 - Superior completo
Classe econômica	1 - Classe A
	2 - Classe B
	3 - Classe C

Consideremos que a pesquisa foi aplicada em 18 estados do Brasil, totalizando 4.105 eleitores. O banco de dados com o resultado da pesquisa pode ser apresentado como na Tabela 1.5.

Tabela 1.5: Dados de pesquisa eleitoral para presidente da República.

eleitor	candidato	sex	id	gri	nse	UF
1	A	1	20	3	1	SP
2	B	1	22	3	2	PR
3	NA	1	35	5	3	ES
4	A	2	65	1	2	AL
5	B	1	45	2	1	MA
6	C	2	36	2	3	SP
7	C	2	54	3	2	SP
8	A	1	36	4	3	SP
9	C	1	42	1	3	RJ
10	BRANCO	2	18	2	3	RS
11	C	1	22	6	1	RN
12	NA	2	21	2	2	MA
13	NULO	2	44	4	2	RJ
14	A	2	23	5	3	RJ
15	C	1	43	3	3	SP
⋮	⋮	⋮	⋮	⋮	⋮	⋮
4.105	C	2	NA	3	1	PR

candidato = candidato escolhido (A, B ou C); NA (indeciso ou não respondeu);
BRANCO (voto em branco); NULO (voto nulo); sex = sexo; id = idade (anos);
gri = grau de instrução; nse = nível socioeconômico; UF = Unidade Federativa.
Fonte: Dados fictícios.

1.2.4 Pesquisa de mercado: lançamento de um novo produto

O gerente de uma fábrica de desinfetante pretende realizar uma pesquisa de mercado para um novo produto que deseja lançar, com o intuito de estimar a porcentagem de potenciais consumidores.

Inicialmente, pretende-se vender na região Sul para, posteriormente, expandir para outros estados. Foi coletada uma amostra composta por 300 famílias, na qual obteve as seguintes informações: existência do interesse em comprar o produto, quantidade mensal de uso e renda familiar mensal (vide Tabela 1.6).

Neste exemplo, temos:

População: conjunto de todas as famílias que moram na região Sul.

Amostra: conjunto de algumas dessas famílias que foram questionadas pela empresa.

Problema: a obtenção de uma estimativa do número de compradores do novo desinfetante na população.

1.2.5 Controle de qualidade: defeito em parafusos

Em uma fábrica de parafusos, pretende-se garantir que a porcentagem de peças defeituosas (considera-se defeituosa, por exemplo, quando o diâmetro for maior que 6 milímetros) não exceda um determinado valor. A cada 2 horas, uma amostra de 50

Tabela 1.6: Dados sobre a intenção de compra do novo desinfetante.

Família	Intenção de compra	Quantidade mensal de uso	Renda familiar mensal (em reais)
1	sim	2	1.375
2	não	3	1.600
3	sim	4	2.050
4	sim	6	2.250
5	não	1	875
6	não	2	1.150
7	sim	3	1.450
8	sim	4	1.400
⋮	⋮	⋮	⋮
300	não	2	1.100

Fonte: Dados fictícios.

parafusos é selecionada (vide exemplo na Tabela 1.7). Após feita a medição, testes estatísticos são realizados para verificar se as medidas (em milímetros, mm) estão dentro do padrão especificado. Caso não estejam, a produção é interrompida e a máquina é regulada.

Neste exemplo, temos:

População: conjunto de todos os parafusos fabricados.

Amostra: conjunto de parafusos escolhidos ao acaso no lote produzido.

Problema: estimar a porcentagem de defeituosos em toda a produção.

Tabela 1.7: Amostra de um conjunto de parafusos.

Parafuso	Medida do diâmetro (em mm)
1	6,01
2	5,99
3	6,00
4	5,98
5	6,02
6	5,99
7	5,96
8	5,99
⋮	⋮
50	5,98

Fonte: Dados fictícios.

1.3 Introdução ao *software* R

Nesta seção apresentaremos alguns conceitos básicos para a manipulação de dados no *software* R (R core). O R é um *software* gratuito voltado para computação estatística e gráfica. Ele está disponível para uma grande variedade de plataformas

(Linux, Windows e Mac OS X), podendo ser baixado facilmente do *website*: <https://cran.r-project.org>. Os algoritmos são implementados por meio de linhas de comandos que podem ser inseridos diretamente no console do R ou por meio de algum editor de texto, como o RStudio.

Uma forma simples de se criar um objeto “x” contendo o valor 11 é:

```
> x<-11 # ou de forma análoga: x=3.
```

Note que “#” é utilizado para adicionar comentários, logo, qualquer texto ou linha de comandos contido à direita não será interpretado pelo programa. Para visualizarmos o elemento “x” criado, devemos apenas inserir “x” na tela e apertar a tecla *Enter*.

```
> x
[1] 11
```

No decorrer dos capítulos seguintes, os comandos que contiverem o argumento “>” estará indicando que eles foram executados no R e estarão acompanhados dos respectivos resultados de interesse. Os seguintes exemplos ilustram a sintaxe básica da linguagem R:

```
> (3^2)/2+7*exp(3)-1 # operações algébricas
[1] 144.0988
> x<-c(1,2,3,4,5) # cria um vetor com 5 elementos
> x
[1] 1 2 3 4 5
> y<-seq(1,5,0.5) # cria uma sequência de valores de 1 a 5 com
  intervalos de 0,5
> y
[1] 1.0 1.5 2.0 2.5 3.0 3.5 4.0 4.5 5.0
> length(y) # retorna o tamanho do vetor y
[1] 9
```

No R, há várias funções específicas assim como pacotes expansíveis disponíveis para realizar diferentes cálculos estatísticos e também construir gráficos. No decorrer deste livro apresentaremos conjuntamente os conceitos de estatística básica e seus respectivos algoritmos.

Capítulo 2

Elementos de probabilidade

Resumo do capítulo: *O conhecimento dos conceitos e teoremas básicos do cálculo de probabilidade é indispensável para o estudo da Estatística Indutiva ou Inferencial. Neste capítulo, são introduzidas as noções de variável aleatória e das principais distribuições de probabilidade discretas e contínuas, juntamente com suas propriedades e particularidades.*

Objetivos: *Proporcionar uma visão abrangente das aplicações dos principais modelos probabilísticos discretos e contínuos em um contexto prático e direcionado.*

2.1 Introdução

A origem e o desenvolvimento da teoria das probabilidades encontram-se nos jogos de azar, por volta do século XVII. Na França dos anos 1650, por exemplo, os jogos eram considerados uma prática comum e elegante. Uma vez que envolviam enormes quantias de dinheiro, em apostas nos estabelecimentos de jogo, surgiu a necessidade de se desenvolver uma metodologia racional para calcular os riscos dos jogadores em diversos jogos de dados, cartas, entre outros. Por este motivo, os jogadores ricos, por meio de consultas a famosos matemáticos da época, usavam o conhecimento da teoria das probabilidades para elaborar estratégias de apostas. Ainda hoje em dia, há várias aplicações que envolvem jogos de azar, tais como os inúmeros tipos de loterias, corridas de cavalos, cassinos, entre outros (Gomes & Monteiro, 2003).

Os governos, as empresas e as organizações profissionais incorporam a teoria das probabilidades em seus processos de decisões, pois ela auxilia a desenvolver estratégias. Mas independente de qual seja a aplicação, a utilização das probabilidades indica a existência de um elemento de incerteza quanto à ocorrência ou não de um evento futuro, permitindo quantificar quão provável é a ocorrência de determinado evento (Medronho *et al.*, 2002).

Todos os dias nos deparamos com diversas situações que nos levam a usar, de forma intuitiva, a noção de probabilidade. Por exemplo:

- Dizemos que existe uma alta probabilidade do motorista pegar algum engarrafamento ao passar por determinadas vias expressas em horários de pico;
- O torcedor de um time de futebol deseja saber qual a probabilidade de seu time ganhar um jogo ou um campeonato;
- O candidato político quer saber qual a probabilidade dele ser eleito.

Nas situações acima, assim como em outros casos da vida cotidiana nas diversas áreas do conhecimento, nos vemos diante de fenômenos não determinísticos, pois não sabemos com certeza o que irá ocorrer quando de sua realização. Por exemplo:

- Quando chega o início da manhã, horário do almoço e final da tarde, dizemos que haverá congestionamento de veículos, pois a experiência passada nos diz que, nesses períodos do dia, é costume ter trânsito intenso e lento;
- Quando disputa uma partida de futebol, uma equipe pode vencê-la, empatá-la ou perdê-la, dependendo do número de gols marcados e sofridos por ela;
- Quando um político decide concorrer às eleições, o número de eleitores que irá votar nele é desconhecido.

Todas essas situações podem ser consideradas exemplos de fenômenos aleatórios, pois ao contrário dos fenômenos determinísticos, seus resultados não podem ser previstos com antecedência e exatidão.

A teoria das probabilidades lida com o estudo de modelos matemáticos especiais, chamados modelos probabilísticos, para explicar/descrever os fenômenos aleatórios.

Certos conhecimentos probabilísticos são essenciais para que o pesquisador seja capaz de interpretar devidamente os resultados das análises estatísticas. Por exemplo, quando se pretende fazer uma inferência estatística, ou seja, tirar conclusões sobre um grande conjunto de elementos (população) com base em somente uma parte dele (amostra), é a probabilidade que permite quantificar a incerteza existente, quando se passa do particular para o geral, quantificando o erro cometido ao tomar decisões.

Para definir o conceito de probabilidade, vamos introduzir alguns conceitos e noções básicas.

2.2 Conceitos básicos

Muitos fenômenos têm a propriedade de conduzir invariavelmente ao mesmo resultado, se repetidos sob condições iguais e específicas. Considere os seguintes experimentos:

1. Queda livre vertical de um corpo sólido;

2. Aquecimento da água contida numa panela.

Conhecidas certas condições, podemos prever a velocidade com que o corpo sólido atingirá o solo e a que temperatura a água entrará em ebulição. Os experimentos cujos resultados podem ser previstos, isto é, podem ser determinados antes mesmo de sua realização, são chamados **experimentos determinísticos**.

Imaginemos agora o seguinte: a face que fica voltada para cima ao lançar uma moeda depende evidentemente de sua posição inicial e de todo o movimento que ela descreve até parar. A expressão matemática da lei desse movimento depende de vários fatores, tais como o impulso inicial, a zona da moeda que atinge primeiro a superfície de contato, as eventuais irregularidades dessa superfície, dentre outros. Em termos práticos, todos esses fatores tornam impossível saber qual a face da moeda que ficará voltada para cima após cada lançamento.

Porém, se admitirmos que a moeda é constituída de uma matéria homogênea, não temos razões para crer mais na saída de uma das faces em detrimento da outra. Essa “crença” pode ser traduzida no modelo probabilístico a seguir:

Imagem da face voltada para cima	Cara	Coroa
Probabilidade	1/2	1/2

O fato de admitir esse modelo de probabilidade para a imagem da face que fica voltada para cima ao lançar uma moeda, nos permite também construir modelos para experimentos mais elaborados, como por exemplo, envolvendo inúmeros lançamentos de uma moeda ou o lançamento de várias moedas.

Considere também os seguintes experimentos:

1. Nascimento de um bebê;
2. Lançamento de um dado comum e leitura do número de pontos na face virada para cima;
3. Lançamento de uma moeda e leitura da imagem da face voltada para cima;
4. Sorteio de uma carta de um baralho comum;
5. Altura (em centímetros, cm) de uma pessoa sorteada da população;
6. Peso (em gramas, g) de um recém-nascido.

Se esses experimentos forem repetidos várias vezes, sob as mesmas condições, não podemos prever os seus resultados. Experimentos que, ao serem repetidos diversas vezes nas mesmas condições, apresentam resultados diversos, não sendo possível, assim, a previsão lógica dos resultados, são chamados **experimentos aleatórios**.

Um experimento aleatório possui as seguintes características fundamentais:

- Pode ser repetido diversas vezes nas mesmas condições;
- É conhecido o conjunto que contém todos os resultados possíveis;
- Não é possível prever qual será o resultado.

Os experimentos aleatórios obedecem à “lei do acaso”. Como não é possível prever o resultado, procura-se descobrir as possibilidades de ocorrência de cada experimento aleatório. A teoria das probabilidades estuda as maneiras de se estabelecer a possibilidade de ocorrência de cada resultado de um experimento aleatório.

Espaço amostral e eventos

Uma vez que os experimentos aleatórios, repetidos sob as mesmas condições, produzem resultados diferentes, então todo experimento aleatório está associado a um **espaço amostral**, isto é, ao conjunto de todos os resultados possíveis do experimento aleatório e é denotado pela letra grega Ω (“ômega maiúsculo”). O espaço amostral Ω é chamado de **discreto** se for finito ou infinito enumerável, como é o caso dos experimentos 1 ao 4; e é chamado de **contínuo** se for infinito não enumerável, isto é, proveniente de medições, como é o caso dos experimentos 5 e 6. Todo subconjunto do espaço amostral é chamado de **evento** e é denotado por letras maiúsculas do nosso alfabeto.

Exemplos de espaço amostral

Considere os seguintes experimentos:

1. No lançamento de uma moeda, temos que o espaço amostral é:

$$\Omega = \{c, k\}, \text{ em que } c = \textit{cara} \text{ e } k = \textit{coroa}.$$

2. Em lançamentos independentes de uma moeda até ocorrer a primeira cara, temos o seguinte espaço amostral:

$$\Omega = \{c, (k, c), (k, k, c), (k, k, k, c), \dots, (k, k, \dots, k, c), \dots\},$$

em que o número de coroas é $0, 1, 2, \dots$

3. Observando o número de veículos que passam por um posto de pedágio, durante 1 hora, temos o seguinte espaço amostral:

$$\Omega = \{0, 1, 2, \dots\}.$$

4. Observando a face do dado voltada para cima após o seu lançamento, temos:

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

5. No lançamento de dois dados, temos:

$$\Omega = \left\{ \begin{array}{l} (1, 1), (2, 1), (3, 1), (4, 1), (5, 1), (6, 1) \\ (1, 2), (2, 2), (3, 2), (4, 2), (5, 2), (6, 2) \\ (1, 3), (2, 3), (3, 3), (4, 3), (5, 3), (6, 3) \\ (1, 4), (2, 4), (3, 4), (4, 4), (5, 4), (6, 4) \\ (1, 5), (2, 5), (3, 5), (4, 5), (5, 5), (6, 5) \\ (1, 6), (2, 6), (3, 6), (4, 6), (5, 6), (6, 6) \end{array} \right\}.$$

Exemplo 1. Considere o lançamento de um dado e observe a face voltada para cima. Temos, então, que: $\Omega = \{1, 2, 3, 4, 5, 6\}$. Agora, considere os seguintes eventos:

Evento A: “Ocorre face par”;

Evento B: “Ocorre face menor ou igual a 3”;

Evento C: “Ocorre face ímpar”;

Evento D: “Ocorre face maior que 5”;

Evento E: “Ocorre face maior que 20”;

Evento F: “Ocorre face maior ou igual a 1 e menor ou igual a 6”.

Então, temos o seguinte:

$$A = \{2, 4, 6\};$$

$$B = \{1, 2, 3\};$$

$$C = \{1, 3, 5\};$$


$$D = \{6\};$$

$$E = \{\} = \emptyset;$$

$$F = \{1, 2, 3, 4, 5, 6\} = \Omega.$$

O evento E é chamado de **evento impossível** e o evento F é chamado de **evento certo**.

Os eventos acima podem ser representados graficamente, como na figura a seguir, em que temos o evento C .



Conjuntos


A teoria dos conjuntos é um ramo da Matemática bastante útil no estudo probabilístico de eventos, visto que estes nada mais são do que subconjuntos de um espaço amostral. Consideremos um espaço amostral finito dado por:

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}.$$

Sejam A e B dois eventos de Ω . Temos três operações básicas com eventos aleatórios: união, intersecção e complementação.


União: O evento união é formado pelos pontos amostrais ω que pertencem a pelo menos um dos eventos A e B .

Definição 1. $A \cup B = \{\omega \in \Omega : \omega \in A \text{ ou } \omega \in B\}$.




Intersecção: O evento intersecção é constituído pelos pontos amostrais ω que pertencem simultaneamente aos eventos A e B .

Definição 2. $A \cap B = \{\omega \in \Omega : \omega \in A \text{ e } \omega \in B\}$.



Complementação: O evento complementação é formado pelos pontos amostrais ω que não pertencem ao evento em questão.

Definição 3. $A^c = \Omega - A = \{\omega \in \Omega : \omega \notin A\}$.



Exemplo 2. No exemplo anterior, referente ao lançamento de um dado, tivemos: $\Omega = \{1, 2, 3, 4, 5, 6\}$. Considerando os eventos encontrados, vamos determinar os seguintes eventos:

$$\begin{array}{l} A \cup B \ ; \ A \cap B \ ; \ A \cup C \ ; \ A \cap C \ ; \ B \cup C \ ; \ B \cap C \ ; \\ A \cup D \ ; \ A \cap D \ ; \ A \cup E \ ; \ A \cap E \ ; \ A^c \ ; \ (B \cup C)^c. \end{array}$$

Temos que:

$$\begin{aligned}
A \cup B &= \{1, 2, 3, 4, 6\}; \\
A \cap B &= \{2\}; \\
A \cup C &= \{1, 2, 3, 4, 5, 6\} = \Omega; \\
A \cap C &= \{\} = \emptyset; \\
B \cup C &= \{1, 2, 3, 5\}; \\
B \cap C &= \{1, 3\}; \\
A \cup D &= \{2, 4, 6\} = A; \\
A \cap D &= \{6\}; \\
A \cup E &= \{2, 4, 6\} = A; \\
A \cap E &= \{\} = \emptyset; \\
A^c &= \{1, 3, 5\}; \\
(B \cup C)^c &= \{4, 6\}.
\end{aligned}$$

Com base nas três operações básicas dos conjuntos, seguem as seguintes propriedades:

Idempotência	$A \cup A = A$	$A \cap A = A$
Comutatividade	$A \cup B = B \cup A$	$A \cap B = B \cap A$
Associatividade	$A \cup (B \cup C) = (A \cup B) \cup C$	$A \cap (B \cap C) = (A \cap B) \cap C$
Distributividade	$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$	$A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
Absorção	$A \cup (A \cap B) = A$	$A \cap (A \cup B) = A$
Identidade	$A \cup \Omega = \Omega$ $A \cup \emptyset = A$	$A \cap \Omega = A$ $A \cap \emptyset = \emptyset$
Complementar	$\Omega^c = \emptyset$ $A \cap A^c = \emptyset$ $(A^c)^c = A$	$\emptyset^c = \Omega$ $A \cup A^c = \Omega$
Leis de De Morgan	$(A \cap B)^c = A^c \cup B^c$	$(A \cup B)^c = A^c \cap B^c$

Exemplo 3. Um número, entre os números de 1 a 10, é selecionado ao acaso. Considere os eventos:

A : “O número selecionado é múltiplo de 3”;

B : “O número selecionado é par”.

Descrever os seguintes eventos:

$$a) \quad A \cap B \quad b) \quad A \cup B \quad c) \quad A \cap B^c \quad d) \quad A^c \cap B$$


Solução: Temos que o espaço amostral é: $\Omega = \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$. Então, os eventos A e B são dados por:

$$A = \{3, 6, 9\} \quad \text{e} \quad B = \{2, 4, 6, 8, 10\}.$$

Assim, temos:

- a) $A \cap B = \{6\}$.
- b) $A \cup B = \{2, 3, 4, 6, 8, 9, 10\}$.
- c) $A \cap B^c = A - B = \{3, 9\}$.
- d) $A^c \cap B = B - A = \{2, 4, 8, 10\}$.

Fazendo o diagrama de Venn, temos:



Exemplo 4. Lançam-se três moedas ao mesmo tempo. Defina o espaço amostral e os eventos abaixo:

- A : “Faces iguais”;
- B : “Cara na 1ª moeda”;
- C : “Coroa na 1ª e na 2ª moedas”.

Solução: O espaço amostral Ω é dado por:

$$\Omega = \{(c, c, c), (c, c, k), (c, k, c), (c, k, k), (k, c, c), (k, c, k), (k, k, c), (k, k, k)\},$$

em que $c = cara$ e $k = coroa$. Então, temos os eventos A , B e C :

- $A = \{(c, c, c), (k, k, k)\}$;
- $B = \{(c, c, c), (c, c, k), (c, k, c), (c, k, k)\}$;
- $C = \{(k, k, c), (k, k, k)\}$.

Exemplo 5. Considere um experimento que consiste em pesquisar famílias com quatro crianças em relação ao sexo das mesmas, conforme a ordem de nascimento. Defina o espaço amostral e os eventos abaixo:

- A : “Ocorrência de duas crianças do sexo feminino”;
- B : “Ocorrência de pelo menos uma criança do sexo feminino”;
- C : “Ocorrência de, no máximo, três crianças do sexo masculino”.

Solução: O espaço amostral Ω é dado por:

$$\Omega = \{(0, 0, 0, 0), (1, 0, 0, 0), (0, 1, 0, 0), (0, 0, 1, 0), (0, 0, 0, 1), (1, 1, 0, 0), (1, 0, 1, 0), (1, 0, 0, 1), (0, 1, 1, 0), (0, 1, 0, 1), (0, 0, 1, 1), (1, 1, 1, 0), (1, 1, 0, 1), (1, 0, 1, 1), (0, 1, 1, 1), (1, 1, 1, 1)\},$$

em que $0 = masc$ e $1 = fem$. Então, temos os eventos A , B e C :

$$\begin{aligned} A &= \{(1, 1, 0, 0), (1, 0, 1, 0), (1, 0, 0, 1), (0, 1, 1, 0), (0, 1, 0, 1), (0, 0, 1, 1)\}; \\ B &= \{(1, 0, 0, 0), (0, 1, 0, 0), (0, 0, 1, 0), (0, 0, 0, 1), (1, 1, 0, 0), (1, 0, 1, 0), (1, 0, 0, 1), \\ &\quad (0, 1, 1, 0), (0, 1, 0, 1), (0, 0, 1, 1), (1, 1, 1, 0), (1, 1, 0, 1), (1, 0, 1, 1), (0, 1, 1, 1), \\ &\quad (1, 1, 1, 1)\} \text{ ou } B = \Omega - \{(0, 0, 0, 0)\}; \\ C &= \{(1, 0, 0, 0), (0, 1, 0, 0), (0, 0, 1, 0), (0, 0, 0, 1), (1, 1, 0, 0), (1, 0, 1, 0), (1, 0, 0, 1), \\ &\quad (0, 1, 1, 0), (0, 1, 0, 1), (0, 0, 1, 1), (1, 1, 1, 0), (1, 1, 0, 1), (1, 0, 1, 1), (0, 1, 1, 1), \\ &\quad (1, 1, 1, 1)\} \text{ ou } C = \Omega - \{(0, 0, 0, 0)\}. \end{aligned}$$

2.3 Probabilidade: definições

Probabilidade é a possibilidade, chance ou medida de ocorrência de um determinado evento. Esse evento está contido em um espaço amostral que, por sua vez, está associado a algum experimento aleatório. A probabilidade só pode assumir valores entre 0 e 1, inclusive os extremos, sendo que um evento que nunca irá ocorrer tem probabilidade 0 (evento impossível) e um evento que certamente ocorrerá tem probabilidade 1 (evento certo).

Considere agora os questionamentos a seguir, que dizem respeito às três abordagens distintas para o cálculo de probabilidades:

1. Qual é a probabilidade de se retirar, ao acaso, uma carta preta de um baralho comum?
2. Qual é a probabilidade de que um eleitor prefira um candidato, ou um partido político, a outro?
3. Qual é a probabilidade de que um cosmético recém-lançado no mercado faça sucesso entre os consumidores?

Na primeira questão, a abordagem refere-se à **probabilidade clássica** (teórica ou prévia), em que a probabilidade de ocorrência de um evento (no caso, a carta preta) associado a um experimento aleatório (retirada, ao acaso, de uma carta de um baralho comum) é baseada no conhecimento prévio do processo de observação. No caso mais simples, em que cada resultado no espaço amostral é igualmente provável, a probabilidade de ocorrência de um evento A definido sobre Ω , denotada por $P(A)$, pode ser calculada pela seguinte fórmula:

$$P(A) = \frac{\text{número de casos favoráveis ao evento } A}{\text{número total de elementos do espaço } \Omega} = \frac{n_A}{n_\Omega},$$

em que:

nA : número de resultados favoráveis à ocorrência do evento A ;
 $n\Omega$: número total de resultados igualmente prováveis do espaço Ω .
Então, para a primeira pergunta, a resposta certa é:

$$P(\text{preta}) = \frac{26}{52} = \frac{1}{2} = 0,5 \text{ ou } 50\%,$$

visto que há 26 cartas pretas em um baralho comum de 52 cartas. O número de resultados favoráveis à ocorrência do evento e o número total de resultados possíveis foram obtidos a partir da composição do baralho comum.

Com base no valor de probabilidade encontrado, pode-se dizer que, se esse experimento for repetido um número grande de vezes, sempre com reposição da carta sorteada, depois de algum tempo a proporção de cartas pretas retiradas irá se estabilizar em torno de 0,5 (ou 50%).

Na segunda questão, a abordagem refere-se à **probabilidade empírica** ou **frequentista**. A probabilidade de ocorrência de um evento ainda é obtida pela razão entre o número de resultados favoráveis ao evento e o número total de resultados, porém esses resultados são baseados na observação de dados oriundos de pesquisas e não no conhecimento prévio do processo de observação. Esse tipo de probabilidade poderia se referir, por exemplo, à proporção de eleitores que pretendem votar num determinado candidato (ou partido político) em detrimento de outro, com base em levantamento de dados realizado durante o período eleitoral.

Finalmente, a terceira questão faz referência à abordagem da **probabilidade subjetiva**. Diferentemente das duas situações anteriores, em que a probabilidade foi calculada objetivamente (isto é, com base no conhecimento prévio do processo de observação ou a partir de dados provenientes de pesquisas reais), a probabilidade subjetiva de que um determinado evento ocorra é atribuída por um sujeito em particular. Esse tipo de probabilidade reflete uma crença ou opinião pessoal e, portanto, pode variar de um indivíduo para outro. Para exemplificar, um perfumista pode atribuir uma probabilidade de aceitação de sua nova fragrância junto aos consumidores muito diferente daquela atribuída pelo comerciante que estiver cogitando vendê-la. A probabilidade subjetiva é particularmente útil para se tomar decisões quando não puder ser calculada usando as definições clássica e empírica.

Exemplo 6. *No lançamento de um dado equilibrado (ou “honesto”), observando-se o resultado da face superior, calcular a probabilidade de ocorrência dos seguintes eventos:*

- a) Face ímpar.*
- b) Face menor do que 5.*
- c) Face ímpar ou menor do que 5.*
- d) Face menor do que 5 e ímpar.*

Solução: No espaço amostral $\Omega = \{1, 2, 3, 4, 5, 6\}$, tem-se que:

- a) $P(\text{face ímpar}) = P(\{1, 3, 5\}) = 3/6 = 0,5$ ou 50%.
- b) $P(\text{face menor do que } 5) = P(\{1, 2, 3, 4\}) = 4/6 = 2/3 \approx 0,667$ ou 66,7%.
- c) $P(\text{face ímpar ou face menor do que } 5) = P(\{1, 2, 3, 4, 5\}) = 5/6 \approx 0,833$ ou 83,3%.
- d) $P(\text{face menor do que } 5 \text{ e face ímpar}) = P(\{1, 3\}) = 2/6 = 1/3 \approx 0,333$ ou 33,3%.

Apresentamos a seguir a definição de **probabilidade axiomática** (axiomas da probabilidade ou axiomas de Kolmogorov), proposta pelo matemático russo Andrey N. Kolmogorov em 1933.

Definição 4. *Probabilidade é a função P que associa a cada evento A de um espaço amostral Ω um número real pertencente ao intervalo $[0, 1]$, satisfazendo os axiomas a seguir:*


- 1) $0 \leq P(A) \leq 1$;
- 2) $P(\Omega) = 1$;
- 3) Se $A_1, A_2, \dots$ for uma sequência de eventos mutuamente exclusivos, isto é, $A_i \cap A_j = \emptyset$, $i \neq j$, então temos:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Podemos verificar que, se $P(\Omega) = 1$, então $P(\emptyset) = 0$.

Partição de um espaço amostral

Seja o espaço amostral Ω conforme o diagrama abaixo.



Definição 5. *Dizemos que os eventos $A_1, A_2, \dots, A_n$ formam uma partição do espaço amostral Ω se:*

- 1) $A_i \neq \emptyset$, $i = 1, 2, \dots, n$;
- 2) $A_i \cap A_j = \emptyset$, $\forall i \neq j$;

$$3) \bigcup_{i=1}^n A_i = \Omega.$$

Exemplo 7. Um colégio particular ofereceu cursos de francês e italiano, devendo os alunos se matricular em pelo menos um deles. Dos 45 alunos de uma classe, 10 decidiram estudar tanto francês como italiano. Em francês, matricularam-se 21 estudantes. Determine a probabilidade de um aluno, sorteado ao acaso, estar matriculado no curso de:

- a) Italiano.
- b) Francês.
- c) Italiano e francês.
- d) Italiano ou francês.
- e) Em apenas um dos cursos.


Solução: Considere os seguintes eventos:

I : “O aluno se matriculou em italiano”;

F : “O aluno se matriculou em francês”;

$I \cap F$: “O aluno se matriculou em ambos os cursos”.

Pelo diagrama de Venn, temos:



a) A probabilidade de um aluno, escolhido ao acaso, estar matriculado no curso de italiano é:

$$P(I) = \frac{nI}{n\Omega} = \frac{34}{45} \approx 0,7556.$$

b) A probabilidade de um aluno, escolhido ao acaso, estar matriculado no curso de francês é:

$$P(F) = \frac{nF}{n\Omega} = \frac{21}{45} = \frac{7}{15} \approx 0,4667.$$

c) A probabilidade de um aluno, escolhido ao acaso, estar matriculado nos cursos de italiano e francês é:

$$P(I \cap F) = \frac{n(I \cap F)}{n\Omega} = \frac{10}{45} = \frac{2}{9} \approx 0,2222.$$

d) A probabilidade de um aluno, escolhido ao acaso, estar matriculado no curso de italiano ou francês é:

$$P(I \cup F) = P(I) + P(F) - P(I \cap F) = \frac{34}{45} + \frac{21}{45} - \frac{10}{45} = \frac{45}{45} = 1.$$

e) A probabilidade de um aluno, escolhido ao acaso, estar matriculado em apenas um dos cursos é:

$$P(F - I) + P(I - F) = \frac{11}{45} + \frac{24}{45} = \frac{35}{45} = \frac{7}{9} \approx 0,7778.$$

2.4 Probabilidade condicional e independência

Quando dois ou mais eventos de um espaço amostral são levados em consideração conjuntamente, passa a haver sentido em conjecturar se a ocorrência de um afeta a ocorrência do outro, em outras palavras, se tais eventos são **independentes** ou não.

Seja $A \subset \Omega$ e $B \subset \Omega$, então a probabilidade condicional de A dado que B ocorreu é dada por:

$$P(A | B) = \frac{P(A \cap B)}{P(B)},$$

em que $P(B) > 0$. Lê-se: “Probabilidade de A dado B ”.

Seja $A \subset \Omega$ e $B \subset \Omega$, então dizemos que A é **independente** de B se sua probabilidade condicional for dada por:

$$P(A | B) = P(A).$$

Exemplo 8. Lançam-se três moedas “honestas” ao mesmo tempo. Deseja-se verificar se são independentes os seguintes eventos:

A : “Saída de coroa na 1ª moeda”;

B : “Saída de cara na 2ª e 3ª moedas”.

Solução: Temos que o espaço amostral para esse experimento e os eventos propostos são:

$$\Omega = \{(c, c, c), (c, c, k), (c, k, c), (c, k, k), (k, c, c), (k, c, k), (k, k, c), (k, k, k)\}$$

$$A = \{(k, c, c), (k, c, k), (k, k, c), (k, k, k)\}$$

$$B = \{(c, c, c), (k, c, c)\}$$

$$A \cap B = \{(k, c, c)\}$$

Assim,

$$P(A | B) = \frac{P(A \cap B)}{P(B)} = \frac{1}{2} \text{ e } P(A) = \frac{4}{8} = \frac{1}{2}.$$


Como $P(A | B) = P(A)$, então A e B são dois eventos independentes.

Teorema da Probabilidade Total

Sejam $A_1, A_2, \dots, A_n$ eventos que formam uma partição do espaço amostral Ω , e seja B um evento qualquer desse espaço. Então, temos:

$$P(B) = \sum_{i=1}^n P(B | A_i) P(A_i).$$

Esquematicamente, temos:



Exemplo 9. Uma urna contém 4 bolas brancas e 2 vermelhas. Uma segunda urna contém 3 bolas brancas e 2 vermelhas. Escolhe-se, ao acaso, uma urna e dela retira-se, também ao acaso, uma bola. Qual a probabilidade da bola retirada ser branca?

Solução: Sejam os eventos:

I : “A urna escolhida é a urna I ”;

II : “A urna escolhida é a urna II ”;

$B | I$: “A bola é branca dado que a urna escolhida foi a I ”;

$B | II$: “A bola é branca dado que a urna escolhida foi a II ”;

B : “A bola retirada é branca”.

As respectivas probabilidades são: $P(I) = \frac{1}{2}$, $P(II) = \frac{1}{2}$, $P(B | I) = \frac{4}{6}$, $P(B | II) = \frac{3}{5}$. Então, temos que a probabilidade $P(B)$ é dada por:

$$\begin{aligned} P(B) &= \sum_{i=1}^n P(B | A_i) P(A_i) = P(B | I) P(I) + P(B | II) P(II) \\ &= \frac{4}{6} \times \frac{1}{2} + \frac{3}{5} \times \frac{1}{2} = \frac{2}{6} + \frac{3}{10} = \frac{38}{60} = \frac{19}{30}. \end{aligned}$$

Exemplo 10. A urna I tem 3 bolas brancas e 2 verdes, a urna II tem 6 bolas brancas e 3 verdes e a urna III tem 2 bolas brancas e 3 verdes. Uma urna é escolhida ao acaso. Desta urna, retira-se, também ao acaso, uma bola. Qual a probabilidade da bola retirada ser branca? E qual a probabilidade dessa bola ser verde?

Solução: Sejam os eventos:

I : “A urna escolhida é a urna I ”;

II : “A urna escolhida é a urna II ”;

III : “A urna escolhida é a urna III ”;

$B \mid I$: “A bola é branca dado que a urna escolhida foi a I ”;

$B \mid II$: “A bola é branca dado que a urna escolhida foi a II ”;

$B \mid III$: “A bola é branca dado que a urna escolhida foi a III ”;

$V \mid I$: “A bola é verde dado que a urna escolhida foi a I ”;

$V \mid II$: “A bola é verde dado que a urna escolhida foi a II ”;

$V \mid III$: “A bola é verde dado que a urna escolhida foi a III ”;

B : “A bola retirada é branca”;

V : “A bola retirada é verde”.

As respectivas probabilidades são: $P(I) = \frac{1}{3}$, $P(II) = \frac{1}{3}$, $P(III) = \frac{1}{3}$,
 $P(B \mid I) = \frac{3}{5}$, $P(B \mid II) = \frac{6}{9}$, $P(B \mid III) = \frac{2}{5}$, $P(V \mid I) = \frac{2}{5}$, $P(V \mid II) = \frac{3}{9}$,
 $P(V \mid III) = \frac{3}{5}$. Então, temos que a probabilidade $P(B)$ é dada por:

$$\begin{aligned} P(B) &= \sum_{i=1}^n P(B \mid A_i) P(A_i) \\ &= P(B \mid I) P(I) + P(B \mid II) P(II) + P(B \mid III) P(III) \\ &= \frac{3}{5} \times \frac{1}{3} + \frac{6}{9} \times \frac{1}{3} + \frac{2}{5} \times \frac{1}{3} = \frac{1}{5} + \frac{2}{9} + \frac{2}{15} = \frac{9+10+6}{45} = \frac{25}{45} = \frac{5}{9}. \end{aligned}$$

E a probabilidade $P(V)$ é dada por:

$$\begin{aligned} P(V) &= \sum_{i=1}^n P(V \mid A_i) P(A_i) \\ &= P(V \mid I) P(I) + P(V \mid II) P(II) + P(V \mid III) P(III) \\ &= \frac{2}{5} \times \frac{1}{3} + \frac{3}{9} \times \frac{1}{3} + \frac{3}{5} \times \frac{1}{3} = \frac{2}{15} + \frac{1}{9} + \frac{1}{5} = \frac{6+5+9}{45} = \frac{20}{45} = \frac{4}{9}. \end{aligned}$$

Note que $P(B) + P(V) = \frac{5}{9} + \frac{4}{9} = 1$.

Exemplo 11. Em uma linha de produção de uma determinada indústria há 4 máquinas. A máquina I produz 1% de itens defeituosos, a máquina II produz 2%, a máquina III produz 1,5% e a máquina IV produz 4% de itens defeituosos. Um item é escolhido, ao acaso, dessa linha de produção. Qual a probabilidade desse item ser defeituoso?

Solução: Sejam os eventos:

I : “A máquina escolhida é a máquina I ”;

II : “A máquina escolhida é a máquina II ”;
 III : “A máquina escolhida é a máquina III ”;
 IV : “A máquina escolhida é a máquina IV ”;
 $D | I$: “A peça é defeituosa dado que foi produzida pela máquina I ”;
 $D | II$: “A peça é defeituosa dado que foi produzida pela máquina II ”;
 $D | III$: “A peça é defeituosa dado que foi produzida pela máquina III ”;
 $D | IV$: “A peça é defeituosa dado que foi produzida pela máquina IV ”;
 D : “A peça escolhida é defeituosa”.

As respectivas probabilidades são: $P(I) = P(II) = P(III) = P(IV) = \frac{1}{4}$, $P(D | I) = \frac{1}{100}$, $P(D | II) = \frac{2}{100}$, $P(D | III) = \frac{15}{1.000}$, $P(D | IV) = \frac{4}{100}$. Desta forma, temos que a probabilidade $P(D)$ é dada por:

$$\begin{aligned}
 P(D) &= \sum_{i=1}^n P(D | A_i) P(A_i) \\
 &= P(D | I) P(I) + P(D | II) P(II) + P(D | III) P(III) + P(D | IV) P(IV) \\
 &= \frac{1}{100} \times \frac{1}{4} + \frac{2}{100} \times \frac{1}{4} + \frac{15}{1.000} \times \frac{1}{4} + \frac{4}{100} \times \frac{1}{4} \\
 &= \frac{1}{400} + \frac{1}{200} + \frac{3}{800} + \frac{1}{100} = \frac{2+4+3+8}{800} = \frac{17}{800} \approx 0,0213.
 \end{aligned}$$

Teorema de Bayes

Considere $A_1, A_2, \dots, A_n$ eventos que formam uma partição do espaço amostral Ω e que $P(A_i)$ e $P(B | A_i)$, $i = 1, 2, \dots, n$, sejam conhecidas. Então, temos:

$$P(A_k | B) = \frac{P(B | A_k) P(A_k)}{\sum_{i=1}^n P(B | A_i) P(A_i)}, \quad k = 1, 2, \dots, n.$$

Observação: O Teorema de Bayes, também conhecido como Teorema da Probabilidade *a Posteriori*, relaciona uma das parcelas da probabilidade total com a própria probabilidade total (Correa, 2003).

Exemplo 12. A urna I contém 3 fichas verdes e 2 amarelas, e a urna II contém 2 fichas verdes e 8 amarelas. Lança-se uma moeda “honestas”. Se sair cara, retira-se uma ficha da urna I ; se sair coroa, retira-se uma ficha da urna II . Uma ficha verde é retirada. Qual a probabilidade de ter saído cara no lançamento da moeda?

Solução: Sejam os eventos:

C : “Cara, isto é, a urna escolhida é a urna I ”;
 $\bar{C}$: “Coroa, isto é, a urna escolhida é a urna II ”;
 $V | C$: “A ficha retirada é verde dado que a urna I foi escolhida”;

$V | \overline{C}$: “A ficha retirada é verde dado que a urna II foi escolhida”;
 V : “A ficha retirada é verde”.

Temos, então, as seguintes probabilidades: $P(C) = P(\overline{C}) = \frac{1}{2}$, $P(V | C) = \frac{3}{5}$ e $P(V | \overline{C}) = \frac{2}{10}$. Logo,

$$P(A_k | B) = \frac{P(B | A_k) P(A_k)}{\sum_{i=1}^n P(B | A_i) P(A_i)}, \quad k = 1, 2, \dots, n.$$

$$P(C | V) = \frac{P(V | C) P(C)}{P(V | C) P(C) + P(V | \overline{C}) P(\overline{C})}$$

$$= \frac{\frac{3}{5} \times \frac{1}{2}}{\frac{3}{5} \times \frac{1}{2} + \frac{2}{10} \times \frac{1}{2}} = \frac{\frac{3}{10}}{\frac{3}{10} + \frac{1}{10}} = \frac{3}{10} \times \frac{10}{4} = \frac{3}{4}.$$

Exemplo 13. (*Controle Estatístico da Qualidade*). Em uma determinada empresa, a máquina I produz 2% de itens defeituosos, a máquina II produz 3%, a máquina III produz 1,5% e a máquina IV produz 5% de itens defeituosos.

a) Uma peça é escolhida ao acaso dessa linha de produção. Qual a probabilidade desta peça ser defeituosa?

b) Dado que a peça escolhida é defeituosa, qual a probabilidade dela ter sido produzida pela máquina I , II , III e IV ?

Solução: Sejam os eventos:

I : “A máquina escolhida é a máquina I ”;

II : “A máquina escolhida é a máquina II ”;

III : “A máquina escolhida é a máquina III ”;

IV : “A máquina escolhida é a máquina IV ”;

$D | I$: “A peça é defeituosa dado que foi produzida pela máquina I ”;

$D | II$: “A peça é defeituosa dado que foi produzida pela máquina II ”;

$D | III$: “A peça é defeituosa dado que foi produzida pela máquina III ”;

$D | IV$: “A peça é defeituosa dado que foi produzida pela máquina IV ”;

D : “A peça escolhida é defeituosa”.

As respectivas probabilidades são: $P(I) = P(II) = P(III) = P(IV) = \frac{1}{4}$, $P(D | I) = \frac{2}{100}$, $P(D | II) = \frac{3}{100}$, $P(D | III) = \frac{15}{1.000}$ e $P(D | IV) = \frac{5}{100}$.

Resolvendo o item (a), temos que a probabilidade $P(D)$ é dada por:

$$P(D) = \sum_{i=1}^n P(D | A_i) P(A_i)$$

$$= P(D | I) P(I) + P(D | II) P(II) + P(D | III) P(III) + P(D | IV) P(IV)$$

$$= \frac{2}{100} \times \frac{1}{4} + \frac{3}{100} \times \frac{1}{4} + \frac{15}{1.000} \times \frac{1}{4} + \frac{5}{100} \times \frac{1}{4}$$

$$= \frac{2}{400} + \frac{3}{400} + \frac{15}{4.000} + \frac{5}{400} = \frac{23}{800} = 0,02875 = 2,875\%.$$

Resolvendo o item (b), temos:

$$P(A_k | B) = \frac{P(B | A_k) P(A_k)}{\sum_{i=1}^n P(B | A_i) P(A_i)}, \quad k = 1, 2, \dots, n.$$

$$\begin{aligned} P(I | D) &= \frac{P(D | I) P(I)}{P(D | I) P(I) + P(D | II) P(II) + P(D | III) P(III) + P(D | IV) P(IV)} \\ &= \frac{\frac{2}{100} \times \frac{1}{4}}{\frac{0,005}{0,02875}} \approx 0,1739. \end{aligned}$$

$$\begin{aligned} P(II | D) &= \frac{P(D | II) P(II)}{P(D | I) P(I) + P(D | II) P(II) + P(D | III) P(III) + P(D | IV) P(IV)} \\ &= \frac{\frac{3}{100} \times \frac{1}{4}}{\frac{0,0075}{0,02875}} \approx 0,2609. \end{aligned}$$

$$\begin{aligned} P(III | D) &= \frac{P(D | III) P(III)}{P(D | I) P(I) + P(D | II) P(II) + P(D | III) P(III) + P(D | IV) P(IV)} \\ &= \frac{\frac{15}{1.000} \times \frac{1}{4}}{\frac{0,00375}{0,02875}} \approx 0,1304. \end{aligned}$$

$$\begin{aligned} P(IV | D) &= \frac{P(D | IV) P(IV)}{P(D | I) P(I) + P(D | II) P(II) + P(D | III) P(III) + P(D | IV) P(IV)} \\ &= \frac{\frac{5}{100} \times \frac{1}{4}}{\frac{0,0125}{0,02875}} \approx 0,4348. \end{aligned}$$

2.5 Variáveis aleatórias

Diz-se que uma variável é aleatória quando seu valor é obtido por meio de experimentação ou observação, e a cada possível valor dela estiver associada uma probabilidade de ocorrência. Convencionalmente, denota-se uma variável aleatória por letra maiúscula (por exemplo, X , Y , Z e W) e os valores assumidos por ela por letra minúscula (por exemplo, x , y , z e w).

Uma variável aleatória é definida como sendo **discreta** se assume valores em pontos isolados ao longo de uma escala (conjunto finito ou infinito enumerável de valores). Alguns exemplos são: número de indivíduos portadores de determinada doença, número de filhos por família, número de “caras” em 10 lançamentos de uma moeda etc.

Uma variável aleatória é **contínua** se assume qualquer valor ao longo de um intervalo (conjunto infinito não enumerável de valores). Alguns exemplos são: tempo para que um determinado medicamento faça efeito, temperatura diária, altura etc.

Distribuições discretas de probabilidade

A função de probabilidade é uma função que associa a cada valor x_k , $k = 1, 2, \dots$, de uma variável aleatória discreta X , a sua probabilidade de ocorrência.

Definição 6. *Seja X uma variável aleatória discreta que assume os valores $x_1, x_2, \dots$. Então, a distribuição de probabilidade (ou função de probabilidade) de X tem que satisfazer:*

$$i) \ 0 \leq P(X = x_k) \leq 1, \quad k = 1, 2, \dots;$$

$$ii) \ \sum_{k=1}^{\infty} P(X = x_k) = 1.$$

Exemplo 14. *Considere o lançamento de duas moedas “honestas” e seja X o número de “caras” obtidas. Sabemos que o espaço amostral é dado por: $\Omega = \{(c, c), (c, k), (k, c), (k, k)\}$ e, portanto, a quantidade de caras que X pode assumir é $X = 0, 1, 2$, tal que:*

$$P(X = 0) = 1/4, \quad P(X = 1) = 2/4 \quad e \quad P(X = 2) = 1/4.$$

Cada valor associado a X tem uma probabilidade entre 0 e 1 e, se somarmos essas três probabilidades, temos o valor 1.

Dentre as principais distribuições discretas de probabilidade, destacam-se: Bernoulli, binomial e Poisson. Tais distribuições (ou modelos) de probabilidade são brevemente descritas a seguir.

- Bernoulli: A variável aleatória X de Bernoulli assume apenas dois valores: 0, se ocorrer “fracasso” (resultado pelo qual não estamos interessados); e 1, se ocorrer “sucesso” (resultado de interesse). Com p , $0 < p < 1$, representando a probabilidade de “sucesso”, então sua função de probabilidade é dada por:

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x = 0, 1.$$

Notação: $X \sim \text{Bernoulli}(p)$.

- Binomial: A variável aleatória X que contabiliza o número de “sucessos” obtidos na realização de n experimentos de Bernoulli independentes e todos com a mesma probabilidade de “sucesso” p , $0 < p < 1$, é denominada binomial com parâmetros n e p , e sua função de probabilidade é dada por:

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}, \quad x = 0, 1, \dots, n.$$

Notação: $X \sim \text{Binomial}(n, p)$.

- Poisson: Uma variável aleatória X tem distribuição de Poisson com parâmetro λ , $\lambda > 0$, se sua função de probabilidade é dada por:

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots,$$

em que o parâmetro λ indica a taxa de ocorrência de eventos por unidade de medida.

Notação: $X \sim \text{Poisson}(\lambda)$.

O cálculo de probabilidades pontuais sob as distribuições discretas acima, pode ser realizado por meio dos seguintes comandos em R:

```
> dbinom(x, n, p)    # Cálculo de P(X=x) sob o modelo Binomial(n,p)
> dpois(x, lambda)   # Cálculo de P(X=x) sob o modelo Poisson(lambda)
```

Exemplo 15. No exemplo anterior, cada lançamento da moeda “honesta” representa um experimento de Bernoulli com probabilidade de “sucesso” (neste caso, “sucesso” = ocorrência de “cara”) $p = 1/2$. Logo, a variável aleatória Y definida como:

$$Y = \begin{cases} 0, & \text{se ocorrer “coroa” no lançamento da moeda “honesta”} \\ 1, & \text{se ocorrer “cara” no lançamento da moeda “honesta”} \end{cases}$$

tem distribuição de Bernoulli com parâmetro $p = 1/2$, isto é, $Y \sim \text{Bernoulli}(1/2)$.

Por sua vez, a variável aleatória $X =$ “número de ‘caras’ obtidas em dois lançamentos sucessivos e independentes da moeda ‘honesta’” tem distribuição binomial com parâmetros $n = 2$ e $p = 1/2$, isto é, $X \sim \text{Binomial}(2; 1/2)$.

Exemplo 16. Seja a variável aleatória X que denota o número de clientes atendidos pelo caixa de um banco em 1 hora. Supõe-se razoável modelar X por uma distribuição de Poisson com parâmetro $\lambda = 5$ clientes atendidos/hora. Assim, $X \sim \text{Poisson}(5)$.

Se houver interesse em calcular a probabilidade de ser atendido apenas 1 cliente em 1 hora, isto pode ser feito como segue:

$$P(X = 1) = \frac{e^{-5} 5^1}{1!} = 5e^{-5} \approx 0,0337.$$

```
> # Código em R:
> dpois(1, 5)
[1] 0.03368973
```

Distribuições contínuas de probabilidade

Variáveis aleatórias contínuas são modeladas/descritas por funções densidade de probabilidade.

Definição 7. Dizemos que $f(x)$ é uma função densidade de probabilidade para uma variável aleatória contínua X , se satisfaz as seguintes propriedades:

- i) $f(x) \geq 0, \quad \forall x \in \mathbb{R};$
- ii) $\int_{-\infty}^{\infty} f(x) dx = 1.$

É importante ressaltar a diferença que há entre o histograma (que nada mais é do que a distribuição de frequências dos dados e será tratado no próximo capítulo) e a curva de densidade. O histograma é uma representação gráfica da distribuição dos

dados de uma amostra extraída de uma população, enquanto a curva de densidade representa a distribuição teórica que melhor se aproxima do histograma observado. Quando consideramos a curva traçada por meio dos topos das barras do histograma, temos uma boa descrição do padrão geral dos dados (forma da distribuição dos dados). Conforme observam Gomes & Lima (2012), a curva é um modelo matemático para a distribuição, isto é, uma descrição idealizada que fornece uma imagem concisa do padrão geral dos dados, ignorando, porém, irregularidades de menor importância, bem como qualquer valor atípico. Observaremos que é mais fácil trabalhar com a curva do que com o histograma. A razão disso é que o histograma depende de nossa escolha de classes, enquanto que podemos usar, sob certas condições, uma curva que não dependa das escolhas que fizemos. Obviamente que nenhum conjunto de dados reais é descrito exatamente por uma curva de densidade. A curva consiste em uma aproximação de fácil utilização e com precisão suficiente para ser usada na prática.

Exemplo 17. A Figura 2.1 mostra o ajuste dos dados sobre idade de clientes à curva de densidade, em uma aplicação de *credit scoring*.




Figura 2.1: Curva de densidade da idade do cliente (dados de *credit scoring*).

Exemplo 18. A Figura 2.2 mostra o ajuste de dados gerados de uma distribuição Normal à sua respectiva curva de densidade.




Figura 2.2: Curva de densidade de dados gerados de uma distribuição Normal.

Dentre as principais distribuições contínuas de probabilidade, destacam-se: Normal e exponencial. A seguir, apresentamos uma breve descrição da distribuição (ou modelo) exponencial. A distribuição Normal, por sua vez, será vista em maiores detalhes na próxima seção. Enquanto que outros modelos importantes, como t -Student, Qui-quadrado e F-Snedecor, serão introduzidos e aplicados intensamente em capítulos posteriores.

- **Exponencial:** Uma variável aleatória X que assume apenas valores não negativos, é dita seguir uma distribuição exponencial com parâmetro λ , $\lambda > 0$, se sua função densidade de probabilidade é dada por:

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{se } x \geq 0 \\ 0, & \text{caso contrário} \end{cases}$$

Notação: $X \sim \text{Exponencial}(\lambda)$.

A probabilidade de uma variável aleatória contínua X assumir valores entre a e b é igual à área sob a curva de densidade entre esses dois pontos. O cálculo desta probabilidade é feito matematicamente através da integração da função densidade de probabilidade $f(x)$ entre os pontos a e b . Ou seja,

$$P(a \leq X \leq b) = \int_a^b f(x)dx.$$

Observação: Se X é uma variável aleatória contínua com função densidade de probabilidade $f(x)$, então as seguintes relações são verdadeiras:

1. $P(a \leq X \leq b) = P(a < X \leq b) = P(a \leq X < b) = P(a < X < b)$;
2. $P(X = k) = \int_k^k f(x)dx = 0, \forall k \in \mathbb{R}$.

Exemplo 19. *O tempo de vida útil (em horas) de uma lâmpada pode ser considerado uma variável aleatória com distribuição exponencial de parâmetro $\lambda = 0,0001$. Qual a probabilidade de que, se escolhermos uma lâmpada ao acaso, ela dure menos de 1 ano?*

Solução:

Seja a variável aleatória $X =$ “tempo de vida útil (em horas) de uma lâmpada”. Do enunciado, sabemos que: $X \sim \text{Exponencial}(0,0001)$.

Assim, considerando 1 ano = 8.760 horas, temos que:

$$\begin{aligned} P(X < 8.760) &= P(0 \leq X < 8.760) = \int_0^{8.760} 0,0001 e^{-0,0001x} dx \\ &= -e^{-0,0001x} \Big|_0^{8.760} = -e^{-0,0001 \times 8.760} - (-e^{-0,0001 \times 0}) \\ &\approx 0,5836. \end{aligned}$$

Função de distribuição acumulada

A seguir, apresentamos a definição de outra importante função associada a variáveis aleatórias, que é a função de distribuição acumulada ou empírica.

Definição 8. A função de distribuição acumulada (fda) de uma variável aleatória X é dada por:

$$F(x) = P(X \leq x) \in [0, 1],$$

em que:

- $F(x) = \sum_{j: x_j \leq x} P(X = x_j)$ se X é variável discreta;
- $F(x) = \int_{-\infty}^x f(t) dt$ se X é variável contínua.

A fda de uma variável aleatória X possui as seguintes propriedades básicas:

Propriedade 1. $\lim_{x \rightarrow -\infty} F(x) = 0$ e $\lim_{x \rightarrow \infty} F(x) = 1$;

Propriedade 2. F é não decrescente, isto é, para quaisquer $x, y \in \mathbb{R}$ tais que $x \leq y$, tem-se $F(x) \leq F(y)$;

Propriedade 3. F é contínua à direita, isto é, para qualquer $y \in \mathbb{R}$, tem-se $\lim_{x \rightarrow y^+} F(x) = F(y)$.

Observações:

1. Podemos usar a fda de uma variável aleatória X para calcular probabilidades como segue:

$$P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F(b) - F(a).$$

2. Ao derivarmos a fda de uma variável aleatória contínua X , obtemos a sua função densidade de probabilidade, isto é,

$$f(x) = \frac{d}{dx} F(x).$$

O cálculo de probabilidades acumuladas sob as distribuições discretas e contínuas vistas anteriormente, pode ser realizado por meio dos seguintes comandos em R:

```
> pbinom(x, n, p) # Cálculo de P(X<=x) sob o modelo Binomial(n,p)
> ppois(x, lambda) # Cálculo de P(X<=x) sob o modelo Poisson(lambda)
> pexp(x, lambda) # Cálculo de P(X<=x) sob o modelo Exp(lambda)
```

Exemplo 20. Considerando o Exemplo 14, temos que a fda da variável aleatória $X = \text{“número de ‘caras’ obtidas em dois lançamentos sucessivos e independentes da moeda ‘honesta’”}$, é dada por:

$$F(x) = \begin{cases} 0, & \text{se } x < 0 \\ 1/4, & \text{se } 0 \leq x < 1 \\ 3/4, & \text{se } 1 \leq x < 2 \\ 1, & \text{se } x \geq 2 \end{cases}$$

Exemplo 21. Considerando o Exemplo 19, temos que a fda da variável aleatória $X = \text{“tempo de vida útil (em horas) de uma lâmpada”} \sim \text{Exponencial}(0,0001)$, é dada por:

$$F(x) = \begin{cases} 1 - e^{-0,0001x}, & \text{se } x \geq 0 \\ 0, & \text{caso contrário} \end{cases}$$

Assim, podemos calcular probabilidades, como por exemplo, da lâmpada durar entre 6 meses e 1 ano, como segue:

$$\begin{aligned} P(4.380 < X \leq 8.760) &= F(8.760) - F(4.380) \\ &= 1 - e^{-0,0001 \times 8.760} - (1 - e^{-0,0001 \times 4.380}) \\ &\approx 0,5836 - 0,3547 = 0,2289. \end{aligned}$$

```
> # Códigos em R:
> # Cálculo de P(X<=8760) com X~Exp(0,0001):
> pexp(8760, 0.0001)
[1] 0.5835546
> # Cálculo de P(4380<X<=8760) com X~Exp(0,0001):
> pexp(8760, 0.0001) - pexp(4380, 0.0001)
[1] 0.2288804
```

Esperança e variância de uma variável aleatória

Esta seção é indispensável para a compreensão dos tópicos que serão abordados nos capítulos referentes ao estudo de populações. Especificamente, em tais capítulos apresentaremos resultados que permitirão fazer certas afirmações (probabilísticas) acerca de características de interesse numa população, considerando somente as informações (constantes) contidas numa amostra (pequena parcela) dessa população. Dentre as mais importantes características (ou parâmetro) de interesse numa população cuja variável estudada seja quantitativa (ou numérica), está a sua média. Para evitar confusão com a média de uma amostra extraída dessa população, a chamaremos de valor médio e representaremos pela letra grega μ .

Por sua vez, a variância populacional será denotada por σ^2 . Quaisquer outras características amostrais (desvio-padrão, coeficiente de variação, proporção etc.) apresentadas nos capítulos posteriores, quando referentes a todos os elementos de uma

população, serão chamadas pelo mesmo nome só que acrescido do termo “populacional” (desvio-padrão populacional, coeficiente de variação populacional, proporção populacional etc.). A probabilidade de um indivíduo sorteado ao acaso da população possuir uma certa propriedade também pode ser vista como um parâmetro de interesse, que tem como correspondente amostral a frequência com que essa propriedade foi observada na amostra.

Com o intuito de ampliar o conceito de população como algo proveniente de qualquer modelo probabilístico, consideraremos uma população finita (por exemplo, os alunos de uma universidade) e uma característica quantitativa de interesse desta (por exemplo, o número de anos de curso pré-vestibular - $0, 1, 2, 3, 4, \dots$). Definindo um modelo probabilístico adequado para o valor observado dessa característica quando seleciona-se um indivíduo ao acaso dessa população (modelo de probabilidade para o número de anos de curso pré-vestibular de um aluno escolhido ao acaso na universidade), pode-se então demonstrar que o valor médio da população (média do número de anos de curso pré-vestibular de todos os alunos da universidade) também pode ser determinado a partir do modelo. Neste caso, basta multiplicar cada valor do espaço de resultados pela probabilidade correspondente e somar todos os valores obtidos.

A seguir, apresentaremos a definição do **valor médio** (ou **valor esperado**) de qualquer variável quantitativa à qual se tenha associado um modelo probabilístico.

Definição 9. *O valor médio ou esperado (μ) de uma variável aleatória X é definido por:*

- $\mu = E(X) = \sum_{k=1}^{\infty} x_k P(X = x_k)$ se X é variável discreta;
- $\mu = E(X) = \int_{-\infty}^{\infty} x f(x) dx$ se X é variável contínua.

Algumas importantes propriedades do valor médio de uma variável aleatória são apresentadas a seguir.

Propriedade 1. *Dada uma constante real c , temos que, se $X = c$ com probabilidade 1, então $E(X) = c$.*

Propriedade 2. *Seja X uma variável aleatória cujo valor médio exista. Dada uma constante real c , temos que:*

$$E(c + X) = c + E(X) \quad \text{e} \quad E(cX) = cE(X).$$

Propriedade 3. *Sejam $X_1, \dots, X_n$ variáveis aleatórias cujos valores médios existam. Então,*

$$E(X_1 + \dots + X_n) = E(X_1) + \dots + E(X_n).$$

Propriedade 4. *Sejam X e Y variáveis aleatórias independentes cujos valores médios existam. Então,*

$$E(XY) = E(X)E(Y).$$

Exemplo 22. *Considerando o Exemplo 14, temos o lançamento de duas moedas e X é o número de “caras” obtidas. Calculamos o valor médio ou esperado para X como segue:*

$$\begin{aligned} E(X) &= \sum_{k=1}^n x_k P(X = x_k) \\ &= 0 \times P(X = 0) + 1 \times P(X = 1) + 2 \times P(X = 2) \\ &= 0 \times \frac{1}{4} + 1 \times \frac{2}{4} + 2 \times \frac{1}{4} = 1. \end{aligned}$$

Interpretação do resultado: Esse exemplo mostra que o valor médio (ou esperado) do número de caras em um lançamento de duas moedas honestas é igual a um, ou seja, esperamos que, ao repetir esse experimento muitas vezes, a média do número de caras seja igual a um.

A seguir, apresentamos a definição de uma importante medida de dispersão, que é a variância de variáveis aleatórias.

Definição 10. *A variância de uma variável aleatória X é definida por:*

$$\text{Var}(X) = E([X - E(X)]^2) = E(X^2) - [E(X)]^2,$$

em que:

- $E(X^2) = \sum_{k=1}^{\infty} x_k^2 P(X = x_k)$ se X é variável discreta;
- $E(X^2) = \int_{-\infty}^{\infty} x^2 f(x) dx$ se X é variável contínua.

Algumas propriedades importantes da variância de uma variável aleatória são expostas a seguir.

Propriedade 1. *Dada uma constante real c , temos que, se $X = c$ com probabilidade 1, então $\text{Var}(X) = 0$.*

Propriedade 2. *Seja X uma variável aleatória e c uma constante real. Então,*

$$\text{Var}(c + X) = \text{Var}(X) \quad \text{e} \quad \text{Var}(cX) = c^2 \text{Var}(X).$$

Propriedade 3. *Sejam $X_1, \dots, X_n$ variáveis aleatórias independentes. Então,*

$$\text{Var}(X_1 + \dots + X_n) = \text{Var}(X_1) + \dots + \text{Var}(X_n).$$

Observações:

1. A raiz quadrada da variância de uma variável aleatória X é conhecida como desvio-padrão e denotada por σ ou $DP(X)$;
2. A variância é expressa em unidades ao quadrado de X (desvantagem em relação ao desvio-padrão).

Exemplo 23. (Continuação) Para determinarmos a variância $Var(X)$, temos que encontrar primeiramente o segundo momento de X , dado por:

$$\begin{aligned} E(X^2) &= \sum_{k=1}^n x_k^2 P(X = x_k) \\ &= 0^2 \times P(X = 0) + 1^2 \times P(X = 1) + 2^2 \times P(X = 2) \\ &= 0^2 \times \frac{1}{4} + 1^2 \times \frac{2}{4} + 2^2 \times \frac{1}{4} = \frac{3}{2}. \end{aligned}$$

E , por sua vez, a variância é dada da seguinte forma:

$$Var(X) = E(X^2) - [E(X)]^2 = \frac{3}{2} - 1^2 = \frac{1}{2}.$$

Exemplo 24. Para os modelos probabilísticos discretos e contínuos vistos anteriormente, pode-se demonstrar que os respectivos valores médios e variâncias são dados por:

- $X \sim \text{Bernoulli}(p) \longrightarrow E(X) = p \quad e \quad Var(X) = p(1 - p);$
- $X \sim \text{Binomial}(n, p) \longrightarrow E(X) = np \quad e \quad Var(X) = np(1 - p);$
- $X \sim \text{Poisson}(\lambda) \longrightarrow E(X) = Var(X) = \lambda;$
- $X \sim \text{Exponencial}(\lambda) \longrightarrow E(X) = \frac{1}{\lambda} \quad e \quad Var(X) = \frac{1}{\lambda^2}.$

2.6 Curva Normal de probabilidade

Esta é a mais importante distribuição de probabilidade para descrever uma variável aleatória contínua, pois abrange uma grande variedade de fenômenos. A distribuição Normal de probabilidade é utilizada em uma ampla variedade de aplicações práticas nas quais as variáveis aleatórias são contínuas. Podemos destacar algumas dessas variáveis: alturas e pesos de pessoas, contagens de quociente de inteligência (QI), medições científicas, níveis de colesterol e triglicerídeos, índice de massa corporal (IMC), pressão arterial, índices pluviométricos e assim por diante. A distribuição Normal foi estudada primeiramente no século XVIII, quando um processo de análise

de erros experimentais conduziu a uma curva em formato de sino. Ela também é chamada de distribuição Gaussiana, em homenagem ao cientista alemão Carl Friedrich Gauss, que foi o primeiro a usá-la em 1809, apesar dela ter surgido muito antes, em 1733, por meio de Abraham de Moivre.

No início, assumia-se que todos os fenômenos reais deveriam se ajustar a uma curva em forma de sino (formato campanular), do contrário, levantava-se suspeitas de uma eventual “anormalidade” no processo de coleta dos dados. Daí, então, a denominação de curva Normal. Contudo, a posterior investigação cuidadosa apontou que essa hipotética universalidade da curva (ou distribuição) Normal não era condizente com a realidade. De fato, não são raros os exemplos de fenômenos reais representados (modelados) por distribuições não Normais, como as curvas assimétricas. Não obstante, a distribuição Normal tem um papel importante na Estatística, sendo que os processos de inferência nela baseados têm ampla aplicação (Correa, 2003).

Dizemos que X tem distribuição Normal se sua função densidade de probabilidade (fdp) é dada por:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}, \quad -\infty < x < \infty,$$

com $-\infty < \mu < \infty$ e $\sigma^2 > 0$.

A Figura 2.3 mostra a forma campanular da distribuição Normal.




Figura 2.3: Forma campanular da distribuição Normal.

Notação: $X \sim N(\mu, \sigma^2)$.

Lê-se: “ X tem distribuição Normal com parâmetros μ e σ^2 ”. O parâmetro de localização μ é a média da curva Normal e o parâmetro de escala σ^2 é a sua variância, em que $\sigma = \sqrt{\sigma^2}$ é o desvio-padrão.

A Figura 2.4 mostra duas distribuições Normais com o mesmo valor de desvio-padrão, mas cada uma com uma média diferente.

A Figura 2.5 mostra três distribuições Normais com a mesma média, mas com variâncias diferentes.




Figura 2.4: Distribuições Normais com o mesmo desvio-padrão e médias diferentes.





Figura 2.5: Distribuições Normais com a mesma média e diferentes variâncias.

2.6.1 Características da curva Normal

A curva Normal tem as seguintes características:

1. $E(X) = \mu$ e $Var(X) = \sigma^2$;
2. O ponto máximo de $f(x)$ é: $x = \mu$;
3. A distribuição tem forma de sino e é simétrica em torno de μ ;
4. A moda e a mediana são iguais à média, isto é, $Me(X) = Mo(X) = E(X) = \mu$;
5. Os pontos de inflexão da curva são: $\mu - \sigma$ e $\mu + \sigma$;
6. O intervalo $[\mu - \sigma; \mu + \sigma]$ compreende aproximadamente 68,26% dos dados;
7. O intervalo $[\mu - 2\sigma; \mu + 2\sigma]$ compreende aproximadamente 95,44% dos dados;
8. O intervalo $[\mu - 3\sigma; \mu + 3\sigma]$ compreende aproximadamente 99,74% dos dados.



Observação: Como o cálculo de probabilidades envolve o cálculo da integral de $f(x)$, que não é trivial, utilizam-se tabelas obtidas a partir da curva Normal padronizada (ver Tabela A1 do Apêndice).


2.6.2 Distribuição Normal reduzida ou padronizada

Como vimos na seção anterior, a probabilidade de uma variável aleatória contínua assumir valores entre a e b é igual à área sob a curva entre esses dois pontos. A determinação dessa probabilidade é realizada matematicamente através da integração da fdp entre os pontos a e b . No caso da distribuição Normal, a integral não pode

ser calculada de forma exata, ou seja, a probabilidade entre dois pontos só pode ser obtida de forma aproximada por métodos numéricos (Correa, 2003). Entretanto, esta tarefa é facilitada pela utilização da distribuição Normal padrão, que é definida a seguir.

Resultado: Se $X \sim N(\mu, \sigma^2)$, então a variável aleatória

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1).$$



Conforme observa Collischonn (2021), uma área sob uma curva de densidade fornece uma proporção das observações em um intervalo da distribuição. Assim, podemos responder qualquer pergunta acerca de qual proporção de observações está em uma certa amplitude de valores, calculando uma área sob a curva. Como todas as distribuições Normais são iguais quando as padronizamos, podemos determinar áreas sob a curva Normal utilizando uma única tabela que nos forneça as áreas sob a curva para a distribuição Normal padrão (ver Tabela A2 do Apêndice).

Cálculo de probabilidades usando a curva Normal padrão

Passos para a determinação das proporções Normais:

Passo 1. Enunciar o problema em termos da variável X observada;

Passo 2. Padronizar X para reformular o problema em termos de uma variável Normal padrão Z . Fazer o gráfico para mostrar a área sob a curva Normal padrão;

Passo 3. Determinar a área solicitada sob a curva Normal padrão, usando a tabela da curva Normal Z e o fato de que a área total sob a curva é 1.

O cálculo de probabilidades acumuladas sob a distribuição Normal, pode ser realizado mediante o uso do seguinte comando no R:


```
> pnorm(x, media, desvio) # Cálculo de P(X<=x) sob o modelo Normal  
com média = media e variância = desvio**2
```

Exemplo 25. Foi feito um estudo sobre a altura dos homens adultos de um município, observando-se que esta é distribuída normalmente com média 172 cm e variância 25 cm². Qual a porcentagem dos indivíduos com altura:

- a) Entre 157 cm e 187 cm?
- b) Acima de 190 cm?

Solução:


a) Seja X a altura (em cm) dos homens adultos deste município. Então, temos que $X \sim N(172, 25)$ e a área de interesse é:



Logo, pela padronização, temos:

$$\begin{aligned} P(157 \leq X \leq 187) &= P\left(\frac{157 - 172}{5} \leq Z \leq \frac{187 - 172}{5}\right) \\ &= P(-3 \leq Z \leq 3), \end{aligned}$$

o que corresponde à seguinte área da distribuição Normal padronizada:




Logo, segue que:

$$\begin{aligned} P(157 \leq X \leq 187) &= P(-3 \leq Z \leq 0) + P(0 < Z \leq 3) \\ &= 0,4987 + 0,4987 \\ &= 0,9974. \end{aligned}$$

Ou seja, a probabilidade de que um homem adulto deste município tenha uma altura entre 157 cm e 187 cm é de 99,74%.

```
> # Código em R:
> pnorm(187, 172, 5) - pnorm(157, 172, 5)
[1] 0.9973002
> # ou de forma equivalente:
> pnorm(3, 0, 1) - pnorm(-3, 0, 1)
[1] 0.9973002
```


b) Temos que a área de interesse é:



Pela padronização, temos:

$$\begin{aligned} P(X > 190) &= P\left(Z > \frac{190 - 172}{5}\right) \\ &= P(Z > 3,6), \end{aligned}$$

o que corresponde à seguinte área da distribuição Normal padronizada:



Logo,

$$\begin{aligned} P(X > 190) &= 0,5 - P(0 \leq Z < 3,6) \\ &= 0,5 - 0,4998 \\ &= 0,0002. \end{aligned}$$

Ou seja, a probabilidade de que um homem adulto deste município tenha uma altura maior do que 190 cm é de 0,02%. Em outras palavras, podemos dizer que é extremamente improvável a ocorrência de uma altura superior a 190 cm.

```
> # Código em R:
> 1 - pnorm(190, 172, 5)
[1] 0.0001591086
> # ou ainda:
> pnorm(190, 172, 5, lower.tail=FALSE)
[1] 0.0001591086
```

Exemplo 26. (Padovani, 2012). A duração das gestações humanas, da concepção até o nascimento, varia segundo uma distribuição que é aproximadamente Normal com média de 266 dias e desvio-padrão de 16 dias.

a) Qual o percentual de gestações com duração menor do que 240 dias (por volta de 8 meses)?

b) Qual o percentual de gestações com duração entre 240 e 270 dias (aproximadamente entre 8 e 9 meses)?

c) Qual o percentual de gestações com duração menor do que 210 dias (por volta de 7 meses)?

Solução:

a) Seja X a duração das gestações humanas (em dias). Então, temos que $X \sim N(266, 16)$. Logo,

$$\begin{aligned} P(X < 240) &= P\left(Z < \frac{240 - 266}{16}\right) \\ &= P(Z < -1,625) \\ &= 0,5 - P(-1,625 < Z < 0) \\ &= 0,5 - 0,4479 \\ &= 0,0521. \end{aligned}$$

Ou seja, 5,21% das gestações duram menos do que 240 dias (ou ≈ 8 meses).

```
> # Código em R:
> pnorm(240, 266, 16)
[1] 0.05208128
```

b)

$$\begin{aligned} P(240 \leq X \leq 270) &= P\left(\frac{240 - 266}{16} \leq Z \leq \frac{270 - 266}{16}\right) \\ &= P(-1,625 \leq Z \leq 0,25) \\ &= P(-1,625 \leq Z \leq 0) + P(0 < Z \leq 0,25) \\ &= 0,4479 + 0,0987 \\ &= 0,5466. \end{aligned}$$

Ou seja, 54,66% das gestações duram entre 240 e 270 dias (por volta de 8 a 9 meses).

```
> # Código em R:  
> pnorm(270, 266, 16) - pnorm(240, 266, 16)  
[1] 0.546625
```

c)

$$\begin{aligned} P(X < 210) &= P\left(Z < \frac{210 - 266}{16}\right) \\ &= P(Z < -3,5) \\ &= 0,5 - P(-3,5 < Z \leq 0) \\ &= 0,5 - 0,4998 \\ &= 0,0002. \end{aligned}$$

Ou seja, 0,02% das gestações duram menos do que 210 dias (ou ≈ 7 meses).

```
> # Código em R:  
> pnorm(210, 266, 16)  
[1] 0.0002326291
```

2.7 Considerações finais

Apresentamos neste capítulo os elementos básicos da teoria das probabilidades para dados discretos e contínuos, usados na Inferência Estatística, que será assunto dos próximos capítulos. Também apresentamos, em geral, de forma breve, as principais distribuições (ou modelos) de probabilidade discretas (Bernoulli, binomial e Poisson) e contínuas (Normal e exponencial, com enfoque na distribuição Normal, também conhecida como distribuição Gaussiana), assim como suas propriedades e particularidades. Entretanto, outras distribuições importantes, como t -Student, Qui-quadrado e F-Snedecor (todas contínuas), serão introduzidas e aplicadas intensamente nos capítulos posteriores.

2.8 Exercícios propostos

Exercício 1. Um restaurante universitário (RU) oferece duas opções de cardápio: padrão e vegetariano. Em uma sondagem com alunos e professores que frequentavam o RU, verificou-se que 65% dos alunos preferem a refeição padrão, 40% dos professores escolhem o prato vegetariano, e 75% dos frequentadores são alunos. Considere os seguintes eventos:

B: “Frequentador prefere a opção vegetariana”.

c) $P(B \mid D)$. f) $P(D \mid A)$.

B: “Face menor ou igual a 3 no 2º lançamento”.

d) O valor h tal que $P(100 - h < X < 100 + h) = 0,90$.

x	0	1	2	3	4	5
$P(X = x)$	0,30	0,40	c	0,10	0,04	0,01

- Qual valor deve ter a constante c ?
- Esboce o gráfico da função de probabilidade de X .
- Determine a função de distribuição acumulada de X e esboce o seu gráfico.
- Calcule $P(X \leq 2)$, $P(1 \leq X < 4)$ e $P(1 \leq X \leq 3 \mid X > 0)$.
- Calcule $E(X)$ e $Var(X)$.
- Encontre $E(2 + X)$ e $Var(5X)$.

$$P(X > x + k \mid X > x) = P(X > k), \quad \forall x, k \geq 0.$$

Exercício 6. Segundo uma empresa fabricante de baterias de *notebook*, as baterias de sua fabricação têm vida média de 550 dias e desvio-padrão de 150 dias, sendo que a duração de vida tem distribuição aproximadamente Normal.

- a) Se a empresa oferece uma garantia de 270 dias, qual a proporção de baterias que deverão ser trocadas por apresentarem falhas neste período?
- b) Qual deveria ser a garantia (em dias) de tal forma a assegurar que a empresa trocaria, sob garantia, no máximo 2% das baterias?
- c) Se são fabricadas 1.000 baterias mensalmente, quantas deverá trocar pelo uso da garantia, mensalmente?

Exercício 7. Suponha que o número de gols marcados por um time em uma partida de futebol siga um modelo de Poisson com uma taxa de 2 gols por partida.

- a) Qual a probabilidade de que, em uma partida escolhida ao acaso, esse time tenha marcado pelo menos 1 gol?
- b) Se 10 partidas desse time são escolhidas, ao acaso e de forma independente, qual é a probabilidade de pelo menos 5 partidas com pelo menos 1 gol marcado?
- c) Dentro das condições de (b), considere a variável que conta o número de partidas com pelo menos 1 gol marcado pelo time em questão. Qual o modelo de probabilidade dessa variável?

Capítulo 3

Sumarização de dados

Resumo do capítulo: *Neste capítulo, o foco é dado à apresentação gráfica e tabular dos dados, medidas de tendência central e de dispersão, análise gráfica e descritiva dos dados.*

Objetivos: *Ao final deste capítulo, o leitor será capaz de fazer uma análise descritiva de dados qualitativos e quantitativos.*

3.1 Introdução

Estudaremos a seguir como extrair informações dos dados por meio da **Estatística Descritiva**, que tem como objetivo sintetizar as informações contidas em uma amostra ou censo por meio de duas ferramentas principais: distribuições de frequências e medidas numéricas descritoras. O elemento fundamental do trabalho de um pesquisador são as observações, que podem ser, por exemplo, a velocidade de um objeto em movimento, a resistência à ruptura de um grampo de suspensão, o rendimento de uma reação química, a suscetibilidade ou não de plantas a doenças, o sexo do primeiro filho de um casal, a cor de cabelo ou dos olhos de um indivíduo, a opinião de consumidores sobre determinado produto ou serviço etc.

Essas observações têm em comum uma característica básica: a variação ou variabilidade, isto é, elas podem assumir diferentes valores de indivíduo para indivíduo. Qualquer característica de interesse, cujos valores variam de elemento para elemento, é chamada de variável. Caso contrário, é chamada de constante. As variáveis podem ser classificadas em:

Qualitativas (ou categóricas): são aquelas características cujos valores são expressos por atributos. Subdividem-se em:

- *Nominais*: não existe uma ordem definida dos níveis ou categorias. Exemplos: sexo, etnia, grupo sanguíneo, cor de cabelo, time de futebol preferido etc.

- *Ordinais*: existe uma ordem definida. Exemplos: gravidade da doença (leve, moderada ou grave), nível socioeconômico (classes A a E) etc.

Quantitativas (ou numéricas): são aquelas características cujos valores são resultados de contagens ou medições. Subdividem-se em:

- *Discretas*: são próprias de dados de contagem, isto é, só podem assumir valores inteiros. Exemplos: número de filhos de um casal, número de ovos depositados por um inseto, número de pessoas desempregadas numa família, número de gols marcados por uma equipe em uma determinada partida de futebol etc.
- *Contínuas*: são aquelas resultantes de medições, logo, podem assumir qualquer valor real dentro de um intervalo. Exemplos: resistência à tração, altura, taxa de colesterol, IMC, tempo que um medicamento demora para fazer efeito etc.

3.2 Representação gráfica

A representação gráfica é uma maneira eficiente e simples de apresentar os dados, pois ajuda a compreender mais rapidamente a distribuição de uma variável, a comparar grupos de dados e verificar se existem relações entre eles.

Há muitas possibilidades gráficas, mas a escolha apropriada do gráfico a ser utilizado está associada ao tipo de variável em estudo. As variáveis qualitativas podem ser representadas por:

- Gráficos em barras;
- Gráficos em setores (Gráficos de “pizza”);
- Gráficos em retângulo.

As variáveis quantitativas, por sua vez, podem ser representadas por:

- Diagramas de pontos;
- Histogramas;
- Funções densidade estimadas (Polígonos de frequências);
- Ramos-e-folhas;
- *Box plots* (Diagramas de caixa).

3.2.1 Representação gráfica: dados categóricos

Gráfico em barras

O gráfico em barras é usado para representar a distribuição de variáveis qualitativas nominais e ordinais. As categorias das variáveis nominais podem ser dispostas em qualquer ordem que se deseje, por exemplo, em ordem alfabética. O gráfico pode ser construído a partir das frequências absolutas, frequências relativas ou percentuais. O uso das frequências relativas é mais vantajoso, pois se houver a necessidade

de comparar gráficos em barras de várias amostras (grupos) com tamanhos distintos, teremos a garantia de que a soma das barras é igual a um. As categorias nas quais as observações estão classificadas são dispostas num eixo horizontal e cada categoria da variável é representada por uma barra. A altura de cada barra é proporcional à frequência (ou algumas vezes, a porcentagem) da categoria. As barras devem ser de mesma largura e separadas uma da outra.

Para os casos em que introduzimos as categorias das variáveis qualitativas em ordem de porcentagem ou frequência relativa, o gráfico em barras é denominado de gráfico de Pareto (a barra mais alta, maior porcentagem, fica mais à esquerda e as barras menores se afastam para a direita).

Num exemplo de *credit scoring*, uma das variáveis qualitativas presente é o *status* (tipo) de cliente. A Figura 3.1 apresenta o gráfico em barras para a variável “*status* de cliente”, no qual podemos perceber que 700 indivíduos (70%) analisados são tidos como bons clientes.




Figura 3.1: Gráfico em barras para a variável “*status* de clientes”.

A seguir, os comandos para a execução do gráfico acima no *software* R.

```
> barplot(c(0.7,0.3), xlab="Status de clientes", ylab="Frequência  
relativa", col=c("darkblue","green"), names.arg=c("Bom","Ruim"),  
beside=T, ylim=c(0,1), xlim=c(0,2.5))
```

Gráfico em setores

O gráfico em setores é construído a partir da divisão de um círculo em proporções apropriadas, ou seja, em tantos setores quantas forem as categorias da variável

e com área proporcional à frequência de cada categoria. Os ângulos dos setores são proporcionais às frequências (ocorrências) das categorias que representam. Por exemplo, uma categoria com frequência relativa igual a 0,45 terá um setor com ângulo igual a $360 \times 0,45 = 162$ graus.

Como este tipo de gráfico é usado para descrever as partes de um todo, então deve-se incluir todas as categorias que o compõe. Por exemplo, pode-se utilizar um gráfico em setores para avaliar o sexo dos clientes analisados no exemplo de *credit scoring*, pois todos os clientes se enquadram em uma das duas categorias (masculino e feminino).

A Figura 3.2 apresenta o gráfico em setores para a variável “sexo” dos clientes analisados no exemplo de *credit scoring*. Por meio deste gráfico, pode-se perceber que a maioria (69,1%) dos indivíduos analisados é do sexo masculino.




Figura 3.2: Gráfico em setores do sexo dos clientes.

A seguir, os comandos para a execução do gráfico acima no *software* R.

```
> fatias<-c(691,309)
> nomes<-c("Masculino","Feminino")
> pct<-round(fatias/sum(fatias)*100,1)
> nomes<-paste(nomes,pct); nomes<-paste(nomes,"%",sep="")
> pie(fatias, col=c("blue","red"), labels=nomes, main="Sexo")
```

Gráfico em retângulo

Exatamente o mesmo caso do gráfico em setores, porém na forma de um retângulo (barra) vertical ou horizontal. A ideia deste gráfico, bem como do gráfico em seto-

res, é mostrar como se dá a divisão do total, sendo que, em ambos os gráficos, o percentual das categorias deve somar 100%.

A Figura 3.3 apresenta o gráfico em retângulo para a variável “sexo” dos clientes analisados no exemplo de *credit scoring*. Por meio deste gráfico, pode-se perceber que a maioria (69,1%) dos indivíduos analisados é do sexo masculino.



Figura 3.3: Gráfico em retângulo para a variável “sexo” dos clientes.

Comandos para a execução do gráfico acima no *software* R:

```
> alunosprof<-matrix(c(0.691,0.309), nrow=2, ncol=1, dimnames=list(c(
  "Masculino","Feminino"), c("Sexo")))
> barplot(alunosprof, col=c("yellow","orange"), xlim=c(0,2), ylab="
  Frequência relativa", legend=c("Masculino","Feminino"), beside=
  FALSE, cex.names=1.1)
```

Gráfico em barras múltiplas

As vantagens da representação gráfica se tornam mais evidentes quando é preciso comparar múltiplos grupos com relação às variáveis.

Muitas vezes, os dados em estudo envolvem mais do que um grupo. Por exemplo, se desejarmos comparar o comportamento da variável “*status* do cliente” nas diferentes categorias da variável “saldo da conta corrente”, podemos utilizar um gráfico em barras múltiplas como apresentado na Figura 3.4, colocando no eixo vertical a frequência relativa ou o percentual para facilitar a comparação. Tal gráfico enfatiza que, nos saldos superiores a R\$ 300,00, encontra-se a maior parte de bons pagadores,

e ainda mostra que, para não correntistas, temos praticamente a mesma proporção de bons e maus pagadores.




Figura 3.4: Gráfico em barras múltiplas do *status* do cliente segundo saldo da conta corrente.

Comandos para a execução do gráfico acima no *software* R:

```
> saldo<-matrix(c(0.014,0.049,0.046,0.348,0.135,0.139,0.105,0.164),
  nrow=2, ncol=4)
> barplot(saldo, col=c("blue","green"), ylim=c(0,0.4), names=c(
  expression("<=",">R$300"),"Não correntista","Inativa"),
  ylab="Frequência relativa", legend=c("Ruim","Bom"), beside=TRUE,
  cex.names=1.1)
```

3.2.2 Representação gráfica: dados quantitativos

Histograma

No caso das variáveis quantitativas, pode ser que a variável estudada assuma um grande número de valores, todos (ou a grande maioria) com baixas frequências. Logo, um gráfico da distribuição torna-se mais claro se os valores próximos entre si forem agrupados.

O histograma é um gráfico em barras justapostas usado para representar a distribuição de uma variável quantitativa contínua, possibilitando uma melhor compreensão do padrão geral assumido pelos dados e de sua variabilidade.

Para a construção do histograma, deve-se proceder da seguinte maneira.

No eixo horizontal, represente a escala da variável cuja distribuição se deseja representar; e no eixo vertical, coloque a frequência relativa ou o percentual.

Se os intervalos de classe tiverem mesma amplitude, as barras construídas para cada classe terão altura proporcional à frequência e base igual ao tamanho da classe. Se os intervalos de classe tiverem amplitudes diferentes, as barras construídas para cada classe terão área proporcional à frequência da classe com base igual ao tamanho da classe e altura obtida da seguinte maneira:

$$\text{altura da barra} = \frac{\text{frequência relativa da classe}}{\text{amplitude da classe}}.$$

Deste modo, se utilizarmos para a altura as frequências relativas, a área total será igual a 1. Porém, se utilizarmos as frequências absolutas, a área total será n .

Na Figura 3.5, apresentamos o histograma dos pesos (em gramas) dos 80 ratos cobaias (ratos de laboratório) em idade adulta (conjunto de dados simulados). Notamos que a distribuição dos pesos é aproximadamente simétrica, com pesos distribuídos em torno de 200 gramas.




Figura 3.5: Histograma dos pesos dos ratos.

Comandos para a execução deste gráfico no *software* R:

```
> x<-c(241,228,126,259,206,201,233,151,197,165,147,276,246,234,
156,199,161,120,199,189,197,174,201,195,201,208,149,243,204,177,
233,207,214,235,202,192,202,228,221,181,204,186,205,193,200,181,
241,200,196,265,206,209,185,242,137,252,174,172,196,262,278,276,
```

```
206,211,209,131,185,214,151,155,222,198,183,237,242,186,193,227,
209,132)
> hist(x, main="", xlab="Peso (gramas)", ylab="Frequência absoluta",
density=6, col="red")
```

Função densidade estimada

A função densidade estimada, também conhecida como polígono de frequência, é um gráfico similar ao histograma, apresentando na ordenada as frequências das classes e na abscissa as classes da variável em questão. Esse gráfico é construído unindo-se os pontos médios dos topos dos retângulos que representam as classes, obtendo assim uma linha poligonal que dá origem ao nome do gráfico.

A Figura 3.6 apresenta a função densidade estimada dos pesos (em gramas) dos 80 ratos cobaias em idade adulta, na qual percebemos que a distribuição dos pesos é aproximadamente simétrica.




Figura 3.6: Função densidade estimada dos pesos dos ratos de laboratório.

Comandos para a execução deste gráfico no *software* R:

```
> aux=hist(x, main="", xlab="Peso (gramas)", ylab="Frequência
absoluta", density=6, col="red")
> plot(c(min(aux$breaks), aux$mids, max(aux$breaks)), c(0,aux$counts
,0), type="b", main="", xlab="Peso (gramas)", ylab="Frequência
absoluta")
```

Função de distribuição empírica

A função de distribuição empírica (fde), também chamada de ogiva, representa graficamente as frequências acumuladas. Nessa representação, cada frequência acumulada é associada a um limite de classe, que pode ser o limite inferior ou o limite superior, conforme a curva seja construída de forma decrescente ou crescente.

Diferentemente do histograma e do polígono de frequências, a ogiva usa os limites das classes no eixo horizontal e as frequências acumuladas no eixo vertical. Os pontos assim obtidos são ligados por segmentos de reta, como mostra a Figura 3.7. Na construção crescente, a frequência acumulada no limite inferior da primeira classe começa em zero.

Pela função de distribuição empírica dos pesos dos 80 ratos, observa-se que aproximadamente metade dos animais pesa menos de 200 gramas.

A Figura 3.7 mostra, para os pesos (em gramas) dos 80 ratos de laboratório em idade adulta, a versão crescente da função de distribuição empírica, ou função de distribuição acumulada empírica (painel esquerdo), e a versão decrescente, ou função de sobrevivência empírica (painel direito).




Figura 3.7: Funções de distribuição empírica crescente (esquerda) e decrescente (direita) dos pesos dos 80 ratos de laboratório.

Comandos para a execução deste gráfico no *software* R:

```
> y<-cumsum(rep(1,length(x)))  
> par(mfrow=c(1,2)) # imprime dois gráficos na mesma figura  
> par(mai=c(0.8,0.8,0.1,0.1))  
> plot(sort(x), y, type="o", col="blue", lwd=1, xlab="Peso (gramas)",  
       ylab="Frequência acumulada", main="", pch=19) # crescente
```

```
> plot(sort(x), sort(y,decreasing=TRUE), type="o", col="blue", lwd=1,
      xlab="Peso (gramas)", ylab="Frequência acumulada", main="", pch
      =19) # decrescente
```

Gráfico temporal

Um caso especial de um gráfico de pontos é um gráfico temporal cujas observações são registradas na ordem em que elas ocorrem.

No eixo vertical do gráfico, é colocado o valor observado da variável; e no eixo horizontal, o tempo em intervalos iguais ou não. A união dos pontos sucessivos por linhas ajuda a enfatizar qualquer mudança que ocorra no decorrer do tempo, como tendências, ciclos ou outras características que não poderiam ser vistas com outros tipos de gráficos.

A Figura 3.8 mostra um gráfico da série temporal para o percentual de alunos ingressantes em uma universidade pública federal, no período de 2001 a 2012, que fizeram o ensino médio em instituições públicas e privadas. Esse gráfico mostra claramente que o percentual de alunos ingressantes que fizeram o ensino médio em escolas públicas sempre foi menor do que o percentual de alunos que fizeram o ensino médio em escolas particulares, e tal diferença vem aumentando ao longo desse período.




Figura 3.8: Percentual de alunos ingressantes em determinada universidade pública federal, no período de 2001 a 2012, segundo o tipo de escola do ensino médio.

Comandos para a execução deste gráfico no *software* R:

```

> publica<-c(45.8,45.4,41.1,37.2,38.3,33.6,33.1,34.07,32.14,
  31.83,27.91,27.17)
> privada<-c(54.2,54.4,59.1,62.8,61.9,66.2,66.6,65.95,67.84,
  68.18,72.07,72.83)
> anos<-c
  (2001,2002,2003,2004,2005,2006,2007,2008,2009,2010,2011,2012)
> plot(anos, publica, type="o", col="blue", lwd=1, ylim=c(0,90), lty
  =1, xlab="Ano", ylab="Percentual", main="", pch=19, xlim=c
  (2001,2012))
> points(anos, privada, type="o", col="red", lwd=2, pch=19)
> legend(2002, 91, lwd=3, cex=1, c("Pública","Privada"), col=c("blue"
  ,"red"), lty=1)

```

Box plot

O *box plot* (ou *boxplot*) é um tipo de gráfico que mostra simultaneamente as características de centro, dispersão, desvios da simetria e identificação de observações discrepantes de um conjunto de dados.

Para construção desse gráfico, obtém-se primeiro as seguintes estatísticas: primeiro quartil (Q_1), segundo quartil (Q_2), terceiro quartil (Q_3) e a distância interquartilica (DQ), definida como $DQ = Q_3 - Q_1$. O conjunto de valores compreendidos entre Q_1 e Q_3 é representado por um retângulo, com a mediana identificada por uma barra; a largura do retângulo pode ser qualquer, pois não fornece nenhuma informação. A partir dos limites do retângulo, traçam-se linhas até encontrar um extremo que não seja menor do que $LI = Q_1 - 1,5DQ$ ou maior do que $LS = Q_3 + 1,5DQ$. As observações que estiverem abaixo do LI ou acima do LS são denominadas de pontos externos e representadas por asteriscos.

A distância dos quartis e dos extremos em relação à mediana dá indicação de simetria ou assimetria da distribuição dos dados. Em uma distribuição simétrica, a mediana está à mesma distância de Q_1 e Q_3 . A DQ mostra a dispersão da metade central do conjunto de dados e os extremos mostram a dispersão de todo o conjunto de dados. Os pontos que estão localizados a mais de $1,5DQ$ do quartil correspondente até $3DQ$ são chamados de pontos externos e, os que estão a mais de $3DQ$, de pontos soltos.

A Figura 3.9 representa o *box plot* para o percentual de alunos ingressantes na universidade mencionada anteriormente. Tal gráfico indica que há uma grande diferença entre os alunos que fizeram o ensino médio em escolas públicas e privadas. Notamos ainda que, em 50% das vezes, o número de alunos ingressantes de escolas privadas é quase 2 vezes maior do que o de escolas públicas.

Comandos para a execução deste gráfico no *software* R:

```
# É necessário ter os dados indexados do exemplo anterior!
```




Figura 3.9: *Box plot* para o percentual de alunos ingressantes em determinada universidade pública federal, segundo o tipo de escola do ensino médio.

```
> boxplot(publica, privada, range = 1.5, col=c("darkblue","green"),
  main="", ylab="Percentual", names=c("Pública", "Privada"),
  horizontal=FALSE)
```

3.3 Medidas de posição central

As medidas de posição, localização ou tendência central resumem os dados por meio de valores que procuram representar o centro da distribuição observada. Entre as medidas mais utilizadas estão a média, a moda e a mediana. Antes de apresentá-las, introduziremos a notação de somatório.

3.3.1 Somatório

O operador linear somatório, denotado por $\sum$, possui propriedades que serão usadas ao longo deste capítulo. Elas servem de apoio para a definição e a manipulação algébrica das medidas de posição e de dispersão.

A seguir, apresentaremos algumas propriedades básicas do somatório.

Propriedade 4. *O somatório de uma constante c ($c \in \mathbb{R}$), para $i = 1, \dots, n$, é dado por n vezes a constante c , isto é, $\sum_{i=1}^n c = nc$, $\forall c \in \mathbb{R}$.*

Demonstração:

$$\sum_{i=1}^n c = \underbrace{c + c + \dots + c}_{n \text{ vezes}} = nc. \quad \blacksquare$$

Propriedade 5. O somatório dos dados em que cada observação foi multiplicada por uma constante c ($c \in \mathbb{R}$), para $i = 1, \dots, n$, é dado pela constante vezes o somatório das observações, isto é, $\sum_{i=1}^n X_i c = c \sum_{i=1}^n X_i$, $\forall c \in \mathbb{R}$.

Demonstração:

$$\sum_{i=1}^n X_i c = X_1 c + X_2 c + \dots + X_n c = c \underbrace{(X_1 + X_2 + \dots + X_n)}_{\sum_{i=1}^n X_i} = c \sum_{i=1}^n X_i. \quad \blacksquare$$

Propriedade 6. O somatório de conjunto de variáveis é dado pelo somatório individual de cada variável, isto é, o somatório da soma (ou subtração) de parcelas é a soma (ou subtração) dos somatórios de cada parcela, ou seja, $\sum_{i=1}^n (X_i \pm Y_i) = \sum_{i=1}^n X_i \pm \sum_{i=1}^n Y_i$.

Demonstração: Vamos considerar somente o caso positivo, pois o caso negativo é análogo.

$$\begin{aligned} \sum_{i=1}^n (X_i + Y_i) &= (X_1 + Y_1) + (X_2 + Y_2) + \dots + (X_n + Y_n) \\ &= X_1 + Y_1 + X_2 + Y_2 + \dots + X_n + Y_n \\ &= \underbrace{X_1 + X_2 + \dots + X_n}_{\sum_{i=1}^n X_i} + \underbrace{Y_1 + Y_2 + \dots + Y_n}_{\sum_{i=1}^n Y_i} \end{aligned}$$

Logo,

$$\sum_{i=1}^n (X_i + Y_i) = \sum_{i=1}^n X_i + \sum_{i=1}^n Y_i. \quad \blacksquare$$

Observação: Esta propriedade se estende a mais de duas variáveis.

Propriedade 7. O somatório do produto é diferente do produto dos somatórios. Em particular, se $X_i > 0$ e $Y_i > 0$, $i = 1, 2, \dots, n$, então o somatório do produto é menor que o produto dos somatórios, isto é,

$$\sum_{i=1}^n X_i Y_i < \sum_{i=1}^n X_i \sum_{i=1}^n Y_i.$$

Demonstração:

$$\begin{aligned}
\sum_{i=1}^n X_i Y_i &< \sum_{i=1}^n X_i \sum_{i=1}^n Y_i \\
X_1 Y_1 + X_2 Y_2 + \dots + X_n Y_n &< (X_1 + X_2 + \dots + X_n) (Y_1 + Y_2 + \dots + Y_n) \\
\underbrace{X_1 Y_1 + X_2 Y_2 + \dots + X_n Y_n}_{\sum_{i=1}^n X_i Y_i} &< \underbrace{X_1 \sum_{i=1}^n Y_i}_{\geq X_1 Y_1} + \underbrace{X_2 \sum_{i=1}^n Y_i}_{\geq X_2 Y_2} + \dots + \underbrace{X_n \sum_{i=1}^n Y_i}_{\geq X_n Y_n}
\end{aligned}$$

Como $X_i Y_i < X_i \sum_{i=1}^n Y_i$, $i = 1, 2, \dots, n$, então segue imediatamente que:

$$\sum_{i=1}^n X_i Y_i < \sum_{i=1}^n X_i \sum_{i=1}^n Y_i. \quad \blacksquare$$

3.3.2 Média aritmética

Entre as medidas de posição central mencionadas, a média aritmética é uma das mais frequentes na prática. Sua popularidade decorre da interpretação direta, do cálculo simples e da facilidade com que pode ser manipulada em expressões algébricas (Tavares, 2014).

De modo intuitivo, a média aritmética corresponde ao valor que equilibra o conjunto de dados. Ela é calculada dividindo a soma dos valores observados pelo número total de observações. Assim, para um conjunto de dados $X_1, X_2, \dots, X_n$, a média aritmética é dada por:

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}.$$

Exemplo 27. *Seja o conjunto de dados abaixo, formado pelos pesos ao nascer (em quilogramas, kg) de oito suínos da raça Landrace:*

1,850	1,900	1,350	1,750	1,700	1,500	1,650	1,700
-------	-------	-------	-------	-------	-------	-------	-------

Temos, então, que o peso médio ao nascer desses suínos é:

$$\begin{aligned}
\bar{X} &= \frac{\sum_{i=1}^n X_i}{n} = \frac{\sum_{i=1}^8 X_i}{8} \\
&= \frac{X_1 + X_2 + X_3 + X_4 + X_5 + X_6 + X_7 + X_8}{8} \\
&= \frac{1,850 + 1,900 + 1,350 + 1,750 + 1,700 + 1,500 + 1,650 + 1,700}{8} \\
&= \frac{13,400}{8} = 1,675 \text{ kg.}
\end{aligned}$$

Interpretação: O peso médio ao nascer dos oito suínos foi de 1,675 kg. Isto quer dizer que 1,675 kg é um valor em torno do qual os pesos ao nascer desses oito animais se concentram. Ainda podemos dizer que 1,675 kg é o valor que nivela esse conjunto de dados.

Propriedades da média

A média apresenta certas propriedades muito importantes que nos auxiliam nas operações algébricas envolvendo as variáveis.

Propriedade 1. *Seja $X_1, X_2, \dots, X_n$ um conjunto de dados tal que $X_i = c$, $i = 1, 2, \dots, n$, ou seja, o conjunto de dados é formado por um valor constante. Então, sua média será o próprio valor constante, isto é, $\bar{X} = c$.*

Demonstração: Usando as propriedades dos somatórios, temos:

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n} = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{\overbrace{c + c + \dots + c}^{n \text{ vezes}}}{n} = \frac{nc}{n} = c. \quad \blacksquare$$

Propriedade 2. *Seja $X_1, X_2, \dots, X_n$ um conjunto de dados, então a soma dos desvios em relação à sua média $\bar{X}$ é nula, isto é, $\sum_{i=1}^n (X_i - \bar{X}) = 0$.*

Demonstração: Usando as propriedades dos somatórios, temos:

$$\begin{aligned} \sum_{i=1}^n (X_i - \bar{X}) &= \sum_{i=1}^n X_i - \sum_{i=1}^n \bar{X} = \sum_{i=1}^n X_i - n\bar{X} = \sum_{i=1}^n X_i - n \frac{\sum_{i=1}^n X_i}{n} \\ &= \sum_{i=1}^n X_i - \sum_{i=1}^n X_i = 0. \end{aligned} \quad \blacksquare$$

Propriedade 3. *A soma dos quadrados dos desvios de um conjunto de dados em relação à sua média é sempre um valor mínimo.*

Definição 11. *Considere $X_1, X_2, \dots, X_n$ um conjunto de dados. Seja $\bar{X}$ a sua média, então para todo $\varepsilon > 0$ e arbitrário, temos:*

$$\sum_{i=1}^n (X_i - \bar{X})^2 \leq \sum_{i=1}^n [X_i - (\bar{X} \pm \varepsilon)]^2, \quad \forall \varepsilon > 0.$$

A Propriedade 3 diz que a quantidade $\sum_{i=1}^n (X_i - \bar{X})^2$ é sempre um valor mínimo.

Propriedade 4. Se acrescentarmos ou subtraírmos um valor constante para cada observação do conjunto de dados, então sua média também será acrescida ou subtraída dessa constante. Em outras palavras, seja $X_1, X_2, \dots, X_n$ um conjunto de dados com média $\bar{X}$ e seja c uma constante arbitrária ($c \in \mathbb{R}$). Se fizermos $W_i = X_i \pm c$, então sua nova média, denominada de $\bar{W}$, será $\bar{X} \pm c$.

Demonstração: Vamos demonstrar apenas para o caso positivo, pois o caso negativo é análogo.

$$\begin{aligned}\bar{W} &= \frac{\sum_{i=1}^n (X_i + c)}{n} = \frac{(X_1 + c) + (X_2 + c) + \dots + (X_n + c)}{n} \\ &= \frac{X_1 + X_2 + \dots + X_n + c + c + \dots + c}{n} \\ &= \frac{X_1 + X_2 + \dots + X_n}{n} + \frac{c + c + \dots + c}{n} \\ &= \frac{\sum_{i=1}^n X_i}{n} + \frac{nc}{n} = \bar{X} + c. \quad \blacksquare\end{aligned}$$

Propriedade 5. Multiplicando cada observação do conjunto de dados por um valor constante, então a nova média também fica multiplicada por esse valor constante. Em outras palavras, seja $X_1, X_2, \dots, X_n$ um conjunto de dados com média $\bar{X}$ e seja c uma constante arbitrária ($c \in \mathbb{R}$). Se fizermos $W_i = X_i c$, então sua nova média, denominada de $\bar{W}$, será $\bar{X}c$, $\forall c \in \mathbb{R}$.

Demonstração:

$$\begin{aligned}\bar{W} &= \frac{\sum_{i=1}^n X_i c}{n} = \frac{(X_1 c) + (X_2 c) + \dots + (X_n c)}{n} = \frac{X_1 c + X_2 c + \dots + X_n c}{n} \\ &= \frac{c(X_1 + X_2 + \dots + X_n)}{n} = c \frac{\sum_{i=1}^n X_i}{n} = \bar{X}c. \quad \blacksquare\end{aligned}$$

Características da média

1. São considerados todos os dados da distribuição para o seu cálculo;
2. Sofre influência de valores extremos da distribuição (desvantagem);
3. É única para um conjunto de dados específico.

Exemplo 28. Seja o conjunto de dados formado por: $\{41, 34, 41, 44, 41, 37, 40\}$. A média é dada por:

$$\frac{1}{7} \sum_{i=1}^7 X_i = \frac{41 + 34 + 41 + 44 + 41 + 37 + 40}{7} \approx 39,714.$$

```
> x<-c(41,34,41,44,41,37,40)
> sum(x)/length(x) # uma forma de calcular a média
[1] 39.714
> mean(x) # função predefinida do R
[1] 39.714
```

3.3.3 Moda

A moda é o valor mais frequente de um conjunto de dados, isto é, o valor que mais se repete. Para um conjunto de dados, a moda pode não ser única, ou mesmo não existir.

Definição 12. *Seja um conjunto de dados formado por $X_1, X_2, \dots, X_n$, então a moda ou o valor modal, denominado de Mo , é dado por:*

$$Mo = X_{freq},$$

em que X_{freq} é o valor mais frequente.

Dizemos que o conjunto de dados é:

Amodal: Quando não apresenta nenhum valor mais frequente;

Unimodal: Quando apresenta um valor mais frequente;

Bimodal: Quando apresenta dois valores mais frequentes;

Trimodal: Quando apresenta três valores mais frequentes;

Multimodal: Quando o conjunto de dados apresenta quatro ou mais de quatro valores mais frequentes.

Propriedades da moda

Propriedade 1. *Somando-se ou subtraindo-se um valor constante a todas as observações do conjunto de dados, então a nova moda fica somada ou subtraída desse mesmo valor constante.*

Definição 13. *Seja $X_1, X_2, \dots, X_n$ um conjunto de dados e Mo a sua moda. Se fizermos $X_1 \pm c, X_2 \pm c, \dots, X_n \pm c$, então sua nova moda, denominada de Mo^* , será $Mo \pm c$.*

Propriedade 2. Multiplicando um valor constante a todas as observações do conjunto de dados, então a nova moda fica multiplicada desse mesmo valor constante.

Definição 14. Seja $X_1, X_2, \dots, X_n$ um conjunto de dados e Mo a sua moda. Se fizermos $X_1c, X_2c, \dots, X_nc$, então sua nova moda, denominada de Mo^* , será $Mo c$.

Características da moda (Silva, 2003)

1. Não sofre influência de valores extremos da distribuição;
2. Não tem boas propriedades algébricas (desvantagem);
3. É muito usada em Estatística Econômica e Industrial.

Comandos para o cálculo da moda no *software* R:

```
> moda<-function(C) { # C é o vetor que deseja calcular a moda
D=sort(C) # comando para ordenar os dados
D1=numeric(); D1=D[1]; l1<-1
for (i in 2:length(C)) {
  if (D[i]!=D[i-1]) {
    l1<-l1+1
    D1[l1]<-D[i] }} # finaliza if e for
contador<-as.numeric(0)
for (i in 1:length(D1)) {
  cont=0
  for (j in 1:length(C)) {
    if(D1[i]==C[j]) cont=cont+1 } # finaliza for
  contador[i]=cont } # finaliza for
lm <-0
moda<-numeric()
for (i in 1:length(D1)) {
  if(contador[i]==max(contador)) {
    lm<-lm+1
    moda[lm]<-D1[i] }} # finaliza if e for
  if(length(moda)!=length(C))
    list(moda=moda) else list(moda<-"Amodal")
} # finaliza function
```

Exemplos:

$\{17, 20, 18, 25, 11, 28, 13, 23\}$	$\Rightarrow$	Amodal, pois não há valor mais frequente;
$\{11, 13, 8, 5, 14, 9, 8, 12, 8\}$	$\Rightarrow$	Unimodal, pois $Mo = 8$;
$\{53, 48, 50, 48, 49, 51, 51, 55\}$	$\Rightarrow$	Bimodal, pois $Mo = 48$ e $Mo = 51$;
$\{81, 85, 81, 74, 82, 83, 82, 86, 83\}$	$\Rightarrow$	Trimodal, pois $Mo = 81$, $Mo = 82$ e $Mo = 83$.

```

> A<-c(17,20,18,25,11,28,13,23)
> B<-c(11,13,8,5,14,9,8,12,8)
> C<-c(53,48,50,48,49,51,51,55)
> D<-c(81,85,81,74,82,83,82,86,83)
> moda(A) # terá a moda do conjunto A
[1] "Amodal"
> moda(B) # terá a moda do conjunto B
[1] 8
> moda(C) # terá a moda do conjunto C
[1] 48 51
> moda(D) # terá a moda do conjunto D
[1] 81 82 83

```

3.3.4 Mediana

A mediana é uma medida de tendência central que deixa 50% dos dados abaixo e 50% dos dados acima de si mesma, dividindo as observações ordenadas em duas partes iguais. Para o seu cálculo, é preciso conhecer a posição central.

Definição 15. *Seja um conjunto de dados constituído por $X_1, X_2, \dots, X_n$ e seja $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ tal conjunto de dados ordenados de forma crescente ou decrescente. Então, consideraremos dois casos para a determinação da mediana, denominada de Me , a saber:*

Caso 1. *Quando n for ímpar, a mediana será dada por:*

$$Me = X_{\left(\frac{n+1}{2}\right)}.$$

Caso 2. *Quando n for par, a mediana será dada por:*

$$Me = \frac{X_{\left(\frac{n}{2}\right)} + X_{\left(\frac{n+2}{2}\right)}}{2}.$$

Comandos para o cálculo da mediana no *software* R (Crawley, 2015):

```

> mediana<-function(x) {
  modulo<-length(x)%%2
  if (modulo == 0) (sort(x)[ceiling(length(x)/2)]+sort(x)[ceiling(1+
    length(x)/2)])/2
  else sort(x)[ceiling(length(x)/2)]
} # finaliza function

```

Exemplo 29. *Seja o conjunto de dados formado por: $\{41, 34, 41, 44, 41, 37, 40\}$. Ordenando os dados, temos:*

$$\{34, 37, 40, 41, 41, 41, 44\}.$$

Então, como n é ímpar ($n = 7$), temos que a mediana é dada por:

$$Me = X_{(\frac{n+1}{2})} = X_{(4)} = 41.$$

```
> x<-c(41,34,41,44,41,37,40)
> mediana(x) # função apresentada (Crawley, 2015)
[1] 41
> median(x) # função predefinida do R
[1] 41
```

Exemplo 30. *Seja o conjunto de dados formado por: $\{14, 8, 7, 12, 9, 10, 10, 8\}$. Ordenando os dados, temos:*

$$\{7, 8, 8, 9, 10, 10, 12, 14\}.$$

Então, como n é par ($n = 8$), temos que a mediana é dada por:

$$Me = \frac{X_{(\frac{n}{2})} + X_{(\frac{n+2}{2})}}{2} = \frac{X_{(4)} + X_{(5)}}{2} = \frac{9 + 10}{2} = \frac{19}{2} = 9,5.$$

```
> x<-c(14,8,7,12,9,10,10,8)
> mediana(x) # função apresentada (Crawley, 2015)
[1] 9.5
> median(x) # função predefinida do R
[1] 9.5
```

Propriedades da mediana

Propriedade 1. *A soma dos módulos dos desvios das observações em relação à mediana é mínima.*

Definição 16. *Seja $X_1, X_2, \dots, X_n$ um conjunto de dados e Me a sua mediana. Então, para todo $\varepsilon > 0$ e arbitrário, temos:*

$$\sum_{i=1}^n |X_i - Me| \leq \sum_{i=1}^n |X_i - (Me \pm \varepsilon)|, \quad \forall \varepsilon > 0.$$

Propriedade 2. *Multiplicando um valor constante a todas as observações do conjunto de dados, então a nova mediana fica multiplicada desse mesmo valor constante.*

Definição 17. *Seja $X_1, X_2, \dots, X_n$ um conjunto de dados e Me a sua mediana. Se fizermos $X_1c, X_2c, \dots, X_nc$, então sua nova mediana, denominada de Me^* , será $Me c$.*

Características da mediana

1. Não sofre influência de valores extremos, mas sim do número de observações (n);
2. Embora seja menos usada (menos familiar) do que a média aritmética, a mediana é mais realista para representar determinadas variáveis, como por exemplo, o salário de funcionários de uma empresa;
3. É bastante utilizada em Toxicologia, na determinação da dosagem necessária de certa substância ou tipo de radiação para causar a morte de 50% dos indivíduos de uma população em teste (cobaias), isto é, da dose letal mediana (DL50).

3.3.5 Relações empíricas entre média, moda, mediana e as distribuições de dados

A Tabela 3.1 mostra as relações empíricas entre média, moda, mediana e as distribuições de dados.

Tabela 3.1: Relações entre média, moda, mediana e as distribuições de dados.

Distribuição	Relação
Simétrica	$\bar{X} \approx Me \approx Mo$
Assimétrica à direita (ou positiva)	$\bar{X} > Me > Mo$
Assimétrica à esquerda (ou negativa)	$\bar{X} < Me < Mo$

Frequentemente, surgem dúvidas sobre qual medida de posição utilizar para descrever e resumir os dados numéricos obtidos.

Como uma regra geral, segundo Ferreira (1996), pode-se definir qual medida é mais adequada para uma determinada situação a partir da análise do histograma ou do polígono de frequências. Quando a distribuição dos dados é assimétrica (isto é, se valores extremos predominarem em uma das caudas da distribuição), deve-se preferir a mediana como medida-resumo. Isto é devido ao fato da mediana ser pouco sensível à presença de valores extremos nos dados, sendo considerada mais robusta do que a média.

Robusto é o termo técnico usado para se referir a essa propriedade (vantagem) da mediana em relação à média aritmética, pois a mediana é uma medida que sofre menos “interferências” nas suas estimativas quando a situação de simetria é violada (Ferreira, 2016).

A Figura 3.10 apresenta o comportamento gráfico das distribuições segundo a sua simetria, isto é, conforme as relações empíricas entre média, moda, mediana e as distribuições de dados.




Figura 3.10: Formas das distribuições com relação à sua assimetria: distribuição assimétrica positiva (painel superior), distribuição simétrica (painel central), e distribuição assimétrica negativa (painel inferior).

Observação: Os conceitos de média e mediana são diferentes. Não podem ser confundidos, pois a média leva em consideração todos os valores de um conjunto de dados numéricos, sendo influenciada pelos valores extremos desse conjunto; enquanto que a mediana, por sua vez, não leva em consideração todos os valores, e sim apenas o valor central (dois valores centrais, no máximo).

3.4 Medidas de dispersão

O uso de uma medida de posição para descrever um conjunto de dados não é suficiente para resumir toda informação nele contida, pois podemos ter diferentes conjuntos de dados que apresentam a mesma média, por exemplo. Abaixo, seguem alguns exemplos de conjuntos de dados diferentes com médias iguais.

$$\begin{aligned}\text{Conjunto A: } \{30, 30, 30, 30, 30\} &\Rightarrow \bar{X} = 30; \\ \text{Conjunto B: } \{60, 10, 10, 10, 60\} &\Rightarrow \bar{X} = 30; \\ \text{Conjunto C: } \{10, 20, 30, 40, 50\} &\Rightarrow \bar{X} = 30; \\ \text{Conjunto D: } \{10, 20, 90, 20, 10\} &\Rightarrow \bar{X} = 30.\end{aligned}$$

Observa-se que esses conjuntos diferem bastante em variabilidade. Por isto, torna-se preciso estabelecer medidas que expressem o grau de dispersão (ou variabilidade) em relação ao valor central.

Deste modo, pode-se afirmar que um conjunto de dados deve ser representado por medidas de posição e dispersão. Portanto, torna-se evidente que é necessário o uso de uma medida de dispersão para acompanhar a medida de posição. Assim, teremos um resumo suficiente dos dados.

Temos várias medidas de dispersão usadas na Estatística. Apresentaremos aqui a amplitude, o desvio médio, a variância, o desvio-padrão e o coeficiente de variação, sendo o desvio médio o menos usado e o desvio-padrão o mais usado.

3.4.1 Amplitude

A amplitude é a medida de dispersão mais simples, pois trata-se da diferença entre o maior e o menor valor observado.

Definição 18. *Seja um conjunto de dados formado por $X_1, X_2, \dots, X_n$, então a amplitude (A) é dada por:*

$$A = X_{(n)} - X_{(1)} = X_{\max} - X_{\min}.$$

Exemplo 31. *Considerando os conjuntos anteriores, vamos determinar a amplitude de cada um deles.*

Conjunto A: $\{30, 30, 30, 30, 30\} \Rightarrow A = X_{\max} - X_{\min} = 30 - 30 = 0;$
Conjunto B: $\{60, 10, 10, 10, 60\} \Rightarrow A = X_{\max} - X_{\min} = 60 - 10 = 50;$
Conjunto C: $\{10, 20, 30, 40, 50\} \Rightarrow A = X_{\max} - X_{\min} = 50 - 10 = 40;$
Conjunto D: $\{10, 20, 90, 20, 10\} \Rightarrow A = X_{\max} - X_{\min} = 90 - 10 = 80.$

```

# Função para o cálculo da amplitude
> amplitude<-function(x) { max(x)-min(x) }
> A<-c(30,30,30,30,30)
> B<-c(60,10,10,10,60)
> C<-c(10,20,30,40,50)
> D<-c(10,20,90,20,10)
> amplitude(A)
[1] 0
> amplitude(B)
[1] 50
> amplitude(C)
[1] 40
> amplitude(D)
[1] 80

```

Podemos observar nos exemplos acima que o conjunto A não apresentou variação e o conjunto D foi o que apresentou a maior variabilidade nos dados.

A amplitude tem algumas desvantagens em relação às demais medidas de dispersão (Ferreira, 1996):

1. Só leva em consideração os valores extremos para o seu cálculo e, principalmente quando houver *outlier*, ela será bastante afetada. Visto que somente dois extremos são considerados, conjuntos com valores intermediários praticamente idênticos podem apresentar grande amplitude se só o maior e o menor valores discrepam dos demais.
2. É influenciada pelo tamanho do conjunto de dados, pois à medida que o número de observações aumenta, a amplitude tende a ser maior.

3.4.2 Desvio médio

O desvio médio absoluto (ou simplesmente, desvio médio) é a medida de dispersão menos utilizada na Estatística. Trata-se da média aritmética dos módulos dos desvios, ou seja, é a média das distâncias das observações em relação à sua média. Para introduzirmos o conceito de desvio médio, vamos primeiramente abordar dois conceitos.

Desvio: É a diferença da i -ésima observação em relação à média, denotado por d_i , isto é, existe um desvio associado a cada observação, dado por:

$$d_i = (X_i - \bar{X}), \quad i = 1, 2, \dots, n.$$

Como já visto nas propriedades da média, a soma de tais desvios é nula, ou seja,

$$\sum_{i=1}^n (X_i - \bar{X}) = 0.$$

Desvio absoluto: É o módulo da diferença da i -ésima observação em relação à média, denotado por $|d_i|$, isto é, existe uma distância associada a cada observação, dada por:

$$|d_i| = |X_i - \bar{X}|, \quad i = 1, 2, \dots, n.$$

Definição 19. *Seja um conjunto de dados formado por $X_1, X_2, \dots, X_n$, então o desvio médio é dado por:*

$$dm = \frac{\sum_{i=1}^n |X_i - \bar{X}|}{n}.$$

Exemplo 32. *Considerando os conjuntos de dados anteriores, vamos determinar o desvio médio de cada um deles.*

$$\begin{aligned} \text{Conjunto A: } \{30, 30, 30, 30, 30\} &\Rightarrow dm = 0; \\ \text{Conjunto B: } \{60, 10, 10, 10, 60\} &\Rightarrow dm = 24; \\ \text{Conjunto C: } \{10, 20, 30, 40, 50\} &\Rightarrow dm = 12; \\ \text{Conjunto D: } \{10, 20, 90, 20, 10\} &\Rightarrow dm = 24. \end{aligned}$$

```
# Função para o cálculo do desvio médio
> desvmed<-function(x) { mean(abs(x-mean(x))) }
> desvmed(A)
[1] 0
> desvmed(B)
[1] 24
> desvmed(C)
[1] 12
> desvmed(D)
[1] 24
```

Podemos observar nos exemplos acima que o conjunto B apresentou o mesmo desvio médio que o conjunto D.

3.4.3 Variância

A variância é uma das medidas de dispersão mais utilizadas. Ela pode ser entendida como sendo a média aritmética dos quadrados de desvios em relação à média.

Definição 20. *Seja um conjunto de dados formado por $X_1, X_2, \dots, X_n$, e seja μ a média populacional, então a variância populacional é dada por:*

$$\sigma^2 = \frac{\sum_{i=1}^n (X_i - \mu)^2}{n}.$$

Para o caso da variância amostral, temos:

$$s^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}.$$

A unidade da variância é igual ao quadrado da unidade dos dados originalmente observados.

Observação: Quando se trabalha com amostras, a variância é dada pela soma dos quadrados dos desvios dividida pelo número de observações menos um ($n - 1$), que é chamado de *graus de liberdade* e será visto mais adiante.

A seguir, apresentaremos algumas propriedades básicas da variância:

Propriedade 1. *Se $X_i = c$, $i = 1, 2, \dots, n$, e $c \in \mathbb{R}$, então $\sigma^2 = 0$.*

Propriedade 2. *Somando ou subtraindo um valor constante c ($c \in \mathbb{R}$) a cada uma das observações do conjunto de dados, a variância não se altera. Em outras palavras, seja σ^2 a variância de um conjunto de dados formado por $X_1, X_2, \dots, X_n$ e seja μ a sua média, então a variância de $X_1 \pm c, X_2 \pm c, \dots, X_n \pm c$, denominada de σ_*^2 , também é σ^2 .*

Propriedade 3. *Multiplicando todas as observações do conjunto de dados por uma constante c ($c \in \mathbb{R}$), a nova variância fica multiplicada por c^2 . Em outras palavras, seja σ^2 a variância de um conjunto de dados formado por $X_1, X_2, \dots, X_n$ e seja μ a sua média, então a variância de $X_1c, X_2c, \dots, X_nc$, denominada de σ_*^2 , é $c^2\sigma^2$.*

Exemplo 33. *Considerando todos os conjuntos de dados anteriores, vamos determinar as variâncias populacional e amostral de cada um deles.*

Conjunto A:

$$\begin{aligned}\sigma^2 &= \frac{\sum_{i=1}^n (X_i - \mu)^2}{n} = \frac{\sum_{i=1}^5 (X_i - \mu)^2}{5} \\&= \frac{(X_1 - \mu)^2 + (X_2 - \mu)^2 + (X_3 - \mu)^2 + (X_4 - \mu)^2 + (X_5 - \mu)^2}{5} \\&= \frac{(30 - 30)^2 + (30 - 30)^2 + (30 - 30)^2 + (30 - 30)^2 + (30 - 30)^2}{5} \\&= \frac{0^2 + 0^2 + 0^2 + 0^2 + 0^2}{5} = \frac{0}{5} = 0.\end{aligned}$$

Quadro-resumo:

Conjunto A: {30, 30, 30, 30, 30} $\Rightarrow \sigma^2 = 0$ e $s^2 = 0$;
Conjunto B: {60, 10, 10, 10, 60} $\Rightarrow \sigma^2 = 600$ e $s^2 = 750$;
Conjunto C: {10, 20, 30, 40, 50} $\Rightarrow \sigma^2 = 200$ e $s^2 = 250$;
Conjunto D: {10, 20, 90, 20, 10} $\Rightarrow \sigma^2 = 920$ e $s^2 = 1.150$.

```
# Função para o cálculo da variância populacional
> varpop<-function(x) { sum((x-mean(x))^2)/length(x) }
# Função predefinida para o cálculo da variância amostral: var(x)
> varpop(A)
[1] 0
> varpop(B)
[1] 600
> varpop(C)
[1] 200
> varpop(D)
[1] 920
> var(A)
[1] 0
> var(B)
[1] 750
> var(C)
[1] 250
> var(D)
[1] 1150
```

3.4.4 Desvio-padrão

O desvio-padrão é a medida de dispersão mais utilizada na Estatística. Trata-se da raiz quadrada da variância. Um grande inconveniente prático da variância é que

ela é expressa em unidades ao quadrado, o que provoca algumas dificuldades de interpretação. Esse é o motivo do desvio-padrão ser mais empregado, já que a sua unidade de medida é a mesma dos dados originais.

Definição 21. Considere um conjunto de dados formado por $X_1, X_2, \dots, X_n$, e seja μ a média populacional, então o desvio-padrão populacional é dado por:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{\sum_{i=1}^n (X_i - \mu)^2}{n}}.$$

Para o caso do desvio-padrão amostral, temos:

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}}.$$

Exemplo 34. Considerando os conjuntos anteriores, vamos determinar os desvios-padrão populacional e amostral de cada um deles.

Conjunto A: $\{30, 30, 30, 30, 30\} \Rightarrow \sigma = 0 \quad e \quad s = 0;$
 Conjunto B: $\{60, 10, 10, 10, 60\} \Rightarrow \sigma \approx 24,49 \quad e \quad s \approx 27,39;$
 Conjunto C: $\{10, 20, 30, 40, 50\} \Rightarrow \sigma \approx 14,14 \quad e \quad s \approx 15,81;$
 Conjunto D: $\{10, 20, 90, 20, 10\} \Rightarrow \sigma \approx 30,33 \quad e \quad s \approx 33,91.$

```
# Função para o cálculo do desvio-padrão populacional
> desviopop<-function(x) { sqrt(sum((x-mean(x))^2)/length(x)) }
# Função predefinida para o cálculo do desvio-padrão amostral: sd(x)
> desviopop(A)
[1] 0
> desviopop(B)
[1] 24.495
> desviopop(C)
[1] 14.142
> desviopop(D)
[1] 30.332
> sd(A)
[1] 0
> sd(B)
[1] 27.386
> sd(C)
[1] 15.811
> sd(D)
[1] 33.912
```

Observação: Podemos notar que, quando calculado sobre o mesmo conjunto de dados, o desvio-padrão amostral apresenta valor igual ou maior do que o desvio-padrão populacional. O desvio-padrão indica a dispersão dos dados, ou a variação desses em relação a uma média. Se o desvio-padrão se aproxima do valor da média, isso indica uma dispersão ou uma variação considerável. Embora o conceito de variação grande ou pequena seja subjetivo, seria interessante analisar sempre o coeficiente de variação, que será estudado a seguir.

Propriedades do desvio-padrão (Silva, 2003)

Propriedade 1. *Somando-se ou subtraindo-se uma constante c ($c \in \mathbb{R}$) a todas as observações do conjunto de dados, o desvio-padrão não se altera.*

$$\mathbf{X}^* = \mathbf{X} \pm c \Rightarrow \sigma(\mathbf{X}^*) = \sigma(\mathbf{X}).$$

Propriedade 2. *Multiplicando-se todas as observações do conjunto de dados por uma constante c ($c \in \mathbb{R}$), o desvio-padrão fica multiplicado por c .*

$$\mathbf{X}^* = \mathbf{X}c \Rightarrow \sigma(\mathbf{X}^*) = c\sigma(\mathbf{X}).$$

3.4.5 Coeficiente de variação

A variância e o desvio-padrão são ditas medidas de dispersão absolutas. Desta forma, ambas permitem a comparação da variabilidade de dois ou mais conjuntos de dados somente quando estes apresentarem a mesma média, o mesmo número de observações e estiverem expressos nas mesmas unidades de medida ou grandeza (Tavares, 2014).

Para comparar quaisquer conjuntos de dados quanto à variabilidade, é indispensável utilizar uma medida de dispersão relativa, como o coeficiente de variação (CV), que indica a variabilidade dos dados observados em relação à sua média.

Definição 22. *Seja um conjunto de dados formado por $X_1, X_2, \dots, X_n$, então o coeficiente de variação populacional é dado por:*

$$CV_P = \frac{\sigma}{\mu} \times 100\%.$$

Para o caso do coeficiente de variação amostral, temos:

$$CV_A = \frac{s}{\bar{X}} \times 100\%.$$

O CV revela qual é a contribuição do desvio-padrão σ na média μ , ou seja, quanto maior sua contribuição para μ , maior o CV . Quando o CV está próximo de 0%, significa que σ é muito pequeno. Quando o CV é próximo de 100%, significa que σ é tão grande quanto μ .

Exemplo 35. Considerando os conjuntos de dados anteriores, vamos determinar os coeficientes de variação populacional e amostral de cada um deles.

Conjunto A: $\{30, 30, 30, 30, 30\} \Rightarrow CV_P = 0\%$ e $CV_A = 0\%$;
 Conjunto B: $\{60, 10, 10, 10, 60\} \Rightarrow CV_P = 81,65\%$ e $CV_A \approx 91,29\%$;
 Conjunto C: $\{10, 20, 30, 40, 50\} \Rightarrow CV_P = 47,14\%$ e $CV_A = 52,70\%$;
 Conjunto D: $\{10, 20, 90, 20, 10\} \Rightarrow CV_P = 101,11\%$ e $CV_A = 113,04\%$.

```
# Função para o cálculo do coeficiente de variação populacional
> cvpop<-function(x) { sqrt(sum((x-mean(x))^2)/length(x))/mean(x)*100
  }
# Função para o cálculo do coeficiente de variação amostral
> cvamo<-function(x) { sd(x)/mean(x)*100 }
> cvpop(A)
[1] 0
> cvpop(B)
[1] 81.65
> cvpop(C)
[1] 47.14
> cvpop(D)
[1] 101.11
> cvamo(A)
[1] 0
> cvamo(B)
[1] 91.287
> cvamo(C)
[1] 52.705
> cvamo(D)
[1] 113.04
```

O conceito de variação grande ou variação pequena é subjetivo, dependendo do conjunto de dados em questão. Para classificar a variação de forma não subjetiva, vários autores fazem uma classificação arbitrária, conforme mostra a Tabela 3.2.

Tabela 3.2: Classificação da variação de um conjunto de dados.

$CV \leq 10\%$	A variação é considerada pequena.
$10\% < CV \leq 20\%$	A variação é considerada intermediária.
$CV > 20\%$	A variação é considerada grande.

A Tabela 3.3 apresenta o resumo estatístico do exemplo anterior.

Tabela 3.3: Resumo estatístico de cada conjunto de dados.

	$\bar{X}$	A	dm	σ^2	s^2	CV_P	CV_A
Conjunto A: (30, 30, 30, 30, 30)	30	0	0	0	0	0%	0%
Conjunto B: (60, 10, 10, 10, 60)	30	50	24	600	750	81,65%	91,29%
Conjunto C: (10, 20, 30, 40, 50)	30	40	12	200	250	47,14%	52,70%
Conjunto D: (10, 20, 90, 20, 10)	30	80	24	920	1.150	101,11%	113,04%

Observação: A Tabela 3.3 faz um resumo das medidas estatísticas para fins didáticos, considerando cada conjunto de dados em questão como uma amostra ou como uma população.

3.5 Dados agrupados em classes

Os primeiros dados obtidos pelo pesquisador, isto é, sem nenhum tipo de tratamento estatístico, são denominados dados brutos ou primários. Geralmente, esses dados fornecem pouca ou nenhuma informação sobre o objeto de estudo, sendo preciso então organizá-los para aumentar sua capacidade de informação.

Para exemplificar, apresentamos na Tabela 3.4 o peso (em kg) de 40 tartarugas em idade adulta.

Tabela 3.4: Peso (em kg) de 40 tartarugas adultas.

19,2	22,3	19,2	19,6	16,5	22,4	18,7	20,3
25,2	25,0	21,2	20,5	21,4	21,0	19,5	19,7
21,6	17,1	18,8	18,5	17,5	18,9	17,6	19,3
23,7	18,8	17,6	21,6	17,9	24,0	20,9	18,9
19,2	20,2	18,3	14,7	19,7	17,6	21,0	17,3

Uma primeira forma de organizar valores numéricos é colocá-los em ordem crescente ou decrescente. Quando os dados são apresentados nessa ordem, dizemos que eles formam um ROL.

A Tabela 3.5 mostra o ROL de dados referentes ao peso das 40 tartarugas em idade adulta.

Tabela 3.5: ROL de dados referentes ao peso das tartarugas.

14,7	16,5	17,1	17,3	17,5	17,6	17,6	17,6
17,9	18,3	18,5	18,7	18,8	18,8	18,9	18,9
19,2	19,2	19,2	19,3	19,5	19,6	19,7	19,7
20,2	20,3	20,5	20,9	21,0	21,0	21,2	21,4
21,6	21,6	22,3	22,4	23,7	24,0	25,0	25,2

A ordenação apresentada na Tabela 3.5 torna o conjunto de dados mais informativo. Enquanto a Tabela 3.4 apenas indicava que havia 40 pesos observados, o

ROL permite identificar rapidamente os valores mínimo e máximo. Nesse caso, a tartaruga mais leve pesou 14,7 kg e a mais pesada, 25,2 kg, resultando em uma variação aproximada de 10,5 kg.

Para variáveis quantitativas, uma alternativa simples de apresentação é a distribuição de frequência, na qual os dados são reunidos em classes ou categorias e se registra quantas observações pertencem a cada uma delas. Esse tipo de agrupamento é especialmente útil quando o número de observações é grande; neste livro, seguiremos a convenção usual de tratar amostras com $n > 30$ como grandes.

3.6 Apresentação tabular

3.6.1 Distribuição de frequência

Após a ordenação, os dados também podem ser reunidos em classes, isto é, em intervalos ou faixas de valores. Esse agrupamento facilita a leitura do conjunto quando há muitas observações. Ao contar o número de dados em cada classe, obtemos a frequência absoluta correspondente.

Chamamos de distribuição de frequência a tabela formada pelas classes e por suas respectivas frequências. Cada classe é identificada por seus limites inferior e superior, que determinam o intervalo de valores incluído naquela faixa (Tavares, 2014).

A definição das classes pode ser guiada pelo conhecimento do pesquisador sobre a variável estudada ou por regras práticas de categorização. Na Seção 3.6.2, apresentamos três critérios para organizar variáveis quantitativas, discretas ou contínuas, em classes.

3.6.2 Construção de uma distribuição de frequência

Para construir uma distribuição de frequência, o primeiro passo é escolher o número de classes (k) em que os dados serão divididos. Por razões práticas e de apresentação, recomenda-se frequentemente trabalhar com algo entre 5 e 20 classes (Tavares, 2014). O valor de k pode ser definido de diferentes maneiras, sempre levando em conta o tamanho do conjunto de dados (n). Algumas possibilidades são:

Situação 1. Quando o número de observações do conjunto de dados é $n \leq 100$,

$$k = \sqrt{n}.$$

Situação 2. Quando o número de observações do conjunto de dados é $n > 100$,

$$k = 5 \log(n).$$

Situação 3. Scott (1979) propõe o seguinte critério, baseado na normalidade dos dados:

$$k = \frac{A\sqrt[3]{n}}{3,49s},$$

sendo:

A : amplitude total;

s : desvio-padrão;

n : número de observações.

Uma vez escolhido o número de classes (k), calcula-se a amplitude de cada classe (h) por meio da expressão:

$$h = \frac{A}{k - 1}.$$

Em seguida, definem-se os intervalos de classe. Adotaremos limites de modo que o menor valor observado fique no ponto médio da primeira classe. Assim, o limite inferior da primeira classe (LI_1) será:

$$LI_1 = X_{\min} - \frac{h}{2}.$$

Os limites seguintes são obtidos acrescentando h ao limite anterior.

Por fim, organizam-se as classes em uma tabela e conta-se quantas observações pertencem a cada intervalo.

A distribuição de frequência resume os dados, melhora sua visualização e serve de base tanto para gráficos quanto para o cálculo de medidas estatísticas de interesse (Tavares, 2014).

Frequência absoluta

A frequência absoluta, também chamada de frequência simples, é o número de observações pertencentes a uma classe. Para a i -ésima classe, denotamos essa quantidade por f_i , $i = 1, 2, \dots, k$. A soma das frequências absolutas deve reproduzir o total de observações, isto é, $\sum_{i=1}^k f_i = n$.

Na Tabela 3.7, apresentamos um exemplo de distribuição de frequências de pesos de ratos de laboratório. Podemos observar que $\sum_{i=1}^k f_i = n$, isto é,

$$\begin{aligned} \sum_{i=1}^9 f_i &= f_1 + f_2 + f_3 + f_4 + f_5 + f_6 + f_7 + f_8 + f_9 \\ &= 2 + 5 + 6 + 12 + 29 + 8 + 11 + 4 + 3 \\ &= 80 = n. \end{aligned}$$

Frequência relativa

A frequência relativa indica a participação de uma classe no total de observações. Para a i -ésima classe, $i = 1, 2, \dots, k$, ela é calculada por:

$$fr_i = \frac{f_i}{\sum_{i=1}^k f_i},$$

sendo:

f_i : frequência absoluta da i -ésima classe, $i = 1, 2, \dots, k$;

$\sum_{i=1}^k f_i = n$: somatório de todas as frequências absolutas, isto é, o número total de observações do conjunto de dados.

A soma de todas as frequências relativas deve ser igual a 1, isto é, $\sum_{i=1}^k fr_i = 1$.

Frequência relativa percentual

A frequência relativa percentual é a frequência relativa expressa em porcentagem. Para a i -ésima classe, $i = 1, 2, \dots, k$, temos:

$$fr_i\% = \frac{f_i}{\sum_{i=1}^k f_i} \times 100\%,$$

sendo:

f_i : frequência absoluta da i -ésima classe, $i = 1, 2, \dots, k$;

$\sum_{i=1}^k f_i = n$: somatório de todas as frequências absolutas, isto é, o número total de observações do conjunto de dados.

A soma de todas as frequências relativas percentuais deve ser igual a 100%, isto é, $\sum_{i=1}^k fr_i\% = 100\%$.

Frequência acumulada absoluta

Em muitas análises, não basta saber quantas observações há em uma classe específica. Também pode ser importante saber quantas observações estão abaixo ou acima de determinado ponto da distribuição (Silva, 2003).

Por isso, define-se a frequência acumulada como a soma das frequências até uma classe de interesse. Assim, temos:

$$F_t = \sum_{i=1}^t f_i, \quad t \leq k,$$

sendo:

f_i : frequência absoluta da i -ésima classe, $i = 1, 2, \dots, t, t \leq k$;
 $\sum_{i=1}^t f_i$: somatório de todas as frequências absolutas até a classe t em questão ($t \leq k$).

Pode-se observar que:

$$F_t - F_{t-1} = f_t, \quad t = 2, 3, \dots, k.$$

Ou ainda,

$$\sum_{i=1}^t f_i - \sum_{i=1}^{t-1} f_i = f_t, \quad t \leq k.$$

Na Tabela 3.7, por exemplo, a frequência absoluta da segunda classe, ($f_2 = 5$), pode ser obtida pela diferença entre a frequência acumulada da segunda classe, ($F_2 = 7$), e a da primeira, ($F_1 = 2$). De modo análogo, a frequência absoluta da terceira classe, ($f_3 = 6$), é dada por $F_3 - F_2 = 13 - 7$, e o mesmo raciocínio vale para as demais classes.

Frequência acumulada relativa

A frequência acumulada relativa corresponde à proporção de observações acumuladas até uma classe. Para a t -ésima classe, $t = 1, 2, \dots, k$, ela é dada por:

$$Fr_t = \frac{\sum_{i=1}^t f_i}{\sum_{i=1}^k f_i}, \quad t \leq k,$$

sendo:

f_i : frequência absoluta da i -ésima classe, $i = 1, 2, \dots, t, t \leq k$;
 $\sum_{i=1}^t f_i$: soma de todas as frequências absolutas até a classe t em questão ($t \leq k$);
 $\sum_{i=1}^k f_i = n$: somatório de todas as frequências absolutas, isto é, o número total de observações do conjunto de dados.

Frequência acumulada relativa percentual

A versão percentual da frequência acumulada relativa da t -ésima classe, $t = 1, 2, \dots, k$, é:

$$Fr_t\% = Fr_t \times 100\%, \quad t \leq k.$$

Pode-se observar que:

$$Fr_t\% - Fr_{t-1}\% = fr_t\%, \quad t = 2, 3, \dots, k.$$

Ou ainda,

$$\sum_{i=1}^t fr_i\% - \sum_{i=1}^{t-1} fr_i\% = fr_t\%, \quad t \leq k.$$

Como ilustração, na Tabela 3.7 a diferença entre a frequência acumulada relativa percentual da segunda classe, ($Fr_2\% = 8,75\%$), e a da primeira classe, ($Fr_1\% = 2,50\%$), resulta na frequência relativa percentual da segunda classe, ($fr_2\% = 6,25\%$). O mesmo procedimento se aplica às classes seguintes.

Exemplo prático de dados agrupados em classes

Para a construção de uma distribuição de frequências, consideremos o seguinte exemplo: em um determinado laboratório de pesquisa, foram pesados 80 ratos cobaias (ratos de laboratório) em idade adulta. Os pesos (em gramas, g) encontram-se na Tabela 3.6.

Tabela 3.6: Peso (em g) de 80 ratos de laboratório.

241	228	126	259	206	201	233	151
197	165	147	276	246	234	156	199
161	120	199	189	197	174	201	195
201	208	149	243	204	177	233	207
214	235	202	192	202	228	221	181
204	186	205	193	200	181	241	200
196	265	206	209	185	242	137	252
174	172	196	262	278	276	206	211
209	131	185	214	151	155	222	198
183	237	242	186	193	227	209	132

Primeiro passo: Determinar a amplitude dos dados.

$$A = X_{\max} - X_{\min} = 278 - 120 = 158 \text{ g.}$$

Segundo passo: Determinar o número k de classes.

Como temos $n = 80$, então:

$$k = \sqrt{n} = \sqrt{80} \approx 8,94 \approx 9 \text{ classes.}$$

Logo, os dados serão agrupados em 9 classes.

Terceiro passo: Determinar a amplitude h de classe.

$$h = \frac{A}{k - 1} = \frac{158}{9 - 1} = \frac{158}{8} = 19,75 \approx 20 \text{ g.}$$

Por questões práticas, arredondamos para $h = 20 \text{ g.}$

Quarto passo: Determinar o limite inferior da primeira classe.

O limite inferior da primeira classe terá o seu valor mínimo ($X_{\min}$) dos dados no ponto médio da primeira classe. Então, temos que:

$$LI_1 = X_{\min} - \frac{h}{2} = 120 - \frac{20}{2} = 120 - 10 = 110 \text{ g.}$$

Portanto, a distribuição dos dados agrupados em 9 classes inicia com o valor 110 g com uma amplitude de classe igual a 20 g.

Quinto passo: Construir a tabela de distribuição de frequências.

A Tabela 3.7 mostra a distribuição de frequências para o exemplo dos pesos dos ratos cobaias.

Tabela 3.7: Distribuição de frequências dos pesos dos ratos.

Classes	f_i	fr_i	$fr_i\%$	F_i	Fr_i	$Fr_i\%$
110 ┤ 130	2	0,0250	2,50%	2	0,0250	2,50%
130 ┤ 150	5	0,0625	6,25%	7	0,0875	8,75%
150 ┤ 170	6	0,0750	7,50%	13	0,1625	16,25%
170 ┤ 190	12	0,1500	15,00%	25	0,3125	31,25%
190 ┤ 210	29	0,3625	36,25%	54	0,6750	67,50%
210 ┤ 230	8	0,1000	10,00%	62	0,7750	77,50%
230 ┤ 250	11	0,1375	13,75%	73	0,9125	91,25%
250 ┤ 270	4	0,0500	5,00%	77	0,9625	96,25%
270 ┤ 290	3	0,0375	3,75%	80	1,0000	100,00%
Σ	80	1,0000	100,00%			

Podemos observar que $\sum_{i=1}^k f_i = n$, isto é,

$$\begin{aligned}
 \sum_{i=1}^9 f_i &= f_1 + f_2 + f_3 + f_4 + f_5 + f_6 + f_7 + f_8 + f_9 \\
 &= 2 + 5 + 6 + 12 + 29 + 8 + 11 + 4 + 3 \\
 &= 80 = n.
 \end{aligned}$$

Interpretação da frequência absoluta (f_i):

f_1 : 2 ratos pesam entre 110 g e 130 g;
 f_2 : 5 ratos pesam entre 130 g e 150 g;
 f_3 : 6 ratos pesam entre 150 g e 170 g;
 $\vdots$

De forma análoga, faz-se a interpretação das frequências relativa e relativa percentual.

Interpretação da frequência acumulada absoluta (F_i):

F_1 : 2 ratos pesam abaixo de 130 g;
 F_2 : 7 ratos pesam abaixo de 150 g;
 F_3 : 13 ratos pesam abaixo de 170 g;
 $\vdots$

De maneira análoga, faz-se a interpretação das frequências acumulada relativa e acumulada relativa percentual.

Comandos para a construção do gráfico da Figura 3.5 no *software* R:

```
> classes<-function(x) { # função que determina o número de classes
n<-length(x)
if (n<=100) k<-sqrt(n) else k<-5*log(n)
return(round(k)) }
> X<-c(241,228,126,259,206,201,233,151,197,165,147,276,246,234,
156,199,161,120,199,189,197,174,201,195,201,208,149,243,204,177,
233,207,214,235,202,192,202,228,221,181,204,186,205,193,200,181,
241,200,196,265,206,209,185,242,137,252,174,172,196,262,278,276,
206,211,209,131,185,214,151,155,222,198,183,237,242,186,193,227,
209,132)
> n<-length(X)
> k<-classes(X) # número de classes
> h<-round((max(X)-min(X))/(k-1)) # amplitude da classe
# Cria os limites das classes
> breaks<-seq(min(X)-(h/2), k*h+min(X)-(h/2), by=h)
> weight.cut<-cut(X, breaks, right=FALSE)
> weight.freq<-table(weight.cut) # tabela de frequências
> cbind(weight.freq,weight.freq/n, cumsum(weight.freq),
cumsum(weight.freq/n))
      weight.freq
[110,130)      2 0.0250  2 0.0250
[130,150)      5 0.0625  7 0.0875
[150,170)      6 0.0750 13 0.1625
[170,190)     12 0.1500 25 0.3125
[190,210)     29 0.3625 54 0.6750
[210,230)      8 0.1000 62 0.7750
[230,250)     11 0.1375 73 0.9125
[250,270)      4 0.0500 77 0.9625
[270,290)      3 0.0375 80 1.0000
```

3.6.3 Medidas de posição ou tendência central

Em distribuições simétricas, ou próximas da simetria, os valores observados costumam se concentrar em torno de uma região central e aparecem com menor frequência à medida que se afastam dela. Identificar esse centro é importante para resumir o comportamento dos dados e apoiar interpretações em pesquisa e extensão (Ferreira, 1996).

Para exemplificar ¹, considere uma grande empresa produtora de soja que precisa estimar a produtividade de uma área de 5.000 hectares plantados em determinada região. Como essa estimativa servirá de base para uma decisão relevante, o agrônomo deve usar um plano amostral adequado, uma medida de posição e uma medida de erro associada, aumentando a confiabilidade da informação fornecida.

Nesta seção, estudaremos medidas de posição e de dispersão quando os dados estão agrupados em classes. Antes disso, apresentaremos a hipótese tabular básica, conceito usado nos cálculos com dados agrupados (Ferreira, 1996).

Hipótese tabular básica

Para viabilizar os cálculos, considera-se que as observações de uma classe podem ser representadas pelo ponto médio do respectivo intervalo. Essa convenção recebe o nome de hipótese tabular básica.

Ao substituir os valores originais pelos pontos médios das classes, perde-se parte da precisão em relação aos cálculos feitos diretamente com os dados brutos.

Na prática, essa perda costuma ser pequena frente aos ganhos de simplicidade. A distribuição de frequência reduz a complexidade da tabela, facilita os cálculos e ainda ajuda a visualizar a forma geral da distribuição por meio de gráficos.

Média

A média é uma das medidas de tendência central mais empregadas e costuma ser informativa quando a distribuição dos dados é simétrica ou aproximadamente simétrica.

Para distinguir a média populacional da média amostral, usaremos a seguinte notação:

Média populacional:

$$\mu = \frac{\sum_{i=1}^k f_i m_i}{\sum_{i=1}^k f_i}.$$

¹Exemplo adaptado de Ferreira (1996).

Média amostral:

$$\bar{X} = \frac{\sum_{i=1}^k f_i m_i}{\sum_{i=1}^k f_i},$$

em que:

m_i : ponto médio da i -ésima classe, $i = 1, 2, \dots, k$;

f_i : frequência absoluta da i -ésima classe, $i = 1, 2, \dots, k$.

Então, no exemplo dos ratos, considerando que os 80 ratos são a população, temos:

$$\mu = \frac{\sum_{i=1}^k f_i m_i}{\sum_{i=1}^k f_i} = \frac{16.140}{80} = 201,75 \text{ g.}$$

```
# Função para o cálculo da média (dados agrupados)
> mediafreq<-function(m,f) { sum(f*m)/sum(f) }
> f<-c(2,5,6,12,29,8,11,4,3)
> m<-seq(120,280,20)
> mediafreq(m,f)
[1] 201.75
```

Interpretação: O peso médio dos ratos é de 201,75 g, ou ainda, o valor médio no qual os pesos do ratos se concentram é de $\mu = 201,75$ g.

Mediana

No caso de dados agrupados em k classes, a mediana pode ser calculada pela seguinte fórmula:

$$Me = LI_{Me} + \left(\frac{\frac{\sum_{i=1}^k f_i}{2} - F_{ant}}{f_{Me}} \right) \times h,$$

em que:

LI_{Me} : limite inferior da classe mediana;

f_i : frequência absoluta da i -ésima classe, $i = 1, 2, \dots, k$;

F_{ant} : frequência acumulada anterior à classe mediana;

f_{Me} : frequência absoluta da classe mediana;

h : altura (amplitude) da classe mediana.

Então, no exemplo dos ratos, temos:

$$Me = LI_{Me} + \left(\frac{\frac{\sum_{i=1}^k f_i}{2} - F_{ant}}{f_{Me}} \right) \times h = 190 + \left(\frac{\frac{80}{2} - 25}{29} \right) \times 20 \approx 200,34 \text{ g.}$$

```
# Função para o cálculo da mediana (dados agrupados)
> medianafreq<-function(m,f) {
acu<-cumsum(f)/sum(f)
for (o in 1:length(acu))
if (acu[o]>=0.5) break
h<-m[o]-m[o-1]
LI<-m[o]-h/2
mediana<-LI+((sum(f)/2-cumsum(f)[o-1])/f[o])*h
return(mediana) }
> medianafreq(m,f)
[1] 200.3448
```

Interpretação: 50% dos ratos pesam abaixo de 200,34 g e 50% pesam acima de 200,34 g.

Moda bruta

A moda bruta para dados agrupados é calculada da seguinte forma:

$$Mo_b = LI_{Mo} + \frac{h}{2},$$

em que:

LI_{Mo} : limite inferior da classe modal;

h : amplitude da classe modal.

Então, no exemplo dos ratos, temos:

$$Mo_b = LI_{Mo} + \frac{h}{2} = 190 + \frac{20}{2} = 200 \text{ g.}$$

```
# Função para o cálculo da moda bruta (dados agrupados)
> modafreq<-function(m,f) {
o<-which.max(f)
h<-m[o]-m[o-1]
LI<-m[o]-h/2
moda<-LI+h/2
return(moda) }
> modafreq(m,f)
[1] 200
```

Moda de Czuber

A moda é a categoria ou o valor mais frequente em um conjunto de dados qualitativos ou quantitativos discretos. Em dados quantitativos contínuos, ela está associada à região de maior densidade. Por isso, nesses casos, sua estimação usa a distribuição de frequência e procura localizar o máximo do polígono de frequências (Ferreira, 1996).

Para dados quantitativos contínuos agrupados, calcularemos a moda a partir da distribuição de frequência usando o método geométrico de Czuber. Esse procedimento considera as frequências das classes vizinhas e ajusta a posição da moda dentro da classe modal, resultando na expressão:

$$Mo = LI_{Mo} + \frac{\Delta_1}{\Delta_1 + \Delta_2} \times h,$$

em que:

LI_{Mo} : limite inferior da classe modal;

Δ_1 : diferença entre as frequências da classe modal e a imediatamente anterior;

Δ_2 : diferença entre as frequências da classe modal e a imediatamente posterior;

h : altura (amplitude) da classe modal.

Então, no exemplo dos ratos, temos:

$$Mo = LI_{Mo} + \frac{\Delta_1}{\Delta_1 + \Delta_2} \times h = 190 + \left(\frac{17}{17 + 21} \right) \times 20 \approx 198,95 \text{ g.}$$

```
# Função para o cálculo da moda de Czuber (dados agrupados)
> modaCzuber<-function(m,f) {
o<-which.max(f)
h<-m[o]-m[o-1]
LI<-m[o]-h/2
moda<-LI+((f[o]-f[o-1])/(2*f[o]-f[o-1]-f[o+1]))*h
return(moda) }
> modaCzuber(m,f)
[1] 198.9474
```

A Figura 3.11 mostra geometricamente a obtenção da moda para dados agrupados em classes pelo método de Czuber.

Sendo LI_{Mo} o limite inferior da classe modal, LS_{Mo} o limite superior da classe modal, e x a distância entre LI_{Mo} e a moda (**Mo**), verifica-se através do histograma dessa figura que:

$$Mo = LI_{Mo} + x. \quad (3.1)$$




Figura 3.11: Representação gráfica da obtenção da moda para dados agrupados.

Como os triângulos **ABE** e **CDE** são semelhantes, segue que:

$$\frac{\overline{EF}}{\overline{AB}} = \frac{\overline{EG}}{\overline{CD}} \Leftrightarrow \frac{x}{\Delta_1} = \frac{h-x}{\Delta_2}.$$

Resolvendo a equação em função de x , obtemos:

$$\begin{aligned} x\Delta_2 &= \Delta_1(h-x) \\ x\Delta_2 &= \Delta_1h - \Delta_1x \\ x\Delta_2 + \Delta_1x &= \Delta_1h \\ x(\Delta_1 + \Delta_2) &= \Delta_1h \\ x &= \frac{\Delta_1h}{\Delta_1 + \Delta_2}. \end{aligned}$$

Desta forma, temos que:

$$x = \frac{\Delta_1}{\Delta_1 + \Delta_2} \times h. \quad (3.2)$$

Substituindo (3.2) em (3.1), obtemos, finalmente, a expressão para a moda pelo método de Czuber:

$$\begin{aligned} Mo &= LI_{Mo} + x \\ &= LI_{Mo} + \frac{\Delta_1}{\Delta_1 + \Delta_2} \times h. \end{aligned}$$

Como observa Ferreira (1996), também é possível representar a moda pelo ponto médio da classe modal, pois a hipótese tabular básica trata os valores de uma classe como equivalentes ao seu ponto médio. Neste material, adotaremos o método geométrico apresentado anteriormente por fornecer uma aproximação mais refinada.

Fato 1. Se $\Delta_1 = \Delta_2$, então a moda de Czuber se resume à moda bruta:

$$Mo = LI_{Mo} + \frac{h}{2}.$$

Demonstração: Como $\Delta_1 = \Delta_2$, segue que:

$$\begin{aligned} Mo &= LI_{Mo} + \frac{\Delta_1}{\Delta_1 + \Delta_2} \times h = LI_{Mo} + \frac{\Delta_1}{\Delta_1 + \Delta_1} \times h \\ &= LI_{Mo} + \frac{\Delta_1}{2\Delta_1} \times h = LI_{Mo} + \frac{h}{2}. \end{aligned} \quad \blacksquare$$

3.6.4 Medidas de dispersão

Para estudar o grau de variabilidade dos valores de um conjunto de dados agrupados em classes, faremos uso das medidas de dispersão (variância e desvio-padrão) já apresentadas na Seção 3.4 para o caso de dados não agrupados.

Variância

Para o caso de dados agrupados em classes, as variâncias populacional e amostral são expressas, respectivamente, por:

Variância populacional:

$$\sigma^2 = \frac{1}{n} \left[\sum_{i=1}^k f_i m_i^2 - \frac{\left(\sum_{i=1}^k f_i m_i \right)^2}{n} \right].$$

Variância amostral:

$$s^2 = \frac{1}{n-1} \left[\sum_{i=1}^k f_i m_i^2 - \frac{\left(\sum_{i=1}^k f_i m_i \right)^2}{n} \right],$$

em que:

m_i : ponto médio da i -ésima classe, $i = 1, 2, \dots, k$;

f_i : frequência absoluta da i -ésima classe, $i = 1, 2, \dots, k$.

Então, no exemplo dos ratos, considerando que os 80 ratos são a população, temos:

$$\begin{aligned}\sigma^2 &= \frac{1}{n} \left[\sum_{i=1}^k f_i m_i^2 - \frac{\left(\sum_{i=1}^k f_i m_i \right)^2}{n} \right] \\ &= \frac{1}{80} \left[3.355.600 - \frac{(16.140)^2}{80} \right] \\ &\approx 1.241,94 \text{ g}^2.\end{aligned}$$

Considerando que os 80 ratos são uma amostra, temos:

$$\begin{aligned}s^2 &= \frac{1}{n-1} \left[\sum_{i=1}^k f_i m_i^2 - \frac{\left(\sum_{i=1}^k f_i m_i \right)^2}{n} \right] \\ &= \frac{1}{79} \left[3.355.600 - \frac{(16.140)^2}{80} \right] \\ &\approx 1.257,66 \text{ g}^2.\end{aligned}$$

```
# Função para o cálculo da variância populacional (dados agrupados)
> varfregpop<-function(m,f) {
  (sum(f*m^2)-(sum(f*m)^2)/sum(f))/sum(f) }
# Função para o cálculo da variância amostral (dados agrupados)
> varfregamo<-function(m,f) {
  (sum(f*m^2)-(sum(f*m)^2)/sum(f))/(sum(f)-1) }
> varfregpop(m,f)
[1] 1241.938
> varfregamo(m,f)
[1] 1257.658
```

Desvio-padrão

Para o caso de dados agrupados em classes, os desvios-padrão populacional e amostral são expressos, respectivamente, por:

Desvio-padrão populacional:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n} \left[\sum_{i=1}^k f_i m_i^2 - \frac{\left(\sum_{i=1}^k f_i m_i \right)^2}{n} \right]}.$$

Desvio-padrão amostral:

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1} \left[\sum_{i=1}^k f_i m_i^2 - \frac{\left(\sum_{i=1}^k f_i m_i \right)^2}{n} \right]},$$

em que:

m_i : ponto médio da i -ésima classe, $i = 1, 2, \dots, k$;

f_i : frequência absoluta da i -ésima classe, $i = 1, 2, \dots, k$.

Então, no exemplo dos ratos, considerando que os 80 ratos são a população, temos:

$$\sigma = \sqrt{\sigma^2} = \sqrt{1.241,94} \approx 35,24 \text{ g.}$$

Considerando que os 80 ratos são uma amostra, temos:

$$s = \sqrt{s^2} = \sqrt{1.257,66} \approx 35,46 \text{ g.}$$

```
# Função para o cálculo do desvio-padrão pop. (dados agrupados)
> sqrt(varfregpop(m,f))
[1] 35.24113
# Função para o cálculo do desvio-padrão amostral (dados agrupados)
> sqrt(varfregamo(m,f))
[1] 35.46348
```

3.6.5 Medidas separatrizes

As separatrizes, também chamadas de quantis, são medidas de posição que particionam uma sequência ordenada de dados (ROL) em partes de mesmo tamanho. Na Estatística Descritiva, destacam-se os quartis, os decis e os percentis.

Quartil

Os quartis separam o ROL em quatro partes com a mesma proporção de observações.

A Figura 3.12 mostra graficamente a separação do conjunto de dados por meio dos quartis.

Assim,

Q_1 : é o primeiro quartil (25% das observações estão abaixo dele);

Q_2 : é o segundo quartil (50% das observações estão abaixo dele);

Q_3 : é o terceiro quartil (75% das observações estão abaixo dele);

Q_4 : é o quarto quartil (100% das observações estão abaixo dele).




Figura 3.12: Separação do conjunto de dados por meio dos quartis.

A expressão abaixo nos fornece o valor do i -ésimo quartil (Q_i), $i = 1, 2, 3, 4$, para dados agrupados em classes:

$$Q_i = LI_{Q_i} + \left(\frac{i \times \frac{\sum_{i=1}^k f_i}{4} - F_{ant}}{f_{Q_i}} \right) \times h,$$

em que:

LI_{Q_i} : limite inferior da classe que contém o Q_i , $i = 1, 2, 3, 4$;

F_{ant} : frequência acumulada anterior à classe que contém o Q_i , $i = 1, 2, 3, 4$;

f_{Q_i} : frequência da classe que contém o Q_i , $i = 1, 2, 3, 4$;

h : altura (amplitude) da classe que contém o Q_i , $i = 1, 2, 3, 4$.

Função para o cálculo dos quartis (dados agrupados)

```
> quartilfreq<-function(m,f) {
quartil<-c()
acu<-cumsum(f)/sum(f)
qaux<-seq(0.25,1,0.25)
for(j in 1:4) {
for (o in 1:length(acu))
if (acu[o]>=qaux[j]) break
h<-m[o]-m[o-1]
LI<-m[o]-h/2
quartil[j]<-LI+(((j*sum(f)/4)-cumsum(f)[o-1])/f[o])*h }
return(quartil) }
```

Observação: A expressão algébrica que permite calcular o segundo quartil (Q_2) da distribuição, coincide com a expressão da mediana (Me), pois ambas as medidas deixam 50% das observações ordenadas abaixo delas. Desta forma, quando nos referimos ao segundo quartil da distribuição, estamos nos referindo à sua mediana.

Vamos determinar o Q_1, Q_2, Q_3 e Q_4 no exemplo dos ratos:

$$Q_1 = LI_{Q_1} + \left(\frac{1 \times \frac{\sum_{i=1}^k f_i}{4} - F_{ant}}{f_{Q_1}} \right) \times h = 170 + \left(\frac{1 \times \frac{80}{4} - 13}{12} \right) \times 20$$

$$\approx 181,67 \text{ g.}$$

Interpretação: 25% dos ratos pesam abaixo de 181,67 g.

$$Q_2 = LI_{Q_2} + \left(\frac{2 \times \frac{\sum_{i=1}^k f_i}{4} - F_{ant}}{f_{Q_2}} \right) \times h = 190 + \left(\frac{2 \times \frac{80}{4} - 25}{29} \right) \times 20$$

$$\approx 200,34 \text{ g.}$$

Interpretação: 50% dos ratos pesam abaixo de 200,34 g.

$$Q_3 = LI_{Q_3} + \left(\frac{3 \times \frac{\sum_{i=1}^k f_i}{4} - F_{ant}}{f_{Q_3}} \right) \times h = 210 + \left(\frac{3 \times \frac{80}{4} - 54}{8} \right) \times 20$$

$$= 225 \text{ g.}$$

Interpretação: 75% dos ratos pesam abaixo de 225 g.

$$Q_4 = LI_{Q_4} + \left(\frac{4 \times \frac{\sum_{i=1}^k f_i}{4} - F_{ant}}{f_{Q_4}} \right) \times h = 270 + \left(\frac{4 \times \frac{80}{4} - 77}{3} \right) \times 20$$

$$= 290 \text{ g.}$$

Interpretação: 100% dos ratos pesam abaixo de 290 g.

```
> quartilfreq(m,f)
[1] 181.6667 200.3448 225.0000 290.0000
```

Decil

Os decis dividem o ROL em dez partes com a mesma proporção de observações.

A Figura 3.13 mostra graficamente a separação do conjunto de dados por meio dos decis.




Figura 3.13: Separação do conjunto de dados por meio dos decis.

Assim,

D_1 : é o primeiro decil (10% das observações estão abaixo dele);

D_2 : é o segundo decil (20% das observações estão abaixo dele);
 D_3 : é o terceiro decil (30% das observações estão abaixo dele);
 $\vdots$
 D_{10} : é o décimo decil (100% das observações estão abaixo dele).

O i -ésimo decil, $i = 1, 2, \dots, 10$, de um conjunto de dados organizados na forma de uma distribuição de frequências, pode ser obtido pela seguinte fórmula:

$$D_i = LI_{D_i} + \left(\frac{i \times \frac{\sum_{i=1}^n f_i}{10} - F_{ant}}{f_{D_i}} \right) \times h,$$

em que:

LI_{D_i} : limite inferior da classe que contém o D_i ;
 F_{ant} : frequência acumulada anterior à classe que contém o D_i ;
 f_{D_i} : frequência da classe que contém o D_i ;
 h : altura (amplitude) da classe que contém o D_i .

```

# Função para o cálculo dos decis (dados agrupados)
> decilfreq<-function(m,f) {
  decil<-c()
  acu<-cumsum(f)/sum(f)
  qaux<-seq(0.1,1,0.1)
  for(j in 1:10) {
    for (o in 1:length(acu))
      if (acu[o]>=qaux[j]) break
    h<-m[o]-m[o-1]
    LI<-m[o]-h/2
    decil[j]<-LI+(((j*sum(f)/10)-cumsum(f)[o-1])/f[o])*h }
  return(decil) }

```

No exemplo dos ratos, temos:

$D_1 \approx 153,33$ g.	Interpretação: 10% dos ratos pesam abaixo de 153,33 g.
$D_2 = 175$ g.	Interpretação: 20% dos ratos pesam abaixo de 175 g.
$D_3 \approx 188,33$ g.	Interpretação: 30% dos ratos pesam abaixo de 188,33 g.
$D_4 \approx 194,83$ g.	Interpretação: 40% dos ratos pesam abaixo de 194,83 g.
$D_5 \approx 200,34$ g.	Interpretação: 50% dos ratos pesam abaixo de 200,34 g.
$D_6 \approx 205,86$ g.	Interpretação: 60% dos ratos pesam abaixo de 205,86 g.
$D_7 = 215$ g.	Interpretação: 70% dos ratos pesam abaixo de 215 g.
$D_8 \approx 233,64$ g.	Interpretação: 80% dos ratos pesam abaixo de 233,64 g.
$D_9 \approx 248,18$ g.	Interpretação: 90% dos ratos pesam abaixo de 248,18 g.
$D_{10} = 290$ g.	Interpretação: 100% dos ratos pesam abaixo de 290 g.

```
> decilfreq(m,f)
[1] 153.3333 175.0000 188.3333 194.8276 200.3448 205.8621
[7] 215.0000 233.6364 248.1818 290.0000
```

Percentil

Os percentis particionam o ROL em 100 partes com a mesma proporção de observações.

A Figura 3.14 mostra graficamente a separação do conjunto de dados por meio dos percentis.




Figura 3.14: Separação do conjunto de dados por meio dos percentis.

Assim,

P_1 : é o primeiro percentil (1% das observações estão abaixo dele);

P_2 : é o segundo percentil (2% das observações estão abaixo dele);

P_3 : é o terceiro percentil (3% das observações estão abaixo dele);

$\vdots$

P_{100} : é o centésimo percentil (100% das observações estão abaixo dele).

O i -ésimo percentil, $i = 1, 2, \dots, 100$, de um conjunto de dados organizados na forma de uma distribuição de frequências, pode ser obtido pela seguinte fórmula:

$$P_i = LI_{P_i} + \left(\frac{i \times \frac{\sum_{i=1}^n f_i}{100} - F_{ant}}{f_{P_i}} \right) \times h,$$

em que:

LI_{P_i} : limite inferior da classe que contém o P_i ;

F_{ant} : frequência acumulada anterior à classe que contém o P_i ;

f_{P_i} : frequência da classe que contém o P_i ;

h : altura (amplitude) da classe que contém o P_i .

```
# Função para o cálculo dos percentis (dados agrupados)
> percentilfreq<-function(m,f,per) {
acu<-cumsum(f)/sum(f)
for (o in 1:length(acu))
```

```

if (acu[o]>=(per/100)) break
if(o!=1) { h<-m[o]-m[o-1]
LI<-m[o]-h/2
percentil<-LI+(((per*sum(f)/100)-cumsum(f)[o-1])/f[o])*h } else {
h<-m[o+1]-m[o]
LI<-m[o]-h/2
percentil<-LI+(((per*sum(f)/100))/f[o])*h }
return(percentil) }

```

No exemplo dos ratos, vamos determinar os percentis: P_5 , P_{13} , P_{35} , P_{45} , P_{50} , P_{65} , P_{85} e P_{97} .

$P_5 = 138$ g.	Interpretação: 5% dos ratos pesam abaixo de 138 g.
$P_{13} \approx 161,33$ g.	Interpretação: 13% dos ratos pesam abaixo de 161,33 g.
$P_{35} \approx 192,07$ g.	Interpretação: 35% dos ratos pesam abaixo de 192,07 g.
$P_{45} \approx 197,59$ g.	Interpretação: 45% dos ratos pesam abaixo de 197,59 g.
$P_{50} \approx 200,34$ g.	Interpretação: 50% dos ratos pesam abaixo de 200,34 g.
$P_{65} \approx 208,62$ g.	Interpretação: 65% dos ratos pesam abaixo de 208,62 g.
$P_{85} \approx 240,91$ g.	Interpretação: 85% dos ratos pesam abaixo de 240,91 g.
$P_{97} = 274$ g.	Interpretação: 97% dos ratos pesam abaixo de 274 g.

Observação: Podemos verificar, no exemplo dos pesos dos ratos, que:

$$Me = Q_2 = D_5 = P_{50} \approx 200,34 \text{ g.}$$

```

> percentilfreq(m,f,5)
[1] 138
> percentilfreq(m,f,13)
[1] 161.3333
> percentilfreq(m,f,35)
[1] 192.069
.....
> percentilfreq(m,f,85)
[1] 240.9091
> percentilfreq(m,f,97)
[1] 274

```

Exemplo 36. Considerando novamente os dados referentes a credit scoring, a Tabela 3.8 mostra a distribuição de frequências para dados agrupados em classes, para a variável “idade” do cliente.

Tabela 3.8: Distribuição de frequências das idades dos clientes.

Classes	f_i	fr_i	$fr_i\%$	F_i	Fr_i	$Fr_i\%$
16 ┤ 20	30	0,0300	3,00%	30	0,0300	3,00%
20 ┤ 24	160	0,1600	16,00%	190	0,1900	19,00%
24 ┤ 28	179	0,1790	17,90%	369	0,3690	36,90%
28 ┤ 32	145	0,1450	14,50%	514	0,5140	51,40%
32 ┤ 36	142	0,1420	14,20%	656	0,6560	65,60%
36 ┤ 40	89	0,0890	8,90%	745	0,7450	74,50%
40 ┤ 44	71	0,0710	7,10%	816	0,8160	81,60%
44 ┤ 48	61	0,0610	6,10%	877	0,8770	87,70%
48 ┤ 52	34	0,0340	3,40%	911	0,9110	91,10%
52 ┤ 56	30	0,0300	3,00%	941	0,9410	94,10%
56 ┤ 60	21	0,0210	2,10%	962	0,9620	96,20%
60 ┤ 64	20	0,0200	2,00%	982	0,9820	98,20%
64 ┤ 68	11	0,0110	1,10%	993	0,9930	99,30%
68 ┤ 72	1	0,0010	0,10%	994	0,9940	99,40%
72 ┤ 76	6	0,0060	0,60%	1.000	1,0000	100,00%
Σ	1.000	1,0000	100,00%			

Para o cálculo das medidas de posição e de dispersão, precisamos da seguinte tabela:

Tabela 3.9: Tabela para o cálculo das medidas-resumo.

Classes	f_i	m_i	F_i	$Fr_i\%$	$f_i m_i$	$f_i m_i^2$
16 ┤ 20	30	18	30	3,00%	540	9.720
20 ┤ 24	160	22	190	19,00%	3.520	77.440
24 ┤ 28	179	26	369	36,90%	4.654	121.004
28 ┤ 32	145	30	514	51,40%	4.350	130.500
32 ┤ 36	142	34	656	65,60%	4.828	164.152
36 ┤ 40	89	38	745	74,50%	3.382	128.516
40 ┤ 44	71	42	816	81,60%	2.982	125.244
44 ┤ 48	61	46	877	87,70%	2.806	129.076
48 ┤ 52	34	50	911	91,10%	1.700	85.000
52 ┤ 56	30	54	941	94,10%	1.620	87.480
56 ┤ 60	21	58	962	96,20%	1.218	70.644
60 ┤ 64	20	62	982	98,20%	1.240	76.880
64 ┤ 68	11	66	993	99,30%	726	47.916
68 ┤ 72	1	70	994	99,40%	70	4.900
72 ┤ 76	6	74	1.000	100,00%	444	32.856
Σ	1.000				34.080	1.291.328

Cálculo da média das idades dos clientes:

$$\bar{X} = \frac{\sum_{i=1}^k f_i m_i}{\sum_{i=1}^k f_i} = \frac{34.080}{1.000} = 34,08 \text{ anos.}$$

Interpretação: A idade média dos clientes do exemplo de *credit scoring* é de 34,08 anos.

```
> f<-c(30,160,179,145,142,89,71,61,34,30,21,20,11,1,6)
> m<-seq(18,74,4)
> mediafreq(m,f)
[1] 34.08
```

Cálculo da mediana das idades dos clientes:

$$\begin{aligned} Me &= LI_{Me} + \left(\frac{\frac{\sum_{i=1}^k f_i}{2} - F_{ant}}{f_{Me}} \right) \times h = 28 + \left(\frac{\frac{1.000}{2} - 369}{145} \right) \times 4 \\ &\approx 31,61 \text{ anos.} \end{aligned}$$

Interpretação: 50% dos clientes têm idade abaixo de 31,61 anos e 50% dos clientes têm idade acima de 31,61 anos.

```
> medianafreq(m,f)
[1] 31.61379
```

Cálculo da moda bruta das idades dos clientes:

$$\begin{aligned} Mo_b &= LI_{Mo} + \frac{h}{2} = 24 + \frac{4}{2} \\ &= 26 \text{ anos.} \end{aligned}$$

```
> modafreq(m,f)
[1] 26
```

Cálculo da moda de Czuber das idades dos clientes:

$$\begin{aligned} Mo &= LI_{Mo} + \frac{\Delta_1}{\Delta_1 + \Delta_2} \times h = 24 + \frac{19}{19 + 34} \times 4 \\ &\approx 25,43 \text{ anos.} \end{aligned}$$

```
> modaCzuber(m,f)
[1] 25.43396
```

Cálculo da variância amostral das idades dos clientes:

$$\begin{aligned} s^2 &= \frac{1}{n-1} \left[\sum_{i=1}^k f_i m_i^2 - \frac{\left(\sum_{i=1}^k f_i m_i \right)^2}{n} \right] \\ &= \frac{1}{999} \left[1.291.328 - \frac{(34.080)^2}{1.000} \right] \\ &\approx 130,01 \text{ anos}^2. \end{aligned}$$

```
> varfreqamo(m,f)
[1] 130.0116
```

Cálculo do desvio-padrão amostral das idades dos clientes:

$$s = \sqrt{s^2} = \sqrt{130,01} \approx 11,40 \text{ anos.}$$

```
> sqrt(varfreqamo(m,f))
[1] 11.40226
```

Cálculo do primeiro quartil das idades dos clientes:

$$\begin{aligned} Q_1 &= LI_{Q_1} + \left(\frac{1 \times \frac{\sum_{i=1}^k f_i}{4} - F_{ant}}{f_{Q_1}} \right) \times h = 24 + \left(\frac{1 \times \frac{1.000}{4} - 190}{179} \right) \times 4 \\ &\approx 30,93 \text{ anos.} \end{aligned}$$

Interpretação: 25% dos clientes têm idade abaixo de 30,93 anos.

Cálculo do segundo quartil das idades dos clientes:

$$\begin{aligned} Q_2 &= LI_{Q_2} + \left(\frac{2 \times \frac{\sum_{i=1}^k f_i}{4} - F_{ant}}{f_{Q_2}} \right) \times h = 28 + \left(\frac{2 \times \frac{1.000}{4} - 369}{145} \right) \times 4 \\ &\approx 31,61 \text{ anos.} \end{aligned}$$

Interpretação: 50% dos clientes têm idade abaixo de 31,61 anos.

Cálculo do terceiro quartil das idades dos clientes:

$$\begin{aligned} Q_3 &= LI_{Q_3} + \left(\frac{3 \times \frac{\sum_{i=1}^k f_i}{4} - F_{ant}}{f_{Q_3}} \right) \times h = 40 + \left(\frac{3 \times \frac{1.000}{4} - 745}{71} \right) \times 4 \\ &\approx 40,28 \text{ anos.} \end{aligned}$$

Interpretação: 75% dos clientes têm idade abaixo de 40,28 anos.

Cálculo do quarto quartil das idades dos clientes:

$$\begin{aligned} Q_4 &= LI_{Q_4} + \left(\frac{4 \times \frac{\sum_{i=1}^k f_i}{4} - F_{ant}}{f_{Q_4}} \right) \times h = 72 + \left(\frac{4 \times \frac{1.000}{4} - 994}{6} \right) \times 4 \\ &= 76 \text{ anos.} \end{aligned}$$

Interpretação: 100% dos clientes têm idade abaixo de 76 anos. Podemos observar que o quarto quartil é o limite superior da última classe do conjunto de dados.

Da maneira análoga, podemos calcular os decis e percentis desejados.

```
> quartilfreq(m,f)
[1] 25.34078 31.61379 40.28169 76.00000
```

3.7 Considerações finais

Estudamos neste capítulo como obter informações dos dados brutos (ou primários) por meio da Estatística Descritiva, que tem como objetivo resumir as informações contidas em uma amostra ou censo através de duas ferramentas principais: distribuições de frequências e medidas numéricas descritoras.

Apresentamos as principais ferramentas gráficas usadas para representar a distribuição de variáveis qualitativas (gráfico em barras, gráfico em setores e gráfico em retângulo) e quantitativas (histograma, polígono de frequência, gráfico temporal e *box plot*). Bem como as medidas de posição (média, moda, mediana e outras separatrizes) e dispersão (amplitude, desvio médio, variância, desvio-padrão e coeficiente de variação) mais comumente empregadas. Apesar de sua importância, as medidas associadas à forma de uma distribuição de dados (coeficientes de assimetria e curtose) não foram abordadas neste material.

Consideramos também a situação na qual os dados estão organizados em grupos ou categorias/classes.

3.8 Exercícios propostos

Exercício 1. Classifique cada uma das variáveis a seguir em qualitativa (nominal ou ordinal) ou quantitativa (discreta ou contínua).

- a) Cor dos cabelos.
- b) Faixa etária.
- c) Número de gols marcados em uma partida do Campeonato Brasileiro de Futebol - Série A - 2025.
- d) Estado civil.
- e) Velocidade de deformação de um corpo de prova em um ensaio de compressão simples.
- f) Número de óbitos por covid-19 registrados diariamente em um município do interior da Bahia.
- g) Grau de escolaridade.
- h) Resistência à pressão de colapso de um tubo de CPVC.

Exercício 2. Em uma pesquisa com moradores de determinada localidade, para saber a opinião deles acerca de um projeto governamental, obteve-se o seguinte resultado:

Favoráveis - 32%; Contrários - 63%; Indiferentes - 5%.

Faça uma representação gráfica apropriada dos resultados dessa pesquisa.

Exercício 3. Em um laboratório de pesquisa, foram pesados 15 coelhos cobaias após certo tratamento. Os pesos (em g) obtidos foram:

961	773	604	987	660	961	733	926
627	802	814	1.093	682	885	897	1.393

- a) Calcule a média, mediana, amplitude e desvio-padrão amostral dos pesos.
- b) Faça uma representação gráfica apropriada da distribuição dos dados.

Exercício 4. Uma pesquisa do Instituto MAS sobre times de futebol de maior torcida na região metropolitana de São Paulo, realizada entre os dias 02 e 03 de outubro de 2018, resultou nos dados (frequências absolutas) apresentados na tabela

abaixo.

Time de preferência	Sexo		Total
	Masculino	Feminino	
Corinthians	130	160	290
Palmeiras	93	54	147
São Paulo	54	76	130
Santos	54	29	83
Flamengo	19	16	35
Outros	16	2	18
Nenhum	105	215	320
Total	471	552	1.023

Construa um gráfico em barras múltiplas e compare o comportamento da variável “Time de preferência” nas diferentes categorias da variável “Sexo”.

Exercício 5. A tabela abaixo apresenta o peso (em kg) e a altura (em cm) de 10 indivíduos escolhidos aleatoriamente de uma população. Onde existe maior variabilidade: na distribuição dos pesos ou das alturas desses indivíduos? Use o coeficiente de variação amostral para responder a essa pergunta.

Peso (kg)	59	80	56	67	70	47	84	86	69	64
Altura (cm)	170	177	196	175	195	173	174	158	171	162

Exercício 6. Em determinado bairro de uma capital brasileira, há três escolas estaduais nas quais a evasão escolar ocorre já há alguns anos. As autoridades das escolas divulgaram os dados de evasão bimestral em número de alunos, conforme abaixo:

Escola A	16	10	12	17	14	18	25	37	29	14
Escola B	13	12	17	43	18	10	23	15	10	11
Escola C	12	17	15	16	10	28	39	33	8	9

a) Obtenha a média, mediana, moda, amplitude, primeiro e terceiro quartis, variância, desvio-padrão e coeficiente de variação para o número de alunos evadidos, em cada escola.

b) Construa, em um mesmo gráfico, o *box plot* do número de alunos evadidos para cada uma das três escolas. Comente sobre a dispersão, pontos extremos, mediana e simetria dos dados, em cada escola.

c) Compare as escolas com relação à evasão de alunos, utilizando os itens (a) e (b).

Exercício 7. Um grande jornal brasileiro deseja entender o movimento de assinaturas segundo a faixa etária de seus assinantes. A proposta é avaliar o perfil do

assinante para o lançamento de campanhas promocionais que atendam a 95% das idades contidas na tabela a seguir.

Idade (em anos)			Frequência (f_i)
15	┤	20	18
20	┤	25	42
25	┤	30	78
30	┤	35	115
35	┤	40	178
40	┤	45	107
45	┤	50	88
50	┤	55	52
55	┤	60	30
60	┤	65	12

- a) Represente graficamente essa distribuição de frequências.
- b) Calcule as seguintes medidas-resumo: μ , Me , Mo_b , Mo , Q_1 , Q_3 , D_2 , D_6 , P_{35} , P_{83} , σ^2 e σ .

Capítulo 4

Distribuições de estatísticas

Resumo do capítulo: *Neste capítulo, abordamos noções introdutórias da distribuição da média amostral em populações finitas e estendemos esses conceitos para populações infinitas. Também apresentamos, brevemente, as distribuições de amostragem associadas à proporção amostral, variância amostral, bem como à diferença entre médias e razão entre variâncias.*

Objetivo: *O objetivo deste capítulo é a compreensão do conceito de distribuição amostral de uma estatística. Veremos também que algumas estatísticas (tais como a proporção e a média) são boas para a estimação de valores de parâmetros populacionais. Objetivamos também preparar o leitor para os conceitos de estimação e testes de hipóteses que serão abordados no próximo capítulo.*

4.1 Introdução

A partir deste capítulo serão apresentados conceitos e procedimentos que fundamentam a “teoria das probabilidades” que é utilizada na investigação científica. Mais especificamente, apresentaremos mecanismos que generalizam para a população as informações contidas nas amostras.

Existem, basicamente, duas maneiras de proceder tal generalização. Uma delas consiste na estimação de parâmetros descritores da população. Por exemplo, se é sabido que determinada população tem distribuição de Bernoulli (como a população de eleitores de um país, referindo-se à preferência ou não por determinado candidato ou partido político), então o parâmetro de interesse é a probabilidade de sucesso, que pode ser estimada pela proporção de favoráveis na amostra (pesquisa eleitoral, por exemplo). A outra maneira de praticar a inferência estatística é pela realização de testes de hipóteses referentes aos parâmetros da população, ou à própria distribuição de probabilidade.

4.2 Conceitos básicos

A população sob estudo é descrita por características escolhidas pelo pesquisador. A essas características chamamos de variáveis ou variáveis descritoras por descreverem a população. População e variável descritora são quase sempre confundidas como a mesma entidade, embora devesse haver consciência da distinção. O ponto importante é que uma variável qualquer, associada a uma população, tem uma distribuição de frequência, a qual pode ser descrita por um modelo probabilístico $f(\cdot)$. Assim, no contexto da Estatística, a cada elemento da população é associada uma variável aleatória.

O modelo $f(\cdot)$ pode ser conhecido ou pressuposto ou ainda selecionado mediante testes específicos.

Da inviabilidade de observar a totalidade de elementos de uma população é que surgiu a ideia de observar apenas uma parte deles. Esse conjunto é chamado de amostra, conforme definido no início deste material. Uma vez que cada elemento da população é associado a uma variável aleatória, a mesma ideia é válida para a amostra, ou seja, matematicamente, uma amostra pode ser definida como um conjunto de n variáveis aleatórias da mesma distribuição $f(\cdot)$.

Quase sempre a preferência é por algum tipo de amostragem aleatória, pela qual os elementos coletados são sorteados, o que faz com que cada elemento da amostra tenha sido tomado independentemente dos demais. Amostras aleatórias, embora possam ser menos representativas do que amostras tomadas sistematicamente, são, em geral, preferidas por permitirem tratamento matemático (e probabilístico) mais simplificado das observações.

Desse fato decorre que, sendo os elementos tomados independentemente, as variáveis aleatórias a eles associadas também o são, e, portanto, a distribuição conjunta de $X_1, X_2, \dots, X_n$ pode ser assim considerada,

$$f(X_1, X_2, \dots, X_n) = f(X_1) \cdot f(X_2) \cdot \dots \cdot f(X_n) = \prod_{i=1}^n f(X_i), \quad (4.1)$$

que é chamada de função de verossimilhança, e por vezes é representada por $L(\mathbf{X}; \boldsymbol{\theta})$, ressaltando que a verossimilhança é função do vetor de dados $\mathbf{X}$ e do vetor de parâmetros $\boldsymbol{\theta}$.

A função de verossimilhança dada em (4.1) evidencia o fato de que a probabilidade de ocorrência de n determinados resultados na amostra, sendo esta aleatória, é igual ao produto das probabilidades individuais, conforme o conceito de independência. Isso permite trabalhar matematicamente os elementos da amostra, bem como especular sobre os parâmetros em $f(\cdot)$.

Se houver algum tipo de dependência entre os elementos da amostra, a relação acima não é válida. Um erro muitas vezes cometido é considerar uma amostragem sistemática e, apesar disso, pressupor independência entre as observações amostrais

e adotar (4.1). Esse procedimento pode levar a falsas quantificações acerca das probabilidades de se cometerem erros de inferência.

A seguir, apresentamos o conceito matemático de amostra aleatória e de algumas particularidades da mesma.

Amostra aleatória: Conjunto de n variáveis aleatórias, independentes entre si, com a mesma distribuição de probabilidade $f(\cdot)$, em que cada elemento da população tem a mesma probabilidade de ser incluído na amostra.

A partir do qual, pode-se definir:

Tamanho da amostra: Quantidade de realizações da variável aleatória, quantidade de elementos que compõem a amostra, indicado por n .

Função de verossimilhança: Distribuição de probabilidade da amostra aleatória, em geral é dada pelo produto da distribuição de probabilidade de cada dado, como em (4.1).

Toda especulação realizada sobre parâmetros populacionais, a partir de amostras, é feita valendo-se de grandezas calculadas utilizando os dados amostrais. Tais grandezas são chamadas estatísticas.

Estatísticas: Funções de, e apenas de observações amostrais, ou seja, de variáveis aleatórias (dados) e que, portanto, são elas próprias variáveis aleatórias.

Por exemplo, a média amostral é uma aproximação para a média populacional e, como é calculada exclusivamente a partir de dados amostrais, é uma estatística. Para entender que a média amostral é uma variável aleatória, basta imaginar a coleta de infinitas amostras aleatórias. Em cada amostra, a média amostral irá variar, sendo essa variação descrita por um modelo probabilístico.

Tecnicamente, quando se diz que a média amostral, por exemplo, é uma aproximação da média populacional, esse processo é chamado estimação.

Estimação: Processo de obtenção de aproximações numéricas para parâmetro(s) associado(s) a $f(\cdot)$.

Estimativa: Uma aproximação numérica particular (ou seja, na dada amostra) para parâmetro(s) associado(s) a $f(\cdot)$.

Estimador: Função ou o processo numérico que permite a geração de estimativas.

Dessa maneira, deve ficar claro que o enfoque da inferência estatística é diferente daquele do cálculo de probabilidades, no qual conhece-se o modelo probabilístico e

seus parâmetros, e obtêm-se as probabilidades da variável estar contida em determinados intervalos. Enquanto, na inferência, dispõe-se de valores para a variável e deseja-se conhecer, com a maior precisão possível, o(s) parâmetro(s) do modelo probabilístico.

4.3 Amostragem

O objetivo da amostragem é estimar o(s) parâmetro(s) da população por meio de amostras. A amostragem apresenta muitas vantagens em relação ao censo. O censo é o estudo que envolve todos os elementos da população. Por meio do censo se determina o valor exato de cada parâmetro da população, que em termos de precisão é o desejável, porém, esse processo geralmente é inviável por ser caro, lento e oneroso.

Por esta razão, o uso de amostras se torna preferível ao censo. A seguir, apresentamos algumas vantagens da amostragem em relação ao censo (cf. Bolfarine & Bussab, 2005; Bussab & Morettin, 2006).

Menor custo: Como os dados são tomados de uma fração da população, a amostragem é mais barata do que o censo.

Maior amplitude: Em certas pesquisas, há necessidade de utilizar equipes bem treinadas e equipamentos sofisticados para a obtenção dos dados, tornando o censo inviável.

Maior exatidão: Com um volume reduzido de dados, trabalha-se com equipes melhor preparadas, obtendo dados mais exatos e confiáveis.

Maior rapidez: Em decorrência do menor volume de dados, esses são coletados e tabulados mais rapidamente na amostragem, o que diminui o tempo para a obtenção dos resultados.

Há vários tipos de amostragens, as quais se concentram em dois grupos: probabilísticas e não probabilísticas. A seguir, apresentamos algumas formas de amostragem em cada um desses grupos.

Amostragem probabilística:

1. Amostragem aleatória simples;
2. Amostragem aleatória estratificada;
3. Amostragem aleatória sistemática;
4. Amostragem aleatória por conglomerados.

Amostragem não probabilística:

1. Inacessibilidade a toda a população;
2. Amostragem a esmo (ou sem norma);
3. Amostragem intencional;
4. População formada por material contínuo (por exemplo, líquidos ou gases).

Neste compêndio, abordaremos apenas a amostragem aleatória simples, dentro do contexto probabilístico.

Ainda no campo da amostragem, nos deparamos com dois tipos de populações: a finita ou infinita enumerável e a infinita. A seguir, apresentamos suas definições e exemplos.

População finita: É a população em que se pode contar ou enumerar todos os seus elementos. Exemplos:

1. Número de itens produzidos numa linha de produção, em um único dia;
2. Número de pessoas com certa doença na cidade desejada;
3. Número de alunos em uma determinada universidade.

População infinita: É aquela população na qual é impossível contar ou enumerar todos os seus elementos. Exemplos:

1. População de mamíferos selvagens no Pantanal Mato-Grossense;
2. Produção brasileira de certo equipamento eletrônico;
3. Número de acidentes de trânsito em uma determinada rodovia federal;
4. População de pessoas com doença de Chagas.

4.4 Número de amostras em população finita

O número de amostras refere-se à quantidade de amostras que são possíveis de serem coletadas na população em questão. Neste caso, consideramos uma população finita da qual conhecemos o tamanho. O número de amostras possíveis está relacionado com o procedimento de amostragem, que pode ser com ou sem repetição, isto é, se o elemento já selecionado será ou não recolocado na população antes da próxima seleção.

Processo com reposição: Seja uma população finita de tamanho N . Então, o número k de amostras possíveis que podem ser retiradas desta população é:

$$k = N^n.$$

Processo sem reposição: Seja uma população finita de tamanho N . Então, o número k de amostras possíveis que podem ser retiradas desta população é:

$$k = \binom{N}{n} = \frac{N!}{n!(N-n)!}.$$

Exemplo 37. Numa população composta por $N = 80$ coelhos, quantas amostras possíveis podem ser extraídas, sendo a amostragem realizada:

- a) Sem reposição e com $n = 2$?
- b) Sem reposição e com $n = 4$?
- c) Com reposição e com $n = 2$?
- d) Com reposição e com $n = 4$?

Solução:

a) $n = 2$ - sem reposição:

$$k = \binom{N}{n} = \binom{80}{2} = 3.160 \text{ possíveis amostras.}$$

```
# Função predeterminada choose(N,n) para calcular o coeficiente  
  binomial  
> choose(80,2)  
[1] 3160
```

b) $n = 4$ - sem reposição:

$$k = \binom{N}{n} = \binom{80}{4} = 1.581.580 \text{ possíveis amostras.}$$

```
> choose(80,4)  
[1] 1581580
```

c) $n = 2$ - com reposição:

$$k = N^n = 80^2 = 6.400 \text{ possíveis amostras.}$$

d) $n = 4$ - com reposição:

$$k = N^n = 80^4 = 40.960.000 \text{ possíveis amostras.}$$

4.5 Erro-padrão da média

Seja k a quantidade possível de amostras de tamanho n que podem ser extraídas de uma população de tamanho N . Se forem tomadas todas as k amostras, então teremos k médias amostrais,

$$\overline{X}_1, \overline{X}_2, \dots, \overline{X}_k.$$

Se fizermos a média das médias amostrais, representada por $\overline{\overline{X}}$, então $\overline{\overline{X}}$ terá o mesmo valor da média populacional μ , isto é,

$$\overline{\overline{X}} = \frac{1}{k} \sum_{i=1}^k \overline{X}_i = \mu.$$

Se fizermos a variância das médias amostrais, representada por $\sigma_{\overline{X}}^2$, então $\sigma_{\overline{X}}^2$ será n vezes menor que a variância populacional σ^2 . Para essa relação, denominamos $\sigma_{\overline{X}}$ de erro-padrão da média, que nada mais é do que o desvio-padrão da distribuição amostral das médias, expresso por:

$$\sigma_{\overline{X}}^2 = \frac{\sigma^2}{n} \Rightarrow \sigma_{\overline{X}} = \frac{\sigma}{\sqrt{n}}.$$

4.5.1 Fator de correção para populações finitas

Como a população é finita, usaremos o fator de correção para população finita, dado por $(N - n)/(N - 1)$. Dessa forma, temos:

$$\sigma_{\overline{X}}^2 = \frac{\sigma^2}{n} \left(\frac{N - n}{N - 1} \right) \Rightarrow \sigma_{\overline{X}} = \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N - n}{N - 1}}.$$

Exemplo 38. *Suponha uma população de tamanho $N = 10$ formada pelos elementos:*

$$\{10, 20, 30, 40, 50, 60, 70, 80, 90, 100\}.$$

Então, temos que a média populacional é dada por $\mu = 55$ e a variância populacional é dada por $\sigma^2 = 825$.

a) *Quantas amostras de tamanho $n = 2$ podem ser extraídas dessa população num processo sem reposição?*

b) *Qual a média das médias amostrais?*

c) *Qual o valor da variância das médias amostrais com o fator de correção para populações finitas?*

Solução:

a) O número total de amostras é:

$$\binom{N}{n} = \binom{10}{2} = \frac{10!}{2!(10-2)!} = 45.$$

Então, temos $k = 45$ possíveis amostras de tamanho $n = 2$ que podem ser extraídas dessa população.

b) Para cada uma das 45 amostras, determinaremos a sua média amostral conforme a Tabela 4.1 a seguir.

Tabela 4.1: Resultados das 45 possíveis amostras do exemplo.

Amostra	Dados			$\bar{X}_i$	Amostra	Dados			$\bar{X}_i$	Amostra	Dados			$\bar{X}_i$
1	10	20	15		16	20	90	55		31	50	60	55	
2	10	30	20		17	20	100	60		32	50	70	60	
3	10	40	25		18	30	40	35		33	50	80	65	
4	10	50	30		19	30	50	40		34	50	90	70	
5	10	60	35		20	30	60	45		35	50	100	75	
6	10	70	40		21	30	70	50		36	60	70	65	
7	10	80	45		22	30	80	55		37	60	80	70	
8	10	90	50		23	30	90	60		38	60	90	75	
9	10	100	55		24	30	100	65		39	60	100	80	
10	20	30	25		25	40	50	45		40	70	80	75	
11	20	40	30		26	40	60	50		41	70	90	80	
12	20	50	35		27	40	70	55		42	70	100	85	
13	20	60	40		28	40	80	60		43	80	90	85	
14	20	70	45		29	40	90	65		44	80	100	90	
15	20	80	50		30	40	100	70		45	90	100	95	

Calculando a média das médias amostrais, denotada por $\bar{\bar{X}}$, obtemos:

$$\bar{\bar{X}} = \frac{1}{45} \sum_{i=1}^{45} \bar{X}_i = \frac{15 + 20 + 25 + \dots + 85 + 90 + 95}{45} = 55.$$

c) Calculando a variância das médias amostrais, encontramos:

$$\begin{aligned} \sigma_{\bar{X}}^2 &= \frac{1}{45} \sum_{i=1}^{45} (\bar{X}_i - \bar{\bar{X}})^2 \\ &= \frac{(15 - 55)^2 + (20 - 55)^2 + (25 - 55)^2 + \dots + (90 - 55)^2 + (95 - 55)^2}{45} \\ &= \frac{16.500}{45} \\ &= \frac{1.100}{3}. \end{aligned}$$

Aplicando o fator de correção para população finita, temos a seguinte relação:

$$\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n} \left(\frac{N-n}{N-1} \right) = \frac{825}{2} \times \left(\frac{10-2}{10-1} \right) = \frac{1.100}{3}.$$

Podemos observar que:

- A média das médias amostrais sempre será a média populacional;
- A variância das médias amostrais será n vezes menor que a variância populacional, ajustada pelo fator de correção para população finita.

4.6 Distribuição de amostragem

Em uma sondagem realizada pelo *Educational and Resources Institute*, 750 estudantes de faculdades foram selecionados aleatoriamente e 64% deles disseram possuir pelo menos um cartão de crédito. Essa sondagem envolveu apenas 750 respondentes da população de cerca de 15 milhões de estudantes de faculdades. Sabemos que as estatísticas amostrais variam naturalmente de amostra para amostra, de modo que outra amostra de 750 estudantes de faculdades provavelmente resultaria em uma proporção amostral diferente dos 64% encontrados na primeira sondagem. Nesse contexto, podemos pensar na proporção amostral como uma variável aleatória (Triola, 2008).

Dado que a amostra de 750 estudantes é uma porcentagem tão pequena (0,005%) da população, podemos esperar que a proporção amostral seja uma estimativa razoável da verdadeira proporção de todos os estudantes de faculdades que têm cartão de crédito? A resposta é sim!

A Estatística apresenta métodos para o uso de resultados amostrais para a estimação de parâmetros populacionais com precisão considerável. Tais métodos se baseiam na compreensão de como a Estatística funciona. Entendendo a distribuição de uma proporção amostral, pode-se determinar quão precisa ela pode ser.

Como comentado anteriormente, estatísticas são variáveis aleatórias, a partir do momento que se imagina a coleta de infinitas amostras aleatórias, acarretando no fato de que os valores das estatísticas variam de amostra para amostra, de acordo com sua distribuição de probabilidade. Esse comportamento probabilístico ao longo de infinitas amostras é fundamental na inferência estatística, pois permite a avaliação da qualidade de estimadores (por exemplo, com respeito à precisão), a construção de intervalos de confiança e a realização de testes de hipóteses. Tais distribuições de probabilidade são chamadas de distribuições de amostragem.

Distribuição de amostragem: Distribuição de probabilidade de estatísticas ou de funções de estatísticas, descrevendo seu comportamento ao longo de infinitas amostras.

Particularmente, neste livro será dada ênfase a distribuições associadas a $\bar{X}$ e s^2 .

4.6.1 População não Normal

Um teorema muito importante associado à distribuição de amostragem da média amostral, sendo a população não necessariamente com distribuição Normal, é o chamado Teorema Central do Limite (TCL), conforme enunciado abaixo.

Teorema 1. (*Teorema Central do Limite - TCL*). *Seja uma população com qualquer distribuição de probabilidade, com média μ e variância σ^2 . Se infinitas amostras de tamanho n são extraídas dessa população, então a média $\bar{X}$ dessas amostras terá distribuição aproximadamente Normal, com média μ e variância σ^2/n , à medida que n tende ao infinito.*

O TCL não será demonstrado aqui, pois envolve uma profundidade matemática que vai além dos objetivos deste livro. Trata-se de um teorema útil, pois muitos procedimentos em Estatística pressupõem que os dados tenham distribuição Normal. Por exemplo, suponha que se esteja estudando uma substância inibidora do crescimento em espécies vegetais. Para tanto, as lâminas são examinadas em microscópio e é contado o número de células em divisão (mitoses). Se cada dado da amostra corresponder a uma lâmina, então a variável em questão é uma contagem (variável discreta), obviamente não Normal, o que não permitirá que se utilizem procedimentos baseados na distribuição Normal, como o uso da variável (estatística) T (apresentada mais adiante). No entanto, se cada dado da amostra corresponder a uma média de 8 lâminas, por exemplo, então esses novos dados já serão mais semelhantes a uma distribuição Normal, e a variável T poderá ser usada.

Um caso particular do TCL é o chamado Teorema de DeMoivre-Laplace, específico para populações com distribuição de Bernoulli. Em tais casos, a amostra consistirá de um conjunto de zeros e uns, e ainda,

$$E(\bar{X}) = p \quad \text{e} \quad Var(\bar{X}) = \frac{p(1-p)}{n}.$$

Nesse caso, é interessante notar que o numerador da média amostral (ou seja, a soma dos dados), por ser uma soma de variáveis de Bernoulli, é uma variável com distribuição binomial. Dessa forma, como a média amostral nada mais é do que a soma dividida por n , o teorema pode ser expresso a partir dela. Ou seja, à medida que n tende ao infinito, a soma das variáveis de Bernoulli (variável binomial) tende a ter distribuição Normal, com média np e variância $np(1-p)$. A importância desse resultado pode ser ilustrada com um exemplo.

Exemplo 39. *Seja uma amostra com $n = 500$ elementos, tomados de uma população de Bernoulli com probabilidade de sucesso $p = 0,4$. Suponha que se deseja determinar a probabilidade de que ocorram 210 sucessos ou menos, na amostra. Pelo modelo binomial, tal probabilidade seria obtida por meio de:*

$$P(X \leq 210) = \sum_{x=0}^{210} \binom{500}{x} (0,4)^x (0,6)^{500-x}, \quad (4.2)$$

sendo X , nesse caso, a soma de n variáveis de Bernoulli, ou seja, o número de sucessos na amostra. Tal cálculo de probabilidade seria extremamente laborioso. Então, o TCL é uma alternativa e, dessa forma, temos:

$$P(X \leq 210) = P\left(Z \leq \frac{210 - np}{\sqrt{np(1-p)}}\right). \quad (4.3)$$

Esta é apenas uma das aplicações do TCL.

A validade do Teorema de DeMoivre-Laplace piora à medida que n se torna pequeno e também quando o valor de p se aproxima dos extremos, 0 ou 1. Nesses casos, a distribuição se torna bastante assimétrica, distanciando-se da distribuição Normal. Uma regra empírica determina que o teorema seja válido com $np \geq 5$ e $np(1-p) \geq 5$.

Alguns autores, como Spiegel (1993), recomendam que se faça uma *correção de continuidade*, ao se aproximar uma variável binomial (discreta) por uma Normal (contínua). Essa correção baseia-se no fato de que um valor x , discreto, corresponderia ao intervalo $[x - 0,5; x + 0,5]$ no caso contínuo.

Assim, no exemplo anterior, se fosse desejado conhecer $P(200 \leq X \leq 300)$, dever-se-ia considerar $P(199,5 \leq X \leq 300,5)$ ao se utilizar a aproximação Normal. Desta forma, (4.3) seria expressa como:

$$P(X \leq x) = P\left(Z \leq \frac{(x + 0,5) - np}{\sqrt{np(1-p)}}\right). \quad (4.4)$$

Note que, se o valor x é excluído, então:

$$P(X < x) = P\left(Z < \frac{(x + 0,5) - np}{\sqrt{np(1-p)}}\right).$$

Exemplo 40. *Continuando o exemplo anterior, obtemos o valor da probabilidade desejada, $P(X \leq 210)$, que é de: $\approx 0,8312$ pelo modelo binomial, isto é, a partir de (4.2); $\approx 0,8193$ por (4.3); e, finalmente, $\approx 0,8311$ considerando a correção de continuidade dada em (4.4).*

```
> sum(dbinom(x=0:210, size=500, prob=0.4))
[1] 0.8311605 # pelo modelo binomial
> pnorm(q=((210-500*0.4)/sqrt(500*0.4*0.6)))
[1] 0.8193448 # pela aproximação Normal (TCL)
> pnorm(q=((210+0.5-500*0.4)/sqrt(500*0.4*0.6)))
[1] 0.8310983 # pela aproximação Normal (TCL) com correção de
continuidade
```

4.6.2 População Normal

Se for razoável admitir que a população em questão segue uma distribuição Normal, então uma série de resultados exatos (sem exigência de amostras grandes) relativos a distribuições de amostragem podem ser obtidos. Isso faz com que a pressuposição de distribuição Normal seja particularmente interessante, por uma forte conveniência matemática.

Distribuição de amostragem associada à média amostral

Seja uma população com distribuição Normal, com média μ e variância σ^2 . Se infinitas amostras de tamanho n são retiradas dessa população, então a média $\bar{X}$ dessas amostras terá distribuição exatamente Normal, com média μ e variância σ^2/n , para qualquer tamanho de amostra. Isto é, se $X \sim N(\mu, \sigma^2)$, então:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Embora esse resultado seja bastante interessante, será de pouca utilidade para as técnicas de estimação, pois, na prática, quando não se conhece o valor do parâmetro μ , também não se conhece o valor do parâmetro σ^2 . O resultado a seguir tem utilidade muito maior, pois faz uso de s^2 ao invés de σ^2 .

Seja uma população com distribuição Normal, com média μ e variância σ^2 . Sejam infinitas amostras de tamanho n coletadas dessa população, a partir das quais são calculadas $\bar{X}$ e s^2 . Temos então:

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \sim t_{n-1},$$

em que t denota a distribuição t -Student e $n - 1$ os graus de liberdade da mesma.

A distribuição t -Student é uma função densidade de probabilidade indexada por um único parâmetro que é o número de graus de liberdade das amostras em questão (dado em função do tamanho amostral n). A seguir, são apresentadas algumas propriedades dessa distribuição:

- i. A média da variável T , ou seja, $E(T)$ é igual a zero, da mesma forma que a distribuição Normal padronizada Z ;
- ii. A distribuição t -Student se assemelha à distribuição Normal, pois é simétrica em relação à média e tem formato campanular (formato de sino);
- iii. Quando o tamanho n da amostra tende para o infinito, as distribuições de Z e de T são iguais;
- iv. A distribuição t -Student é definida a partir de um único parâmetro, o número de graus de liberdade relativo ao cálculo de s^2 .

Da mesma forma que a distribuição de Z , não é possível calcular analiticamente integrais (e, portanto, probabilidades) para a distribuição t -Student. Assim, também é necessário o uso de tabela apropriada (ver Tabela A2 do Apêndice) ou então do *software* R como segue:

```
# p é a probabilidade
# n-1 é o número de graus de liberdade
> qt(p, n-1)
```

Distribuição de amostragem associada à variância amostral

Quando o interesse reside na variância populacional, é interessante trabalhar com distribuições de amostragem associadas a s^2 .

Consideremos infinitas amostras de tamanho n coletadas de uma população Normal, a partir das quais são calculadas as variâncias amostrais s^2 . Temos, então, que:

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2,$$

em que χ_{n-1}^2 denota a distribuição Qui-quadrado com $n-1$ graus de liberdade.

A distribuição Qui-quadrado também é definida a partir de um único parâmetro, os graus de liberdade, como a distribuição t -Student. A expressão de sua densidade de probabilidade é de um grau de complexidade maior ao que nos propomos tratar neste material, mas vale ressaltar que não é possível expressar integrais da função Qui-quadrado analiticamente, fazendo-se necessário o uso de tabelas apropriadas (ver Tabela A3 do Apêndice) ou então podemos obter tais valores por meio do *software* R, utilizando o comando a seguir.

```
# p é a probabilidade
# n-1 é o número de graus de liberdade
> qchisq(p, n-1)
```

4.6.3 Duas populações Normais

Frequentemente, existe interesse na comparação entre populações, particularmente em relação às suas médias, por exemplo, quando tem-se por objetivo comparar o efeito de duas rações no desenvolvimento de suínos. Nesse caso, o conjunto dos animais que são ou poderão ser tratados com cada uma das rações em questão corresponde a uma população. A cada animal está associado um ganho de peso após determinado período de tempo. Naturalmente, em estudos dessa natureza, há interesse em identificar qual ração confere o maior ganho de peso médio.

Distribuição de amostragem associada à diferença entre médias amostrais

A comparação entre médias de duas populações é usualmente feita a partir da diferença entre elas. Esta grandeza, desconhecida, é estimada a partir da diferença entre médias de amostras (com n_1 e n_2 elementos) coletadas em cada uma das populações. O interesse do pesquisador, nesse caso, é pela distribuição de amostragem associada a $\bar{X}_1 - \bar{X}_2$. Aqui, apresentaremos apenas o caso particular de quando as variâncias associadas às médias são consideradas iguais.

Se as populações apresentarem **variâncias iguais**, então temos:

$$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\bar{s}^2 \left[\frac{1}{n_1} + \frac{1}{n_2} \right]}} \sim t_{n_1+n_2-2},$$

em que:

$$\bar{s}^2 = \frac{(n_1 - 1) s_1^2 + (n_2 - 1) s_2^2}{n_1 + n_2 - 2}$$

é a média ponderada entre as duas variâncias amostrais, tendo como fator de ponderação os correspondentes números de graus de liberdade.

Distribuição de amostragem associada à razão entre variâncias

Na Subseção anterior, abordamos a distribuição da diferença entre médias amostrais, admitindo que as variâncias entre duas populações eram iguais. Uma forma de julgar se as variâncias entre duas populações podem ser consideradas iguais é por meio da estatística s_1^2/s_2^2 , e é importante que se tenha uma distribuição de amostragem associada a ela.

Sejam infinitos pares de amostras com n_1 e n_2 elementos, e tomadas, respectivamente, em duas populações com distribuição Normal e variâncias σ_1^2 e σ_2^2 . Temos, então, que:

$$\frac{s_1^2 \sigma_2^2}{s_2^2 \sigma_1^2} \sim F_{n_1-1, n_2-1},$$

em que F_{n_1-1, n_2-1} denota a distribuição F de Snedecor com parâmetros $n_1 - 1$ e $n_2 - 1$.

Também não é possível expressar analiticamente as integrais da distribuição F e, assim, é necessário o uso de tabelas apropriadas (ver Tabelas A4-A9 do Apêndice) ou então podemos obter tais valores por meio do *software* R, utilizando o comando a seguir.

```
# p é a probabilidade  
# n1-1 e n2-1 são os parâmetros  
> qf(p, n1-1, n2-1)
```

4.7 Considerações finais

Abordamos neste capítulo o conceito importante de distribuição de amostragem ou distribuição amostral, que nada mais é do que a distribuição de probabilidade de estatísticas ou de funções de estatísticas ao longo de infinitas amostras aleatórias. Apresentamos, de forma breve, as distribuições de amostragem associadas às seguintes características amostrais: média, proporção, variância, diferença entre médias e razão entre variâncias.

Tais resultados serão usados nos Capítulos 5 e 6, que tratam da construção de intervalos de confiança e realização de testes de hipóteses para uma e duas populações, respectivamente.

4.8 Exercícios propostos

Exercício 1. Seja uma população constituída pelos números: $\{10, 12, 14, 16, 18\}$.

- Determine a quantidade de amostras possíveis de tamanho $n = 3$, sem reposição, que podem ser retiradas dessa população.
- Identifique todas as amostras de tamanho $n = 3$ e calcule suas médias.
- Compare a média populacional com a média das médias amostrais.
- Compare a variância populacional com a variância das médias amostrais.

Exercício 2. Repita o exercício anterior para o caso de extrações com reposição. Verifique que, neste caso, a média das médias amostrais é igual à média populacional (isto é, $\overline{\overline{X}} = \mu$), e a variância das médias amostrais é igual à variância populacional dividida pelo tamanho amostral (isto é, $\sigma_{\overline{X}}^2 = \sigma^2/n$).

Exercício 3. Um levantamento realizado pela empresa distribuidora de determinada marca de cerveja, em todos os pontos de venda do produto no país, mostrou que a média do preço de venda é R\$ 9,95 com desvio-padrão R\$ 3,90. Se for retirada uma amostra aleatória em 45 pontos de venda, determine a probabilidade de que a média do preço de venda dessa cerveja seja menor que R\$ 9,00.

Exercício 4. Os dados apresentados a seguir descrevem as temperaturas (em graus Celsius, °C) registradas na cidade de Salvador entre 2011 e 2019. As temperaturas medidas em fevereiro foram obtidas como se segue:

27,56	27,04	28,64	26,14	27,25	27,85	28,00	27,75	29,30
-------	-------	-------	-------	-------	-------	-------	-------	-------

Supondo normalidade da variável temperatura, responda os itens a seguir.

- a) Qual a probabilidade de se registrar uma temperatura média inferior a 27 °C?
- b) Qual a probabilidade de se registrar uma temperatura média superior a 28,5 °C?

Exercício 5. Segundo o *National Eye Institute*, nos Estados Unidos, cerca de 8% dos homens do mundo têm algum grau de daltonismo. Com base nessa informação, calcule a probabilidade de que, em uma amostra de 100 indivíduos do sexo masculino, a proporção de daltônicos:

- a) Seja superior a 10%.
- b) Esteja entre 7% e 9%.
- c) Seja inferior a 4%.

Exercício 6. Supõe-se que o consumo mensal de energia elétrica (em quilowatt-hora, kWh) por residência em certo bairro de Ribeirão Preto tem distribuição Normal com média 150 kWh e desvio-padrão 25 kWh. Para uma amostra de 16 residências, qual é a probabilidade de a média amostral não se afastar da verdadeira média por mais de 10 kWh?

Exercício 7. Suponha que a distribuição das alturas (em cm) das mulheres de duas diferentes localidades (A e B) do Brasil são aproximadamente Normais com variâncias iguais. Foram retiradas duas amostras aleatórias de 16 mulheres, uma de cada localidade, obtendo-se: $\bar{X}_A = 164$ cm; $\bar{X}_B = 152$ cm; $s_A^2 = 49$ cm²; $s_B^2 = 25$ cm². Portanto, a diferença entre as médias de alturas das mulheres das duas amostras é de $\bar{X}_A - \bar{X}_B = 12$ cm. Se não houver diferença entre as duas localidades quanto às alturas médias das mulheres, qual seria a probabilidade de que a diferença entre as médias de duas amostras aleatórias de 16 mulheres selecionadas das duas localidades seja maior que 12 cm, ou seja, $P(\bar{X}_A - \bar{X}_B > 12)$?

Capítulo 5

Intervalos de confiança e testes de hipóteses para uma população

Resumo do capítulo: *Neste capítulo, abordamos intervalos de confiança e testes de hipóteses para média, proporção e variância (desvio-padrão) considerando uma única amostra. Também apresentamos uma explanação breve sobre tipos de erros em testes de hipóteses e p-valor, índice altamente usado na tomada de decisões que utilizam softwares para realização dos cálculos. Em cada tópico dispomos de exemplos resolvidos e no final do capítulo propomos alguns exercícios.*

Objetivo: *Este capítulo tem como objetivo exemplificar situações em que as teorias apresentadas se aplicam e que o leitor seja capaz de utilizar a metodologia adequada para obtenção de intervalos de confiança e testes de hipóteses que envolvam média, variância e proporção, bem como interpretá-los.*

5.1 Introdução

Intervalos de confiança

Quando coletamos uma amostra e dela extraímos estatísticas como média, desvio-padrão, variância e proporção, devemos ter consciência que aos resultados obtidos estão vinculados erros. Erros são oriundos da limitação de conhecimento que a amostra apresenta em relação à população. Isto pode ser facilmente verificado se tomarmos duas amostras e calcularmos suas médias, por exemplo. Provavelmente seus valores numéricos serão distintos.

Uma alternativa no intuito de atenuar esse problema, é o intervalo de confiança para o parâmetro, que tem como objetivo amenizar as variações que podem ocorrer nas estimativas. Essas variações são ocasionadas, muitas vezes, por fatores aleatórios de amostragem, fazendo com que, frequentemente, as estatísticas intervalares sejam preferíveis às pontuais.

Valor pontual é o valor numérico da média, desvio-padrão, proporção, ou qualquer outra estatística, enquanto que o intervalo de confiança é um intervalo numérico que apresenta um valor mínimo e um valor máximo, entre os quais está o valor pontual estimado. Eles se dizem de confiança pelo fato de que cada intervalo é construído considerando uma probabilidade de acerto que chamamos de nível de confiança.

Declarar que intervalos de confiança são preferíveis aos valores pontuais, corresponde ao fato de que é mais difícil errarmos, por exemplo, ao dizer que a média de gols por partida em uma rodada do campeonato brasileiro de futebol estará entre 0 e 3 gols do que se afirmamos que será exatamente 1,5 gols.

Testes de hipóteses

Testes de hipóteses são utilizados em tomadas de decisão a respeito do valor do parâmetro de interesse na população, tendo como base apenas uma amostra da mesma. Esse parâmetro é comumente a média, variância ou proporção. Por exemplo:

- Comparar se o desempenho médio (nota) de uma classe em determinada matéria é igual ao desempenho de outra classe;
- Comparar se o QI de uma pessoa é igual ao valor μ_0 fixado;
- Comparar se a variabilidade do diâmetro dos parafusos produzidos numa linha de produção é igual ao valor σ_0 fixado pelo controle de qualidade, que indica a variabilidade aceitável.

Neste capítulo, apresentaremos técnicas para construção de intervalo de confiança para a média com variância conhecida e desconhecida, e de testes de hipóteses unilaterais e bilateral. Trataremos teoricamente dos tipos de erros envolvidos nas decisões, serão abordados exemplos de aplicação destas, bem como atividades propostas para o leitor. Assumiremos que os conjuntos de dados provêm de distribuições de probabilidade Normal.

Em ambas as teorias, teste de hipóteses e intervalo de confiança, apresentaremos as diferenças relacionadas ao fato de considerar ou não que o desvio-padrão populacional é conhecido.

5.2 Probabilidade de cobertura

O intervalo de confiança é mais abrangente do que a estimativa pontual. Em termos estatísticos, dizemos que é mais informativo, pois é um intervalo numérico obtido a partir da estimativa pontual e associado a um procedimento com probabilidade de cobertura do verdadeiro valor do parâmetro. Tal probabilidade é denominada probabilidade de cobertura teórica. Para cada uma das probabilidades teóricas

de cobertura, está associado um valor tabelado. Considerando o desvio-padrão conhecido, esses valores estão relacionados com a distribuição de probabilidade Normal padrão e apresentados na Tabela 5.1 a seguir.

Tabela 5.1: Valores da distribuição Normal padrão.

Nível de confiança	Nível de significância		
$100(1 - \alpha)\%$	$100(\alpha)\%$	$z_{\alpha/2}$	z_{α}
99,74	0,26	3,00	2,81
99,00	1,00	2,58	2,33
97,50	2,50	2,24	1,96
95,44	4,56	2,00	1,69
95,00	5,00	1,96	1,64
90,00	10,00	1,65	1,28
85,00	15,00	1,44	1,04

A probabilidade de cobertura teórica também é chamada de nível de confiança, seus valores são obtidos da tabela da distribuição Normal padrão (ver Anexo) e interferem na amplitude (tamanho) do intervalo.

Para fins ilustrativos da probabilidade de cobertura, na Figura 5.1 são apresentados 50 intervalos com 95% de confiança para a média (μ), obtidos por simulação de amostras extraídas de uma população com média $\mu = 2$, representada pela linha vertical no gráfico. Foram construídos 50 intervalos para cada um dos quatro casos, os quais são representados pelas linhas horizontais. De acordo com os resultados obtidos, observamos que:

- Em A, tivemos 3 intervalos construídos que não contêm o verdadeiro valor do parâmetro. Neste caso, a probabilidade de cobertura efetiva é $\frac{50-3}{50} = \frac{47}{50} = 94\%$, portanto menor que a proposta.
- Em B, houve 5 intervalos que não contiveram o valor verdadeiro do parâmetro, resultando em 90% de cobertura.
- Em C e D, tivemos 2 casos dos intervalos obtidos não conterem o verdadeiro valor do parâmetro. Desta forma, a probabilidade de cobertura efetiva é $\frac{50-2}{50} = \frac{48}{50} = 96\%$, ficando maior que a probabilidade proposta.

A média de cobertura é 94%, sendo portanto aceitável, pois ficou próxima do valor desejado.

O gráfico da Figura 5.1 foi produzido no *software* R, cujo código é dado a seguir.

```
> par(mfrow=c(2,2))
> aux<-c("A", "B", "C", "D")
> sem<-0
```




Figura 5.1: Intervalos de confiança de 95% para a média $\mu = 2$, considerando 50 amostras extraídas da população.

```
> for (j in 1:4) {
plot(c(1.5,2.5),c(1,6), main=aux[j], xlab=expression(mu),
ylab="Amostra", yaxt="n", type="n")
axis(2, at=1:6, labels=seq(1,51,10))
segments(2,.9,2,6) # média da distribuição Normal
n=50; k=.9
for(i in 1:n) { k=k+0.1
sem=sem+10*i; set.seed(sem)
x=rnorm(100,2,1) # 100 valores com distribuição Normal(2,1)
li=mean(x)-1.96/10; ls=mean(x)+1.96/10
segments(li,k,ls,k) } }
```

5.3 Média populacional

A média é uma das medidas estatísticas mais conhecidas e utilizadas. Frequentemente, ouve-se falar em média de crescimento econômico, consumo médio por família, média das notas escolares, produtividade média, média de gols por partida, enfim,

uma infinidade de referências à estatística média.

Mesmo sendo amplamente utilizada, como é obtida geralmente de amostras da população, ela não está ílesa a erros. Na tentativa de minimizar as deficiências de representar a população em questão, os conceitos de intervalo de confiança e teste de hipóteses são utilizados.

5.3.1 Intervalo de confiança com desvio-padrão conhecido

O intervalo de confiança para a média é dado por:

$$IC[\mu, 100(1 - \alpha)\%] = \bar{X} \pm \frac{\sigma z_{\alpha/2}}{\sqrt{n}},$$

em que $\bar{X}$ é a média amostral, n é o tamanho da amostra, σ é o desvio-padrão, e $z_{\alpha/2}$ é o valor relacionado à probabilidade de cobertura, apresentado na Tabela 5.2.

Isso significa que o intervalo calculado para a média populacional (μ), ao nível de confiança $100(1 - \alpha)\%$, tem limite inferior $\bar{X} - \frac{\sigma z_{\alpha/2}}{\sqrt{n}}$ e limite superior $\bar{X} + \frac{\sigma z_{\alpha/2}}{\sqrt{n}}$, ou seja,

$$\bar{X} - \frac{\sigma z_{\alpha/2}}{\sqrt{n}} \leq \mu \leq \bar{X} + \frac{\sigma z_{\alpha/2}}{\sqrt{n}}.$$

Ao valor $\bar{X} - \frac{\sigma z_{\alpha/2}}{\sqrt{n}}$ denominamos Limite ou Limitante Inferior do intervalo (LI), e ao valor $\bar{X} + \frac{\sigma z_{\alpha/2}}{\sqrt{n}}$ denominamos Limite ou Limitante Superior (LS).

Código no *software* R para o cálculo do intervalo de confiança para a média:

```
# Função para o cálculo do IC
> ICmedia<-function(x,alpha,desvio) {
n<-length(x)
z<-qnorm(alpha/2, lower.tail=FALSE)
LI<-mean(x)-z*desvio/sqrt(n)
LS<-mean(x)+z*desvio/sqrt(n)
return(c(LI,LS)) }
```

Exemplo 41. Consideremos 12 observações de idade de bebês (em meses) que deram entrada na unidade de saúde em um dia. Suponha que o desvio-padrão seja conhecido e igual a 4. Os dados observados são apresentados a seguir.

2	14	5	8	9	1	15	6	8	5	5	3
---	----	---	---	---	---	----	---	---	---	---	---

a) Podemos afirmar, com 95% de confiança, que a média de idade dos bebês que deram entrada na unidade de saúde está entre quais valores?

b) E com 99% de confiança, qual é o intervalo de confiança?

Solução:

Para construir o intervalo de confiança para a média populacional, isto é, para todos os bebês que poderiam adentrar a unidade de saúde, com base nos dados observados, precisamos do valor da média amostral e estipular a probabilidade de cobertura.

Obtendo os dados:

Tamanho da amostra: n	12
Média: $\bar{X}$	$\frac{\sum_{i=1}^{12} X_i}{12} = \frac{81}{12} = 6,75$
Desvio-padrão: σ	4
Probabilidade de cobertura: 95%	$z_{0,025} = 1,96$
Probabilidade de cobertura: 99%	$z_{0,005} = 2,58$

O intervalo de confiança é obtido pela fórmula: $\bar{X} - \frac{\sigma z_{\alpha/2}}{\sqrt{n}} < \mu < \bar{X} + \frac{\sigma z_{\alpha/2}}{\sqrt{n}}$.

a) Substituindo os valores, tem-se:

$$\begin{aligned} 6,75 - \frac{4 \times 1,96}{\sqrt{12}} &< \mu < 6,75 + \frac{4 \times 1,96}{\sqrt{12}} \\ 6,75 - 2,26 &< \mu < 6,75 + 2,26 \\ 4,49 &< \mu < 9,01. \end{aligned}$$

Pode-se representar na forma intervalar: $IC[\mu, 95\%] = (4,49; 9,01)$.

```
> x<-c(2,14,5,8,9,1,15,6,8,5,5,3)
> ICmedia(x,0.05,4)
[1] 4.486829 9.013171
```

b) Se mudarmos a probabilidade de cobertura de 95% para 99% no cálculo do intervalo de confiança, o que muda é o valor de $z_{\alpha/2}$, que, neste caso, passa a ser 2,58 e o novo intervalo será:

$$IC[\mu, 99\%] = (3,78; 9,72).$$

```
> ICmedia(x,0.01,4)
[1] 3.775689 9.724311
```

Observe que o LI do intervalo de 99% é menor que o do intervalo de 95% e, por sua vez, o LS dele é maior, o que faz com que a amplitude do intervalo de 99% seja maior que a amplitude do intervalo de 95%. Quem controla a amplitude dos intervalos é o valor de $z_{\alpha/2}$. Quanto maior seu valor, maior a amplitude do intervalo e, consequentemente, maior a probabilidade de conter o verdadeiro valor do parâmetro.

No entanto, é necessário ter certo cuidado em relação à amplitude do intervalo de confiança. Podemos ter probabilidades de cobertura bem altas mas intervalos muito grandes. Neste caso, ganhamos na cobertura mas perdemos na precisão.

Por exemplo, dizer com 99,99% de confiança que o peso dos bebês ao nascerem pertence ao intervalo de 0 a 30 kg não é informativo. A precisão é enorme mas a informação se torna vaga pela amplitude do intervalo.

O bom senso sempre deve ser utilizado para determinar o nível de significância dos intervalos.

Até aqui, consideramos que o desvio-padrão da população da qual se extraiu a amostra é conhecido, mas na prática, isto pode não acontecer. Quando a informação que se tem sobre o desvio-padrão da população é com base na estimativa feita a partir da amostra, o procedimento apresentado acima para obter o intervalo de confiança não é recomendado.

A seguir, apresentamos um método de obtenção do intervalo de confiança quando o desvio-padrão populacional (σ) é desconhecido.

5.3.2 Intervalo de confiança com desvio-padrão desconhecido

Quando o valor do desvio-padrão populacional for desconhecido (σ desconhecido), a determinação do intervalo de confiança para a média populacional recebe uma correção, que é realizada substituindo o valor de $z_{\alpha/2}$ pelo valor de $t_{\alpha/2}(gl)$, em que $t_{\alpha/2}(gl)$ corresponde ao valor tabelado, relacionado com a tabela da distribuição *t*-Student (ver Tabela A2 do Apêndice), em que *gl* é o número de graus de liberdade, dado por $n - 1$, em que n é o tamanho da amostra.

Neste contexto, o intervalo de confiança para a média é dado por:

$$\text{IC}[\mu, 100(1 - \alpha)\%] = \bar{X} \pm \frac{s \times t_{\alpha/2}(n - 1)}{\sqrt{n}},$$

em que $s = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}}$ é o estimador não viciado para σ , n é o tamanho da amostra e $\bar{X}$ é a média amostral.

Código no *software* R para o cálculo do intervalo de confiança para a média com desvio-padrão desconhecido:

```
# Função para o cálculo do IC
> ICmedia<-function(x,alpha,desvio) {
n<-length(x)
z<-qnorm(alpha/2, lower.tail=FALSE)
if(missing(desvio)) {
desvio<-sd(x)
z<-qt(1-alpha/2, n-1) }
```

```

LI<-mean(x)-z*desvio/sqrt(n)
LS<-mean(x)+z*desvio/sqrt(n)
return(c(LI,LS)) }

```

É importante ressaltar que nessa função foram implementados ambos os casos, ou seja, o cálculo do intervalo de confiança para a média com desvio-padrão conhecido e desconhecido. Caso o elemento “desvio” não seja preenchido, a função reconhecerá que o desvio-padrão é desconhecido.

Exemplo 42. *Similar ao exemplo anterior, porém o desvio-padrão populacional é desconhecido.*

Consideremos 12 observações de idade, em meses, de bebês que deram entrada na unidade de saúde em um dia, cujos dados são apresentados a seguir.

2	14	5	8	9	1	15	6	8	5	5	3
---	----	---	---	---	---	----	---	---	---	---	---

a) Construir o intervalo de confiança para a média, considerando um nível de confiança de 95%.

b) Repetir o procedimento para 99% de confiança.

Solução:

Para construir os intervalos de confiança para a média populacional, com base nestes dados, precisamos do valor da média amostral e o valor tabelado relacionado com a probabilidade de cobertura.

Obtendo os dados:

Tamanho da amostra: n	12
Média: $\bar{X}$	$\frac{\sum_{i=1}^{12} X_i}{12} = \frac{81}{12} = 6,75$
Desvio-padrão: s	4,35
Probabilidade de cobertura: 95%	$t_{0,025}(11) = 2,20$
Probabilidade de cobertura: 99%	$t_{0,005}(11) = 3,11$

O intervalo de confiança é obtido pela fórmula:

$$\bar{X} - \frac{s \times t_{\alpha/2}(n-1)}{\sqrt{n}} < \mu < \bar{X} + \frac{s \times t_{\alpha/2}(n-1)}{\sqrt{n}}.$$

a) Substituindo os valores, tem-se:

$$\begin{aligned}
6,75 - \frac{4,35 \times 2,2}{\sqrt{12}} &< \mu < 6,75 + \frac{4,35 \times 2,2}{\sqrt{12}} \\
6,75 - 2,76 &< \mu < 6,75 + 2,76 \\
3,99 &< \mu < 9,51.
\end{aligned}$$

Na forma intervalar,

$$IC[\mu, 95\%] = (3,99; 9,51).$$

```
> ICmedia(x,0.05)
[1] 3.985461 9.514539
```

b) Com probabilidade de cobertura de 99%, o que muda na determinação do novo intervalo de confiança é o valor de $t_{\alpha/2}(n-1)$. Assim,

$$\begin{aligned} IC[\mu, 99\%] &= \left(6,75 - \frac{4,35 \times 3,11}{\sqrt{12}}; 6,75 + \frac{4,35 \times 3,11}{\sqrt{12}} \right) \\ IC[\mu, 99\%] &= (6,75 - 3,90; 6,75 + 3,90) \\ IC[\mu, 99\%] &= (2,85; 10,65). \end{aligned}$$

```
> ICmedia(x,0.01)
[1] 2.848964 10.651036
```

Percebemos que a amplitude do intervalo sofreu um acréscimo com o aumento da probabilidade de cobertura.

Comparando os limitantes do exemplo acima com os limitantes do exemplo anterior, percebemos que também há distinção mesmo quando a probabilidade de cobertura é a mesma, mostrando a influência de considerar a metodologia para desvio-padrão populacional conhecido e desconhecido.

5.3.3 Testes de hipóteses

Situação-problema:

“Pela experiência e observação da realidade, a comunidade médica sabe que, em determinada localidade, o peso das crianças ao nascerem é, em média, igual a 2,1 kg. Como o peso é baixo, podendo ocasionar problemas na saúde dos bebês, medidas preventivas no pré-natal estão sendo tomadas com o intuito de elevar o peso dos bebês ao nascerem. Alguns tratamentos são propostos e um deles é aplicado com um grupo de gestantes, escolhido aleatoriamente. Será que o peso dos bebês dessas gestantes será diferente do peso que estava ocorrendo antes dessa iniciativa de tratamento?”

Esse pode ser considerado um exemplo típico de teste de hipóteses. O pesquisador poderia estar interessado em verificar se a média dos pesos dos bebês nascidos das gestantes que fizeram esse novo tratamento é:

- a) diferente do peso dos bebês que nasciam antes;
- b) maior que o peso dos bebês que nasciam antes;

c) menor que o peso dos bebês que nasciam antes.

Desta forma, temos três possíveis hipóteses a serem testadas e cada uma delas tem suas particularidades no que tange ao interesse do pesquisador e também na regra de decisão envolvida.

De maneira geral, em testes de hipóteses, não apenas com respeito à média, como tratamos neste tópico, supomos que existam informações a respeito do parâmetro e essas informações serão consideradas verdadeiras até que se prove o contrário.

No nosso caso, o parâmetro em questão é a média do peso dos bebês ao nascer e a hipótese considerada verdadeira é que esta média é 2,1 kg, a qual é validada pela experiência da comunidade médica local. Provar que isto não é verdadeiro corresponde a verificar, por meios estatísticos, que o peso dos bebês não é 2,1 kg, podendo ser: a) diferente; b) maior; ou c) menor.

Considerando que as medidas médicas adotadas prezam pelo aumento de peso dos bebês, então a hipótese de interesse é a b) elencada acima. Representando a média por μ , podemos indicar as hipóteses a serem testadas da seguinte forma:

$$\begin{cases} \mu = 2,1 \\ \mu > 2,1 \end{cases}$$

Para diferenciar as condições (hipóteses), indicamos a primeira por $H_0 : \mu = 2,1$, chamada de hipótese nula, e a segunda por $H_a : \mu > 2,1$, chamada de hipótese alternativa. Geralmente, as hipóteses são apresentadas como segue:

$$\begin{cases} H_0 : \mu = 2,1 \\ H_a : \mu > 2,1 \end{cases}$$

Se, ao invés de considerar o caso b) *igualdade contra maior*, o interesse fosse no caso a) *igualdade contra diferença*, ou no caso c) *igualdade contra menor*, o que mudaria seria H_a , a hipótese alternativa. A hipótese nula H_0 é sempre a mesma, isto é, a hipótese da igualdade a um valor fixado.

As hipóteses são testadas utilizando informações obtidas da amostra e considerando alguma medida comparativa para decidir se rejeita ou não rejeita a hipótese nula H_0 .

Como utiliza-se uma amostra da população, a decisão tomada pode estar certa ou não, e isto está relacionado com os erros Tipo I e Tipo II que discutiremos no final do capítulo.

Note que devemos levar em consideração a questão do desvio-padrão populacional (σ) ser conhecido ou não.

5.3.4 Tipos de hipótese - unilaterais e bilateral

Podemos ter testes unilaterais e bilateral para a média com desvio-padrão populacional conhecido ou não. Testes do tipo bilateral são os testes de igualdade

versus diferença; os demais são testes unilaterais. O que muda de um para o outro é o valor tabelado que será utilizado na decisão do teste, bem como a própria regra de decisão.

A seguir, apresentaremos as estatísticas para cada um dos testes, seguidas das respectivas regras de decisão.

Estatísticas

Se o desvio-padrão populacional for conhecido (σ conhecido), a estatística do teste é dada por:

$$Z = \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma},$$

em que μ_0 é o valor fixado de interesse, n é o número de dados da amostra, σ é o desvio-padrão populacional e $\bar{X}$ é a média amostral.

Se o desvio-padrão populacional for desconhecido (σ desconhecido), a estatística do teste é dada por:

$$T = \sqrt{n} \frac{\bar{X} - \mu_0}{s},$$

em que μ_0 é o valor fixado de interesse, n é o número de dados da amostra, s é o desvio-padrão amostral e $\bar{X}$ é a média amostral.

Regra de decisão

A decisão é sempre tomada em termos de H_0 . Costuma-se dizer que se rejeita ou não H_0 ; em caso de rejeição de H_0 , as evidências se voltam para H_a . Então, pode-se dizer que os dados favorecem a hipótese alternativa.

A decisão depende do tipo do teste e da estatística utilizada, lembrando que a decisão pela estatística depende de conhecer ou não o desvio-padrão populacional.

A seguir, são apresentados os testes (unilaterais e bilateral) com suas respectivas regras de decisão.

Igualdade *versus* diferença - teste bilateral

Para testar $\begin{cases} H_0 : \mu = \mu_0 \\ H_a : \mu \neq \mu_0 \end{cases}$, temos as seguintes situações:

- i) Se σ for conhecido, rejeita-se H_0 se $|Z| > z_{\alpha/2}$ ao nível $100(\alpha)\%$ de significância;
- ii) Se σ for desconhecido, rejeita-se H_0 se $|T| > t_{\alpha/2}(n-1)$ ao nível $100(\alpha)\%$ de significância.

Igualdade *versus* maior - teste unilateral à direita

Para testar $\begin{cases} H_0 : \mu = \mu_0 \\ H_a : \mu > \mu_0 \end{cases}$, temos as seguintes situações:

- i) Se σ for conhecido, rejeita-se H_0 se $Z > z_\alpha$ ao nível $100(\alpha)\%$ de significância;
- ii) Se σ for desconhecido, rejeita-se H_0 se $T > t_\alpha(n-1)$ ao nível $100(\alpha)\%$ de significância.

Igualdade *versus* menor - teste unilateral à esquerda

Para testar $\begin{cases} H_0 : \mu = \mu_0 \\ H_a : \mu < \mu_0 \end{cases}$, temos as seguintes situações:

- i) Se σ for conhecido, rejeita-se H_0 se $Z < -z_\alpha$ ao nível $100(\alpha)\%$ de significância;
- ii) Se σ for desconhecido, rejeita-se H_0 se $T < -t_\alpha(n-1)$ ao nível $100(\alpha)\%$ de significância.

Observações:

- 1) Evidentemente, se o valor da estatística estiver fora dos intervalos indicados acima, a decisão será contrária, isto é, não rejeita H_0 ;
- 2) Para $n > 30$, tem-se que $t_\alpha(n-1) = z_\alpha$, ou ainda, $t_{\alpha/2}(n-1) = z_{\alpha/2}$.

Algoritmo para construir testes de hipóteses

1. Extrair os dados disponíveis;
2. Estabelecer as hipóteses nula e alternativa;
3. Decidir qual estatística será utilizada no teste - dependendo se conhece ou não o desvio-padrão;
4. Fixar a probabilidade α e encontrar o valor crítico;
5. Calcular a estatística do teste;
6. Comparar o valor obtido com o valor crítico e decidir, conforme regra de decisão, se rejeita ou não a hipótese H_0 .

Código no *software* R para realizar testes de hipóteses para a média:

```
# Função para realizar testes de hipóteses para a média
> testeHipmedia<-function(x,media,alpha,decisao,desvio) {
n<-length(x)
if(decisao=="diferente") {
if(!missing(desvio)) {
critico=qnorm(alpha/2, lower.tail=FALSE) # valor crítico
z<-sqrt(n)*(mean(x)-media)/desvio }
if(missing(desvio)) {
```

```

critico<-qt(1-alpha/2, n-1)
z<-sqrt(n)*(mean(x)-media)/sd(x) }
Decisao=if(abs(z) > critico) { "Rejeito H0" } else
"Não Rejeito H0" }
if(decisao=="maior") {
if(!missing(desvio)) {
critico=qnorm(alpha, lower.tail=FALSE) # valor crítico
z<-sqrt(n)*(mean(x)-media)/desvio }
if(missing(desvio)) {
critico<-qt(1-alpha, n-1)
z<-sqrt(n)*(mean(x)-media)/sd(x) }
Decisao=if(z > critico) { "Rejeito H0" } else
"Não Rejeito H0" }
if(decisao=="menor") {
if(!missing(desvio)) {
critico=qnorm(alpha, lower.tail=FALSE) # valor crítico
z<-sqrt(n)*(mean(x)-media)/desvio }
if(missing(desvio)) {
critico<-qt(1-alpha, n-1)
z<-sqrt(n)*(mean(x)-media)/sd(x) }
Decisao=if(z < -critico) { "Rejeito H0" } else "Não Rejeito H0" }
return(Decisao) }

```

A função `testeHipmedia` tem como argumentos o vetor de observações “x”, a média a ser testada “media”, o nível de significância “alpha”, a decisão a ser tomada “decisao”, sendo ela: “diferente” para testar se difere, “maior” para o teste unilateral à direita e “menor” para o teste unilateral à esquerda. Por fim, temos o desvio-padrão. De forma análoga à função feita para o intervalo de confiança, caso o argumento “desvio” não seja preenchido, o programa entende que o desvio-padrão é desconhecido.

Exemplo 43. Considere o consumo de energia mensal de 10 famílias, em que o desvio-padrão é conhecido e igual a 15 kWh.

113	142	126	132	98	109	150	132	121	143
-----	-----	-----	-----	----	-----	-----	-----	-----	-----

Estamos interessados em testar se:

- a)** A média de consumo pode ser considerada igual a 120 kWh, com 90% de confiança, ou é diferente de 120 kWh?
- b)** Com 95% de confiança, o consumo médio de energia é igual a 115 kWh ou maior?
- c)** Com 90% de confiança, a média de consumo de energia é menor ou igual a 130 kWh?

Solução:

a) A média de consumo pode ser considerada igual a 120 kWh, com 90% de confiança, ou é diferente de 120 kWh?

1. Obtendo os dados: $n = 10$, $\sigma = 15$, $\bar{X} = 126,6$, $\mu_0 = 120$ (valor para comparação);
2. Hipóteses: $\begin{cases} H_0 : \mu = 120 \\ H_a : \mu \neq 120 \end{cases}$;
3. Estatística: $Z = \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma}$, pois o desvio-padrão é conhecido;
4. Fixar $\alpha = 10\%$ (dado na questão), logo pela tabela da distribuição Normal, o valor crítico é $z_{0,05} = 1,65$ (valor de $z_{\alpha/2}$ por ser teste bilateral);
5. Cálculo da estatística: $Z = \sqrt{10} \frac{126,6 - 120}{15} \approx 1,39$;
6. Decisão: Pela regra de decisão, se $|Z| > z_{0,05}$ rejeita-se H_0 . Como $Z \approx 1,39 \not> 1,65 = z_{0,05}$, então não rejeitamos H_0 .

Isto é, com 90% de confiança não rejeitamos a hipótese de que o consumo médio de energia das famílias em questão é igual a 120 kWh, mesmo tendo a média amostrada diferente desse valor.

```
> x<-c(113,142,126,132,98,109,150,132,121,143)
> testeHipmedia(x,120,0.1,"diferente",15)
[1] "Não Rejeito H0"
```

b) Com 95% de confiança, o consumo médio de energia é igual a 115 kWh ou maior?

1. Obtendo os dados: são os mesmos do caso anterior, com exceção de $\mu_0 = 115$ (valor para comparação);
2. Hipóteses: $\begin{cases} H_0 : \mu = 115 \\ H_a : \mu > 115 \end{cases}$;
3. Estatística: $Z = \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma}$, a mesma do caso anterior;
4. Fixar $\alpha = 5\%$, dado na questão. Pela tabela da distribuição Normal, o valor crítico é $z_{0,05} = 1,65$ (é z_{α} por ser teste unilateral);
5. Cálculo da estatística: $Z = \sqrt{10} \frac{126,6 - 115}{15} \approx 2,45$;

6. Decisão: Pela regra de decisão, se $Z > z_{0,05}$ rejeita-se H_0 . Como $Z \approx 2,45 > 1,65 = z_{0,05}$, rejeitamos H_0 .

```
> testeHipmedia(x,115,0.05,"maior",15)
[1] "Rejeito H0"
```

Isto é, com 95% de confiança rejeitamos a hipótese de igualdade (H_0) e concluímos que o consumo médio de energia é maior que 115 kWh.

c) Com 90% de confiança, a média de consumo de energia é menor ou igual a 130 kWh?

1. Obtendo os dados: são os mesmos do caso anterior, com exceção de $\mu_0 = 130$ (valor para comparação);
2. Hipóteses: $\begin{cases} H_0 : \mu = 130 \\ H_a : \mu < 130 \end{cases}$;
3. Estatística: $Z = \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma}$, a mesma do caso anterior;
4. Fixar $\alpha = 10\%$, dado na questão. Pela tabela da distribuição Normal, o valor crítico é $-z_{0,10} = -1,28$ ($-z_\alpha$ por ser teste unilateral);
5. Cálculo da estatística: $Z = \sqrt{10} \frac{126,6 - 130}{15} \approx -0,72$;
6. Decisão: Pela regra de decisão, se $Z < -z_{0,10}$ rejeita-se H_0 . Como $Z \approx -0,72 \not< -1,28 = -z_{0,10}$, não rejeitamos H_0 .

```
> testeHipmedia(x,130,0.1,"menor",15)
[1] "Não Rejeito H0"
```

Isto é, com 90% de confiança não rejeitamos a hipótese de igualdade (H_0), ou seja, o consumo médio de energia não difere de 130 kWh a 10% de significância.

Exemplo 44. Considerando os consumos de energia mensal, em kWh, de 10 famílias, em que o desvio-padrão é desconhecido, estamos interessados em testar se:

- a) A média de consumo pode ser considerada igual a 100 kWh, com 90% de confiança, ou é diferente de 100 kWh?
- b) Com 90% de confiança, o consumo médio de energia é igual a 100 kWh ou maior?
- c) Com 90% de confiança, a média de consumo de energia é menor ou igual a 100 kWh?

Os dados são os mesmos do exemplo anterior:

113	142	126	132	98	109	150	132	121	143
-----	-----	-----	-----	----	-----	-----	-----	-----	-----

Solução:

A estatística usada neste caso é: $T = \sqrt{n} \frac{\bar{X} - \mu_0}{s}$, em que $n = 10$, $\bar{X} = 126,6$ e $s \approx 16,52$.

a) O objetivo é verificar se o consumo médio desses moradores é igual a 100 kWh, o que equivale a testar as hipóteses:

$$\begin{cases} H_0 : \mu = 100 \\ H_a : \mu \neq 100 \end{cases}$$

Temos que $\mu_0 = 100$, e o valor da estatística do teste é $T = \sqrt{10} \frac{126,6 - 100}{16,52} \approx 5,09$.

Pela tabela da distribuição t -Student, obtemos $t_{0,05}(9) = 1,83$. Pela regra de decisão apresentada, se $|T| > t_{0,05}(9)$ rejeita-se H_0 . Como isso ocorreu, rejeitamos H_0 .

```
> testeHipmedia(x,100,0.1,"diferente")
[1] "Rejeito H0"
```

b) O objetivo é verificar se o consumo médio desses moradores é maior que 100 kWh. Isto é, testar as seguintes hipóteses:

$$\begin{cases} H_0 : \mu = 100 \\ H_a : \mu > 100 \end{cases}$$

Pelo caso anterior, temos que $T \approx 5,09$ e, pela tabela da distribuição t -Student, obtemos $t_{0,10}(9) = 1,38$.

Pela regra de decisão apresentada, se $T > t_{0,10}(9)$ rejeita-se H_0 . Como isso ocorreu, rejeitamos H_0 .

```
> testeHipmedia(x,100,0.1,"maior")
[1] "Rejeito H0"
```

c) O objetivo é verificar se o consumo médio desses moradores é menor que 100 kWh. Isto equivale a testar as hipóteses:

$$\begin{cases} H_0 : \mu = 100 \\ H_a : \mu < 100 \end{cases}$$

Pelo caso anterior, temos que $T \approx 5,09$ e $t_{0,10}(9) = 1,38$.

Pela regra de decisão apresentada, se $T < -t_{0,10}(9)$ rejeita-se H_0 . Como isso não ocorreu, não rejeitamos H_0 .

```
> testeHipmedia(x,100,0.1,"menor")
[1] "Não Rejeito H0"
```

5.4 Proporção populacional

Situação-problema:

“A direção de uma instituição de ensino (IE) precisa determinar a proporção de seus alunos que utilizam o transporte público. Entrevistar todos os alunos é inviável, então tomou-se uma amostra de 25 alunos e a partir dela pretende-se obter respostas para as seguintes questões:

a) Com 95% de confiança, qual a proporção de alunos que utilizam o transporte público?

b) Tem-se que uma linha de ônibus atende a IE e se a proporção de alunos que utilizam o transporte público for inferior a 30%, com 95% de confiança, o serviço será suspenso.

c) Pode-se afirmar, com 99% de confiança, que 1/3 dos alunos da instituição em questão utilizam este tipo de transporte?

Tem-se que, dentre os entrevistados, 9 responderam afirmativamente”.

O valor exato dessa porcentagem só seria conhecido se fossem entrevistados todos os alunos. Com base na amostra, teremos uma estimativa da porcentagem, que é obtida pela razão entre o número de alunos que responderam afirmativamente e o total de entrevistados. Mas como em toda estimativa há erro, o intervalo de confiança fornece uma faixa plausível para a proporção populacional, construída a partir de um procedimento com a cobertura especificada. Para responder às questões b) e c), utilizaremos testes de hipóteses.

Proporção é sempre um valor entre 0 e 1. Pode aparecer multiplicado por 100 e então acompanhado do símbolo % (porcentagem).

A seguir, apresentamos métodos para obter a resposta da primeira questão, bem como a generalização dos métodos.

5.4.1 Intervalo de confiança

Denotaremos a proporção obtida da amostra por $\hat{p}$ e dizemos que esta é uma estimativa da proporção real p , que também é denominada de proporção verdadeira ou de proporção da população.

O intervalo de confiança ao nível de significância α para a proporção p , é dado por:

$$\text{IC}[p, 100(1 - \alpha)\%] = \hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}},$$

ou então,

$$\text{IC}[p, 100(1 - \alpha)\%] = \left(\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right),$$

em que $\hat{p}$ é a estimativa da proporção obtida da amostra, α é o nível de significância que acarreta no valor de $z_{\alpha/2}$ tabelado (ver Tabela 5.2), e n é o total de dados da amostra.

O valor de $z_{\alpha/2}$ é oriundo da distribuição Normal de probabilidade. A utilização dessa distribuição é justificada pela Lei dos Grandes Números, pois, para n grande, temos que:

$$\hat{p} \rightarrow N \left(p, \frac{p(1-p)}{n} \right).$$

Esta verdade estatística, que não será aqui demonstrada, corrobora a utilização dos valores da distribuição de probabilidade Normal para a estimação dos intervalos.

Os níveis de confiança utilizados dependem do interesse do usuário, mas os mais comuns são 90%, 95% e 99%, como também no caso da média, os quais podem variar dependendo da área de atuação e da precisão desejada.

Considere que y é o número de elementos portadores de certa característica, n é o tamanho da amostra e α é o nível de significância. O comando no R para obter o intervalo de confiança para a proporção é:

```
# Função para o cálculo do IC
> ICprop<-function(y,n,alpha) {
p<-y/n
z<-qnorm(alpha/2, lower.tail=FALSE)
LI<-max(p-z*sqrt((p*(1-p))/n),0)
LS<-min(p+z*sqrt((p*(1-p))/n),1)
return(c(LI,LS)) }
```

Exemplo 45. *Considere a situação-problema apresentada no início desta seção. O primeiro interesse é obter o intervalo de confiança ao nível de significância de 5% para a proporção de alunos da instituição que utilizam o transporte público, tendo como resultado da amostragem que 9 dos 25 alunos responderam afirmativamente.*

Solução:

Nível de confiança = 95% $\Rightarrow \alpha = 5\% \Rightarrow z_{\alpha/2} = 1,96$ (Tabela 5.2);

$n = 25$;

$\hat{p} = \frac{9}{25} = 0,36$.

Assim,

$$\begin{aligned} \text{IC}[p, 100(1 - \alpha)\%] &= \left(\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right) \\ \text{IC}[p, 95\%] &= \left(0,36 - 1,96 \sqrt{\frac{0,36 \times 0,64}{25}}; 0,36 + 1,96 \sqrt{\frac{0,36 \times 0,64}{25}} \right) \\ &= (0,36 - 0,19; 0,36 + 0,19) \\ &= (0,17; 0,55). \end{aligned}$$

Ou seja, com 95% de confiança, estima-se que a proporção de alunos que utilizam o transporte público esteja entre 17% e 55%.

```
> ICprop(9,25,0.05)
[1] 0.1718435 0.5481565
```

Para calcular intervalos de confiança para essa proporção com outros níveis de significância, basta alterar o valor de $z_{\alpha/2}$ adequadamente ao valor correspondente ao nível de confiança desejado.

Os itens b) e c) da situação-problema serão resolvidos posteriormente.

Exemplo 46. *O setor de controle de qualidade de uma fábrica de chinelos, retirou uma amostra de 100 peças para verificar a resistência do produto. No teste, 13 chinelos apresentaram problemas.*

a) *Com 90% de confiança, qual a proporção de chinelos defeituosos dessa fábrica?*

b) *Se a empresa produz 5.900 peças/dia, com 90% de confiança qual a quantidade/dia de peças defeituosas?*

Solução:

a) Precisamos construir o $\text{IC}[p, 90\%]$. Para tanto, temos:

Nível de confiança = 90% $\Rightarrow \alpha = 10\% \Rightarrow z_{\alpha/2} = 1,65$ (Tabela 5.2);
 $n = 100$ e $\hat{p} = \frac{13}{100} = 0,13$.

Assim,

$$\begin{aligned} \text{IC}[p, 100(1 - \alpha)\%] &= \left(\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right) \\ \text{IC}[p, 90\%] &= \left(0,13 - 1,65 \sqrt{\frac{0,13 \times 0,87}{100}}; 0,13 + 1,65 \sqrt{\frac{0,13 \times 0,87}{100}} \right) \\ &= (0,13 - 0,055; 0,13 + 0,055) \\ &= (0,075; 0,185). \end{aligned}$$

Ou seja, com 90% de confiança, estima-se que a proporção de chinelos com defeito na fábrica seja menor que 20%, ou em termos mais específicos, que fique entre 7,5% e 18,5%.

```
> ICprop(13,100,0.1)
[1] 0.0747 0.1853
```

b) Neste caso, basta multiplicar o total de peças produzidas pelos limitantes do $IC[p, 90\%]$, ou seja,

$$IC[\text{Defeituosos/dia}, 90\%] = (0,07 \times 5.900; 0,19 \times 5.900) = (442; 1.092).$$

Sabendo o custo da produção de cada peça, é possível obter os valores do prejuízo que a fábrica tem com a produção de peças defeituosas. E se a quantidade de peças, ou mesmo o total do prejuízo, forem considerados prejudiciais à “saúde” financeira da empresa, medidas de correção poderão ser adotadas.

Desta forma, percebemos que um cálculo simples decorrente de uma amostragem simples pode mensurar e auxiliar na detecção de problemas.

Todavia, como os intervalos são para a proporção e como mencionamos no início da Seção, a proporção é um valor entre 0 e 1. Se o resultado do cálculo do LI for menor que zero, deverá ser atribuído o valor zero como LI; e se o cálculo para o LS for maior que 1, o valor 1 deverá ser atribuído como LS. Isto por uma questão de coerência, mesmo porque não faz sentido termos a representação de um intervalo de confiança para a proporção como $(0,5; 1,2)$, sendo que seu valor nunca será superior a 1.

5.4.2 Teste de hipóteses

Para responder às questões b) e c) da situação-problema, testes de hipóteses serão montados.

O nível de significância para os testes, muitas vezes, não é designado. Nestes casos, estipula-se uma probabilidade aceitável, de acordo com o problema, como mencionamos anteriormente.

Apresentaremos a seguir os passos para realizar o teste de hipóteses para a proporção e, em seguida, alguns exemplos serão resolvidos.

Algoritmo do teste de hipóteses

- i) Obter os dados;
- ii) Montar as hipóteses;
- iii) Estabelecer o nível de significância α ;
- iv) Calcular a estatística do teste;

v) Tomar a decisão, baseado na regra de decisão correta.

Estatística

No teste da proporção, a estatística do teste é dada por:

$$Z = \frac{\hat{p} - p_0}{\sigma_0},$$

em que $\sigma_0 = \sqrt{\frac{p_0(1-p_0)}{n}}$, sendo n o número de dados e p_0 o valor da proporção fixado para comparação.

Regra de decisão

As regras de decisão são sempre considerando o nível α de significância.

a) Para testar $\begin{cases} H_0 : p = p_0 \\ H_a : p \neq p_0 \end{cases}$, rejeita-se H_0 se $|Z| > z_{\alpha/2}$;

b) Para testar $\begin{cases} H_0 : p = p_0 \\ H_a : p > p_0 \end{cases}$, rejeita-se H_0 se $Z > z_{\alpha}$;

c) Para testar $\begin{cases} H_0 : p = p_0 \\ H_a : p < p_0 \end{cases}$, rejeita-se H_0 se $Z < -z_{\alpha}$.

O teste apresentado em a) é denominado teste bicaudal (ou bilateral) e os apresentados em b) e c) são denominados testes unicaudais (ou unilaterais) à direita e à esquerda, respectivamente.

Código no *software* R para realizar o teste de hipóteses para a proporção:

```
# Função para realizar o teste de hipóteses
> testeHiprop<-function(y,n,p0,alpha,decisao) {
p<-y/n
z<-(p-p0)/sqrt((p0*(1-p0)/n))
if(decisao=="diferente"){
critico=qnorm(alpha/2, lower.tail=FALSE) # valor crítico
Decisao=if(abs(z) > critico) { "Rejeito H0" } else
"Não Rejeito H0" }
if(decisao=="maior") {
critico=qnorm(alpha, lower.tail=FALSE) # valor crítico
Decisao=if(z > critico) { "Rejeito H0" } else
"Não Rejeito H0" }
if(decisao=="menor") {
critico=qnorm(alpha, lower.tail=FALSE) # valor crítico
Decisao=if(z < -critico) { "Rejeito H0" } else
```

```
"Não Rejeito H0" }  
return(Decisao) }
```

A função `testeHipop` tem como argumentos o número de eventos de interesse “y”, o número total “n”, o valor da hipótese a ser testada “p0”, o nível de significância “alpha”, a decisão a ser tomada “decisao”, sendo ela: “diferente” para testar se difere, “maior” para o teste unilateral à direita e “menor” para o teste unilateral à esquerda.

Perante a metodologia apresentada, temos condições de resolver os itens b) e c) da situação-problema.

Exemplo 47. *Suponha que 9 dos 25 entrevistados responderam afirmativamente à utilização do transporte público. Sabe-se que a linha de ônibus que atende a IE será suspensa se a proporção de alunos que utilizam o transporte público for inferior a 30%, com 95% de confiança. Os dados fornecem evidências de que a linha de ônibus será mantida?*

Solução:

Teste de hipóteses com nível de significância de 5%, com $p_0 = 0,3$.

1. Dados: $n = 25$ e $y = 9$. Logo, $\hat{p} = \frac{9}{25} = 0,36$. Além disso,

$$p_0 = 0,3;$$

$$\sigma_0 = \sqrt{\frac{p_0(1-p_0)}{n}} = \sqrt{\frac{0,3(1-0,3)}{25}} \approx 0,092.$$

2. Montar as hipóteses: A hipótese nula é sempre da igualdade, enquanto que, neste caso, a hipótese alternativa é unilateral à esquerda, portanto,

$$\begin{cases} H_0 : p = 0,3 \\ H_a : p < 0,3 \end{cases}$$

3. O nível de significância α estabelecido pelo problema: Como $\alpha = 5\%$, logo o valor crítico é $-z_{0,05} = -1,65$.

4. Estatística do teste: Seu cálculo é feito diretamente pela aplicação da fórmula, sendo assim,

$$Z = \frac{\hat{p} - p_0}{\sigma_0} = \frac{0,36 - 0,3}{0,092} \approx 0,652.$$

5. Decisão: Baseado na regra de decisão, que é “Rejeita-se H_0 se $Z < -z_\alpha$ ao nível α de significância”, como $0,652 \not< -1,65$, então não se rejeita H_0 . Portanto, temos indícios de que a proporção de alunos que utilizam o transporte coletivo não é menor que 30% e, portanto, a linha de ônibus será mantida.

```
> testeHipop(9,25,0.3,0.05,"menor")
[1] "Não Rejeito H0"
```

Continuando a resolução dos itens da situação-problema, temos:

Exemplo 48. *Sendo que 9 dos 25 entrevistados responderam afirmativamente à utilização do transporte público, pode-se afirmar com 99% de confiança que 1/3 dos alunos da instituição em questão utilizam este tipo de transporte?*

Solução:

Teste de hipóteses com nível de significância de 1% e $p_0 = 1/3$.

1. Dados: $n = 25$ e $y = 9$. Logo, $\hat{p} = \frac{9}{25} = 0,36$. Ademais,

$$p_0 = 1/3;$$

$$\sigma_0 = \sqrt{\frac{p_0(1-p_0)}{n}} = \sqrt{\frac{1/3(1-1/3)}{25}} \approx 0,094.$$

2. Montar as hipóteses: A hipótese nula é sempre a da igualdade, enquanto que, neste caso, a hipótese alternativa é a bilateral, portanto,

$$\begin{cases} H_0 : p = 1/3 \\ H_a : p \neq 1/3 \end{cases}$$

3. O nível de significância α estabelecido pelo problema: Como $\alpha = 1\%$, logo o valor crítico é $z_{0,005} = 2,58$.
4. Estatística do teste: Seu cálculo é feito diretamente por aplicação da fórmula, sendo assim,

$$Z = \frac{\hat{p} - p_0}{\sigma_0} = \frac{0,36 - 1/3}{0,094} \approx 0,2837.$$

5. Decisão: Baseado na regra de decisão, que é “Rejeita-se H_0 se $|Z| > z_{\frac{\alpha}{2}}$ ao nível α de significância”, como $0,2837 \not> 2,58$, então não se rejeita H_0 . Portanto, temos indícios de que a proporção de alunos que utilizam o transporte coletivo não é diferente de 1/3.

```
> testeHipop(9,25,1/3,0.01,"diferente")
[1] "Não Rejeito H0"
```

5.5 Variância populacional

Situação-problema:

“Uma fábrica produz parafusos cujo diâmetro médio é 2 cm. Para o controle de qualidade, a variabilidade não pode superar 0,05 cm por parafuso. Caso esse valor seja superado, a produção é parada e a máquina é regulada. Porém, é inviável medir o diâmetro de todos os parafusos para obter a variabilidade, então decidiu-se tomar uma amostra de 20 parafusos a cada hora, de forma aleatória, para verificar a variabilidade.

Duas questões ficam em aberto:

- a) Com 95% de confiança, esta variabilidade obtida está entre quais valores?*
- b) Tem-se a informação de que a variabilidade no mês passado era de 0,01 cm por unidade. Atualmente, a variabilidade permanece inalterada?”*

Para responder a essas questões, temos as metodologias de intervalo de confiança e teste de hipóteses para a variância, ou para o desvio-padrão.

Por motivos interpretativos, apresentaremos a metodologia de intervalo de confiança já adaptada para o desvio-padrão, valendo lembrar que, para utilizá-la para a variância, basta elevar ao quadrado.

5.5.1 Intervalo de confiança

O intervalo de confiança para o desvio-padrão é dado por:

$$\sqrt{\frac{(n-1)s^2}{\chi_{(n-1)}^2(1-\alpha/2)}} \leq \sigma \leq \sqrt{\frac{(n-1)s^2}{\chi_{(n-1)}^2(\alpha/2)}},$$

em que s é o desvio-padrão amostral, n é o tamanho da amostra e $\chi_{(n-1)}^2(1-\alpha/2)$ é o valor relacionado à probabilidade de cobertura, apresentado na tabela da distribuição Qui-quadrado (Tabela A3 do Apêndice) com $n-1$ graus de liberdade.

Ao valor $\sqrt{\frac{(n-1)s^2}{\chi_{(n-1)}^2(1-\alpha/2)}}$ denominamos Limite ou Limitante Inferior do intervalo (LI); e ao valor $\sqrt{\frac{(n-1)s^2}{\chi_{(n-1)}^2(\alpha/2)}}$ denominamos Limite ou Limitante Superior (LS).

Código no *software* R para obter o intervalo de confiança do desvio-padrão:

```
# Função para o cálculo do IC
> ICdesvio<-function(x,alpha,s,n) {
  if(!missing(x)) { # Caso haja o vetor de observação x, calcule
    n<-length(x)
    s<-sd(x) }
  LI<-sqrt(((n-1)*s^2)/qchisq(1-alpha/2,n-1))
```

```
LS<-sqrt(((n-1)*s^2)/qchisq(alpha/2,n-1))
return(c(LI,LS)) }
```

A função `ICdesvio` tem como argumentos o vetor de observações “x”, o nível de significância “alpha”, o desvio-padrão amostral “s” e o tamanho da amostra “n”. Essa função permite obter o intervalo de confiança do desvio-padrão considerando um vetor de observações “x”, ou através dos valores do desvio-padrão e do tamanho amostral. Caso “x” não seja preenchido, a função irá considerar os valores “s” e “n” declarados.

Exemplo 49. Considere uma amostra de 20 parafusos ($n = 20$), que apresentou desvio-padrão amostral $s = 0,015$. Com um nível de significância $\alpha = 5\%$, determine o intervalo de confiança para:

- a) o desvio-padrão;
- b) a variância.

Solução:

a) Pela metodologia apresentada acima, temos que o intervalo de confiança de 95% para o desvio-padrão é dado por:

$$\begin{aligned} \sqrt{\frac{(20-1) \times 0,015^2}{\chi_{(20-1)}^2(1-0,05/2)}} &\leq \sigma \leq \sqrt{\frac{(20-1) \times 0,015^2}{\chi_{(20-1)}^2(0,05/2)}} \\ \sqrt{\frac{19 \times 0,015^2}{\chi_{(19)}^2(0,975)}} &\leq \sigma \leq \sqrt{\frac{19 \times 0,015^2}{\chi_{(19)}^2(0,025)}} \\ \sqrt{\frac{19 \times 0,015^2}{32,852}} &\leq \sigma \leq \sqrt{\frac{19 \times 0,015^2}{8,907}} \\ 0,0114 &\leq \sigma \leq 0,0219. \end{aligned}$$

Desta forma, obtemos que:

$$IC[\sigma, 95\%] = (0,0114; 0,0219).$$

```
> ICdesvio(,0.05,0.015,20)
[1] 0.0114 0.0219
```

b) Para a variância σ^2 , o intervalo de confiança é obtido elevando ao quadrado o intervalo de confiança do desvio-padrão. Assim,

$$IC[\sigma^2, 95\%] = (0,0114^2; 0,0219^2) = (0,00013; 0,00048).$$

```
> ICdesvio(,0.05,0.015,20)^2
[1] 0.00013 0.00048
```

5.5.2 Teste de hipóteses

Estatística

Para testar a variância σ^2 , considere a estatística:

$$Q = \frac{(n-1)s^2}{\sigma^2}.$$

Regra de decisão

a) Para testar $\begin{cases} H_0 : \sigma^2 = \sigma_0^2 \\ H_a : \sigma^2 \neq \sigma_0^2 \end{cases}$ (teste bilateral),

rejeita-se H_0 se $Q > \chi_{(n-1)}^2(1 - \alpha/2)$ ou $Q < \chi_{(n-1)}^2(\alpha/2)$ ao nível $100(\alpha)\%$ de significância;

b) Para testar $\begin{cases} H_0 : \sigma^2 = \sigma_0^2 \\ H_a : \sigma^2 > \sigma_0^2 \end{cases}$ (teste unilateral à direita),

rejeita-se H_0 se $Q > \chi_{(n-1)}^2(1 - \alpha)$ ao nível $100(\alpha)\%$ de significância;

c) Para testar $\begin{cases} H_0 : \sigma^2 = \sigma_0^2 \\ H_a : \sigma^2 < \sigma_0^2 \end{cases}$ (teste unilateral à esquerda),

rejeita-se H_0 se $Q < \chi_{(n-1)}^2(\alpha)$ ao nível $100(\alpha)\%$ de significância.

Código no *software* R para realizar o teste de hipóteses para a variância:

```
# Função para realizar o teste de hipóteses para a variância
> testeHipvar<-function(x,sigma2,alpha,decisao,s2,n) {
  if(!missing(x)) {
    n<-length(x)
    s2<-var(x) }
  Q<-(n-1)*s2/sigma2 # estatística de teste
  if(decisao=="diferente") {
    critico1<-qchisq(1-alpha/2,n-1) # Quantil 1-alpha/2 da Qui-quadrado
    critico2<-qchisq(alpha/2,n-1)   # Quantil alpha/2 da Qui-quadrado
    Decisao=if(Q > critico1 | Q < critico2) { "Rejeito H0" } else
    "Não Rejeito H0" }
  if(decisao=="maior") {
    critico<-qchisq(1-alpha,n-1) # Quantil 1-alpha da Qui-quadrado
    Decisao=if(Q > critico) { "Rejeito H0" } else
    "Não Rejeito H0" }
  if(decisao=="menor") {
    critico<-qchisq(alpha,n-1)   # Quantil alpha da Qui-quadrado
    Decisao=if(Q < critico) { "Rejeito H0" } else
    "Não Rejeito H0" }
  return(Decisao) }
```

A função `testeHipvar` tem como argumentos o vetor de observações “x”, a variância a ser testada “sigma2”, o nível de significância “alpha”, a decisão a ser tomada “decisao”, sendo ela: “diferente” para testar se difere, “maior” para o teste unilateral à direita e “menor” para o teste unilateral à esquerda. Por fim, de forma análoga às outras funções, caso o vetor “x” não seja preenchido, a função considera a variância amostral dada por “s2” e o tamanho amostral “n”.

Exemplo 50. Considere uma amostra da altura, em cm, de 15 adolescentes com a mesma idade, cujos dados são apresentados a seguir.

153	163	162	142	164	156	168	152	169	148	159	157	170	162	171
-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----

O objetivo da análise é verificar se, ao nível de significância de 10%, a variância entre as alturas dos adolescentes pode ser considerada:

- a) Igual ou diferente de 50 cm²;
- b) Igual ou maior que 50 cm²;
- c) Igual ou menor que 50 cm².

Solução:

a) Se a variância dos tamanhos é igual a 50.

$$\text{Testar: } \begin{cases} H_0 : \sigma^2 = 50 \\ H_a : \sigma^2 \neq 50 \end{cases} .$$

O valor da estatística do teste é: $Q = \frac{(n-1)s^2}{\sigma^2} = \frac{(15-1) \times 71,78}{50} = 20,0984$.

Pela tabela da distribuição Qui-quadrado, obtemos os valores críticos:

$$\chi_{14}^2(0,95) = 23,685 \text{ e } \chi_{14}^2(0,05) = 6,571.$$

Pela regra de decisão apresentada, se $Q > \chi_{14}^2(0,95)$ ou $Q < \chi_{14}^2(0,05)$, rejeita-se H_0 . Como isso não ocorreu, não rejeitamos H_0 .

```
> x<-c(153,163,162,142,164,156,168,152,169,148,159,157,170,
162,171)
> testeHipvar(x,50,0.1,"diferente")
[1] "Não Rejeito H0"
```

b) Se a variância dos tamanhos é maior que 50.

$$\text{Testar: } \begin{cases} H_0 : \sigma^2 = 50 \\ H_a : \sigma^2 > 50 \end{cases} .$$

O valor da estatística do teste é $Q = 20,0984$ e o valor crítico é $\chi_{14}^2(0,90) = 21,064$.

Pela regra de decisão apresentada, se $Q > \chi_{14}^2(0,90)$ rejeita-se H_0 . Como isso não ocorreu, não rejeitamos H_0 .

```
> testeHipvar(x,50,0.1,"maior")
[1] "Não Rejeito H0"
```

c) Se a variância dos tamanhos é menor que 50.

$$\text{Testar: } \begin{cases} H_0 : \sigma^2 = 50 \\ H_a : \sigma^2 < 50 \end{cases} .$$

O valor da estatística do teste é $Q = 20,0984$ e o valor crítico é $\chi_{14}^2(0,10) = 7,789$.

Pela regra de decisão apresentada, se $Q < \chi_{14}^2(0,10)$ rejeita-se H_0 . Como isso não ocorreu, não rejeitamos H_0 .

```
> testeHipvar(x,50,0.1,"menor")
[1] "Não Rejeito H0"
```

5.6 Relação entre teste de hipóteses e intervalo de confiança

Suponha que estamos interessados em realizar um teste de hipóteses para a média, ao nível de significância de 5%, no qual as hipóteses envolvidas são *igualdade contra diferença*. Dispomos do intervalo de confiança para essa média, construído também com o nível de 5%. Então, a decisão em relação ao teste de hipóteses é:

“Se o valor ao qual está se comparando a média, pertencer ao intervalo, então não rejeite a hipótese de igualdade; caso contrário, rejeite-a.”

Exemplo 51. Temos que o intervalo de confiança para a média é $IC[\mu, 95\%] = (18,3; 22,9)$ e queremos testar as hipóteses:

$$\begin{cases} H_0 : \mu = 22 \\ H_a : \mu \neq 22 \end{cases}$$

ao nível de significância de 5%.

Solução:

Observe que o valor $\mu_0 = 22 \in IC[\mu, 95\%]$, então não rejeitamos H_0 , ou seja, não temos evidências para rejeitar a hipótese de igualdade da média.

Temos também que, com 95% de confiança, não podemos rejeitar a hipótese da média assumir qualquer valor entre 18,3 e 22,9, pois a 5% de significância, qualquer valor entre esses pertence ao intervalo de confiança.

Exemplo 52. Testar as hipóteses: $\begin{cases} H_0 : \mu = 2,8 \\ H_a : \mu \neq 2,8 \end{cases}$ ao nível de significância de 1%.

Solução:

Podemos utilizar o mesmo método aplicado no exemplo anterior, isto é, calcular o intervalo de confiança e verificar se ele contém o valor crítico. Neste caso, temos: $IC[\mu, 99\%] = (2,9; 4,2)$.

Assim, $\mu_0 = 2,8$ e como $\mu_0 \notin IC[\mu, 99\%]$, temos evidências para rejeitar a hipótese de igualdade da média; isto é, ao nível de 1% de significância, há evidências de que a média é diferente de 2,8.

5.7 Tipos de erros

Os erros em testes de hipóteses são determinados em termos da hipótese nula (H_0) e podem ser dois:

- Rejeitar H_0 e H_0 ser verdadeira;
- Aceitar H_0 e H_0 ser falsa.

Ao primeiro, denominamos erro Tipo I; e ao segundo, erro Tipo II. A cada um desses erros está associada uma probabilidade, representada por α e β , respectivamente. Veja o quadro a seguir.

Decisão	Realidade	
	H_0 Verdadeira	H_0 Falsa
Não rejeitar H_0	Decisão Correta ($1 - \alpha$)	Erro Tipo II (β)
Rejeitar H_0	Erro Tipo I (α)	Decisão Correta ($1 - \beta$)

No caso, α é denominado nível de significância do teste e $1 - \beta$ é o poder do teste.

O problema reside no fato de não conhecermos a realidade, então se a decisão for “Não rejeitar H_0 ”, poderemos ter tomado a decisão correta ou cometido o erro Tipo II; e ainda, se a decisão for “Rejeitar H_0 ”, poderemos estar tomando a decisão correta ou cometendo o erro Tipo I.

Para que o teste de hipóteses (ou regra de decisão) seja considerado bom, ele deve ser tal que os possíveis erros na tomada de decisão sejam mínimos. Se pudéssemos ter $\alpha = \beta = 0$, teríamos a situação ideal, mas considerando amostras isso não é possível. Devemos tomar cuidado, pois, geralmente, o decréscimo de uma das probabilidades de erro pode acarretar no acréscimo da outra. Então, o mais recomendado é controlar o erro mais sério.

Veja a seguinte situação: “Um cliente busca a financeira para obter uma linha de crédito. A financeira, por sua vez, está preocupada em classificar esse cliente em

bom pagador ou mau pagador, em termos de teste de hipóteses. Dessa forma, temos as seguintes alternativas:

H_0 : Cliente = mau pagador

H_a : Cliente $\neq$ mau pagador”.

A decisão será com base nas informações que conseguirá a respeito da vida financeira desse cliente.

Mas, considerando que as informações que a financeira tem acesso podem ser poucas, ou ainda pior, elas podem ser falsas, a classificação do cliente pode ser correta ou não. Então, poderá acontecer:

Decisão da Financeira	Verdade a respeito do cliente	
	Mau pagador	Bom Pagador
Cliente mau pagador = Não empresta	Decisão Correta	Erro Tipo II
Cliente não é mau pagador = Emprresta	Erro Tipo I	Decisão Correta

Se a decisão tomada for:

- Emprrestar dinheiro para um bom pagador; ou
- Não emprrestar dinheiro para um mau pagador,

a decisão foi correta.

Porém, se a financeira cometeu um dos erros:

- Emprrestar dinheiro para um mau pagador; ou
- Não emprrestar dinheiro para um bom pagador,

qual desses erros é mais sério para ela?

Obviamente que emprrestar dinheiro para um mau pagador, isto é, erro Tipo I. Este tipo de erro o pesquisador consegue controlar, pois é o nível de significância do teste, que é estipulado por ele.

Ao realizar o teste, um dos erros será fixado pelo pesquisador, que corresponderá à probabilidade máxima que ele admite de rejeitar H_0 quando H_0 é verdadeira, que é o α . A outra probabilidade de erro poderá ser determinada e dependerá do α e da estatística do teste. As estatísticas e as regras de decisão aqui apresentadas minimizam esse erro.

5.8 P-valor

Suponha que queremos realizar o seguinte teste de hipóteses para a média:

$$\begin{cases} H_0 : \mu = \mu_0 \\ H_a : \mu \neq \mu_0 \end{cases}$$

Para este teste, podemos ter o seguinte resultado:

Resultado do teste	População	
	$\mu = \mu_0$	$\mu \neq \mu_0$
Não rejeito H_0	Decisão Correta	Erro Tipo II
Rejeito H_0	Erro Tipo I	Decisão Correta

Dado que H_0 é verdadeira, rejeitamos H_0 se a probabilidade de obter uma média amostral tão extrema quanto o valor fixado for pequena. Nessa situação, os dados não são compatíveis com a hipótese nula, dando um maior suporte à hipótese alternativa.

Concluimos, então, que a média da população não pode ser μ_0 e o teste é dito estatisticamente significativo.

A probabilidade de cometer o erro Tipo I é chamada de nível de significância do teste de hipóteses e geralmente denotada por α . O mais usual é escolher o nível de significância 5%. Outros valores também podem ser utilizados, como, por exemplo, 1% (mais conservativo) e 10% (menos conservativo).

Chamamos de nível descritivo do teste (ou p-valor) a probabilidade de se obter uma média tão ou mais extrema do que a média fixada μ_0 , dado que a hipótese nula é verdadeira.

Utilizamos o p-valor para comparar com o nível de significância predeterminado (fixado) e, então, decidir se a hipótese nula deve ou não ser rejeitada.

Para esta comparação, temos a seguinte regra de decisão:

- Rejeitamos H_0 se p-valor $\leq \alpha$;
- Não rejeitamos H_0 se p-valor $> \alpha$.

5.9 Considerações finais

A teoria que circunda a probabilidade associada aos tipos de erros pode ser utilizada para determinar o tamanho de amostra, mas isso não é abordado neste

compêndio, como também não tratamos com maiores detalhes o que tange a “poder do teste”, por se tratar de um assunto teórico com enfoque mais probabilístico.

A metodologia de teste de hipóteses abordada se adequa a uma amostra, mas há casos em que é necessária a comparação entre duas amostras, o que requer procedimentos específicos que serão abordados no próximo capítulo.

5.10 Exercícios propostos

Exercício 1. Considere uma amostra de 16 coelhos cujo peso médio é 2,2 kg.

a) Supondo que o desvio-padrão populacional seja conhecido e igual a 0,2 kg, determine os intervalos de confiança para a média aos níveis de significância de 2,5% e 1%.

b) Determine os intervalos de confiança do item anterior, considerando que o desvio-padrão populacional é desconhecido e o desvio-padrão amostral é igual a 0,3 kg.

c) Comente sobre as diferenças nos resultados encontrados nos itens (a) e (b).

Exercício 2. Num levantamento feito pelo Instituto MAS entre os dias 02 e 03 de outubro de 2018, verificou-se que, de um total de 1.023 moradores da capital e região metropolitana de São Paulo entrevistados, 290 se declararam torcedores do Corinthians. Com base nessa informação, construa um intervalo de 90% de confiança para a proporção de corintianos na Grande São Paulo.

Exercício 3. Considere uma amostra do peso (em g) de 30 barras de chocolate produzidas por uma empresa alimentícia brasileira, cujos dados são apresentados a seguir.

107	95	85	108	89	107	93	105	87	97
98	115	90	102	103	103	108	84	97	80
103	109	108	112	93	95	84	100	124	85

a) O peso da barra de chocolate segue distribuição Normal? (Sugestão: use a função `shapiro.test` do R.)

b) Considerando um nível de significância de 5%, determine o intervalo de confiança para:

b.1) o desvio-padrão.

b.2) a variância.

Exercício 4. Um processo de determinação da concentração (em %) de um metal extremamente tóxico em certo produto forneceu os seguintes resultados:

0,018	0,012	0,020	0,021	0,029	0,019	0,030	0,024
-------	-------	-------	-------	-------	-------	-------	-------

De acordo com a norma reguladora, a concentração desse metal não deve ser superior a 0,03%. Sendo assim, a amostra retirada permite afirmar que o produto

está dentro da norma? Com um nível de significância de 1%, defina as hipóteses e faça o teste, considerando:

- a) desvio-padrão conhecido e igual a 0,005%.
- b) desvio-padrão desconhecido.

Exercício 5. Ainda segundo a pesquisa feita pelo Instituto MAS, 12,7% dos 1.023 moradores entrevistados se declararam torcedores do São Paulo. Teste, com o nível de significância de 10%, a hipótese $H_0 : p = 0,15$ contra a alternativa $H_a : p \neq 0,15$, sendo p a verdadeira proporção de torcedores são-paulinos na capital e região metropolitana de São Paulo.

Exercício 6. Considere os dados sobre concentração de substância tóxica em determinado produto, fornecidos no Exercício 4. Ainda de acordo com a norma reguladora, a concentração do metal no produto não deve ter um desvio-padrão superior a 0,01%.

- a) Formule as hipóteses nula e alternativa.
- b) Discuta os erros Tipo I e Tipo II que podem ocorrer no teste de hipóteses.
- c) Efetue o teste e conclua ao nível de significância de 2,5%.

Exercício 7. Para os testes de hipóteses a seguir, calcule o p-valor e conclua adotando $\alpha = 5\%$. (Sugestão: use as funções `pnorm`, `pt` e `pchisq` do R.)

- a) $\begin{cases} H_0 : \mu = 30 \\ H_a : \mu \neq 30 \end{cases}$, sabendo que: $\sigma^2 = 225$, $n = 100$ e $\bar{X} = 33$.
- b) $\begin{cases} H_0 : \mu = 50 \\ H_a : \mu > 50 \end{cases}$, sabendo que: $n = 20$, $s^2 = 144$ e $\bar{X} = 60$.
- c) $\begin{cases} H_0 : p = 0,25 \\ H_a : p < 0,25 \end{cases}$, sabendo que: $n = 500$ e $\hat{p} = 0,21$.
- d) $\begin{cases} H_0 : \sigma^2 = 100 \\ H_a : \sigma^2 \neq 100 \end{cases}$, sabendo que: $n = 45$ e $s^2 = 87,5$.

Capítulo 6

Testes de hipóteses para duas populações

Resumo do capítulo: *Neste capítulo, abordamos, inicialmente, testes de hipóteses com o intuito de verificar se, estatisticamente, a certo nível de significância, as variâncias de dois grupos podem ser consideradas iguais. O fato das variâncias serem iguais ou não, induz a metodologias específicas para comparação de médias de dois grupos. Os procedimentos são apresentados passo a passo e via rotinas no software R. Em cada tópico dispomos de exemplos resolvidos e no final do capítulo propomos alguns exercícios.*

Objetivos: *Para comparar médias de duas populações, primeiramente é necessário saber se suas variâncias podem ou não ser consideradas iguais. Este capítulo tem como objetivo fornecer bases para o leitor decidir sobre a igualdade ou não das variâncias e também auxiliá-lo nos procedimentos de comparação entre médias para as duas situações.*

6.1 Introdução

Em uma visão primária, a comparação de variâncias é realizada para que tenhamos embasamento científico na decisão de qual procedimento adotar para comparação de médias de duas populações. Porém, ela também pode ser utilizada para verificar se, em dois processos que historicamente possuem médias iguais, a variabilidade também é igual, isto é, se a variabilidade dos processos que geram essas médias é a mesma.

6.2 Comparação entre duas variâncias

Situação-problema:

“Uma linha de produção utiliza peças oriundas de duas fábricas. A especificação para adquirir as peças é que elas tenham entre 161 e 166 mm, em média. Tal especificação é garantida por ambas, no entanto, no final do processo vários produtos apresentam problemas e, como consequência, são rejeitados pelo controle de qualidade, ocasionando prejuízos.

Em referência ao problema, uma hipótese levantada por um grupo de técnicos é que possa haver grande variabilidade nos tamanhos das peças utilizadas, mesmo que cumpram a exigência quanto ao tamanho médio. Se uma das fábricas fornecedoras das peças garantir o tamanho e, além disso, apresentar significativamente menor variabilidade, suas peças teriam preferência nos novos testes.”

Esse problema requer comparação entre variâncias. Para isso, amostras devem ser coletadas e analisadas. Esta situação é novamente mencionada no Exemplo 53.

Verificar a homogeneidade das medidas corresponde a verificar se a variabilidade delas pode ou não ser considerada igual. Para tanto, é necessário formular hipóteses, estabelecer uma estatística de teste, compará-la com uma distribuição de probabilidade específica e, então, decidir.

Ressaltamos novamente que a comparação de variâncias pode ser utilizada tanto para o caso da situação-problema, como também como primeiro passo para a comparação de médias, pois metodologias distintas são necessárias para comparar médias de amostras com variâncias consideradas iguais ou diferentes.

Apresentamos uma metodologia para comparação de variâncias de duas populações.

Hipóteses

Queremos verificar se as variâncias dos dois grupos são iguais ou distintas. Em termos de teste de hipóteses, isso corresponde a testar:

$$\begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_a : \sigma_1^2 \neq \sigma_2^2 \end{cases}$$

O que é equivalente a testar as seguintes hipóteses:

$$\begin{cases} H_0 : \frac{\sigma_1^2}{\sigma_2^2} = 1 \\ H_a : \frac{\sigma_1^2}{\sigma_2^2} \neq 1 \end{cases}$$

Podemos também ter o interesse em testar se uma variância é maior ou menor do que outra. Todos esses casos são contemplados pela teoria e a estatística utilizada para eles é a mesma. O que muda é a regra de decisão, como apresentaremos.

Estatística do teste

Para comparar duas variâncias, a estatística do teste é:

$$F_{calc} = \frac{s_1^2}{s_2^2},$$

em que s_i^2 é a variância amostral referente à amostra i , $i = 1, 2$.

Regra de decisão

No teste de igualdade *versus* diferença, isto é, $\begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_a : \sigma_1^2 \neq \sigma_2^2 \end{cases}$, rejeita-se H_0 , ou seja, há evidências, a $100(\alpha)\%$ de significância, de que as variâncias são diferentes se:

$$F_{calc} > F_{(n_1-1, n_2-1)}(1 - \alpha/2) \quad \text{ou} \quad F_{calc} < F_{(n_1-1, n_2-1)}(\alpha/2).$$

Quando as hipóteses consideradas são: $\begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_a : \sigma_1^2 > \sigma_2^2 \end{cases}$, rejeita-se H_0 , isto é, há evidências, a $100(\alpha)\%$ de significância, de que a variância do grupo 1 é maior do que a variância do grupo 2 se:

$$F_{calc} > F_{(n_1-1, n_2-1)}(1 - \alpha).$$

No entanto, se as hipóteses forem: $\begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_a : \sigma_1^2 < \sigma_2^2 \end{cases}$, rejeita-se H_0 , isto é, há evidências, a $100(\alpha)\%$ de significância, de que a variância do grupo 1 é menor do que a variância do grupo 2 se:

$$F_{calc} < F_{(n_1-1, n_2-1)}(\alpha),$$

em que n_1 é o número de dados da amostra do grupo 1, n_2 é o número de dados da amostra do grupo 2, α é o nível de significância do teste, $F_{(n_1-1, n_2-1)}(\alpha)$ é o valor tabelado referente à distribuição de probabilidade F-Snedecor (ver Tabelas A4-A9 do Apêndice).

No programa R está implementada a função `var.test` para testar variâncias. Fizemos o cálculo de duas formas: na primeira, passo a passo e, na segunda, utilizando a função.

```
# Função para realizar o teste de hipóteses
> testeHidifvar<-function(x,y,alpha,decisao) {
dx<-length(x)-1 # graus de liberdade da amostra x
dy<-length(y)-1 # graus de liberdade da amostra y
varx<-var(x)
```

```

vary<-var(y)
Fcalc<-varx/vary # estatística Fcalc.
if(decisao=="diferente") {
  critico1<-qf(1-alpha/2, dx, dy) # quantil da F(1-alpha/2)
  critico2<-qf(alpha/2, dx, dy) # quantil da F(alpha/2)
  Decisao=if(Fcalc > critico1 | Fcalc < critico2) { "Rejeito H0" } else
  "Não Rejeito H0" }
if(decisao=="maior") {
  critico<-qf(1-alpha, dx, dy) # quantil da F(1-alpha)
  Decisao=if(Fcalc > critico) { "Rejeito H0" } else
  "Não Rejeito H0" }
if(decisao=="menor") {
  critico<-qf(alpha, dx, dy) # quantil da F(alpha)
  Decisao=if(Fcalc < critico) { "Rejeito H0" } else
  "Não Rejeito H0" }
return(Decisao) }

```

A função `testeHpdifvar` tem como argumentos os vetores de observações “x” e “y”, o nível de significância “alpha”, a decisão a ser tomada “decisao”, sendo ela: “diferente” para testar se difere, “maior” para o teste unilateral à direita, e “menor” para o teste unilateral à esquerda. Considere agora a função predeterminada do R:

```
var.test(x, y, alternative="two.sided", conf.level=1-alpha)
```

A função `var.test` possui os mesmos argumentos da função anterior. No entanto, o critério de decisão deverá ser dado por: “two.sided” para testar se difere, “greater” para o teste unilateral à direita, e “less” para o teste unilateral à esquerda.

Exemplo 53. *Consideremos a situação-problema, em que desejamos verificar se há diferença na variabilidade do tamanho das peças produzidas pelas duas fábricas, a 5% de significância.*

Foram selecionadas duas amostras com 10 peças cada, cujos dados são:

<i>Amostra 1</i>	164	167	171	149	147	155	180	166	160	159
<i>Amostra 2</i>	153	168	172	158	167	168	170	158	174	171

Solução:

Precisamos dos valores das variâncias de cada amostra. Fazendo os cálculos, temos que: $s_1^2 \approx 100,62$ e $s_2^2 \approx 49,66$.

1. O valor da estatística do teste é: $F_{calc} = \frac{s_1^2}{s_2^2} = \frac{100,62}{49,66} \approx 2,026$;
2. Considerando $\alpha = 5\%$, na tabela da distribuição F-Snedecor, temos que:

- $F_{(n_1-1, n_2-1)}(1 - \alpha/2) = F_{(9,9)}(0,975) = 4,026$ e
 - $F_{(n_1-1, n_2-1)}(\alpha/2) = F_{(9,9)}(0,025) = 0,248$;
3. Decisão: Como $F_{calc} \approx 2,026$ é menor do que $F_{(9,9)}(0,975) = 4,026$ e maior do que $F_{(9,9)}(0,025) = 0,248$, então não rejeitamos H_0 ao nível 5% de significância, isto é, não há evidências de que as variâncias sejam diferentes.

```
> x<-c(164,167,171,149,147,155,180,166,160,159)
> y<-c(153,168,172,158,167,168,170,158,174,171)
> testeHpdifvar(x,y,0.05,"diferente")
[1] "Não Rejeito H0"
> # Considerando a função predeterminada do R
> var.test(x, y, alternative="two.sided", conf.level=0.95)
      F test to compare two variances
data:  x and y
F = 2.0264, num df = 9, denom df = 9, p-value = 0.3076
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.5033301 8.1582911
sample estimates: ratio of variances  2.026404
```

A decisão também poderia ser tomada utilizando o p-valor. Para essa situação, o p-valor da estatística foi de 0,3076, isto é, maior do que 0,05. Logo, não se rejeita H_0 .

Exemplo 54. Considere os seguintes valores dos pesos (kg) de sete melancias, obtidas de duas lavouras com diferenças no cultivo.

Amostra 1	3,689	4,876	4,005	4,876	3,670	4,890	4,142
Amostra 2	4,876	3,998	3,025	4,772	4,654	3,023	4,098

Ao nível de significância $\alpha = 10\%$, verifique se:

$$a) \begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_a : \sigma_1^2 \neq \sigma_2^2 \end{cases}$$

$$b) \begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_a : \sigma_1^2 > \sigma_2^2 \end{cases}$$

$$c) \begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_a : \sigma_1^2 < \sigma_2^2 \end{cases}$$

Solução:

a) Para realizar tal teste, considere os seguintes passos:

1. O valor da estatística do teste é: $F_{calc} = \frac{s_1^2}{s_2^2} = \frac{0,3156}{0,6129} \approx 0,5149$;

2. Na tabela da distribuição F-Snedecor, temos que:

- $F_{(n_1-1, n_2-1)}(1 - \alpha/2) = F_{(6,6)}(0,95) = 4,284$ e
- $F_{(n_1-1, n_2-1)}(\alpha/2) = F_{(6,6)}(0,05) = 0,233$;

3. Decisão: Como $F_{calc} \approx 0,5149$ é menor do que $F_{(6,6)}(0,95) = 4,284$ e maior do que $F_{(6,6)}(0,05) = 0,233$, então não rejeitamos H_0 ao nível 10% de significância, isto é, não há evidências de que as variâncias sejam diferentes.

```
> x<-c(3.689,4.876,4.005,4.876,3.670,4.890,4.142)
> y<-c(4.876,3.998,3.025,4.772,4.654,3.023,4.098)
> var.test(x, y, alternative="two.sided", conf.level=0.90)
F test to compare two variances
data:  x and y
F = 0.51491, num df = 6, denom df = 6, p-value = 0.4394
alternative hypothesis: true ratio of variances is not equal to 1
90 percent confidence interval: 0.120197 2.205796
sample estimates: ratio of variances 0.5149078
```

Isto significa que, ao nível de 10% de significância, não há evidências de que a variabilidade do tamanho das melancias difira entre as lavouras. Lembrando que esta conclusão é tão somente a respeito das variâncias, visto que, até o momento, nenhuma conclusão a respeito dos tamanhos das melancias pode ser tirada.

b) A regra de decisão para este teste é: se $F_{calc} > F_{(6,6)}(0,90)$, rejeita-se H_0 .

Temos que $F_{(6,6)}(0,90) = 3,054$, então não rejeitamos H_0 . Portanto, as variâncias podem ser consideradas iguais ao nível de 10% de significância.

```
> var.test(x, y, alternative="greater", conf.level=0.90)
F test to compare two variances
data:  x and y
F = 0.51491, num df = 6, denom df = 6, p-value = 0.7803
alternative hypothesis: true ratio of variances is greater than 1
90 percent confidence interval: 0.1685707      Inf
sample estimates: ratio of variances 0.5149078
```

A decisão também poderia ser tomada utilizando o p-valor. Para essa situação, o p-valor da estatística foi de 0,7803, isto é, maior do que 0,05. Logo, não se rejeita H_0 .

c) Pela regra de decisão apresentada, se $F_{calc} < F_{(6,6)}(0,10)$, então rejeita-se H_0 . Temos que $F_{(6,6)}(0,10) = 0,327$. Como isso não ocorreu, não rejeitamos H_0 .

```
> var.test(x, y, alternative="less", conf.level=0.90)
F test to compare two variances
data:  x and y
F = 0.51491, num df = 6, denom df = 6, p-value = 0.2197
alternative hypothesis: true ratio of variances is less than 1
90 percent confidence interval: 0.000000 1.572812
sample estimates: ratio of variances 0.5149078
```

A decisão também poderia ser tomada utilizando o p-valor. Para essa situação, o p-valor da estatística foi de 0,2197, isto é, maior do que 0,05. Logo, não se rejeita H_0 .

No exemplo anterior, a hipótese de igualdade não foi rejeitada em nenhum momento. Se isto não tivesse ocorrido, teríamos uma incoerência. Este fato, mesmo parecendo absurdo, pode ocorrer com algumas teorias estatísticas, geralmente relacionadas a valores extremos, mas estas não são de interesse no momento.

6.3 Comparação de duas médias

A comparação da média de dois grupos pode ter o intuito de assegurar que os resultados são iguais apesar de possíveis diferenças numéricas, ou então para comprovar que realmente existem diferenças. Porém, antes de comparar as médias de dois grupos, é preciso verificar se suas variâncias podem ser consideradas iguais, para escolher o método apropriado para a comparação. A comparação de variâncias é feita utilizando o procedimento apresentado anteriormente.

Na abordagem de comparação de médias, também temos os casos em que as amostras envolvidas podem ou não possuir a mesma quantidade de dados e, ainda, podem não ser de mesma unidade amostral, o que ocasionará alterações na estatística do teste.

As hipóteses envolvidas, bem como os objetivos de cada teste, não mudam. No entanto, mediante particularidades dos dados, ajustes na estatística do teste são feitos.

6.3.1 Dados pareados

Dados pareados é quando os conjuntos de dados para a análise se referem a amostras obtidas das mesmas unidades amostrais em dois momentos. Como nas seguintes situações:

- i) Produtividade de cafezais antes e depois do uso de certo adubo;

- ii) Ganho ou perda de peso por animais antes e depois de submetidos a determinado tratamento;
- iii) Produtividade da máquina antes e depois de passar por manutenção.

Para o caso de dados pareados, não há necessidade de comparar se as variâncias são iguais.

Situação-problema:

“Uma franquia de produtos alimentícios modificou um produto de grande procura e pretende verificar se a mudança ocasionou diferença na quantidade de itens vendidos. Para tanto, tomou nota da quantidade de itens vendidos em oito de suas lojas, na semana anterior à alteração do produto e também duas semanas após efetuada a alteração.”

As possibilidades de comparação entre os conjuntos de dados são várias, porém, neste caso, o objetivo da situação é: *“verificar se a mudança no produto ocasionou diferença na quantidade de itens vendidos”*, o que nos leva a considerar como hipótese alternativa a *diferença*. No entanto, poderíamos ter como hipótese alternativa: *maior do que* ou *menor do que*.

A hipótese nula é sempre da igualdade, por isso não se comenta a sua formulação, mas decidir qual é ou como montar a hipótese alternativa é importante, pois cada hipótese alternativa tem uma regra de decisão específica. A seguir, comentamos um pouco mais a respeito das hipóteses envolvidas em cada situação e suas particularidades.

Outro ponto importante a ser decidido é o nível de significância do teste. Precisamos ter claro qual o erro máximo que iremos admitir no teste.

Antes de resolver a situação-problema, apresentaremos a estatística do teste e a regra de decisão para cada possível situação.

Hipóteses

Neste caso, as hipóteses envolvidas são com respeito às médias. Sendo assim, consideremos:

- μ_1 : média do grupo 1
- μ_2 : média do grupo 2

Primeiramente, vamos montar as hipóteses para testes bilaterais, isto é, igualdade *versus* diferença. Neste caso, podemos escrever:

$$\begin{cases} H_0 : \mu_1 = \mu_2 \\ H_a : \mu_1 \neq \mu_2 \end{cases}$$

No entanto, em relação a essas hipóteses, podemos ter a seguinte relação:

$$\begin{cases} H_0 : \mu_1 - \mu_2 = 0 \\ H_a : \mu_1 - \mu_2 \neq 0 \end{cases}$$

Ou então, considerando $\Delta = 0$, podemos escrever:

$$\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_a : \mu_1 - \mu_2 \neq \Delta \end{cases}$$

Esta é a forma mais comumente utilizada para expressar a comparação de médias de dois grupos, que é bastante útil quando precisamos verificar se uma média supera outra em certa quantidade de unidades.

Um exemplo deste tipo de problema pode ser em estudo de produtividade *versus* fertilizante, em que aos fertilizantes está associado um custo e, mesmo tendo produtividades diferentes, o fertilizante alternativo pode não ser vantajoso se a diferença na produtividade média não for superior a 5. Neste caso, teríamos $\Delta = 5$.

Desta forma, as hipóteses serão apresentadas sempre em função da diferença entre as médias em relação à quantidade Δ , mesmo para as hipóteses unilaterais.

Estatística do teste

$$T = \frac{\bar{d} - \Delta}{s_{\bar{d}}},$$

em que:

$\bar{d}$: média das diferenças, com $\bar{d} = \frac{1}{n} \sum_{i=1}^n d_i$;

$d_i = x_i - y_i$: diferença entre os pares (deve ser mantida a ordem);

n : tamanho das amostras;

$\Delta = \mu_1 - \mu_2$: diferença entre as médias;

$s_{\bar{d}} = \sqrt{\frac{s_d^2}{n}}$, sendo:

$$s_d^2 = \frac{1}{n-1} \left[\sum_{i=1}^n d_i^2 - \frac{\left(\sum_{i=1}^n d_i \right)^2}{n} \right] : \text{variância da amostra das diferenças.}$$

Regra de decisão

A estatística T segue a distribuição de probabilidade t -Student. Portanto, comparamos a estatística T calculada com o percentil da distribuição t -Student, relacionando com o tipo de teste (unilateral ou bilateral), nível de significância e graus de liberdade.

As regras de decisão listadas a seguir são sempre em relação ao nível $100(\alpha)\%$ de significância com $n - 1$ graus de liberdade.

- i) Para testar $\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_a : \mu_1 - \mu_2 \neq \Delta \end{cases}$, rejeita-se H_0 se $|T| > t_{\alpha/2}(n - 1)$;
- ii) Para testar $\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_a : \mu_1 - \mu_2 > \Delta \end{cases}$, rejeita-se H_0 se $T > t_{\alpha}(n - 1)$;
- iii) Para testar $\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_a : \mu_1 - \mu_2 < \Delta \end{cases}$, rejeita-se H_0 se $T < -t_{\alpha}(n - 1)$.

Ressaltamos que podemos comparar se as médias são iguais ou não (neste caso, $\Delta = 0$), ou se a diferença entre elas é um valor específico.

No programa R está implementada a função `t.test` para testar a igualdade de médias, sendo esta dada por:

```
t.test(x, y,                                # dados
       alternative="two.sided",             # bilateral (= vs dif.)
       paired=TRUE,                        # dados pareados
       conf.level=1-alpha)                 # nível de confiança
```

Exemplo 55. *Situação-problema:* Queremos saber se a alteração na composição do produto provocou diferença na quantidade de itens vendidos. Foram obtidas as quantidades vendidas antes e depois da alteração em oito lojas, cujos dados estão apresentados a seguir.

Loja	A	B	C	D	E	F	G	H
Antes	145	156	187	341	231	142	153	182
Depois	321	234	323	234	122	123	312	134

Solução:

Neste caso, as hipóteses a serem consideradas são:

$$\begin{cases} H_0 : \text{as médias são iguais} \\ H_a : \text{as médias são diferentes} \end{cases} \iff \begin{cases} H_0 : \mu_1 - \mu_2 = 0 \\ H_a : \mu_1 - \mu_2 \neq 0 \end{cases}$$

Consideremos o nível de significância de 5%. Os demais dados são: $n = 8$ e $\Delta = 0$.

Para obter a estatística do teste, precisamos de alguns resultados. Para facilitar os cálculos e a compreensão da resolução, as diferenças d_i e seus quadrados d_i^2 , estão apresentadas no quadro a seguir.

Loja	Antes	Depois	d_i	d_i^2
A	145	321	-176	30.976
B	156	234	-78	6.084
C	187	323	-136	18.496
D	341	234	107	11.449
E	231	122	109	11.881
F	142	123	19	361
G	153	312	-159	25.281
H	182	134	48	2.304
Soma			-266	106.832

De posse desses valores, obtemos $\bar{d}$ e s_d^2 :

$$\bar{d} = \frac{1}{n} \sum_{i=1}^n d_i = \frac{1}{8} \times (-266) = -33,25$$

e

$$\begin{aligned} s_d^2 &= \frac{1}{n-1} \left[\sum_{i=1}^n d_i^2 - \frac{\left(\sum_{i=1}^n d_i \right)^2}{n} \right] \\ &= \frac{1}{7} \left[106.832 - \frac{(-266)^2}{8} \right] \\ &= \frac{1}{7} [106.832 - 8.844,5] = 13.998,21. \end{aligned}$$

Portanto,

$$s_{\bar{d}} = \sqrt{\frac{s_d^2}{n}} = \sqrt{\frac{13.998,21}{8}} \approx 41,83.$$

Calculando a estatística do teste, temos:

$$\begin{aligned} T &= \frac{\bar{d} - \Delta}{\frac{s_{\bar{d}}}{\sqrt{n}}} \\ &= \frac{-33,25 - 0}{41,83} \approx -0,795. \end{aligned}$$

Decisão: Rejeita-se H_0 se $|T| > t_{\alpha/2}(n-1)$. Considerando os graus de liberdade $gl = n - 1 = 7$ e nível de significância $\alpha = 5\%$, temos que: $t_{0,025}(7) = 2,36$.

Logo, como $|T| \approx 0,795 \not\geq 2,36 = t_{0,025}(7)$, não rejeitamos a hipótese nula, isto é, a 5% de significância, os dados não apresentaram evidências de que houve alteração na quantidade de itens vendidos após a modificação do produto.

O exemplo todo pode ser resolvido no R:

```
> x<-c(145,156,187,341,231,142,153,182) # dados do primeiro grupo
> y<-c(321,234,323,234,122,123,312,134) # dados do segundo grupo
> alpha<-0.05 # nível de significância
> t.test(x, y, alternative="two.sided", paired=TRUE, conf.level=1-
  alpha) # nível de confiança
Paired t-test
data: x and y
t = -0.79488, df = 7, p-value = 0.4528
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval: -132.16302 65.66302
sample estimates: mean of the differences -33.25
> critico=qt(alpha/2, length(x)-1, lower.tail=FALSE)
> critico
[1] 2.364624
```

A tomada de decisão pode então ser feita por meio do p-valor (0,4528), ou comparando com o valor crítico (2,364624).

O valor de $t_{0,025}(7) \approx 2,36$ pode ser obtido no R pelo comando apresentado acima, ou na tabela da distribuição de probabilidade *t*-Student (ver Tabela A2 do Apêndice), mas para fins ilustrativos de como encontrar o valor em questão, temos parte da tabela apresentada na figura abaixo.

Como encontrar o valor crítico na tabela da distribuição *t*-Student:

Parte da tabela *t*-Student

	Fixado para o problema									Graus de liberdade
<i>gl</i>	0,25	0,1	0,05	0,025	0,01	0,005	0,0025	0,001	0,0005	
1	1,0000	3,0777	6,3138	12,7062	31,8205	63,6567	127,3213	318,3088	636,6192	1
2	0,8165	1,8856	2,9200	4,3027	6,9646	9,9248	14,0890	22,3271	31,5991	2
3	0,7649	1,6377	2,3534	3,1824	4,5407	5,8409	7,4533	10,2145	12,9240	3
4	0,7407	1,5332	2,1318	2,7764	3,7469	4,6041	5,5976	7,1732	8,6103	4
5	0,7267	1,4759	2,0150	2,5706	3,3649	4,0321	4,7733	5,8934	6,8688	5
6	0,7176	1,4398	1,9432	2,4469	3,1427	3,7074	4,3168	5,2076	5,9588	6
7	0,7111	1,4149	1,8946	2,3646	2,9980	3,4995	4,0293	4,7853	5,4079	7
8	0,7064	1,3968	1,8595	2,3060	2,8965	3,3554	3,8325	4,5008	5,0413	8
9	0,7027	1,3830	1,8331	2,2622	2,8214	3,2498	3,6897	4,2968	4,7809	9
10	0,6998	1,3722	1,8125	2,2281	2,7638	3,1693	3,5814	4,1437	4,5869	10
11	0,6974	1,3634	1,7959	2,2010	2,7181	3,1058	3,4966	4,0247	4,4370	11

Valor crítico

Nível de significância

determinado: $n - 1$

Observações: A decisão pode ser feita:

1. Pela regra de decisão apresentada, comparando o valor de t (dado no teste) ou T com o valor crítico que é $t_\alpha(gl)$;
2. Pela interpretação do p-valor: se p-valor $< \alpha$, rejeito H_0 . Equivalentemente, p-valor $> \alpha$ não rejeita H_0 .

Exemplo 56. *Uma experiência verificou que a quantidade de gordura contida no leite sofria variação conforme o trato que as vacas recebiam. Uma ração foi formulada com o escopo de aumentar a gordura no leite, porém esta nova alimentação, comparada com a alimentação tradicional oferecida ao rebanho, tem maiores custos. Após alguns cálculos, verificou-se que a nova alimentação só será vantajosa se a quantidade de gordura conseguida com essa alimentação for 3,25 u.m. (unidades de medida) maior que a quantidade anterior.*

Para tanto, foram consideradas 13 vacas leiteiras de diferentes raças e tomou-se nota da quantidade de gordura do leite de cada uma delas com a dieta usual e com a dieta alternativa, cujos resultados estão apresentados a seguir.

<i>Dieta usual</i>	14,50	13,21	18,95	11,37	10,43	14,61	8,56
	7,87	8,41	6,23	7,14	11,53	18,22	
<i>Dieta alternativa</i>	18,21	16,33	25,05	15,42	15,23	17,52	12,21
	10,97	11,22	10,20	9,81	15,03	24,08	

A nova dieta é vantajosa para os produtores de leite?

Solução:

Denotemos:

μ_1 : média de gordura do leite pela dieta usual;

μ_2 : média de gordura do leite pela dieta alternativa.

Como a dieta alternativa aumentou a quantidade de gordura do leite, então temos que $\mu_2 > \mu_1$.

Desta forma, $\mu_1 - \mu_2 < 0$, isto é, negativo, e quanto maior a quantidade de gordura que a dieta alternativa produz, menor será o valor da diferença entre as médias.

Todavia, considerando o valor mínimo fixado para a diferença entre as médias, $\Delta = -3,25$, as hipóteses adequadas a essa situação são:

$$\begin{cases} H_0 : \text{diferença entre médias} = -3,25 \\ H_a : \text{diferença entre médias} < -3,25 \end{cases} \iff \begin{cases} H_0 : \mu_1 - \mu_2 = -3,25 \\ H_a : \mu_1 - \mu_2 < -3,25 \end{cases}$$

Temos $n = 13$ e consideremos que o nível de significância de interesse é $\alpha = 10\%$.

Para obter a estatística do teste, precisamos dos valores de d_i e seus quadrados d_i^2 , os quais estão no quadro a seguir.

Vaca	Dieta usual	Dieta alternativa	d_i	d_i^2
1	14,50	18,21	-3,71	13,76
2	13,21	16,33	-3,12	9,73
3	18,95	25,05	-6,10	37,21
4	11,37	15,42	-4,05	16,40
5	10,43	15,23	-4,80	23,04
6	14,61	17,52	-2,91	8,46
7	8,56	12,21	-3,65	13,32
8	7,87	10,97	-3,10	9,61
9	8,41	11,22	-2,81	7,90
10	6,23	10,20	-3,97	15,76
11	7,14	9,81	-2,67	7,13
12	11,53	15,03	-3,50	12,25
13	18,22	24,08	-5,86	34,34
Soma			-50,25	208,93

De posse desses valores, obtemos $\bar{d}$ e s_d^2 :

$$\bar{d} = \frac{1}{n} \sum_{i=1}^n d_i = \frac{1}{13} \times (-50,25) \approx -3,87$$

e

$$\begin{aligned}
 s_d^2 &= \frac{1}{n-1} \left[\sum_{i=1}^n d_i^2 - \frac{\left(\sum_{i=1}^n d_i \right)^2}{n} \right] \\
 &= \frac{1}{12} \left[208,93 - \frac{(-50,25)^2}{13} \right] \\
 &= \frac{1}{12} [208,93 - 194,24] \approx 1,22.
 \end{aligned}$$

Portanto,

$$s_{\bar{d}} = \sqrt{\frac{s_d^2}{n}} = \sqrt{\frac{1,22}{13}} \approx 0,31.$$

Calculando a estatística do teste, temos:

$$T = \frac{\bar{d} - \Delta}{s_{\bar{d}}} = \frac{-3,87 + 3,25}{0,31} = -2.$$

Decisão: Rejeita-se H_0 se $T < -t_{\alpha}(n-1)$ ao nível $100(\alpha)\%$ de significância com $n-1$ graus de liberdade. O valor crítico para este teste é: $-t_{0,10}(12) = -1,36$.

Como $-2 < -1,36$, então rejeitamos H_0 , isto é, a diferença entre as médias é maior que 3,25, sendo, portanto, vantajoso considerar a alimentação alternativa, pois o acréscimo no gasto com a nova ração é compensado pelo acréscimo de gordura no leite.

Poderíamos resolver a questão utilizando um programa no R. Primeiramente, apresentamos o procedimento passo a passo.

```
> x<-c(14.50,13.21,18.95,11.37,10.43,14.61,8.56,7.87,8.41,
      6.23,7.14,11.53,18.22) # ração usual
> y<-c(18.21,16.33,25.05,15.42,15.23,17.52,12.21,10.97,11.22,
      10.20,9.81,15.03,24.08) # ração alternativa
> alpha<-0.1 # nível de significância
> d<-x-y
> d2<-d^2
> n<-length(x)
> d_barra<-sum(d)/n
> k<-(sum(d)^2)/n
> s2<-(sum(d2)-k)/(n-1)
> sd<-sqrt(s2/n)
> t<-(d_barra+3.25)/sd
> t
[1] -2.005282
```

Agora, utilizando a função predefinida do R.

```
> x<-c(14.50,13.21,18.95,11.37,10.43,14.61,8.56,7.87,8.41,
      6.23,7.14,11.53,18.22) # ração usual
> y<-c(18.21,16.33,25.05,15.42,15.23,17.52,12.21,10.97,11.22,
      10.20,9.81,15.03,24.08) # ração alternativa
> alpha<-0.1 # nível de significância
> t.test(x, y, # dados
  alternative="less", # indica o teste "menor do que"
  paired=TRUE, # dados pareados
  conf.level=1-alpha) # nível de confiança
# Resultado
Paired t-test
data: x and y
t = -12.596, df = 12, p-value = 1.407e-08
alternative hypothesis: true difference in means is less than 0
90 percent confidence interval: -Inf -3.449186
sample estimates: mean of the differences -3.865385
```

Há diferença entre a estatística t calculada passo a passo e a calculada pela função `t.test`, mas elas são equivalentes, isto pelo fato de que a função `t.test` considera sempre $\Delta = 0$. Desta forma, a leitura dos resultados apresentados pelo teste é: “a diferença entre as médias ($\mu_1 - \mu_2$) é menor que zero, e ao nível de significância fixado, a diferença é -3,87”, superando a diferença desejada. Então, concluímos que a dieta alternativa é satisfatória na produção de gordura no leite.

Passamos agora a tratar o caso de situações em que os dados nos dois momentos não advêm das mesmas unidades amostrais.

6.3.2 Dados não pareados

Neste caso, trabalhamos com problemas em que os conjuntos de dados (amostras independentes) podem ter números de dados diferentes. Consideramos então n_1 e n_2 , respectivamente, como o número de dados do grupo 1 e do grupo 2. Por causa da possibilidade de diferença na quantidade de dados, não é sensato pensarmos em diferença de valores amostrais. Então, trabalharemos com a diferença das médias de cada grupo.

Porém, em dados não pareados, precisamos fazer referência às variâncias de cada grupo, pois elas podem não ser iguais. Desta forma, antes de partirmos para a comparação de médias, devemos verificar se as variâncias são ou não são iguais. A forma de comparar as variâncias foi apresentada e discutida anteriormente neste capítulo.

Vejamos alguns exemplos de situações que se encaixam no tópico de dados não pareados.

1. Comparação de desempenho do fertilizante A em relação ao fertilizante B. Compara-se a produtividade média da cultura utilizando o fertilizante A com a produtividade média da cultura utilizando o fertilizante B.
2. Comparação da eficácia de dois tratamentos na cura de uma doença. Criam-se dois grupos, um para cada tratamento.
3. Se duas máquinas produzem quantidades iguais de peças defeituosas por dia.
4. Se dois funcionários têm o mesmo rendimento, em média, na produção diária, semanal ou mensal.
5. Se a produtividade da empresa permanece inalterada, em dois períodos de tempo.

As hipóteses possíveis para esses procedimentos são as mesmas apresentadas para os dados pareados, coincidindo também o ensejo envolvido.

Passos para construir o teste de hipóteses

O procedimento para realizar o teste de hipóteses para comparação de médias para dados não pareados é um pouco mais meticoloso do que para dados pareados. A seguir, pautamos, como sugestão, alguns passos para realizar a ação em questão.

1. Montar as hipóteses a serem testadas:

$$\text{a) } \left\{ \begin{array}{l} H_0 : \mu_1 - \mu_2 = \Delta \\ H_a : \mu_1 - \mu_2 \neq \Delta \end{array} \right. \quad \text{b) } \left\{ \begin{array}{l} H_0 : \mu_1 - \mu_2 = \Delta \\ H_a : \mu_1 - \mu_2 > \Delta \end{array} \right. \quad \text{c) } \left\{ \begin{array}{l} H_0 : \mu_1 - \mu_2 = \Delta \\ H_a : \mu_1 - \mu_2 < \Delta \end{array} \right.$$

2. Fixar o nível de significância α ;
3. Comparar as variâncias, com nível de significância α , para verificar se são iguais ou distintas. Isto conduzirá a uma estatística específica para o teste;
4. Calcular a estatística do teste de comparação de médias, escolhida após resultado do teste de comparação de variâncias;
5. Obter o valor crítico correspondente ao nível α de significância e aos graus de liberdade envolvidos;
6. Utilizar a regra de decisão para rejeitar ou não rejeitar H_0 .

A seguir, expomos os dois procedimentos, considerando variâncias iguais e diferentes, com suas estatísticas, regras de decisão e exemplos.

Estatística do teste

Duas estatísticas são expostas, uma quando o teste de comparação de variâncias as julgarem iguais e outra quando elas forem julgadas diferentes.

Com variâncias iguais:

$$T = \frac{\bar{X}_1 - \bar{X}_2 - \Delta}{s \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}},$$

em que:

n_i : número de elementos do grupo i , $i = 1, 2$;

$\bar{X}_i$: média do grupo i , $i = 1, 2$;

$s = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$: variância ponderada (raiz);

s_i^2 : variância do grupo i , $i = 1, 2$.

Se os dois grupos tiverem a mesma quantidade de elementos amostrados, isto é, n , então temos:

$$T = \frac{\bar{X}_1 - \bar{X}_2 - \Delta}{s\sqrt{\frac{2}{n}}}$$

e

$$s = \sqrt{\frac{(n-1)(s_1^2 + s_2^2)}{2n-2}}.$$

Com variâncias diferentes:

$$T = \frac{\bar{X}_1 - \bar{X}_2 - \Delta}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}},$$

em que:

- n_i : número de elementos do grupo i , $i = 1, 2$;
- $\bar{X}_i$: média do grupo i , $i = 1, 2$;
- s_i^2 : variância do grupo i , $i = 1, 2$.

Regra de decisão

A estatística T segue uma distribuição t -Student. Portanto, comparamos a estatística T calculada com o percentil da distribuição t -Student, relacionando com o tipo de teste (unilateral ou bilateral), graus de liberdade e nível de significância.

As regras de decisão postadas a seguir estão relacionadas ao nível $100(\alpha)\%$ de significância com ν graus de liberdade.

- a) Para as hipóteses: $\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_a : \mu_1 - \mu_2 \neq \Delta \end{cases}$, rejeita-se H_0 se $|T| > t_{\alpha/2}(\nu)$;
- b) Para as hipóteses: $\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_a : \mu_1 - \mu_2 > \Delta \end{cases}$, rejeita-se H_0 se $T > t_{\alpha}(\nu)$;
- c) Para as hipóteses: $\begin{cases} H_0 : \mu_1 - \mu_2 = \Delta \\ H_a : \mu_1 - \mu_2 < \Delta \end{cases}$, rejeita-se H_0 se $T < -t_{\alpha}(\nu)$.

Podemos considerar o fato de que, se os tamanhos amostrais n_1 e n_2 forem grandes, então T tem distribuição aproximadamente Normal padrão. Contudo, quando estes são ambos pequenos, devemos utilizar uma distribuição t -Student, cujos graus de liberdade ν são usualmente definidos como:

Variâncias iguais:

$$\nu = n_1 + n_2 - 2.$$

Variâncias diferentes:

$$\nu = \frac{(w_1 + w_2)^2}{\frac{w_1^2}{n_1 - 1} + \frac{w_2^2}{n_2 - 1}},$$

em que $w_i = \frac{s_i^2}{n_i}$, $i = 1, 2$.

A seguir, são apresentados os comandos no *software* R para realizar o teste de hipóteses para comparação de médias para dados não pareados.

```
# Função para realizar o teste de hipóteses
> testemediasnp<-function(x,y,alpha,decisao) {
  varteste<-var.test(x,y,alternative="two.sided",conf.level=1-alpha)
  if(varteste$p.value > alpha) { igualdade<-TRUE } else
  { igualdade<-FALSE }
  if(decisao=="diferente") {
    aux<-t.test(x,y,alternative="two.sided",paired=FALSE,var.equal=
      igualdade,conf.level=1-alpha)
    Decisao=if(aux$p.value>alpha) { "Não Rejeito H0" } else
    "Rejeito H0" }
  if(decisao=="maior") {
    aux<-t.test(x,y,alternative="greater",paired=FALSE,var.equal=
      igualdade,conf.level=1-alpha)
    Decisao=if(aux$p.value>alpha) { "Não Rejeito H0" } else
    "Rejeito H0" }
  if(decisao=="menor") {
    aux<-t.test(x,y,alternative="less",paired=FALSE,var.equal=igualdade,
      conf.level=1-alpha)
    Decisao=if(aux$p.value>alpha) { "Não Rejeito H0" } else
    "Rejeito H0" }
  return(c(Decisao,aux)) }
```

A função `testemediasnp` tem como argumentos os vetores de observações “x” e “y”, o nível de significância “alpha”, a decisão a ser tomada “decisao”, sendo ela: “diferente” para testar se difere, “maior” para o teste unilateral à direita, e “menor” para o teste unilateral à esquerda.

Note que esta função realiza inicialmente o teste de igualdade *versus* diferença de variâncias, selecionando automaticamente se as variâncias são iguais ou diferentes para a realização do teste de hipóteses para comparação de médias para dados não pareados.

Exemplo 57. *A primeira situação apresentada para comparar variâncias foi relacionada à medida das peças utilizadas em uma linha de produção. No problema,*

supunha-se que testes anteriores haviam concluído que as médias eram iguais. Uma das hipóteses consideradas era que as variâncias seriam diferentes, a qual foi rejeitada pelo teste de hipóteses. Mas será que as médias são realmente iguais? Para responder a esta questão, vamos utilizar os dados amostrados e comparar as médias.

Amostra 1	164	167	171	149	147	155	180	166	160	159
Amostra 2	153	168	172	158	167	168	170	158	174	171

Solução:

1. Hipóteses de interesse: $\begin{cases} H_0 : \mu_1 - \mu_2 = 0 \\ H_a : \mu_1 - \mu_2 \neq 0 \end{cases}$, como mencionado no problema;
2. Nível de significância $\alpha = 5\%$, o mesmo considerado no teste de hipóteses para as variâncias;
3. Comparar as variâncias: Foi realizada no Exemplo 53, cuja decisão foi de que elas podem ser consideradas iguais a 5% de significância;
4. Cálculo da estatística. Temos:

$$\Delta = 0;$$

$$n_1 = n_2 = n = 10;$$

$$s_1^2 \approx 100,62; s_2^2 \approx 49,66;$$

$$\bar{X}_1 = 161,8; \bar{X}_2 = 165,9.$$

Primeiro, precisamos obter o valor de s ,

$$s = \sqrt{\frac{(n-1)(s_1^2 + s_2^2)}{2n-2}} = \sqrt{\frac{9(100,62 + 49,66)}{18}} \approx 8,67.$$

Agora, podemos obter a estatística do teste,

$$T = \frac{\bar{X}_1 - \bar{X}_2 - \Delta}{s\sqrt{\frac{2}{n}}} = \frac{161,8 - 165,9 - 0}{8,67\sqrt{\frac{2}{10}}} = \frac{-4,10}{3,88} \approx -1,06;$$

5. Valor crítico: Temos que $t_{crítico} = t_{0,025}(18) = 2,10$, o qual pode ser obtido no R ou na tabela da distribuição t -Student (ver Tabela A2 do Apêndice);
6. Decisão: Como $|T| \not\geq t_{0,025}(18)$, então há indícios de que as médias não diferem entre si a 5% de significância.

Considerando a função do R:

```

> x<-c(164,167,171,149,147,155,180,166,160,159)
> y<-c(153,168,172,158,167,168,170,158,174,171)
> testemediasnp(x,y,0.05,"diferente")
[1] "Não Rejeito H0"
$statistic t -1.057637
$parameter df 18
$p.value
[1] 0.3042093
$conf.int
[1] -12.244367 4.044367
attr(,"conf.level")
[1] 0.95
$estimate mean of x mean of y
      161.8      165.9
$null.value difference in means 0

```

O quantil da distribuição t -Student para comparação é 2,10. E as conclusões podem ser obtidas pela comparação desse valor com o valor da estatística apresentado nas rotinas, segundo a mesma regra de decisão usada na resolução apresentada, cuja conclusão é que não rejeitamos H_0 .

Exemplo 58. *Consideramos o desempenho de duas equipes de vendas de seguros pessoais, que estão atuando em duas cidades com grandes similaridades quanto ao número de habitantes e renda familiar. A administradora dos seguros deseja comparar o desempenho das equipes na venda. Foram observadas as quantidades de vendas efetuadas em uma semana.*

Grupo	Segunda	Terça	Quarta	Quinta	Sexta	Sábado
A	56	46	23	13	14	56
B	34	34	-	21	24	34

O dado faltante corresponde a um dia de feriado na cidade, no qual a equipe B não atuou.

Solução:

1. Hipóteses de interesse: $\begin{cases} H_0 : \mu_1 - \mu_2 = 0 \\ H_a : \mu_1 - \mu_2 \neq 0 \end{cases}$, pois o interesse é verificar se os

grupos tiveram desempenhos similares;

2. Nível de significância: Vamos utilizar $\alpha = 5\%$;

3. Comparar as variâncias: Vamos utilizar o teste via programa R, para decidir sobre a igualdade ou não das variâncias.

```
> x<-c(56,46,23,13,14,56)
> y<-c(34,34,21,24,34)
> var.test(x, y, alternative="two.sided", conf.level=0.95)
F test to compare two variances
data:  x and y
F = 10.154, num df = 5, denom df = 4, p-value = 0.04331
alternative hypothesis: true ratio of variances is not equal to
1
95 percent confidence interval: 1.084268 75.013598
sample estimates: ratio of variances 10.15359
```

Os resultados foram: $F_{calc} = 10,15$ e $F_{tab} = 9,36$. Como $F_{calc} > F_{tab}$, ou também, como o p-valor é menor que 0,05, então a 5% de significância as variâncias são consideradas distintas.

4. Cálculo da estatística: Temos:

$n_1 = 6$, $n_2 = 5$, $s_1^2 \approx 414,27$, $s_2^2 = 40,80$, $\bar{X}_1 \approx 34,67$, $\bar{X}_2 = 29,40$
e $\Delta = 0$.

Agora, podemos obter a estatística do teste:

$$T = \frac{\bar{X}_1 - \bar{X}_2 - \Delta}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} = \frac{34,67 - 29,40 - 0}{\sqrt{\frac{414,27}{6} + \frac{40,80}{5}}} = \frac{5,27}{8,79} \approx 0,60;$$

5. Valor crítico: Precisamos determinar os graus de liberdade para obtermos o valor crítico. Tem-se que: $w_i = \frac{s_i^2}{n_i}$, portanto, $w_1 \approx 69,04$ e $w_2 = 8,16$. Aplicando na fórmula, temos:

$$\nu = \frac{(w_1 + w_2)^2}{\frac{w_1^2}{n_1 - 1} + \frac{w_2^2}{n_2 - 1}} = \frac{(69,04 + 8,16)^2}{\frac{69,04^2}{5} + \frac{8,16^2}{4}} = \frac{5.959,84}{953,30 + 16,65} = \frac{5.959,84}{969,95} \approx 6,14.$$

Logo, consideramos $\nu = 6$.

E, por consequência, $t_{crítico} = t_{0,025}(6) = 2,44$, o qual pode ser obtido na tabela da distribuição t -Student (Tabela A2 do Apêndice) ou no R.

6. Decisão: Como $|T| < t_{0,025}(6)$, o teste revela que não há indícios de que as equipes de vendas apresentaram desempenhos médios diferentes ao nível de 5% de significância.

Utilizando o *software* R para realizar o teste de comparação de médias para dados não pareados, procede-se da seguinte forma:

```
> x<-c(56,46,23,13,14,56)
> y<-c(34,34,21,24,34)
> testemediasnp(x,y,0.05,"diferente")
[1] "Não Rejeito H0"
$statistic t 0.5993972
$parameter df 6.144407
$p.value
[1] 0.5703349
$conf.int
[1] -16.11149 26.64482
attr("conf.level")
[1] 0.95
$estimate mean of x mean of y
      34.66667 29.40000
$null.value difference in means 0
$alternative
[1] "two.sided"
$method
[1] "Welch Two Sample t-test"
```

Conforme estes resultados, como o p-valor $> 0,05$, não rejeitamos a hipótese de igualdade das médias. É importante ressaltar que esta função também retorna o intervalo de confiança para a diferença das médias: $(-16,11149; 26,64482)$. Como foi discutido no capítulo anterior, já que o valor 0 (não há diferença) está contido dentro do intervalo, não rejeitamos a hipótese de igualdade das médias a 5% de significância.

Exemplo 59. *Considere as medidas estatísticas obtidas de duas amostras não pareadas, sendo que as variâncias são consideradas diferentes a 5% de significância. Verifique se, a 5% de significância, as médias podem ser consideradas iguais.*

Grupo	Média	Variância	n
A	24	56,98	12
B	30	24,89	8

Solução:

As hipóteses de interesse são: $\begin{cases} H_0 : \mu_1 - \mu_2 = 0 \\ H_a : \mu_1 - \mu_2 \neq 0 \end{cases}$ e temos variâncias distintas com $\alpha = 5\%$.

Alguns passos do processo já foram supridos, então vamos aos que estão faltando.

4. Cálculo da estatística do teste:

$$T = \frac{\bar{X}_1 - \bar{X}_2 - \Delta}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} = \frac{24 - 30 - 0}{\sqrt{\frac{56,98}{12} + \frac{24,89}{8}}} = \frac{-6}{2,8} \approx -2,14;$$

5. Valor crítico: Precisamos dos graus de liberdade: $w_i = \frac{s_i^2}{n_i}$, donde temos $w_1 \approx 4,75$ e $w_2 \approx 3,11$. Logo,

$$\nu = \frac{\frac{(w_1 + w_2)^2}{\frac{w_1^2}{n_1 - 1} + \frac{w_2^2}{n_2 - 1}}}{2,05 + 1,38} \approx 18,01.$$

Assim, consideramos $\nu = 18$.

Temos que: $t_{crítico} = t_{0,025}(18) = 2,10$ (ver tabela ou R);

6. Decisão: Como $|T| > t_{0,025}(18)$, conclui-se que os dados apresentam evidências de que as médias são diferentes ao nível de 5% de significância.

Como não temos o conjunto de dados, este teste não pode ser realizado utilizando a função `t.test`, mas é possível implementar passo a passo as contas no R. O código está a seguir.

```
> x1<-24; x2<-30; s1<-56.98; s2<-24.89; n1<-12; n2<-8; alpha<-0.05
> T<-(x1-x2)/sqrt(s1/n1+s2/n2)
> w1<-s1/n1
> w2<-s2/n2
> gl<-((w1+w2)^2)/(((w1^2)/(n1-1))+((w2^2)/(n2-1)))
> tcritico<-qt(alpha/2, gl, lower.tail=FALSE)
> abs(T); tcritico
[1] 2.140186
[1] 2.100953
```

Como $|T| > t_{0,025}(18)$, conclui-se que os dados apresentam evidências de que as médias são diferentes ao nível de 5% de significância.

Exemplo 60. Considere as medidas estatísticas obtidas de duas amostras não pareadas, sendo que as variâncias são consideradas iguais a 10% de significância. Verifique se, a 10%, as médias podem ser consideradas iguais.

Grupo	Média	Variância	n
A	8,54	32,21	9
B	12,87	25,89	15

Solução:

As hipóteses a serem testadas são: $\begin{cases} H_0 : \mu_1 - \mu_2 = 0 \\ H_a : \mu_1 - \mu_2 \neq 0 \end{cases}$, com $\alpha = 10\%$ e as variâncias são iguais.

4. Cálculo da estatística do teste:

$$n_1 = 9, \quad n_2 = 15, \quad s_1^2 = 32,21, \quad s_2^2 = 25,89, \quad \bar{X}_1 = 8,54, \quad \bar{X}_2 = 12,87$$

e $\Delta = 0$.

Primeiro, precisamos obter o valor de s , que é dado por:

$$\begin{aligned} s &= \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}} = \sqrt{\frac{8 \times 32,21 + 14 \times 25,89}{9 + 15 - 2}} \\ &= \sqrt{\frac{620,14}{22}} \approx 5,31. \end{aligned}$$

Calculando a estatística do teste, temos:

$$T = \frac{\bar{X}_1 - \bar{X}_2 - \Delta}{s \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} = \frac{8,54 - 12,87 - 0}{5,31 \sqrt{\frac{1}{9} + \frac{1}{15}}} = \frac{-4,33}{2,24} \approx -1,93;$$

5. Valor crítico: Temos que $t_{crítico} = t_{0,05}(22) = 1,71$, o qual pode ser obtido no R ou em tabelas;
6. Decisão: Como $|T| > t_{0,05}(22)$, os dados evidenciam que as médias diferem entre si a 10% de significância. Portanto, a diferença quantitativa observada nas médias amostrais não é fruto do acaso.

A seguir, expomos a rotina para efetuar os cálculos do exemplo anterior via R.

```
> n1<-9; n2<-15; s1<-32.21; s2<-25.89; x1<-8.54; x2<-12.87; delta<-0
> alpha<-0.1
> S<-sqrt(((n1-1)*s1+(n2-1)*s2)/(n1+n2-2))
> T<-(x2-x1-delta)/(S*sqrt((1/n1)+(1/n2)))
> gl<-n1+n2-2
> tcritico<-qt(alpha/2, gl, lower.tail=FALSE)
> abs(T); tcritico
[1] 1.934263
[1] 1.717144
```

Como $|T| > t_{0,05}(22)$, os dados evidenciam que as médias diferem entre si a 10% de significância.

6.4 Considerações finais

Em artigos científicos, geralmente as conclusões de testes de hipóteses são feitas pelo p-valor, mas concluir pela estatística é equivalente.

A metodologia de testes de hipóteses abordada se adequa a duas amostras, mas há casos com maior quantidade de amostras envolvidas e, nestes casos, outras metodologias devem ser utilizadas, como por exemplo, a abordada no próximo capítulo.

6.5 Exercícios propostos

Exercício 1. Numa fábrica de parafusos, deseja-se verificar se há diferença na variabilidade do diâmetro (em mm) das peças produzidas por duas máquinas (M1 e M2). Foram selecionadas duas amostras com 10 parafusos cada, cujos dados são:

M1	6,00	5,98	6,00	6,00	6,02	6,00	6,02	6,01	5,99	6,01
M2	5,96	5,98	5,97	5,99	6,00	6,00	5,95	6,00	5,98	6,01

Supondo normalidade das populações, podemos concluir com 2% de significância, que as duas máquinas produzem parafusos com a mesma variância?

Exercício 2. Com base nos resultados encontrados no exercício anterior, teste, com o nível de significância de 2%, as hipóteses:

$$\text{a) } \begin{cases} H_0 : \mu_1 = \mu_2 \\ H_a : \mu_1 \neq \mu_2 \end{cases}$$

$$\text{b) } \begin{cases} H_0 : \mu_1 = \mu_2 \\ H_a : \mu_1 < \mu_2 \end{cases}$$

$$\text{c) } \begin{cases} H_0 : \mu_1 = \mu_2 \\ H_a : \mu_1 > \mu_2 \end{cases}$$

Exercício 3. Seja $n_1 = 9$, $\bar{X}_1 = 7,3$, $s_1^2 = 9$, $n_2 = 11$, $\bar{X}_2 = 14,1$ e $s_2^2 = 36$. Teste, com o nível de significância de 10%, a hipótese $H_0 : \mu_1 = \mu_2$ contra a alternativa $H_a : \mu_1 \neq \mu_2$, considerando variâncias iguais e diferentes. Comente sobre as diferenças (ou não diferenças) encontradas.

Exercício 4. Suponha que a distribuição das alturas (em cm) dos homens de duas diferentes localidades (A e B) do Brasil são aproximadamente Normais. Foram retiradas duas amostras aleatórias, uma de cada localidade, obtendo-se: $n_A = 16$ homens; $\bar{X}_A = 167$ cm; $s_A = 9$ cm; $n_B = 25$ homens; $\bar{X}_B = 176$ cm; $s_B = 5$ cm. Admitindo um nível de significância de 5%, teste a hipótese de igualdade contra diferença para a variância e média das alturas dos homens das duas localidades.

Exercício 5. Para avaliar a eficácia de uma campanha regional para o consumo racional de energia elétrica durante os meses de inverno em uma cidade do interior paulista, tomou-se uma amostra aleatória de 24 residências e registrou-se o consumo total de energia elétrica (em kWh) nos 30 dias antes e depois da veiculação da campanha nos meios de comunicação. Os dados são apresentados a seguir.

Antes da campanha	267,2	293,7	250,0	310,8	315,2	191,8	290,6	279,5
	330,6	227,3	273,8	226,7	251,7	239,7	296,3	266,1
	194,8	227,7	211,6	232,1	256,8	262,3	262,1	266,8
Após a campanha	175,4	196,9	184,9	218,9	239,5	124,8	197,5	201,2
	237,5	140,7	196,3	177,4	163,6	173,4	166,7	233,4
	124,1	126,7	180,3	175,9	186,2	190,3	192,9	186,5

Com 6% de significância, pode-se concluir que a campanha regional surtiu efeito?

Exercício 6. Uma pesquisa visava avaliar a eficácia de um medicamento na redução do nível do colesterol total. Foram considerados 7 pacientes e mediu-se a concentração (em miligramas por decilitro, mg/dl) de colesterol total antes e depois do tratamento. Os dados obtidos foram:

Antes	217	230	227	245	206	230	229
Depois	184	199	190	215	183	182	198

Considerando o nível de significância de 1%, pode-se concluir que o tratamento com esta droga:

- Reduziu a taxa média de colesterol total ($\Delta = 0$)?
- Reduziu a taxa média de colesterol total em mais de 30 mg/dl ($\Delta = 30$)?
- Considerando $\alpha = 5\%$, as conclusões dos itens (a) e (b) seriam as mesmas?

Comente.

Exercício 7. Para os testes de hipóteses a seguir, calcule o p-valor e conclua adotando $\alpha = 5\%$. (Sugestão: use as funções `pt` e `pf` do R.)

- $\begin{cases} H_0 : \mu_1 - \mu_2 = 10 \\ H_a : \mu_1 - \mu_2 \neq 10 \end{cases}$, sabendo que: $n = 20$, $\bar{d} = 13,5$ e $s_d^2 = 28,1$.
- $\begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_a : \sigma_1^2 < \sigma_2^2 \end{cases}$, sabendo que: $n_1 = 12$, $s_1^2 = 144$, $n_2 = 15$ e $s_2^2 = 256$.
- $\begin{cases} H_0 : \mu_1 - \mu_2 = 5 \\ H_a : \mu_1 - \mu_2 > 5 \end{cases}$, sabendo que: $n_1 = 10$, $\bar{X}_1 = 27,5$, $s_1^2 = 100$, $n_2 = 10$, $\bar{X}_2 = 20,4$ e $s_2^2 = 196$.

Capítulo 7

Análise de variância

Resumo do capítulo: *Neste capítulo, abordamos a análise de variância considerando experimentos completamente aleatorizados com um e dois fatores fixos, nos quais há o interesse de verificar o efeito dos tratamentos (níveis do fator ou combinações de níveis dos fatores) na variável resposta X . Os procedimentos de cálculos dessa metodologia são apresentados passo a passo e também via rotinas para o software R. Em cada tópico dispomos de exemplos resolvidos e no final do capítulo propomos alguns exercícios.*

Objetivos: *Neste capítulo, exploramos procedimentos para testar diferenças entre médias de três ou mais grupos. Temos como objetivo proporcionar ao leitor condições de identificar situações em que a análise de variância (ANOVA) pode ser utilizada, bem como ter condições de realizá-la e decidir com base nos resultados obtidos.*

7.1 Introdução

É fato que se subgrupos possuem médias quantitativamente bem diferentes, então medidas de variabilidade (variância, desvio-padrão) do grupo composto pelos subgrupos superam as dos subgrupos. A análise de diferenças entre médias é baseada neste fato, assim justifica-se o nome “análise de variância” para testes de comparação de médias.

Esse assunto está fortemente ligado às análises de experimentos que se desenvolvem em áreas diversificadas, como engenharias, ciências sociais, biologia, ciências médicas, indústria, agronomia e outras.

Portanto, utiliza-se a ANOVA - análise de variância - quando se quer comparar subgrupos da população para verificar se possíveis diferenças na variável resposta de cada um deles são devidas ao subgrupo ao qual pertencem ou ao acaso.

Também podemos entender que a ANOVA é usada para comparar tratamentos e verificar se as possíveis diferenças no resultado final são produzidas pelo próprio

tratamento ou pelo acaso. As comparações sempre são feitas sob certa probabilidade de confiança, similar aos casos de teste de hipóteses dos capítulos anteriores e também denotada por $1 - \alpha$.

As análises de variâncias aqui expostas consideram experimentos completamente aleatorizados, com um e dois fatores fixos, nos quais tem-se o interesse em verificar a influência dos K tratamentos na variável resposta X .

Ressaltamos que os níveis do fator, ou ainda, as combinações de níveis dos dois fatores, são frequentemente denominados tratamentos.

7.2 Exemplos e discussões

Em artigos científicos de diversas áreas, é frequente a utilização da ANOVA. Esses abrangem desde estudos acadêmicos até elaboradas e caras pesquisas científicas. Muitas situações poderiam ser explanadas para exemplificar. A seguir, apresentamos algumas.

1) Área agrícola

i) Fertilizantes e desenvolvimento da planta.

Objetivo: Verificar se certas composições de fertilizantes influenciam na produtividade (crescimento, resistência) de plantas. Podem ser testadas K composições, em que K geralmente é denominado número de tratamentos.

Desenvolvimento: Obtendo amostras (variável resposta) das K composições, faz-se a comparação dos resultados para verificar se as K composições podem ser consideradas iguais. A ANOVA indica apenas se há ou não diferenças, levando em consideração o nível de significância fixado. A classificação de qual ou quais são os melhores/piores tratamentos, requer novas metodologias.

Observação: Se as composições forem testadas para uma espécie específica, o resultado não pode ser estendido para outras espécies, consequência do que chamamos de “experimento de um fator fixo”.

ii) Espaçamento no plantio e desenvolvimento da planta.

Objetivo: Verificar se o espaçamento entre as plantas é um fator que influencia no seu desenvolvimento. Pode-se testar, ao mesmo tempo, vários espaçamentos e eles são denominados de níveis do fator, cuja quantidade será indicada por K .

Desenvolvimento: Dispondo dos dados, a ANOVA indicará se o desenvolvimento da planta sofre influência dos espaçamentos. Ressaltando que o delineamento do experimento deve ser criterioso a fim de não invalidar o experimento. Lembramos também que os procedimentos relacionados ao delineamento experimental não são assuntos deste compêndio, mas são facilmente encontrados em literaturas específicas.

Observação: Nessa área, a metodologia também é utilizada para testar se um novo conceito de cultivo é realmente benéfico, os quais podem ser: irrigação, clima, solo, cultivar etc.

2) Ciências médicas

i) Dosagem e enfermidade.

Objetivo: Verificar se a dosagem de medicamento afeta a enfermidade em questão.

Desenvolvimento: Testam-se várias dosagens em cobaias, bactérias ou vírus, e analisam-se os resultados para decidir se as diferenças observadas foram provocadas pelas dosagens utilizadas, ou simplesmente foram oriundas do acaso.

Observação: Até mesmo a dosagem ótima para combater uma moléstia pode ser obtida em decorrência de sucessivas ANOVAs, em que a menor dose que proporciona os melhores resultados deve ser recomendada. Uma situação similar é quando, ao invés de dosagens diferentes, tem-se compostos diferentes para combater a doença.

ii) Dieta e desnutrição infantil.

Objetivo: Verificar se, no tratamento de desnutrição infantil, as K dietas propostas possuem diferentes desempenhos.

Desenvolvimento: Utilizando os dados de ganhos de peso das crianças sujeitas às dietas, realiza-se a ANOVA para verificar a existência de possível contribuição das dietas nos resultados.

3) Ciências sociais

i) Metodologias de ensino e aprendizagem.

Objetivo: Verificar se a aprendizagem dos alunos está relacionada com o tipo de metodologia de ensino utilizada.

Observação: Variados métodos de ensino são propostos por pesquisadores, alguns deles são defendidos por muitos educadores. Pode-se testar se os métodos de ensino surtem efeitos distintos em populações distintas (comunidades carentes, grandes centros, periferias). Mas também pode-se comparar apenas os efeitos dos diferentes métodos.

ii) Grau de privação econômica e delinquência juvenil.

Objetivo: Verificar se o grau de privação econômica (ausente, brando, moderado, severo) a que um jovem é submetido, influencia na sua adesão à marginalidade, ou se este fator é irrelevante para caracterizar a delinquência juvenil.

iii) Grau de instrução e tempo de desemprego (planejamento familiar, realização pessoal, rendimento profissional).

Objetivo: Será que o grau de instrução está relacionado com os índices de desemprego, ou então com a atuação profissional das pessoas? Ou será que o grau de instrução interfere na realização profissional que o cidadão atinge, bem como no rendimento profissional que consegue? E ainda, o grau de instrução influencia no tempo de procura por uma colocação no mercado de trabalho?

Observação: Tais comparações são realizadas pelo IBGE após o censo. A elas, podem ser incorporados outros fatores, como região demográfica e sexo.

4) Indústria

i) Produção e equipamento.

Objetivo: Comparar se diversos tipos de ajustes nos equipamentos da indústria produzem resultados iguais, em média.

ii) Produção e turno de serviço.

Objetivo: Verificar se a produtividade (quantidade, qualidade) sofre influência do turno de produção ou se as possíveis diferenças são apenas frutos do acaso.

7.2.1 Notações

Fator: Corresponde a “o que” a variável resposta está associada. Isto é, “o que” possivelmente está influenciando na resposta. Em uma situação, podemos ter um, dois ou mais fatores envolvidos.

Exemplo 61. Na relação “grau de instrução e tempo de desemprego”, adotamos como variável resposta o “tempo de desemprego” e julgamos que o fator “grau de instrução” pode estar influenciando-a. Mas poderíamos ter outros fatores incorporados na análise, como, por exemplo, idade, localização geográfica, sexo, raça e experiência profissional.

Tratamentos/níveis do fator: Correspondem às classes entre as quais pretende-se verificar diferenças ou semelhanças. Sua quantidade é denotada por K .

Exemplo 62. Na relação “grau de instrução e tempo de desemprego”, é possível subdividir o primeiro quesito em:

k_1 : Analfabeto;

k_2 : Educação básica incompleta;

k_3 : Educação básica completa;

k_4 : Fundamental incompleto;

k_5 : Fundamental completo;

k_6 : Superior incompleto;

k_7 : Superior completo;

k_8 : *Especialista*.

Poderíamos considerar outros níveis, mas pelo exposto, temos $K = 8$.

Quantidade de dados da variável resposta: Tendo K níveis do fator, coletam-se dados de cada um deles. O total de dados coletados é indicado por N e $N = \sum_{i=1}^K R_i$, em que i é o nível do fator e R_i é a quantidade de dados de cada nível.

Variável resposta: Dados numéricos serão obtidos e indicados por X_{ij} , em que i indica o nível do fator e j corresponde à quantidade de elementos do nível, $j = 1, 2, \dots, R_i$ e $i = 1, 2, \dots, K$. Os valores X_{ij} são realizações da variável aleatória X .

Exemplo 63. Na tabela a seguir, ilustramos como pode ser representado um conjunto de dados para ANOVA.

	<i>Nível (Tratamento)</i>			
	T_1	T_2	$\dots$	T_K
<i>Dados</i>	X_{11}	X_{21}	$\dots$	X_{K1}
	X_{12}	X_{22}	$\dots$	X_{K2}
	$\vdots$	$\vdots$	$\vdots$	$\vdots$
	X_{1R_1}	X_{2R_2}	$\dots$	X_{KR_K}
<i>Média amostral</i>	$\bar{X}_1$	$\bar{X}_2$	$\dots$	$\bar{X}_K$

Para proceder à ANOVA, é necessário expressar os dados em termos de médias amostrais, obter número de repetições e total de dados e fixar o nível de significância desejado.

Média amostral: Serão K médias, uma para cada tratamento: $\bar{X}_i = \frac{1}{R_i} \sum_{j=1}^{R_i} X_{ij}$, $i = 1, 2, \dots, K$

Total de dados: $N = \sum_{i=1}^K R_i$

Média amostral geral: $\bar{X} = \frac{1}{N} \sum_{i=1}^K \sum_{j=1}^{R_i} X_{ij} = \frac{1}{K} \sum_{i=1}^K \bar{X}_i$

Precisamos também indicar o nível de significância α .

7.3 Análise de variância com um fator fixo

7.3.1 Modelo estatístico

O modelo estatístico associado aos experimentos com um fator fixo é da forma:

$$X_{ij} = \mu + E_i + e_{ij}, \quad (7.1)$$

para $i = 1, 2, \dots, K$ e $j = 1, 2, \dots, R_i$.

Em (7.1), temos que:

- X_{ij} é a variável resposta;
- μ é a média geral, comum a todas as observações (ela é estimada por $\bar{X}$);
- E_i é o efeito do i -ésimo nível do fator (tratamento) em X_{ij} . Ele mede o desvio da média do tratamento (μ_i) em relação à média geral (μ): $E_i = \mu_i - \mu$ (ele é estimado por $\bar{X}_i - \bar{X}$);
- e_{ij} é o erro aleatório associado a X_{ij} . Ele não é controlado e nem observado, mas espera-se que assuma valores pequenos e que X_{ij} dependa mais de E_i do que de e_{ij} .

7.3.2 Suposições do modelo

As suposições geralmente estão associadas aos erros (e_{ij}), os quais devem ser variáveis aleatórias independentes e identicamente distribuídas (iid) com distribuição $N(0, \sigma^2)$.

Porém, a variável resposta X_{ij} é função dos erros, portanto, como consequência das suposições sobre os erros, temos que X_{ij} são variáveis aleatórias independentes, com $X_{ij} \sim N(\mu_i, \sigma^2)$ e $\mu_i = \mu + E_i$.

Assim, as amostras aleatórias dos K tratamentos podem ou não ter médias iguais.

7.3.3 Hipóteses

Quer-se verificar se as médias dos K tratamentos são iguais. Sendo $\mu_i = \mu + E_i$, testar a igualdade das médias dos tratamentos equivale a testar se os efeitos dos tratamentos são iguais a zero.

Logo, escrevemos as hipóteses como sendo:

$$\begin{cases} H_0 : E_i = 0 & \text{para todo } i, i = 1, 2, \dots, K & \rightarrow & \text{hipótese nula} \\ H_a : E_i \neq 0 & \text{para pelo menos um } i & \rightarrow & \text{hipótese alternativa} \end{cases}$$

A decisão entre as hipóteses é feita mediante a ANOVA.

7.3.4 Tabela ANOVA

A ANOVA apresenta evidências, ao nível de significância fixado, de existir ou não efeito do nível (tratamento) na variável resposta.

A tabela ANOVA é apresentada da seguinte forma:

Fonte de variação	Graus de liberdade	Soma dos quadrados	Quadrados médios	Estatística F
Fator	$K - 1$	SQF	$QMF = \frac{SQF}{K - 1}$	$F_0 = \frac{QMF}{QMR}$
Resíduo	$N - K$	SQR	$QMR = \frac{SQR}{N - K}$	
Total	$N - 1$	$SQT = SQF + SQR$		

Em que:

$$SQF = \sum_{i=1}^K R_i (\bar{X}_i - \bar{X})^2 \quad \text{e} \quad SQR = \sum_{i=1}^K \sum_{j=1}^{R_i} (X_{ij} - \bar{X}_i)^2.$$

7.3.5 Regra de decisão

Temos que, sob a hipótese H_0 , a estatística do teste tem distribuição F de Fisher-Snedecor com $K - 1$ e $N - K$ graus de liberdade no numerador e denominador, respectivamente, isto é,

$$F_0 \sim F_{(K-1, N-K)}.$$

A regra de decisão está fundamentada na comparação da estatística do teste com o quantil $1 - \alpha$ da distribuição F com graus de liberdade e nível de confiança já especificados, e seu valor pode ser obtido via programas como o R ou na tabela da distribuição.

Portanto,

a) Se $F_0 > F_{(K-1, N-K)}(1 - \alpha)$, concluímos que há diferenças entre as médias dos tratamentos (níveis do fator). Logo, rejeitamos H_0 em favor de H_a ao nível de significância $100(\alpha)\%$.

Ou pelo p-valor:

b) Se $\text{p-valor} = P(F_{(K-1, N-K)} > F_0) < \alpha$, concluímos que, ao nível de significância $100(\alpha)\%$, as médias dos tratamentos diferem entre si, ou seja, rejeitamos H_0 .

7.3.6 Interpretação dos elementos da ANOVA

SQF : Soma dos quadrados entre tratamentos $\rightarrow$ mede a variabilidade entre as médias dos tratamentos em relação à média geral. Quanto maior a diferença entre estas, maior será o valor de SQF . Sob H_0 , temos que $SQF/\sigma^2 \sim \chi_{K-1}^2$.

SQR : Soma dos quadrados dentro dos tratamentos ou dos resíduos $\rightarrow$ medida de homogeneidade dos tratamentos. Quanto mais próximos forem os valores observados em cada tratamento, menor será seu valor. Sob H_0 , temos que $SQR/\sigma^2 \sim \chi_{N-K}^2$.

SQT : Soma total dos quadrados $\rightarrow$ mede a variabilidade total das observações em relação à média geral.

QMF : Quadrados médios entre tratamentos $\rightarrow$ é um estimador não viciado da variância σ^2 , isto se H_0 for verdadeira.

QMR : Quadrados médios dentro dos tratamentos $\rightarrow$ é um estimador não viciado da variância σ^2 .

7.3.7 Intervalo de confiança para a média de cada tratamento

Das suposições de normalidade, temos que $\bar{X}_i \sim N(\mu_i, \sigma^2/R_i)$. Como geralmente σ^2 é desconhecido, utilizamos QMR como estimador não viciado deste parâmetro. Assim,

$$\text{IC}[\mu_i, 100(1 - \alpha)\%] = \bar{X}_i \pm t_c \sqrt{\frac{QMR}{R_i}},$$

em que t_c é o quantil de ordem $1 - \alpha/2$ da distribuição t -Student com $N - K$ graus de liberdade.

Isto decorre do fato que $\frac{\bar{X}_i - \mu_i}{\sqrt{\frac{QMR}{R_i}}} \sim t_{N-K}$.

Exemplo 64. *Uma fábrica de bombons está com três tipos de máquinas que auxiliam na produção dos mesmos. Os bombons são produzidos pelas máquinas e posteriormente são embalados. Foram escolhidos aleatoriamente 9 bombons de cada uma das*

máquinas e obtidos seus pesos (g).

Observação	Máquina 1	Máquina 2	Máquina 3
1	35,0	38,9	36,4
2	35,3	36,7	36,0
3	34,3	38,7	35,3
4	35,7	38,8	36,8
5	35,2	37,6	36,9
6	34,2	37,2	37,5
7	36,5	38,8	35,3
8	35,6	38,0	36,0
9	35,5	37,2	35,7

O objetivo da amostragem é determinar se existe diferença no peso dos bombons que as máquinas produzem.

Solução:

Temos um caso de comparação de médias com um fator apenas - máquina - e três níveis desse fator/tratamentos - máquinas 1, 2 e 3. Para cumprir com os objetivos da amostragem, a ANOVA pode ser utilizada. Porém, será que ela é realmente necessária? Antes de iniciar a ANOVA, façamos a análise exploratória dos dados, para conhecê-los melhor e justificar ou não o uso da metodologia.

Obtemos as estatísticas descritivas dos dados:

Dados	Média	Desvio-padrão
Máquina 1	35,26	0,71
Máquina 2	37,99	0,84
Máquina 3	36,21	0,75
Todos	36,4	1,37

É evidente que a variância, considerando todos os dados, supera a variância de cada tratamento, como anteriormente mencionado. Isto é uma evidência de que o conjunto de dados tem características que justificam a aplicação da ANOVA.

Outra questão importante que precede a ANOVA, é a análise gráfica dos dados de cada nível do fator (tratamento), com o intuito de verificar a dispersão e a disposição dos dados de cada nível em relação aos outros. Isto pode ser realizado utilizando o gráfico *box plot*, apresentado na Figura 7.1.

Percebe-se que há supremacia dos dados do segundo grupo (máquina 2).

Passamos agora a identificar os dados e obter as estatísticas necessárias para a construção da tabela ANOVA e, posteriormente, concluirmos a análise.




Figura 7.1: *Box plots* dos diferentes níveis.

$$\begin{aligned}
 R_1 &= 9; & R_2 &= 9; & R_3 &= 9; \\
 N &= 27; & K &= 3; & \bar{X} &= 36,49; \\
 \bar{X}_1 &= 35,26; & \bar{X}_2 &= 37,99; & \bar{X}_3 &= 36,21.
 \end{aligned}$$

Obtendo os elementos da tabela ANOVA:

$$\begin{aligned}
 SQF &= \sum_{i=1}^K R_i (\bar{X}_i - \bar{X})^2 = R_1 (\bar{X}_1 - \bar{X})^2 + R_2 (\bar{X}_2 - \bar{X})^2 + R_3 (\bar{X}_3 - \bar{X})^2 \\
 &= 9 \times (35,26 - 36,49)^2 + 9 \times (37,99 - 36,49)^2 + 9 \times (36,21 - 36,49)^2 \\
 &= 13,61 + 20,35 + 0,68 \\
 &= 34,63.
 \end{aligned}$$

$$\begin{aligned}
 SQR &= \sum_{i=1}^K \sum_{j=1}^{R_i} (X_{ij} - \bar{X}_i)^2 \\
 &= \sum_{j=1}^9 (X_{1j} - \bar{X}_1)^2 + \sum_{j=1}^9 (X_{2j} - \bar{X}_2)^2 + \sum_{j=1}^9 (X_{3j} - \bar{X}_3)^2 \\
 &= 4,02 + 5,71 + 4,53 \\
 &= 14,26.
 \end{aligned}$$

De posse desses resultados, podemos montar a tabela ANOVA.

Fonte de variação	Graus de liberdade (<i>gl</i>)	Soma dos quadrados (<i>SQ</i>)	Quadrados médios (<i>QM</i>)	Estatística <i>F</i>
Entre (Fator)	2	34,63	17,32	29,14
Dentro (Resíduo)	24	14,26	0,59	
Total	26	48,89		

Antes de decidirmos, precisamos fixar o nível de significância que desejamos para o teste. Consideremos $\alpha = 5\%$.

Para decidir se as máquinas produzem bombons com pesos diferentes, comparamos o valor $F_0 = 29,14$, com o valor tabelado, $F_{tab} = F_{(2,24)}(0,95) = 3,40$.

Pela regra de decisão, como $F_0 > F_{tab}$, rejeitamos H_0 , isto é, os dados apresentam evidências, a 5% de significância, de que há diferença entre as médias.

Essa análise indica apenas que as três máquinas não trabalham de forma semelhante (a 5% de significância), não evidenciando se todas diferem entre si, ou qual delas difere. Novamente enfatizando, indica apenas que elas produzem resultados diferentes a 5% de significância.

Para decidirmos qual a melhor máquina (seja ela associada ao maior ou ao menor valor de peso), é necessário realizar testes de comparação de médias, que se considerarmos duas a duas, podem ser os testes aqui apresentados em capítulos anteriores, ou então as metodologias, como os testes de Tukey, Duncan, Scheffé, Bonferroni e outros, os quais não são tratados neste material.

Os cálculos da ANOVA acima podem ser realizados passo a passo no R, cujos códigos são dados a seguir.

```
# Códigos em R:
> m1<-c(35,35.3,34.3,35.7,35.2,34.2,36.5,35.6,35.5)
> m2<-c(38.9,36.7,38.7,38.8,37.6,37.2,38.8,38,37.2)
> m3<-c(36.4,36,35.3,36.8,36.9,37.5,35.3,36,35.7)
> d<-c(m1,m2,m3)
> boxplot(m1,m2,m3,names=c("Máquina 1","Máquina 2","Máquina 3"),ylab=
  "Peso (g)",col=c("darkblue","green","red"))
> alpha<-0.05          # nível de significância do teste
> K<-3                 # número de tratamentos
> N<-length(d); R1<-length(m1); R2<-length(m2); R3<-length(m3)
> X<-mean(d); X1<-mean(m1); X2<-mean(m2); X3<-mean(m3)
> X; X1; X2; X3      # médias
> sd(d); sd(m1); sd(m2); sd(m3)  # desvios-padrão
> SQF<-R1*((X1-X)^2)+R2*((X2-X)^2)+R3*((X3-X)^2)
> SQR1<-sum((m1-X1)^2); SQR2<-sum((m2-X2)^2); SQR3<-sum((m3-X3)^2)
```

```

> SQR<-sum(SQR1+SQR2+SQR3); SQT<-SQF+SQR
> QMF<-SQF/(K-1); QMR<-SQR/(N-K)
> F0<-QMF/QMR
> F_tab=qf(1-alpha, K-1, N-K) # quantil da distribuição F-Snedecor
# Resultados
> SQR; SQF; SQT; QMF; QMR
> F0; F_tab

```

Os resultados obtidos são os mesmos apresentados na tabela ANOVA. Note que mostramos, inicialmente, o passo a passo para calcular os resultados de interesse. Vale ressaltar que o *software* R já possui tal procedimento implementado por meio da função `anova`. No entanto, antes de apresentar tal função, iremos organizar o conjunto de dados da seguinte forma:

```

> m1<-c(35,35.3,34.3,35.7,35.2,34.2,36.5,35.6,35.5)
> m2<-c(38.9,36.7,38.7,38.8,37.6,37.2,38.8,38,37.2)
> m3<-c(36.4,36,35.3,36.8,36.9,37.5,35.3,36,35.7)
> dados<-c(m1,m2,m3)
> maquina<-c(rep("Máquina 1",length(m1)),rep("Máquina 2",
length(m2)),rep("Máquina 3",length(m3)))
> mydata<-data.frame(maquina, dados)
> mydata
  maquina dados
1 Máquina 1  35.0
2 Máquina 1  35.3
.....
9 Máquina 1  35.5
10 Máquina 2  36.7
.....
27 Máquina 3  35.7

```

Note que, inicialmente, colocamos todos os elementos em um vetor “dados”. Em seguida, criamos um outro vetor contendo a informação de a quais máquinas as observações pertenciam. Tais informações foram agrupadas em um *data.frame* (“mydata”). Por fim, utilizando a função `anova`, teremos:

```

> anova(lm(dados ~ maquina, mydata)) # ANOVA
Analysis of Variance Table

Response: dados
      Df Sum Sq Mean Sq F value    Pr(>F)
maquina    2  34.63   17.317    29.14 3.79e-07 ***
Residuals 24   14.26    0.594
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

É importante ressaltar que o vetor “dados” é a variável resposta, e “maquina” é a variável explicativa, logo “dados ~ maquina”. A função `lm` refere-se ao ajuste de um modelo de regressão linear. Tal tópico será discutido detalhadamente no próximo capítulo.

Exemplo 65. *Consideremos o experimento com quatro tratamentos, cujos valores estão apresentados na tabela a seguir.*

Repetição	Tratamento			
	A	B	C	D
1	14	13	13	14
2	16	12	22	21
3	15	15	21	16
4	18	16	18	12
5	21	18	15	14
6	13	12	19	18
Média	16,17	14,33	18,00	15,83
Desvio-padrão	2,93	2,42	3,46	3,25

A 5% de significância, os tratamentos podem ser considerados iguais?

Solução:

Temos que $\bar{X} \approx 16,08$, com desvio-padrão $s \approx 3,13$. Percebemos que o desvio-padrão geral não supera todos os desvios-padrão dos tratamentos, como no caso anterior. Pela análise dos *box plots* na Figura 7.2, percebemos que o tratamento B foi o que apresentou os menores resultados. No entanto, mais de 50% de seus valores coincidem com a região de variação dos resultados de A, e 100% com a região de variação de D.

Será que existe diferença significativa, a 5%, nas médias dos tratamentos ou podemos considerar todas elas iguais? Para responder a essa questão, realizamos a ANOVA.

Passando agora a identificar os dados, temos $K = 4$ níveis, $N = 24$ dados, sendo que cada um dos tratamentos tem $R_i = 6$ dados, $i = 1, 2, 3, 4$. Precisamos calcular os elementos da tabela ANOVA.

$$\begin{aligned}
 SQF &= \sum_{i=1}^K R_i (\bar{X}_i - \bar{X})^2 \\
 &= R_1 (\bar{X}_1 - \bar{X})^2 + R_2 (\bar{X}_2 - \bar{X})^2 + R_3 (\bar{X}_3 - \bar{X})^2 + R_4 (\bar{X}_4 - \bar{X})^2 \\
 &= 6 \times [(0,09)^2 + (-1,75)^2 + (1,92)^2 + (-0,25)^2] \\
 &= 6 \times [0,0081 + 3,0625 + 3,6864 + 0,0625] \\
 &= 40,9170.
 \end{aligned}$$




Figura 7.2: *Box plots* dos dados de cada tratamento.

$$\begin{aligned}
 SQR &= \sum_{i=1}^K \sum_{j=1}^{R_i} (X_{ij} - \bar{X}_i)^2 \\
 &= \sum_{j=1}^6 (X_{1j} - \bar{X}_1)^2 + \sum_{j=1}^6 (X_{2j} - \bar{X}_2)^2 \\
 &\quad + \sum_{j=1}^6 (X_{3j} - \bar{X}_3)^2 + \sum_{j=1}^6 (X_{4j} - \bar{X}_4)^2 \\
 &= 42,83 + 29,33 + 60,00 + 52,83 \\
 &= 184,99.
 \end{aligned}$$

Montando a tabela ANOVA:

Fonte de variação	Graus de liberdade (<i>gl</i>)	Soma dos quadrados (<i>SQ</i>)	Quadrados médios (<i>QM</i>)	Estatística <i>F</i>
Entre (Fator)	3	40,92	13,64	1,47
Dentro (Resíduo)	20	184,99	9,25	
Total	23	225,91		

Para concluirmos a respeito dos tratamentos, comparamos o valor $F_0 = 1,47$ com o valor tabelado $F_{tab} = F_{(3, 20)}(0,95) = 3,09$. Pela regra de decisão, como $F_0 \not\geq F_{tab}$,

não rejeitamos H_0 , isto é, os dados não apresentam evidências, a 5% de significância, de que haja diferença entre as médias. Desta forma, a 5% de significância, as médias entre os tratamentos podem ser consideradas iguais e as diferenças em grandeza que há entre estas não são atribuídas aos tratamentos e sim ao acaso.

Os cálculos da ANOVA acima podem ser realizados no R pelos códigos dados a seguir. Sendo que eventuais diferenças observadas são devidas a erros de aproximação.

```
> t1<-c(14,16,15,18,21,13); t2<-c(13,12,15,16,18,12)
> t3<-c(13,22,21,18,15,19); t4<-c(14,21,16,12,14,18)
> dados<-c(t1,t2,t3,t4)
> tratamento<-c(rep("T1",length(t1)),rep("T2",length(t2)),rep("T3",
  length(t3)),rep("T4",length(t4)))
> mydata<-data.frame(tratamento, dados)
> anova(lm(dados ~ tratamento, mydata)) # ANOVA
Analysis of Variance Table

Response: dados
          Df Sum Sq Mean Sq F value Pr(>F)
tratamento  3  40.83   13.61   1.471  0.252
Residuals  20 185.00    9.25
```

7.4 Análise de variância com dois fatores fixos

Em muitas situações, a variável resposta é influenciada simultaneamente por dois ou mais fatores.

A análise estatística de um experimento com dois fatores depende da forma como eles estão combinados e se são fixos ou aleatórios.

Nesta seção estudaremos os casos em que há interesse em avaliar a influência exercida pelos efeitos de dois fatores fixos, obedecendo uma classificação cruzada entre eles, denominada de interação.

Em geral, no estudo de ANOVA com dois fatores, tem-se:

- a níveis do fator A ; e
- b níveis do fator B ,

de forma que cada repetição do estudo contém informações dos dois tratamentos, e temos $a \times b$ possíveis combinações. A tabela a seguir auxilia a compreensão dessa afirmação e elucida as considerações posteriores. Ela é um esboço de um conjunto de dados típico de um experimento com dois fatores fixos.

Fator A	Fator B				Médias
	1	2	...	b	
1	X_{111}	X_{121}	...	X_{1b1}	$\bar{X}_{1..}$
	X_{112}	X_{122}	...	X_{1b2}	
	$\vdots$	$\vdots$	...	$\vdots$	
	X_{11r}	X_{12r}	...	X_{1br}	
2	X_{211}	X_{221}	...	X_{2b1}	$\bar{X}_{2..}$
	X_{212}	X_{222}	...	X_{2b2}	
	$\vdots$	$\vdots$	...	$\vdots$	
	X_{21r}	X_{22r}	...	X_{2br}	
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	$\vdots$
a	X_{a11}	X_{a21}	...	X_{ab1}	$\bar{X}_{a..}$
	X_{a12}	X_{a22}	...	X_{ab2}	
	$\vdots$	$\vdots$	...	$\vdots$	
	X_{a1r}	X_{a2r}	...	X_{abr}	
Médias	$\bar{X}_{.1.}$	$\bar{X}_{.2.}$	...	$\bar{X}_{.b.}$	$\bar{X}_{...}$

Temos que r é a quantidade de repetições de cada possível combinação entre tratamentos e X_{ijk} é a observação relativa à k -ésima unidade experimental submetida ao i -ésimo nível do fator A e ao j -ésimo nível do fator B.

7.4.1 Notações

- $N_{i.}=br$: representa o número de observações no i -ésimo nível do fator A;
- $N_{.j}=ar$: representa o número de observações no j -ésimo nível do fator B;
- $N=abr$: representa o número total de observações;
- $\bar{X}_{ij.} = \frac{1}{r} \sum_{k=1}^r X_{ijk}$: representa a média amostral da variável resposta no i -ésimo nível do fator A e no j -ésimo nível do fator B;
- $\bar{X}_{i..} = \frac{1}{br} \sum_{j=1}^b \sum_{k=1}^r X_{ijk}$: representa a média amostral da variável resposta no i -ésimo nível do fator A;
- $\bar{X}_{.j.} = \frac{1}{ar} \sum_{i=1}^a \sum_{k=1}^r X_{ijk}$: representa a média amostral da variável resposta no j -ésimo nível do fator B;
- $\bar{X}_{...} = \frac{1}{abr} \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^r X_{ijk}$: representa a média amostral geral;

- μ_{ij} : representa a média populacional da variável resposta no i -ésimo nível do fator A e no j -ésimo nível do fator B;
- $\mu_{i.}$: representa a média populacional da variável resposta no i -ésimo nível do fator A;
- $\mu_{.j}$: representa a média populacional da variável resposta no j -ésimo nível do fator B;
- μ : representa a média populacional total.

7.4.2 Modelo estatístico

O modelo estatístico associado a experimentos com dois fatores fixos é:

$$X_{ijk} = \mu + \alpha_i + \beta_j + \alpha\beta_{ij} + e_{ijk}, \quad (7.2)$$

em que $i = 1, 2, \dots, a$, $j = 1, 2, \dots, b$, $k = 1, 2, \dots, r$; e

- α_i é o efeito do i -ésimo nível do fator A, definido como $\alpha_i = \mu_{i.} - \mu$;
- β_j é o efeito do j -ésimo nível do fator B, definido como $\beta_j = \mu_{.j} - \mu$;
- $\alpha\beta_{ij}$ é o efeito da interação entre o i -ésimo nível do fator A e o j -ésimo nível do fator B, definido como $\alpha\beta_{ij} = \mu_{ij} - \mu_{i.} - \mu_{.j} + \mu$;
- e_{ijk} é o erro aleatório associado a X_{ijk} .

7.4.3 Suposições do modelo

As suposições estão associadas aos erros (e_{ijk}), os quais devem ser variáveis aleatórias iid com distribuição $N(0, \sigma^2)$.

Pela forma com que o modelo foi definido, temos as seguintes restrições:

$$\begin{aligned} \sum_{i=1}^a \alpha_i &= 0; \\ \sum_{j=1}^b \beta_j &= 0; \\ \sum_{i=1}^a \alpha\beta_{ij} &= 0, \text{ para todo } j; \text{ e} \\ \sum_{j=1}^b \alpha\beta_{ij} &= 0, \text{ para todo } i. \end{aligned}$$

Essas restrições têm como consequência que as respostas são independentes com distribuição Normal de média $\mu + \alpha_i + \beta_j + \alpha\beta_{ij}$ e variância σ^2 , ou seja,

$$X_{ijk} \sim N(\mu + \alpha_i + \beta_j + \alpha\beta_{ij}, \sigma^2).$$

Os efeitos α_i e β_j são denominados efeitos principais.

Caso não haja interação, temos que os efeitos A e B são aditivos e o modelo dado em (7.2) é substituído por:

$$X_{ijk} = \mu + \alpha_i + \beta_j + e_{ijk}.$$

7.4.4 Hipóteses

Em geral, as hipóteses de interesse são:

$$\begin{aligned} \text{a)} \quad & \begin{cases} H_{01} : \forall i, \alpha_i = 0 & \rightarrow \text{Não há efeito do fator A} \\ H_{a1} : \exists i : \alpha_i \neq 0 & \rightarrow \text{Há efeito do fator A} \end{cases} \end{aligned} \quad (7.3)$$

$$\begin{aligned} \text{b)} \quad & \begin{cases} H_{02} : \forall j, \beta_j = 0 & \rightarrow \text{Não há efeito do fator B} \\ H_{a2} : \exists j : \beta_j \neq 0 & \rightarrow \text{Há efeito do fator B} \end{cases} \end{aligned} \quad (7.4)$$

$$\begin{aligned} \text{c)} \quad & \begin{cases} H_{03} : \forall ij, \alpha\beta_{ij} = 0 & \rightarrow \text{Não há efeito da interação AB} \\ H_{a3} : \exists ij : \alpha\beta_{ij} \neq 0 & \rightarrow \text{Há efeito da interação AB} \end{cases} \end{aligned} \quad (7.5)$$

Na tabela ANOVA, os três pares de hipóteses são comparados ao mesmo tempo. Desta forma, teremos 3 estatísticas e a rejeição ou não rejeição da hipótese nula em um dos pares não afeta a decisão dos outros dois.

7.4.5 Tabela ANOVA

A tabela ANOVA para dois fatores, com amostras de mesmo tamanho, é dada por:

Fonte de variação	Graus de liberdade (<i>gl</i>)	Soma dos quadrados (<i>SQ</i>)	Quadrados médios (<i>QM</i>)	Estatística <i>F</i>
Fator A	$a - 1$	SQA	QMA	F_{01}
Fator B	$b - 1$	SQB	QMB	F_{02}
Interação AB	$(a - 1)(b - 1)$	$SQAB$	$QMAB$	F_{03}
Dentro (Resíduo)	$ab(r - 1)$	SQR	QMR	
Total	$abr - 1$	SQT		

Em que:

- $SQT = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^r (X_{ijk} - \bar{X}_{...})^2$: soma dos quadrados total;
- $SQA = br \sum_{i=1}^a (\bar{X}_{i..} - \bar{X}_{...})^2$: soma dos quadrados devido ao fator A;
- $SQB = ar \sum_{j=1}^b (\bar{X}_{.j.} - \bar{X}_{...})^2$: soma dos quadrados devido ao fator B;
- $SQAB = r \sum_{i=1}^a \sum_{j=1}^b (\bar{X}_{ij.} - \bar{X}_{i..} - \bar{X}_{.j.} + \bar{X}_{...})^2$: soma dos quadrados devido à interação entre os fatores A e B;
- $SQR = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^r (X_{ijk} - \bar{X}_{ij.})^2$: soma dos quadrados residual;
- $QMA = \frac{SQA}{a-1}$;
- $QMB = \frac{SQB}{b-1}$;
- $QMAB = \frac{SQAB}{(a-1)(b-1)}$;
- $QMR = \frac{SQR}{ab(r-1)}$;
- $F_{01} = \frac{QMA}{QMR}$: estatística de teste das hipóteses em (7.3);
- $F_{02} = \frac{QMB}{QMR}$: estatística de teste das hipóteses em (7.4);
- $F_{03} = \frac{QMAB}{QMR}$: estatística de teste das hipóteses em (7.5).

7.4.6 Interpretação dos elementos da ANOVA

SQT : Mede a variabilidade das observações em relação à média geral estimada.

SQR : Mede a variação devida ao acaso, ou seja, a variação das observações dentro de cada tratamento. A soma dos quadrados residual capta a variação natural do experimento, não levando em conta os possíveis efeitos de A e B e da interação AB.

SQA : Mede a variação devida ao acaso quando o fator A não exerce efeito sobre a variável resposta. Se existe efeito de A, então SQA reflete a variabilidade provocada por ele, além da variação devida ao acaso.

SQB : Mede a variação devida ao acaso quando o fator B não exerce efeito sobre a variável resposta. Se existe efeito de B, então SQB reflete a variabilidade provocada por ele, além da variação devido ao acaso.

$SQAB$: Mede a variação devida ao acaso quando a interação dos fatores A e B não exerce efeito sobre a variável resposta. Se existe efeito da interação dos fatores A e B, então $SQAB$ reflete a variabilidade provocada pela interação, além da variação devida ao acaso.

7.4.7 Regra de decisão

Na tabela abaixo, apresentamos a estatística de teste das hipóteses H_{01} , H_{02} e H_{03} , e a distribuição de cada estatística sob a hipótese nula.

Hipótese nula	Estatística do teste	Distribuição da estatística sob H_0
$H_{01} : \alpha_1 = \alpha_2 = \dots = \alpha_a = 0$	F_{01}	$F_{(a-1, ab(r-1))}$
$H_{02} : \beta_1 = \beta_2 = \dots = \beta_b = 0$	F_{02}	$F_{(b-1, ab(r-1))}$
$H_{03} : \alpha\beta_{11} = \alpha\beta_{12} = \dots = \alpha\beta_{ab} = 0$	F_{03}	$F_{((a-1)(b-1), ab(r-1))}$

Fixado o nível de significância $100(\alpha)\%$ e sendo $F_{(\nu, \psi)}(1 - \alpha)$ o quantil de ordem $1 - \alpha$ da distribuição F com ν e ψ graus de liberdade, temos as seguintes regras de decisão:

- Rejeitamos H_{01} em favor de H_{a1} se $F_{01} > F_{(a-1, ab(r-1))}(1 - \alpha)$;
- Rejeitamos H_{02} em favor de H_{a2} se $F_{02} > F_{(b-1, ab(r-1))}(1 - \alpha)$;
- Rejeitamos H_{03} em favor de H_{a3} se $F_{03} > F_{((a-1)(b-1), ab(r-1))}(1 - \alpha)$.

Ressaltamos que as comparações são individuais, e cada par de hipóteses tem sua estatística.

Exemplo 66. Na calibração de um dado instrumento de medição, o avaliador tomou 3 pontos e realizou 3 tipos de leituras. Os resultados estão apresentados na tabela

abaixo.

<i>Leituras</i>	<i>Ponto 1</i>	<i>Ponto 2</i>	<i>Ponto 3</i>	<i>Médias</i>
<i>A</i>	16,0	11,0	24,5	$\bar{X}_{1..} = 16,142$
	13,5	12,5	21,0	
	11,2	12,4	20,0	
	17,0	16,0	18,6	
<i>B</i>	14,0	22,6	24,0	$\bar{X}_{2..} = 21,542$
	12,0	24,8	26,0	
	17,0	22,8	30,0	
	14,5	23,6	27,2	
<i>C</i>	17,0	21,0	31,5	$\bar{X}_{3..} = 23,55$
	12,0	23,7	32,0	
	14,6	27,3	29,0	
	15,5	23,6	35,4	
<i>Médias</i>	$\bar{X}_{.1.} = 14,525$	$\bar{X}_{.2.} = 20,11$	$\bar{X}_{.3.} = 26,6$	$\bar{X}_{...} = 20,41$

Considerando o nível de significância de 5%, responda às seguintes questões:

- a) O ponto escolhido influenciou no resultado?
- b) O tipo de leitura feita teve influência no resultado obtido?
- c) Houve interação entre ponto de leitura e tipo de leitura?

Solução:

Dispondo dos dados, façamos uma análise exploratória rápida, via *box plot* (Figura 7.3), para verificar se, graficamente, temos indícios de que possa haver diferenças entre os níveis dos fatores, isto é, entre ponto de leitura e tipo de leitura.

O gráfico indica que pode realmente haver diferenças. Portanto, seguimos com a ANOVA.

Vamos apresentar a tabela ANOVA para esta situação, ocultando o cálculo detalhado de cada item, que pode ser feito utilizando o R via códigos apresentados posteriormente.

Fonte de variação	Graus de liberdade (<i>gl</i>)	Soma dos quadrados (<i>SQ</i>)	Quadrados médios (<i>QM</i>)	Estatística <i>F</i>
Fator A (Método)	2	352,3072	176,1536	33,5756
Fator B (Local)	2	876,4839	438,2419	83,5306
Interação AB	4	193,8294	48,4574	9,2361
Dentro (Resíduo)	27	141,6550	5,2465	
Total	35	1.564,28		

Temos:




Figura 7.3: *Box plots* dos níveis: ponto de leitura (esquerda) e tipo de leitura (direita).

- a) $F_{01} = 33,5756$ que, comparado com $F_{(2,27)}(0,95) = 3,3541$, concluímos que existe influência do método de leitura no resultado obtido.
- b) $F_{02} = 83,5306$ que, comparado com $F_{(2,27)}(0,95) = 3,3541$, concluímos que existe influência do local de amostragem no resultado obtido.
- c) $F_{03} = 9,2361$ que, comparado com $F_{(4,27)}(0,95) = 2,7278$, concluímos que existe interação entre método de leitura e local de amostragem.

Portanto, rejeitamos as três hipóteses nulas.

Embora no exemplo acima as conclusões tenham sido as mesmas para os três conjuntos de hipóteses possíveis, isto não é regra, podendo haver casos em que rejeitamos a hipótese nula em apenas um dos casos, ou apenas em dois deles.

A seguir, apresentamos o comando em R para obter os valores da tabela ANOVA do Exemplo 66.

```
> x1<-c(16,13.5,11.2,17,14,12,17,14.5,17,12,14.6,15.5)
> x2<-c(11,12.5,12.4,16,22.6,24.8,22.8,23.6,21,23.7,27.3,23.6)
> x3<-c(24.5,21,20,18.6,24,26,30,27.2,31.5,32,29,35.4)
> dados<-c(x1,x2,x3)
> ponto<-c(rep("Ponto 1",length(x1)),rep("Ponto 2",length(x2)),
rep("Ponto 3",length(x3)))
> leituras<-c(rep("A",4),rep("B",4),rep("C",4))
> mydata<-data.frame(ponto, leituras, dados) # Cria o data frame
> anova(lm(dados ~ leituras*ponto, mydata)) # ANOVA
```

Analysis of Variance Table

Response: dados

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
leituras	2	352.3	176.2	33.576	4.75e-08 ***
ponto	2	876.5	438.2	83.531	2.73e-12 ***
leituras:ponto	4	193.8	48.5	9.236	7.75e-05 ***
Residuals	27	141.7	5.2		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

É importante ressaltar que o vetor “dados” é a variável resposta, “leituras” e “ponto” são as variáveis explicativas. Para que a função `lm` considere a interação entre as variáveis explicativas, é necessário que o programa contenha o seguinte comando: “leituras*ponto”.

7.5 Considerações finais

Para casos em que a ANOVA evidencia diferenças entre as médias, sugerimos testes como Tukey, Fisher e Scheffé, entre outros (ver, por exemplo, Montgomery, 2013), para comparar quais médias são iguais e quais podem ser consideradas distintas. Situações que cogitam influência simultânea de mais de dois fatores na variável resposta, são possíveis e também tratáveis na ANOVA, porém não foram abordadas neste capítulo por serem situações mais complexas e, portanto, destinadas a cursos mais avançados. Entretanto, a fundamentação é a mesma.

7.6 Exercícios propostos

Exercício 1. Com o intuito de comparar o preço de terrenos em cinco diferentes cidades do interior paulista, selecionou-se aleatoriamente 8 terrenos que estavam à venda em cada uma das cidades e registrou-se os seus respectivos preços, cujos valores (expressos em milhares de reais) estão apresentados na tabela abaixo.

Cidade	Terreno							
	I	II	III	IV	V	VI	VII	VIII
A	51	56	69	77	69	48	41	81
B	80	86	101	111	101	76	67	115
C	57	62	73	81	73	54	48	84
D	68	72	82	89	82	66	59	92
E	50	56	71	81	71	46	37	85

a) Faça uma análise descritiva dos dados e interprete os resultados.

b) Faça uma ANOVA e verifique se há evidência de que existe diferença real entre os preços médios dos terrenos das cinco cidades. Use $\alpha = 10\%$.

Exercício 2. Considere o conjunto de dados a seguir.

Repetição	Tratamento		
	A	B	C
1	2,8	2,2	5,5
2	5,1	5,4	5,2
3	3,9	4,1	4,7
4	5,0	2,3	4,5
5	5,9	2,5	4,6
6	5,8	1,2	-
Média	4,75	2,95	4,90
Desvio-padrão	1,19	1,52	0,43

a) Ao nível de significância de 5%, há evidência de diferença entre as médias dos tratamentos?

b) Ao considerar $\alpha = 1\%$, a conclusão permanece inalterada?

Exercício 3. Complete a tabela ANOVA preenchendo os espaços assinalados pelas letras de (a) a (e).

Fonte de variação	Graus de liberdade	Soma dos quadrados	Quadrados médios	Estatística F
Fator	3	(b)	21,7965	(e)
Resíduo	(a)	(c)	(d)	
Total	19	111,2695		


Exercício 4. Os dados abaixo são pesos (em g) de 10 garças-brancas-pequenas (*Egretta thula*) de diferentes bandos. O interesse é verificar se as médias diferem de um bando para outro a 2% de significância.

Bando	Garça									
	1	2	3	4	5	6	7	8	9	10
I	385	369	394	399	373	380	359	346	347	393
II	365	349	374	379	353	360	339	326	327	373
III	374	359	383	388	363	370	350	337	338	382
IV	364	349	373	378	353	360	340	327	328	372

Exercício 5. É importante sempre verificar os pressupostos de realização da ANOVA. Para averiguar se as variâncias de todos os grupos são constantes ou homogêneas, podemos utilizar um teste de homogeneidade de variâncias, como, por

exemplo, o teste de Levene. Já para averiguar se os erros são provenientes de uma distribuição Normal, faz-se uma **análise de resíduos**. Os resíduos são definidos como (ANOVA com um fator fixo): $\hat{e}_{ij} = X_{ij} - \bar{X}_i$, para $i = 1, 2, \dots, K$ e $j = 1, 2, \dots, R_i$. Assim, podemos construir gráficos de quantis (ou Q-Q *plots*) e fazer testes de ajustamento à Normal, como, por exemplo, o teste de normalidade de Lilliefors.

Considere os dados sobre pesos de garças-brancas-pequenas de diferentes bandos, fornecidos no exercício anterior. Neste caso, obtemos os resultados a seguir. Interprete-os.



```
# Códigos em R:
> B1<-c(385,369,394,399,373,380,359,346,347,393)
> B2<-c(365,349,374,379,353,360,339,326,327,373)
> B3<-c(374,359,383,388,363,370,350,337,338,382)
> B4<-c(364,349,373,378,353,360,340,327,328,372)
> dados<-c(B1,B2,B3,B4)
> bando<-c(rep("B1",length(B1)), rep("B2",length(B2)),rep("B3",length
  (B3)),rep("B4",length(B4)))
> mydata<-data.frame(dados,bando)
> mod<-lm(dados~bando, mydata)
> residuos<-residuals(mod) # resíduos
> # Q-Q plot
> qqnorm(residuos, xlab="Quantis teóricos", ylab="Quantis amostrais",
  main="Normal Q-Q plot"); qqline(residuos)
> # Teste de normalidade de Lilliefors
```

```

> require(nortest) # carregar pacote
> lillie.test(residuos)

      Lilliefors (Kolmogorov-Smirnov) normality test

data:  residuos
D = 0.13574, p-value = 0.0612

> # Teste de Levene (homogeneidade de variâncias)
> require(car) # carregar pacote
> leveneTest(dados ~ bando, data = mydata)
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  3  0.0173 0.9968
      36

```

Exercício 6. Numa fábrica de parafusos, deseja-se verificar se há diferença na média do diâmetro (em mm) das peças produzidas por duas máquinas, utilizando-se matéria-prima de dois fornecedores. Foram selecionadas quatro amostras, uma de cada combinação máquina - fornecedor de matéria-prima, com 10 parafusos cada, cujos dados são:

	Máquina 1					Máquina 2				
Fornecedor 1	6,01	6,00	6,02	6,02	6,00	5,99	5,99	6,03	5,98	6,02
	6,01	5,99	5,98	5,98	6,02	6,00	6,01	6,01	6,02	6,00
Fornecedor 2	5,89	5,91	5,89	5,90	5,88	6,02	6,01	6,02	6,03	6,01
	5,90	5,91	5,90	5,89	5,89	6,02	6,03	6,02	6,02	6,03

- a) Faça uma análise exploratória dos dados e comente os resultados.
- b) Considerando o nível de significância de 5%, responda às seguintes questões:
 - b.1) A máquina utilizada na fabricação dos parafusos influenciou no diâmetro dos mesmos?
 - b.2) O fornecedor da matéria-prima empregada na fabricação dos parafusos influenciou no diâmetro dos mesmos?
 - b.3) Houve interação entre máquina e fornecedor de máquina-prima?

Exercício 7. Complete a tabela ANOVA preenchendo os espaços assinalados pelas letras de (a) a (g). Em seguida, a partir dos resultados dos p-valores apresentados na tabela, verifique se os fatores A e B influenciam ou não a variável resposta. Use

$\alpha = 1\%$.

Fonte de variação	Graus de liberdade	Soma dos quadrados	Quadrados médios	Estatística	
				F	p-valor
Fator A	(a)	(c)	(d)	7,91	0,0020
Fator B	2	39.118,72	(e)	(f)	1,91e-07
Interação AB	(b)	9.613,78	2.403,44	(g)	0,0186
Resíduo	27	18.230,75	675,21		
Total	35	77.646,97			

Capítulo 8

Tópicos básicos em análise de regressão

Resumo do capítulo: *Neste capítulo, apresentamos o comportamento conjunto de duas variáveis quantitativas por meio de gráficos e do coeficiente de correlação.*

Objetivo: *Capacitar o leitor a verificar se existe relação entre duas ou mais variáveis, descrevendo matematicamente tal relação por meio de uma função cujos parâmetros são estimados.*

8.1 Introdução

A análise estatística de um conjunto de dados pode ser realizada utilizando uma coleção de métodos. A seleção do método estatístico apropriado dependerá do tipo de informação disponível e dos objetivos que se quer alcançar.

A análise de regressão é um dos métodos estatísticos mais usados por pesquisadores de áreas distintas para investigar e modelar o relacionamento existente entre duas ou mais variáveis. O principal objetivo desta importante técnica estatística é encontrar uma função que esteja o mais próximo possível dos pontos observados, conforme um critério preestabelecido. O formato dessa função varia de caso a caso, podendo ser sugerido por experiências passadas com o mesmo tipo de informação, por evidências teóricas que temos interesse em investigar ou então pela amostra observada (Ferreira Filho, 1988). Em estudos deste escopo, é de fundamental importância que se faça uma análise final dos resultados obtidos, com o propósito de verificar a adequação do modelo construído.

8.2 Relação entre as variáveis

Havendo indicativo lógico ou suposição fundamentada de que uma variável pode influenciar outra, podemos iniciar a investigação da relação entre elas.

Ressaltamos a importância de haver indícios da relação, pois podemos encontrar relação numérica entre variáveis sem haver qualquer importância ounexo na mesma. Por exemplo, um desocupado poderia obter dados referentes ao número de anfíbios (sapos, rãs e pererecas) e número de divórcios em determinados períodos em uma cidade, e se pôr a estudar a relação dessas variáveis. Tal estudo não faz sentido algum, não tem relevância e, havendo relação, a mesma não passa de uma desastrosa coincidência.

Havendo explicações plausíveis para a relação de duas ou mais variáveis, podemos estabelecer a relação entre elas. Como por exemplo:

- Peso e altura de uma pessoa;
- Tamanho e idade gestacional de um feto;
- Número de clientes de um representante comercial e seu tempo de trabalho no ramo;
- Preço de um produto e quantidade vendida;
- Produção de melancias e quantidade de chuva no período (irrigação).

Poderíamos tecer muitas outras possibilidades de variáveis relacionadas, mas vamos abranger outros aspectos da teoria.

Primeiramente, precisamos identificar a variável explicativa e a variável resposta.

Variável explicativa: É a variável que influencia a variável resposta, ou seja, fazendo alterações nela, variável explicativa, teremos resultados diferentes. Também poderíamos dizer, em alguns casos, que a variável explicativa é a que podemos controlar. Nos exemplos acima, temos como variáveis explicativas: altura, idade gestacional, tempo de trabalho, preço do produto e quantidade de chuva, pois estas variáveis influenciam as respostas. Ela também pode ser entendida como a variável independente.

Há casos em que temos mais de uma variável explicativa. Por exemplo, na produção de melancias, poderíamos dizer que a produtividade também é influenciada pela adubação feita; neste caso, teríamos duas variáveis explicativas: adubação e quantidade de água. Ou então na relação de preço do produto com quantidade vendida. Poderíamos pensar no fato que a quantidade vendida é influenciada também pela qualidade do produto e grau de importância na vida diária. Neste último caso, temos 3 variáveis explicativas: preço, qualidade e grau de importância.

Variável resposta: É a variável que é explicada, ou seja, a consequência da variável explicativa, o resultado obtido. Das situações apresentadas acima, temos como variáveis respostas: peso, tamanho, número de clientes, quantidade vendida e quantidade de melancias produzidas. Ela também pode ser entendida como a variável dependente.

Geralmente, e aqui assim faremos, denotamos a variável explicativa por X , ou por $X_1, X_2, \dots, X_p$ quando temos p variáveis explicativas. E a variável resposta denotamos por Y .

Observe que, em cada estudo, teremos apenas uma variável resposta.

A maneira matemática como essas variáveis se relacionam será tratada na Seção 8.3, apresentada posteriormente.

Mesmo que, supostamente, as variáveis X e Y estejam relacionadas teoricamente, nem sempre isso realmente ocorrerá (ou seja, nem sempre a relação será estatisticamente significativa). Há técnicas para identificar as relações e também coeficientes que indicam o quão relacionadas são as variáveis.

O diagrama de dispersão é uma excelente ferramenta exploratória para indicar a relação entre variáveis. Apresentamos quatro possíveis resultados dos diagramas de dispersão (outras formas são possíveis, mas não serão aqui tratadas).

Supomos que X e Y são, respectivamente, as variáveis explicativa e resposta.




Figura 8.1: Diagramas de dispersão. *Esquerda:* Associação linear negativa. *Direita:* Associação linear positiva.

No caso da Figura 8.1 (painel esquerdo), temos uma associação linear entre as variáveis X e Y , e dizemos que é associação linear negativa, pois quando o valor de X aumenta, o valor de Y diminui. No caso da Figura 8.1 (painel direito), também temos uma associação linear entre as variáveis X e Y , mas neste caso, associação linear positiva, pois o acréscimo de X faz com que haja acréscimo nos valores de Y .

Na Figura 8.2 (painel esquerdo), temos um caso de ausência de correlação entre X e Y , ou seja, não é possível determinar o valor de Y a partir do valor de X . Na Figura 8.2 (painel direito), temos uma associação quadrática, que é associação não linear.




Figura 8.2: Diagramas de dispersão. *Esquerda:* Ausência de associação. *Direita:* Associação quadrática (não linear).

Vale ressaltar que, nos exemplos apresentados na Figura 8.2, o coeficiente que adotaremos para mensurar o grau de associação entre as variáveis, dará valores parecidos para ambos os casos, pois ele avalia o grau de correlação linear entre as variáveis, e nenhuma delas apresenta tal associação. Dito isto, enfatizamos que, sendo descartada a hipótese de associação linear entre as variáveis, deve-se avaliar se há alguma outra forma de associação entre elas, como no caso da Figura 8.2 (painel direito). As associações não lineares não serão tratadas neste material.

8.2.1 Coeficiente de correlação linear

A literatura estatística apresenta diversas maneiras de quantificar relações entre variáveis, sendo que a mais comum envolve o chamado **coeficiente de correlação linear de Pearson**. Tal coeficiente quantifica quão linear é a associação das variáveis.

O coeficiente de correlação linear de Pearson populacional é geralmente denotado por ρ , mas como trabalhamos com amostras, precisamos de um estimador para ρ , que é denominado coeficiente de correlação linear de Pearson amostral, denotado por r e assume valor no intervalo $[-1, 1]$. Tal estimador é definido por:

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{(n-1)s_X s_Y},$$

em que s_X e s_Y são os desvios-padrão de X e Y , respectivamente; $\bar{X}$ e $\bar{Y}$ são os valores das médias; e n é o tamanho da amostra.

Em relação aos valores que r pode assumir, podemos afirmar que:

- Se $r < 0$, isto indica correlação linear negativa;
- Se $r > 0$, indica correlação linear positiva;
- Se $r = 0$, indica ausência de correlação linear.

Observações:

- A ausência de correlação linear pode ser oriunda da falta de associação entre as variáveis ou então pelo fato da associação ser de outra forma (quadrática, por exemplo);
- Quanto mais próximo dos extremos do intervalo for o valor de r , mais forte é a correlação.

Exemplo 67. *Considere os três conjuntos de dados a seguir.*

X_1	2	4	5	6	8	9	10
Y_1	23	27	30	32	35	37	40
X_2	2	3	4	5	6	7	9
Y_2	12	9	8	5	3	2	2
X_3	2	3	4	5	6	7	8
Y_3	2	15	22	25	21	16	2

Determine o coeficiente de correlação linear de Pearson para os pares de amostras e obtenha os respectivos diagramas de dispersão.

Solução:

Tanto os gráficos como os coeficientes serão obtidos via *software* R, mas podem ser obtidos manualmente.

```
> x1<-c(2,4,5,6,8,9,10)
> y1<-c(23,27,30,32,35,37,40)
> x2<-c(2,3,4,5,6,7,9)
> y2<-c(12,9,8,5,3,2,2)
> x3<-c(2,3,4,5,6,7,8)
> y3<-c(2,15,22,25,21,16,2)
> # coeficientes de correlação:
> cor(x1,y1); cor(x2,y2); cor(x3,y3)
```

Os coeficientes de correlação linear são:

- $r_1 \approx 0,9961$, indicando correlação linear positiva ou direta;

- $r_2 \approx -0,9392$, indicando correlação linear negativa ou inversa;
- $r_3 \approx 0,0083$, indicando ausência de correlação linear.

```
> # Diagramas de dispersão:
> par(mfrow=c(1,3)) # permite imprimir três gráficos conjuntamente
> plot(x1,y1); plot(x2,y2); plot(x3,y3)
```

Os diagramas de dispersão são dados a seguir (Figura 8.3) e, como ressaltamos anteriormente, mesmo não havendo indicativos de correlação linear, não podemos afirmar que não existe associação entre as variáveis X_3 e Y_3 . A partir do resultado de $r_3 \approx 0,0083$, podemos somente afirmar que há muito pouca evidência de correlação linear entre elas. E o diagrama de dispersão para os dados indica que existe uma associação quadrática entre X_3 e Y_3 (Figura 8.3, painel direito).




Figura 8.3: Diagramas de dispersão do Exemplo 67.

8.2.2 Teste de hipóteses

Mesmo sabendo que, quanto mais próximo dos limites do intervalo $[-1, 1]$ for o valor de r , mais forte é a correlação, questionamentos em relação à significância da correlação podem surgir. E para valores não muito expressivos de r , esses questionamentos só aumentam.

Para responder a essas questões com propriedade, consideramos o resultado do teste de hipóteses para o coeficiente de correlação. As hipóteses de interesse são:

$$\begin{cases} H_0 : \rho = 0 \\ H_a : \rho \neq 0 \end{cases}$$

Para realizar o teste, consideramos que os n pares de valores de (X, Y) são oriundos de uma população bivariada, a qual supomos ser descrita segundo uma distribuição Normal bivariada.

Também é necessário conhecer a distribuição amostral de r . Em geral, existe interesse em testar a hipótese de correlação linear nula ($H_0 : \rho = 0$). Neste caso, a

distribuição em questão é simétrica e as hipóteses podem ser testadas usando uma estatística com distribuição t -Student.

Esta estatística é dada por:

$$t_c = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}},$$

a qual tem distribuição t -Student com $n - 2$ graus de liberdade.

Considerando o nível de significância $100(\alpha)\%$, a regra de decisão é:

Se $|t_c| > t_{\alpha/2}(n - 2)$, rejeito a hipótese H_0 .

O valor crítico acima vem da tabela da distribuição t -Student com $n - 2$ graus de liberdade, ou então, é obtido via comando `qt(1-alpha/2, n-2)` no R. Por meio deste, também podemos realizar o teste via função `cor.test` e decidir pelo p-valor.

Exemplo 68. *Considere o seguinte conjunto de dados bivariados e avalie, por meio do teste de hipóteses, se há evidências de correlação linear entre eles.*

X	2	5	4	3	8	4	6	8	9
Y	12	15	16	22	35	12	16	5	9

Solução:

Considere os seguintes comandos inseridos no R:

```
> x<-c(2,5,4,3,8,4,6,8,9)
> y<-c(12,15,16,22,35,12,16,5,9)
> cor.test(x,y)
Pearson's product-moment correlation
data:  x and y
t = 0.013831, df = 7, p-value = 0.9894
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:  -0.6611896  0.6670336
sample estimates: cor 0.005227682
```

O coeficiente de correlação para os dados é $r \approx 0,0052$ e a estatística do teste é $t_c = 0,013831$. O p-valor associado ao teste é alto (p-valor = 0,9894). Desta forma, não rejeitamos a hipótese nula ($\rho = 0$), pois não há evidências estatísticas de correlação linear entre X e Y .

Observação: Uma forma rápida de decidir se há correlação linear, considerando o teste de hipóteses, pode ser avaliando o p-valor. Se ele for próximo de 1, há evidências de que não há correlação linear; e se o p-valor for próximo de zero, há evidências de correlação linear.

Porém, utilizando a regra de decisão, fixamos, por exemplo, $\alpha = 1\%$ e, pelo comando `qt(0.995, 7)`, temos $t_{0,005}(7) \approx 3,4995$, sendo que $t_c \approx 0,0138$. Logo, não rejeitamos a hipótese de ausência de correlação linear entre X e Y , a 1% de significância.

A seguir, apresentamos o diagrama de dispersão dos dados e, então, podemos afirmar que não há nenhuma forma de correlação visível entre X e Y .




Figura 8.4: Diagrama de dispersão para os dados do Exemplo 68.

```
> # Comando para construir o diagrama de dispersão:
> plot(x,y)
```

8.3 O modelo estatístico

Um dos objetivos da análise de dados é obter modelos que expliquem as variações da variável resposta. Esta explicação é dada em função das variáveis explicativas e de variações aleatórias.

Tendo como objetivo identificar a estrutura de variação, supomos que cada observação é formada por duas partes: uma previsível, que muitas vezes é possível controlar, e outra aleatória. Desta forma, cada observação pode ser representada em um modelo aditivo, como sendo:

$$\text{OBSERVAÇÃO} = \text{PREVISÍVEL} + \text{ALEATÓRIO}.$$

A primeira parte é descrita pelo pesquisador por meio de um modelo matemático com parâmetros desconhecidos e a segunda componente é oriunda de um fenômeno

aleatório, aos quais impomos condições e supomos que obedecem a um modelo de probabilidade.

Em termos matemáticos, podemos representar o modelo acima como sendo:

$$Y = f(X) + \varepsilon.$$

Assim, procuramos estabelecer modelos que, a partir do conhecimento dos valores das variáveis preditoras X_i , $i = 1, 2, \dots, p$, possamos “prever” o valor da variável resposta Y .

O modelo usado com maior frequência para descrever relação entre variáveis é o linear, cuja forma matricial é dada por:

$$\begin{pmatrix} Y_1 \\ Y_2 \\ Y_3 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p} \\ 1 & X_{31} & X_{32} & \cdots & X_{3p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \vdots \\ \varepsilon_n \end{pmatrix}.$$

Que pode ser representado da seguinte forma:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

Os elementos do modelo linear dado são:

- $\mathbf{Y}$: vetor com n linhas, contendo a variável resposta;
- $\mathbf{X}$: matriz de dimensão $n \times (p+1)$, com as variáveis explicativas ou preditoras;
- $\boldsymbol{\beta}$: vetor com $p+1$ parâmetros desconhecidos;
- $\boldsymbol{\varepsilon}$: vetor de erros aleatórios, os quais supomos serem iid;
- p : quantidade de variáveis explicativas ou preditoras;
- n : tamanho da amostra.

Regressão linear simples

Relaciona duas variáveis quantitativas, sendo uma delas a variável resposta e a outra a variável explicativa. A forma matemática do modelo é:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad (8.1)$$

em que:

- β_0 (intercepto ou coeficiente linear) é o valor esperado para Y quando $X = 0$. Representa o ponto em que a reta corta o eixo das ordenadas. Nem sempre tem interpretação lógica, mas em alguns casos indica a variação de Y que não depende da variável explicativa X ;
- β_1 (coeficiente angular) representa a variação na média de Y associada com o aumento de uma unidade da variável X . O sinal deste coeficiente indica o sentido da correlação.

Regressão linear múltipla

Relaciona mais de duas variáveis quantitativas, sendo uma delas a variável resposta e as demais são as variáveis explicativas. Sua forma matemática é:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip} + \varepsilon_i. \quad (8.2)$$

A inclusão de outras variáveis explicativas implica no acréscimo de parâmetros e, conseqüentemente, aumenta a complexidade do modelo.

Linearidade

A linearidade de um modelo é estabelecida em relação aos parâmetros β 's e não em relação às variáveis explicativas X_i , $i = 1, 2, \dots, p$.

Por exemplo, os modelos a seguir são modelos lineares com uma variável explicativa:

- $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$;
- $Y_i = \beta_0 + \beta_1 X_i^2 + \varepsilon_i$;
- $Y_i = \beta_0 + \beta_1 (1/X_i) + \varepsilon_i$.

Existem também modelos linearizáveis, isto é, modelos que, inicialmente, não são lineares nos parâmetros, mas serão após transformação adequada. O modelo a seguir é um exemplo de modelo linearizável:

$$Y_i = \beta_0 X_i^{\beta_1}.$$

Temos também modelos tradicionais que podem ser linearizados, sendo que dois deles estão apresentados no quadro a seguir.

	Modelo ajustado	Linearização	Modelo linearizado	Em que:
Exponencial	$\hat{Y} = \hat{\beta}_0 \hat{\beta}_1^X$	$\underbrace{\log(\hat{Y})}_{\hat{Y}^*} = \underbrace{\log(\hat{\beta}_0)}_{\hat{\beta}_0^*} + X \underbrace{\log(\hat{\beta}_1)}_{\hat{\beta}_1^*}$	$\hat{Y}^* = \hat{\beta}_0^* + \hat{\beta}_1^* X$	$\begin{cases} \hat{Y} = e^{\hat{Y}^*} \\ \hat{\beta}_0 = e^{\hat{\beta}_0^*} \\ \hat{\beta}_1 = e^{\hat{\beta}_1^*} \end{cases}$
Potência	$\hat{Y} = \hat{\beta}_0 X^{\hat{\beta}_1}$	$\underbrace{\log(\hat{Y})}_{\hat{Y}^*} = \underbrace{\log(\hat{\beta}_0)}_{\hat{\beta}_0^*} + \hat{\beta}_1 \underbrace{\log(X)}_{X^*}$	$\hat{Y}^* = \hat{\beta}_0^* + \hat{\beta}_1 X^*$	$\begin{cases} \hat{Y} = e^{\hat{Y}^*} \\ \hat{\beta}_0 = e^{\hat{\beta}_0^*} \\ X = e^{X^*} \end{cases}$

Há também modelos não lineares, para os quais não há transformação que os tornem lineares, como por exemplo:

$$Y_i = \frac{\beta_0}{\beta_1} X_i + \varepsilon_i.$$

A seleção do modelo de regressão que descreverá o fenômeno em análise, deve estar alicerçada em algumas propriedades quanto à “qualidade do ajuste” que o modelo escolhido permite aos dados. A qualidade do ajuste do modelo de regressão é normalmente avaliada em função de algumas propriedades que se espera do mesmo. São elas (Marion & Silva, 1986):

- **Plausibilidade teórica:** O modelo deve descrever e explicar a situação analisada de forma adequada;
- **Capacidade explicativa:** O modelo deve ser capaz de explicar os dados observados pela relação estabelecida;
- **Simplicidade:** O modelo deve representar a relação entre as variáveis com o máximo de simplicidade possível, em termos de forma matemática e número de parâmetros. Neste quesito, dizemos que os modelos lineares são os mais simples;
- **Exatidão das estimativas:** Os parâmetros estimados devem se aproximar tanto quanto possível dos valores verdadeiros dos parâmetros;
- **Capacidade preditiva:** O modelo deve ser capaz de prever satisfatoriamente valores futuros da variável resposta.

A seguir, vamos explorar algumas dessas propriedades.

8.4 Estimação dos parâmetros

Na utilização do modelo linear (8.1) ou (8.2), dispomos dos valores de X e Y , que são amostrados, e queremos estimar o vetor de parâmetros (desconhecidos) $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top$ tal que o hiperplano ajustado esteja o mais próximo possível do vetor de observações (respostas) $\mathbf{Y}$. Uma medida de proximidade ou distância frequentemente utilizada é a norma L_k . Neste caso, nosso objetivo consiste em obter um vetor $\boldsymbol{\beta}$ tal que:

$$\sum_{i=1}^n |Y_i - \mathbf{X}_i \boldsymbol{\beta}|^k$$

seja mínima, para $k \geq 1$, em que $\mathbf{X}_i$ é a i -ésima linha da matriz $\mathbf{X}$.

Assumimos $k = 1, 2, \dots, \infty$. Sendo assim,

- Se $k = 1$, temos o critério de minimização dos erros absolutos;
- Se $k = 2$, temos o critério dos mínimos quadrados;
- Se $k = \infty$, temos o critério do erro máximo absoluto.

Dentre esses critérios, o mais utilizado na análise de regressão é o dos mínimos quadrados (ou método dos Mínimos Quadrados). Segundo Ferreira Filho (1988), isto se deve principalmente à sua simplicidade computacional e matemática.

8.4.1 Suposições do modelo

Pensemos em um modelo de regressão linear simples, em que temos apenas os parâmetros β_0 e β_1 . Para que a estimação desses parâmetros seja válida em termos de confiabilidade, requer-se que algumas suposições sejam feitas *a priori*, as quais posteriormente devem ser verificadas.

Das suposições, quatro delas são em relação aos erros ε_i ($i = 1, 2, \dots, n$) e a sétima é garantida no momento do planejamento e amostragem.

São estas as suposições do modelo de regressão:

1. Os erros são variáveis aleatórias com média zero, isto é, $E(\varepsilon_i) = 0$;
2. Homocedasticidade: Variância constante ou homogeneidade de variâncias, isto é, $Var(\varepsilon_i) = \sigma^2$;
3. Independência dos erros: Ausência de correlação entre os erros, ou seja, $E(\varepsilon_i \varepsilon_j) = 0$ para $i \neq j$;
4. Os erros são identicamente distribuídos com distribuição Normal de probabilidade, isto é, $\varepsilon_i \sim N(0, \sigma^2)$;
5. A relação entre X e Y é linear;
6. Em caso de regressão múltipla, as variáveis explicativas $X_1, X_2, \dots, X_p$ não devem apresentar colinearidade perfeita;
7. A variável preditora X não é variável aleatória no experimento; ela é controlada pelo experimentador e medida com erro desprezível.

A verificação dessas suposições será tratada na Seção 8.7, mas lembramos que a última suposição deve ser garantida ao estabelecer os elementos da análise, e a penúltima é considerada apenas em regressão múltipla, que não trataremos neste compêndio.

8.4.2 Mínimos Quadrados

Seja o modelo:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

em que β_0 e β_1 são parâmetros desconhecidos.

O método dos Mínimos Quadrados (MQ) consiste em estimar β_0 e β_1 por $\hat{\beta}_0$ e $\hat{\beta}_1$, respectivamente, de tal forma a minimizar a soma dos quadrados dos erros:

$$\sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n [Y_i - (\beta_0 + \beta_1 X_i)]^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2.$$

Para minimizar a expressão anterior, derivamos-a em relação a β_0 e β_1 , obtendo:

$$\begin{aligned} \frac{\partial \sum_{i=1}^n \varepsilon_i^2}{\partial \beta_0} &= -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i), \\ \frac{\partial \sum_{i=1}^n \varepsilon_i^2}{\partial \beta_1} &= -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i) X_i. \end{aligned}$$

Igualando a zero, temos:

$$\begin{cases} -2 \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0, \\ -2 \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) X_i = 0, \end{cases}$$

que, desenvolvendo, chegamos em:

$$\begin{cases} \sum_{i=1}^n Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n X_i, \\ \sum_{i=1}^n X_i Y_i = \hat{\beta}_0 \sum_{i=1}^n X_i + \hat{\beta}_1 \sum_{i=1}^n X_i^2. \end{cases}$$

Resolvendo o sistema acima para $\hat{\beta}_0$ e $\hat{\beta}_1$, obtemos os estimadores de MQ, dados por:

$$\begin{cases} \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}, \\ \hat{\beta}_1 = \frac{n \sum_{i=1}^n X_i Y_i - \sum_{i=1}^n Y_i \sum_{i=1}^n X_i}{n \sum_{i=1}^n X_i^2 - \left(\sum_{i=1}^n X_i \right)^2}. \end{cases}$$

Ou de forma mais simplificada,

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y}}{\sum_{i=1}^n X_i^2 - n \bar{X}^2} \quad (8.3)$$

e

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}. \quad (8.4)$$

Obtém-se, assim, a equação estimada:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i,$$

que se aproxima da verdadeira relação $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$.

Outro fator importante da utilização do método dos MQ, é que ele está implementado em praticamente todos os *softwares* estatísticos disponíveis atualmente no mercado.

Contudo, desvios da hipótese de normalidade dos erros e/ou a presença de valores aberrantes (*outliers*) podem afetar a análise por meio deste método.

Rice & White (1964) mostraram, por meio de um estudo de Monte Carlo, que se os erros se afastarem da hipótese de normalidade e se sua distribuição possuir cauda mais alongada do que a da Normal, o critério de minimização dos erros absolutos resulta em estimadores com menor erro quadrático médio do que aqueles obtidos pelo método dos MQ. Hogg (1979), por sua vez, sugeriu que se deveria dar mais atenção a métodos robustos de estimação em análise de regressão. Recomendou empregar o método dos MQ e também procedimentos robustos ao ajustar um modelo linear.

Se o conjunto de observações não satisfizer as hipóteses dos MQ, devemos então investigá-lo detalhadamente a fim de verificar a presença de valores aberrantes e/ou dados influentes. Quando valores aberrantes e/ou influentes são encontrados, estes devem ser examinados cuidadosamente. Se forem dados de má qualidade ou erros de codificação, por exemplo, podemos corrigi-los ou abandoná-los. Se forem resultantes do processo de geração dos dados, eles devem ser mantidos na análise e, então, se aplica um método robusto para estimação dos parâmetros desconhecidos (Ferreira Filho, 1988).

Exemplo 69. *Num certo experimento de uma indústria química está sendo estudada a relação entre a porcentagem de amônia perdida como ácido nítrico não absorvido (Y) e a corrente de ar (X), num processo de conversão de amônia em ácido nítrico. Os dados obtidos foram ¹:*

- a) Calcule o coeficiente de correlação linear entre X e Y .
- b) Qual é o modelo linear que descreve a relação entre X e Y ?
- c) Interprete os parâmetros.

¹O conjunto de dados (arquivo `stack.txt`) está disponível para *download* em: <https://www.maths.lancs.ac.uk/~rowlings/Teaching/Sheffield2013/data.html>.

X	80	80	75	62	62	62	62	62	58	58	58
	58	58	58	50	50	50	50	50	56	70	
Y	42	37	37	28	18	18	19	20	15	14	14
	13	11	12	8	7	8	8	9	15	15	

Solução:

a) O coeficiente de correlação linear de Pearson pode ser facilmente obtido com o auxílio do programa R.

```
> x<-c(80,80,75,62,62,62,62,62,58,58,58,58,58,50,50,50,50,
      50,56,70)
> y<-c(0.42,0.37,0.37,0.28,0.18,0.18,0.19,0.20,0.15,0.14,0.14,
      0.13,0.11,0.12,0.08,0.07,0.08,0.08,0.09,0.15,0.15)
> cor(x,y) # coeficiente de correlação linear de Pearson
[1] 0.9196635
```

Logo, o coeficiente de correlação linear de Pearson amostral é $r \approx 0,9197$, o que indica correlação linear forte, pois o valor está próximo do extremo do intervalo. A correlação linear é positiva, significando que o aumento da corrente de ar aumenta o percentual de amônia perdida no processo de conversão em ácido nítrico.

b) O modelo linear que descreve a relação entre as duas variáveis, pode ser obtido pelo uso da função `lm` do R.

```
> ajuste<-lm(y~x) # ajuste do modelo
> ajuste
Call: lm(formula = y ~ x)
Coefficients: (Intercept)          x
           -0.4413          0.0102
```

Dela, extraímos os parâmetros do modelo linear: $\hat{\beta}_0 \approx -0,44$ e $\hat{\beta}_1 \approx 0,01$. Desta forma, o modelo que descreve a relação entre a pressão de ar e o percentual de perda de amônia é:

$$\hat{Y} = 0,01X - 0,44. \quad (8.5)$$

A partir do modelo, poderíamos verificar o percentual de perda de amônia para valores de pressão não testados.

A seguir, o comando no R para obter o gráfico de dispersão da Figura 8.5.

```
> plot(x, y, xlab="Corrente de ar", ylab="Porcentagem de amônia")
> abline(ajuste)
```

c) Como interpretação dos parâmetros ajustados, temos:

- O coeficiente linear não tem interpretação lógica neste caso;




Figura 8.5: Modelo ajustado para a relação de porcentagem de amônia perdida *versus* corrente de ar.

- O coeficiente angular significa que, para cada 10 unidades de pressão de ar a mais que é usada no processo, temos 10% a mais de perda de amônia. Ou então, para cada unidade de pressão de ar, perdemos mais 1% de amônia.

O modelo também poderia ser obtido manualmente. Para tanto, é necessário obter os valores de:

- $\sum_{i=1}^n X_i Y_i = 239,53$;
- $\sum_{i=1}^n X_i^2 = 78.365$;
- $\bar{X} \approx 60,43$;
- $\bar{Y} \approx 0,17$;
- $n = 21$.

Aplicando nas fórmulas (8.3) e (8.4), obtemos o modelo (8.5).

Propriedades do estimador de MQ

Pelo teorema de Gauss-Markov, temos que $\hat{\beta}_0$ e $\hat{\beta}_1$ são estimadores não tendenciosos (não viciados) e de mínima variância entre os estimadores lineares, isto é, $\hat{\beta}_0$ e $\hat{\beta}_1$ têm propriedades ótimas.

Além disso, são válidas as seguintes propriedades da regressão linear, ajustada pelo método dos MQ (Azevedo, 2016):

1. A soma dos resíduos ² de qualquer modelo ajustado com intercepto é zero,

$$\sum_{i=1}^n e_i = \sum_{i=1}^n (Y_i - \hat{Y}_i) = 0.$$

2. A soma dos valores observados da variável resposta é igual à soma dos valores ajustados,

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{Y}_i.$$

3. O modelo ajustado passa pelo ponto $(\bar{X}, \bar{Y})$, como mostramos na Figura 8.6.




Figura 8.6: Disposição da média dos dados em relação ao modelo ajustado, para o Exemplo 69.

```
> # Código em R:
> plot(x,y,xlab="Corrente de ar", ylab="Porcentagem de amônia")
> abline(ajuste)
> points(mean(x),mean(y),col="red",pch=19,cex=1.4)
```

4. A soma dos resíduos ponderados pelos correspondentes valores da variável preditora X é zero,

$$\sum_{i=1}^n e_i X_i = 0.$$

Deste modo, X é ortogonal aos resíduos e $\bar{X}$ é independente dos resíduos.

²Os resíduos serão definidos mais adiante na Seção 8.7.

5. A soma dos resíduos ponderados pelos correspondentes valores ajustados é zero,

$$\sum_{i=1}^n e_i \hat{Y}_i = 0.$$

8.5 Qualidade do ajuste

Dentre as propriedades que um modelo deve apresentar, neste tópico vamos nos deter na que tange à “*capacidade explicativa do modelo*”. Para tanto, propõe-se que partimos do princípio de que a variabilidade total dos dados é particionada em duas componentes, uma devida ao modelo ajustado e outra em função dos resíduos.

Um ajuste com boa qualidade deve “*explicar a maior parte da variabilidade dos dados Y*”. Quanto maior for a parcela explicada pelos erros, pior é o ajuste.

Temos que a variância total é dada por:

$$\sigma_Y^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

E temos que:

$$SQTot = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n Y_i^2 - n\bar{Y}^2,$$

$$SQReg = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = \hat{\beta}_1^2 \sum_{i=1}^n (X_i - \bar{X})^2 = \hat{\beta}_1^2 \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right),$$

$$SQe = SQTot - SQReg.$$

Esses valores fazem parte da tabela ANOVA apresentada no capítulo anterior, possibilitando obter uma estatística para avaliar a significância global do ajuste do modelo.

A tabela ANOVA para o ajuste de modelos lineares é apresentada da seguinte forma:

Fonte de variação	Graus de liberdade	Soma dos quadrados	Quadrados médios	Estatística F
Regressão	1	$SQReg$	$QMReg = SQReg$	$F = \frac{QMReg}{QMe}$
Erro	$n - 2$	SQe	$QMe = \frac{SQe}{n - 2}$	
Total	$n - 1$	$SQTot$		

Espera-se que o modelo de regressão explique parte relevante da variabilidade, então $QMReg > QMe$, ou seja, quanto maior for a razão $\frac{QMReg}{QMe}$, maior é a evidência de significância do ajuste.

Se o modelo explicar a mesma proporção da variabilidade que é atribuída aos erros, o que não é desejável, teríamos $\frac{QMReg}{QMe} \approx 1$. A partir dessa relação, podemos dizer que:

- $\frac{QMReg}{QMe} \leq 1$: o ajuste não apresenta evidência de significância;
- $\frac{QMReg}{QMe} > 1$: o ajuste pode apresentar evidência de significância.

Questão: Quão maior deve ser o $QMReg$ com relação ao QMe para que o ajuste seja considerado significativo?

Para responder a essa pergunta, incluímos na análise o nível de significância. Pois a resposta será obtida em relação ao nível de significância desejado e o p-valor associado à estatística do teste.

A regra de decisão é: Se o p-valor for menor que o nível de significância fixado, o ajuste é significativo.

Ou então, podemos utilizar a regra de decisão pela estatística do teste; neste caso, dizemos que o ajuste é significativo ao nível $100(\alpha)\%$ se:

$$F = \frac{QMReg}{QMe} > F_{(1, n-2)}(1 - \alpha),$$

em que $F_{(1, n-2)}(1 - \alpha)$ é valor da tabela da distribuição F.

Exemplo 70. (Continuação do exemplo anterior) Verificar se o ajuste é significativo.

Solução:

A análise será feita mediante funções do R, pelo código a seguir.

```
> anova(ajuste) # cálculo da ANOVA
Analysis of Variance Table

Response: y
      Df Sum Sq Mean Sq F value    Pr(>F)
x       1  0.17501  0.17501    104.2 3.77e-09 ***
Residuals 19  0.03191  0.00168
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

O QMe é uma estimativa da variância dos erros (σ^2), portanto, $s^2 = 0,00168$.

No quesito “*qualidade do ajuste*”, como o p-valor é bem próximo de zero, concluímos que o ajuste é significativo.

8.5.1 Coeficiente de determinação

O coeficiente de determinação, denotado por R^2 , mede a qualidade do modelo em relação à sua habilidade de estimar corretamente os valores da variável resposta (Wikipédia, 2022).

O R^2 indica quanto da variabilidade da variável resposta é explicada pela variabilidade das variáveis explicativas. Quanto maior seu valor, mais explicativo é o modelo. Por exemplo, se o R^2 de determinado modelo é 0,925, isto significa que X explica 92,5% da variabilidade de Y .

Exemplo 71. Para uma amostra de n valores de (X, Y) , temos que, se a reta ajustada passa por todos os pontos, então $SQReg = SQTot$, isto é,

$$\frac{SQReg}{SQTot} = 1.$$

Ou seja, toda a variabilidade de Y é explicada por X .

Porém, geralmente $SQReg < SQTot$, então:

$$R^2 = \frac{SQReg}{SQTot},$$

em que $0 \leq R^2 \leq 1$.

Desta forma, valores mais próximos de 1 indicam maior proporção da variabilidade explicada pelo modelo. No entanto, um R^2 alto, por si só, não garante a qualidade do ajuste.

O coeficiente de determinação R^2 está diretamente ligado ao coeficiente de correlação linear de Pearson r :

$$R^2 = r^2.$$

Desta forma, temos que:

$$r = \frac{Cov(x, y)}{\sigma_x \sigma_y}.$$

Prova-se que $Cor(x, y) = r = \pm\sqrt{R^2}$. A escolha do sinal “+” ou “−” é dada pelo sinal de $\hat{\beta}_1$.

O coeficiente de determinação é uma medida descritiva da qualidade do modelo ajustado, porém, seu valor depende do número de observações da amostra (n), tendendo a aumentar conforme a diminuição de n . Para $n = 2$, número mínimo de pontos necessário para se obter um modelo, temos $R^2 = 1$.

Em esforços para corrigir ou coibir a influência do número de dados, foi definido o **coeficiente de determinação ajustado** ou **coeficiente de determinação corrigido**, denotado por $\bar{R}^2$ e dado por:

$$\bar{R}^2 = R^2 - \frac{1 - R^2}{n - 2}.$$

Exceto para $R^2 = 1$, tem-se: $\overline{R}^2 < R^2$.

Vale ressaltar que o R^2 é uma medida descritiva da qualidade do ajuste, e não deve ser utilizada sozinha. O diagnóstico de ajuste do modelo deve sempre ser realizado.

Exemplo 72. *Obtenha o coeficiente de determinação para os dados do Exemplo 69.*

Solução:

A análise será feita mediante funções do R, pelo código a seguir.

```
> summary(ajuste)
Call: lm(formula = y ~ x)
Residuals:
    Min       1Q   Median       3Q      Max
-0.12290 -0.01127 -0.00046  0.01117  0.08873
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.4413     0.0611   -7.23  7.3e-07 ***
x              0.0102     0.0010   10.21  3.8e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.041 on 19 degrees of freedom
Multiple R-squared:  0.846,    Adjusted R-squared:  0.838
F-statistic: 104 on 1 and 19 DF,  p-value: 3.77e-09
```

Obtivemos diversas estatísticas para o modelo ajustado, dentre elas, $R^2 = 0,846$ e $\overline{R}^2 = 0,838$.

8.6 Distribuição amostral dos estimadores

Nesta seção, vamos apresentar algumas propriedades dos estimadores e técnicas de inferência a respeito dos mesmos.

Propriedade 1. *Os estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ são não viciados, isto é,*

$$E(\hat{\beta}_0) = E(\overline{Y} - \hat{\beta}_1 \overline{X}) = \beta_0 \quad e \quad E(\hat{\beta}_1) = E\left(\frac{\sum_{i=1}^n X_i Y_i - n \overline{X} \overline{Y}}{\sum_{i=1}^n X_i^2 - n \overline{X}^2}\right) = \beta_1.$$

Propriedade 2. As variâncias dos estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ são dadas por:

$$\begin{aligned} Var(\hat{\beta}_0) &= Var(\bar{Y} - \hat{\beta}_1 \bar{X}) = \sigma^2 \frac{\sum_{i=1}^n X_i^2}{n \sum_{i=1}^n (X_i - \bar{X})^2}, \\ Var(\hat{\beta}_1) &= Var\left(\frac{\sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y}}{\sum_{i=1}^n X_i^2 - n \bar{X}^2}\right) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}. \end{aligned}$$

Resultado: Y_i , dado por $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$, tem distribuição Normal de probabilidade, ou seja, $Y_i \sim N(\beta_0 + \beta_1 X_i, \sigma^2)$.

A partir desse resultado, podemos provar que os estimadores possuem distribuição Normal de probabilidade, com média igual ao verdadeiro valor do parâmetro e variância igual à variância dos estimadores. Isto é,

$$\hat{\beta}_0 \sim N(\beta_0, Var(\hat{\beta}_0)) \quad \text{e} \quad \hat{\beta}_1 \sim N(\beta_1, Var(\hat{\beta}_1)).$$

8.6.1 Teste de hipóteses

Suponha que desejamos testar a hipótese de que os coeficientes β_0 e β_1 são iguais às constantes b_0 e b_1 , respectivamente. Ou mesmo, se eles são significativos no modelo, isto é, $b_i = 0$, $i = 0, 1$. Então, teremos:

Hipóteses

$$\begin{cases} H_0 : \beta_i = b_i \\ H_a : \beta_i \neq b_i \end{cases}, \quad i = 0, 1.$$

Estatística do teste

$$t_i = \frac{\hat{\beta}_i - b_i}{\sqrt{Var(\hat{\beta}_i)}}, \quad i = 0, 1,$$

em que t_i segue a distribuição t -Student com $n - 2$ graus de liberdade.

Regra de decisão

Para um teste com nível de significância $100(\alpha)\%$, a hipótese H_0 deverá ser rejeitada se:

$$|t_i| > t_{\alpha/2}(n - 2),$$

em que $t_{\alpha/2}(n - 2)$ é o percentil de ordem $100(1 - \alpha/2)$ da distribuição t -Student com $n - 2$ graus de liberdade.

Este teste está implementado no R e será utilizado no exemplo resolvido no final deste capítulo.

8.6.2 Intervalos de confiança

Os intervalos de confiança são mais informativos que os valores pontuais, pois fornecem faixas de valores nas quais os parâmetros podem estar, atrelados ao nível de significância fixado. Desta forma, além das estimativas pontuais para β_0 e β_1 , também podemos obter intervalos de confiança para eles.

Sendo garantidas as suposições do modelo, então um intervalo de $100(1 - \alpha)\%$ de confiança para os parâmetros β_0 e β_1 , é dado por:

$$\text{IC} [\beta_0, 100(1 - \alpha)\%] = \hat{\beta}_0 \pm t_{\alpha/2}(n - 2) s \sqrt{\frac{\sum_{i=1}^n X_i^2}{n \sum_{i=1}^n (X_i - \bar{X})^2}}$$

e

$$\text{IC} [\beta_1, 100(1 - \alpha)\%] = \hat{\beta}_1 \pm t_{\alpha/2}(n - 2) s \sqrt{\frac{1}{\sum_{i=1}^n (X_i - \bar{X})^2}}.$$

8.7 Adequação do modelo de regressão linear simples

Antes da modelagem de dados relacionados, algumas suposições foram feitas e apresentadas anteriormente. Dentre elas, nesta seção iremos apresentar métodos de verificação das seguintes suposições:

1. Os erros são variáveis aleatórias com média zero, isto é, $E(\varepsilon_i) = 0$;
2. Homocedasticidade: Variância constante ou homogeneidade de variâncias, isto é, $\text{Var}(\varepsilon_i) = \sigma^2$;
3. Independência dos erros: Ausência de correlação entre os erros, ou seja, $E(\varepsilon_i \varepsilon_j) = 0$ para $i \neq j$;
4. Os erros são identicamente distribuídos com distribuição Normal de probabilidade, isto é, $\varepsilon_i \sim N(0, \sigma^2)$;
5. A relação entre X e Y é linear.

A análise de adequação do modelo é feita somente pela confirmação das suposições de regularidades. Coeficiente de determinação e teste de hipóteses medem propriedades do modelo, não adequação do mesmo.

As suposições de variável aleatória com esperança nula, homocedasticidade e independência dos erros, são necessárias para validar a estimação dos parâmetros. Enquanto que a suposição de normalidade dos erros é necessária para garantir a utilização das técnicas de intervalo de confiança e teste de hipóteses para os parâmetros.

Definição 23. *Um resíduo é definido como:*

$$e_i = Y_i - \hat{Y}_i,$$

para $i = 1, 2, \dots, n$, em que Y_i 's são as observações da variável resposta, e $\hat{Y}_i$'s são os valores preditos pelo modelo ajustado.

Interpretamos os resíduos como valores observados para o erro que aparece no modelo. Assim, qualquer suposição feita para os erros pode ser verificada pela análise de resíduos, pois os resíduos devem refletir as propriedades dos erros. Por isso, muitas vezes usa-se a mesma notação (por exemplo, ε_i ou e_i) para erros e resíduos.

A análise de adequação do modelo será feita utilizando métodos gráficos e testes de hipóteses em alguns casos.

a) Gráfico resíduos *versus* tempo (ordem de coleta)

Este recurso gráfico é usado para avaliar a suposição de independência entre os erros e de que são variáveis aleatórias com média zero. Procuramos identificar no gráfico, se existir, algum tipo de tendência ou associação entre a ordem de coleta e os resíduos; se isso ocorrer, a suposição não é garantida. Esse gráfico permite detectar padrões não suspeitados devido ao tempo.

O gráfico é um diagrama de dispersão e espera-se que nele os pontos estejam espalhados sem qualquer ordem aparente em torno do zero, isto é, alocados aleatoriamente.

b) Gráfico resíduos *versus* valores preditos

Também pode ser utilizado o gráfico de resíduos *versus* valores preditos (ou valores da variável preditora), que auxilia na detecção de:

- Heterocedasticidade da variância dos erros (variância não constante para os resíduos);
- Presença de pontos discrepantes;
- Relação entre as variáveis não é linear.

Espera-se que os pontos estejam distribuídos em torno do zero, sem padrões e com amplitude constante. Ou seja, uma distribuição aleatória de média 0 e amplitude constante.

Para corroborar com o resultado visual, podemos fazer um teste de comparação de variâncias. Divide-se o conjunto de dados em duas partes, utilizando a mediana como ponto de corte, e comparamos a variância dos subgrupos.

No exemplo, aplicaremos o teste e apresentaremos os comandos para realizá-lo.

c) Normalidade dos resíduos

Este gráfico permite identificar se a distribuição originária dos dados é Normal e também se existem valores que se sobressaem.

O pressuposto de normalidade será considerado válido se os pontos do gráfico estiverem localizados ao longo de uma linha reta, aproximadamente.

Usualmente, o julgamento de proximidade dos pontos à linha reta é subjetivo. Para completar a avaliação de normalidade, pode ser realizado um teste de normalidade, como o de Shapiro-Wilk, que apresentaremos no exemplo.

Observação: Algumas disposições dos pontos em torno da reta indicam ausência de normalidade. Por exemplo, se a disposição dos pontos lembram o formato da letra S ou mesmo S-invertido, temos distribuição de caudas muito curtas (valores próximos da média) e distribuição com caudas muito longas (muitos valores extremos), respectivamente. Outro formato possível de ser identificado, é o da letra J ou J-invertido, os quais indicam distribuições assimétricas positivas e negativas, respectivamente.

Exemplo 73. *Certa imobiliária deseja verificar a viabilidade do uso da informação relativa à idade da casa para inferir sobre o preço de aluguel da mesma. Para tanto, observou algumas casas, registrando-se a idade (em anos) e o valor de aluguel (em reais), conforme a tabela abaixo. A partir destes dados, deseja-se verificar a viabilidade ou não do uso de um modelo de regressão linear simples para solução desta questão, bem como proceder toda a análise, como solicitado a seguir.*

<i>Idade</i>	10	13	5	7	18	8	10	4	1	4
<i>Aluguel</i>	450	350	620	580	290	400	400	700	650	530

a) *Obtenha o coeficiente de correlação linear para os dados e o diagrama de dispersão.*

b) *Determine o modelo de regressão linear simples, interprete os parâmetros e represente o modelo no diagrama de dispersão.*

c) *Teste o ajuste. A variabilidade dos valores de aluguel para os dados amostrados é explicada pela idade do imóvel?*

d) *Qual a porcentagem da variação do aluguel que a idade do imóvel explica?*

- e) Obtenha o intervalo de confiança de 95% para β_0 e β_1 .
 f) Teste as hipóteses seguintes ao nível de 5% de significância:

$$\begin{cases} H_0 : \beta_0 = 750 \\ H_a : \beta_0 \neq 750 \end{cases}$$

e

$$\begin{cases} H_0 : \beta_1 = -50 \\ H_a : \beta_1 \neq -50 \end{cases}$$

g) Realize a análise de resíduos para validar os resultados obtidos.

h) Pelo modelo, qual o valor do aluguel de imóveis com 3 e 9 anos? E se souberes que o aluguel do imóvel custa 300 reais, e considerando que o imóvel possui características compatíveis com os considerados na análise, qual seria sua idade?

Solução:

O exemplo será resolvido no R. Os códigos e as saídas serão colocados de acordo com a necessidade.

a) Considere os seguintes comandos e resultados:

```
> idade<-c(10,13,5,7,18,8,10,4,1,4)
> aluguel<-c(450,350,620,580,290,400,400,700,650,530)
> plot(idade, aluguel, lwd=2) # diagrama de dispersão
> cor(idade, aluguel) # cálculo do coeficiente de correlação
[1] -0.8926152
```

O coeficiente de correlação linear de Pearson indica correlação linear inversa, significando que, quanto mais velha a casa, mais barato é o aluguel, e a correlação pode ser considerada alta, pois $r \approx -0,8926$. O diagrama de dispersão dos dados é dado na Figura 8.7.

b) Para ajustar o modelo, iremos utilizar novamente a função `lm`, como segue.

```
> ajuste<-lm(aluguel~idade) # ajuste do modelo
> ajuste # fornece os coeficientes
Call: lm(formula = aluguel ~ idade)
Coefficients:
(Intercept)      idade
      695.57      -24.82
```

O coeficiente angular é negativo, como era de se esperar, pois ele tem o mesmo sinal de r . E o aluguel de cada imóvel pode ser estimado pela relação:

$$Aluguel = 695,57 - 24,82 \times Idade.$$




Figura 8.7: Diagrama de dispersão dos dados do Exemplo 73.

Se denotarmos X como a variável explicativa e Y como a variável resposta, o modelo é escrito da forma tradicional: $Y = 695,57 - 24,82X$.

Para este caso, o parâmetro linear (β_0) possui interpretação lógica. Segundo o modelo, uma casa nova com as mesmas especificações das que foram observadas, terá um aluguel de 695,57 reais. Este é o valor de partida do aluguel.

O parâmetro angular β_1 indica que, sem contar com o reajuste do aluguel, a cada ano o aluguel diminui 24,82 reais, ou seja, para cada ano que aumenta na idade do imóvel, o valor do aluguel cai 24,82 reais.




Figura 8.8: Disposição da média dos dados em relação ao modelo ajustado (Exemplo 73).

A representação do modelo ajustado em relação aos dados observados, está na

Figura 8.8.

```
> # Comando no R para obter o diagrama de dispersão:
> plot(idade, aluguel, lwd=2) # diagrama de dispersão
> abline(ajuste) # traça o modelo no gráfico
> points(mean(idade), mean(aluguel), col="red", pch=19, cex=1.4)
> legend(12, 680, c("Ajustado", "Observado", "Média"), col=c("black", "black", "red"), lty=c(1, NA, NA), pch=c(NA, 1, 19), lwd=c(1, NA, NA))
```

c) A significância global do modelo é avaliada a partir da ANOVA.

```
> anova(ajuste)
Analysis of Variance Table

Response: aluguel
          Df Sum Sq Mean Sq F value    Pr(>F)
idade      1 138007   138007    31.36 0.00051 ***
Residuals  8  35203     4400
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Temos que $F = 31,36$. Se fixarmos o nível de significância de 5%, então, pela regra de decisão, temos que $F_{(1,8)}(0,95) = 5,32$ e, como o valor obtido é maior que o valor tabelado, temos evidências de que a idade do imóvel explica a variação do preço do aluguel.

Observamos que o p-valor da ANOVA é bem próximo de 0, com algarismo significativo na quarta casa decimal. Então, podemos concluir por ele que há evidências de significância global do ajuste; a adequação do modelo deve ser verificada também pelos diagnósticos dos resíduos.

Da ANOVA, temos também uma estimativa da variância dos erros, que é dada por QMe ; neste caso, $s^2 = 4.400$.

d) O coeficiente de determinação pode ser obtido de duas formas: $R^2 = r^2$ e $R^2 = \frac{SQReg}{SQTot}$. E seu valor é $R^2 = 0,7968$.

Mas vamos trabalhar com o $\bar{R}^2 = 0,7714$, que indica que 77,14% da variação do aluguel é explicada pela idade do imóvel. O restante da variação do preço (22,86%) é devido a causas aleatórias ou a outras variáveis que poderiam ser consideradas na análise de regressão múltipla. Variáveis como a localização do imóvel podem influenciar no preço do aluguel.

e) Os intervalos de confiança de 95% para os parâmetros são:

$$\begin{aligned} IC[\beta_0, 95\%] &= (600,5685; 790,5743), \\ IC[\beta_1, 95\%] &= (-35,0421; -14,6007), \end{aligned}$$

que são obtidos por meio da função `confint` predefinida no R, como segue.

```
> confint(ajuste)
                2.5 %    97.5 %
(Intercept) 600.5685 790.5743
idade       -35.0421 -14.6007
```

Pelos dados obtidos, com 95% de confiança, o valor médio estimado do aluguel de uma casa nova com as mesmas especificações das consideradas está entre 600 e 790 reais. E a depreciação média estimada do preço com o passar dos anos está entre 14 e 35 reais.

f) O teste de hipóteses para os parâmetros da regressão, está programado no R considerando $b_i = 0$, $i = 0, 1$, isto é, para testar as hipóteses:

$$\begin{cases} H_0 : \beta_0 = 0 \\ H_a : \beta_0 \neq 0 \end{cases} \quad (8.6)$$

e

$$\begin{cases} H_0 : \beta_1 = 0 \\ H_a : \beta_1 \neq 0 \end{cases} \quad (8.7)$$

Os resultados para os testes de hipóteses (8.6) e (8.7) podem ser obtidos através do comando:

```
> summary(ajuste)
Call: lm(formula = aluguel ~ idade)
Residuals:
    Min       1Q   Median       3Q      Max
-97.00 -41.24  -9.05   46.71 103.71
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    695.57     41.20    16.9 1.5e-07 ***
idade         -24.82      4.43     -5.6 0.00051 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 66.3 on 8 degrees of freedom
Multiple R-squared:  0.797,    Adjusted R-squared:  0.771
F-statistic: 31.4 on 1 and 8 DF,  p-value: 0.00051
```

Inicialmente, o comando `summary(ajuste)` retorna os quantis dos resíduos. E em *Coefficients*, temos as estimativas na primeira coluna (*Estimate*); na segunda, temos os valores do erro-padrão (*Std. Error*); em seguida, as estatísticas dos testes (*t value*) e o p-valor associado a cada uma delas ($Pr(> |t|)$), que, por serem da ordem de 10^{-4} ou menor, então rejeitam as hipóteses de que $\beta_0 = 0$ e $\beta_1 = 0$.

O valor do R^2 é também fornecido (*Multiple R-squared*), bem como a estatística da ANOVA do ajuste do modelo (*F-statistic*) e seu p-valor.

Porém, como queremos testar as hipóteses nulas: $H_0 : \beta_0 = 750$ e $H_0 : \beta_1 = -50$, e para executar estes testes precisaríamos desenvolver um código para obter $Var(\hat{\beta}_0)$ e $Var(\hat{\beta}_1)$, então vamos utilizar o conceito de intervalo de confiança para verificar se podemos rejeitar ou não as hipóteses nulas.

Considerando os resultados dados no item anterior, rejeitamos a hipótese nula referente a β_1 e não rejeitamos a hipótese nula referente a β_0 .

g) Análise de resíduos:

Para avaliar os pressupostos de que os erros possuem variância constante e são não correlacionados entre si, utilizamos os gráficos de resíduos *versus* valores ajustados e/ou resíduos *versus* valores da variável preditora.

```
> # Código em R para realizar a análise de resíduos:  
> plot(fitted(ajuste), residuals(ajuste), xlab="Valores ajustados",  
      ylab="Resíduos")  
> abline(h=0)  
> dev.new() # cria uma nova janela de gráfico  
> plot(idade, residuals(ajuste), xlab="Idade", ylab="Resíduos")  
> abline(h=0)
```




Figura 8.9: Gráficos de resíduos.

Aparentemente, teremos problemas com a hipótese de homocedasticidade, pois pelos gráficos dados na Figura 8.9, os resíduos para os primeiros valores da amostra tendem a ter valores positivos, e para os últimos valores os resíduos são negativos.

Para esclarecer esta dúvida, vamos fazer o teste de comparação de variâncias. Para tanto, vamos dividir o conjunto de dados em duas partes: na primeira, vamos

considerar os 5 primeiros dados; e na outra, os 5 últimos (a divisão também poderia ser feita utilizando a mediana).

```
> var.test(residuals(ajuste)[1:5], residuals(ajuste)[6:10])
F test to compare two variances
data:  residuals(ajuste)[1:5] and residuals(ajuste)[6:10]
F = 0.19647, num df = 4, denom df = 4, p-value = 0.1441
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval: 0.0204557 1.8869764
sample estimates: ratio of variances 0.1964673
```

O resultado do teste apresentou p-valor = 0,1441, que é maior que os níveis de significância usualmente utilizados (1%, 5% e 10%). Logo, não há evidências contra a homocedasticidade dos resíduos.

Para avaliar o pressuposto de normalidade dos erros, deve-se construir o gráfico Q-Q dos resíduos e/ou fazer o teste de normalidade.

```
> # Gráfico Q-Q Normal dos resíduos:
> qqnorm(residuals(ajuste), xlab="Quantis teóricos", ylab="Quantis amostrais", main="Normal Q-Q plot")
> qqline(residuals(ajuste))
```




Figura 8.10: Gráfico Q-Q Normal dos resíduos.

```
> # Teste de normalidade:
> shapiro.test(residuals(ajuste))
Shapiro-Wilk normality test
data:  residuals(ajuste)
W = 0.97708, p-value = 0.9477
```

O resultado do teste de normalidade de Shapiro-Wilk apresentou p-valor = 0,9477, que é considerado alto. Então, não rejeitamos a hipótese de normalidade dos resíduos.

Para finalizar, resta a análise do gráfico dos resíduos *versus* tempo, para descartar a hipótese de autocorrelação entre os erros. Neste caso, observamos que, aparentemente, as primeiras amostras apresentaram valores estimados maiores do que os observados, e esta relação foi invertida para as últimas amostras (ver Figura 8.11). A decisão de considerar ou não esta relação relevante, cabe a especialistas da área, pois, se os dados fossem apresentados em ordem crescente em X (idade do imóvel), tal relação já não é observada.




Figura 8.11: Comportamento dos resíduos em relação à ordem de coleta dos dados.

```
> # Comportamento dos resíduos:
> plot(residuals(ajuste), xlab="Índice", ylab="Resíduos")
> abline(0,0)
```

Para finalizar, é possível obter os valores numéricos dos resíduos e os valores estimados/preditos pelo modelo. Isto pode ser feito utilizando os seguintes comandos, respectivamente.

```
> residuals(ajuste) # ou ainda: ajuste$residuals
> fitted(ajuste) # ou ainda: ajuste$fitted.values
```

h) Para obter os valores do aluguel para as idades fornecidas, é só substituir as idades na fórmula: $Aluguel = 695,57 - 24,82 \times Idade$.

Para idade igual a 3 anos, o valor do aluguel é 621,11 reais.

Para idade de 9 anos, o valor do aluguel é 472,19 reais.

Para obter a idade do imóvel, dado que o aluguel é 300 reais, utilizamos a inversa da função acima. Neste caso, para um aluguel de 300 reais, a idade do imóvel estimada pelo modelo é de 15,95 anos, ou seja, aproximadamente 16 anos.

8.8 Considerações finais

As técnicas de regressão e correlação descritas neste capítulo têm por objetivo estimar uma relação linear que possa existir entre duas variáveis na população. A análise de correlação, por meio do coeficiente de correlação linear de Pearson, visa mensurar o grau de associação linear entre essas variáveis, enquanto que a regressão linear simples obtém a equação matemática da reta que melhor descreve esse relacionamento.

Como visto na Seção 8.4.1, a análise de regressão linear simples requer fortes suposições para seu uso, como: linearidade da relação entre X e Y , normalidade, independência e homocedasticidade dos erros. Foi a partir dessas limitações que surgiram extensões dos modelos lineares clássicos (regressão linear simples e múltipla), como por exemplo, os modelos lineares generalizados (MLG), que não são abordados neste compêndio. Para uma introdução aos MLG, sugerimos os livros (em inglês) de Dobson & Barnett (2018), Dunn & Smyth (2018), e Agresti (2015), dentre outros. Já em português, recomendamos os livros de Paula (2025)³, Cordeiro & Demétrio (2008), Turkman & Silva (2000).

8.9 Exercícios propostos

Exercício 1. Construa o diagrama de dispersão e calcule o coeficiente de correlação linear para cada par de variáveis a seguir. Interprete os resultados.

X_1	20	21	14	18	19	26
Y_1	5	4	10	8	7	1

X_2	1,5	1,2	-1,1	-0,6	1,6	1,0	-1,4	0,0	-0,1
Y_2	11,2	6,3	16,3	17,1	11,8	14,7	1,8	13,6	10,5

X_3	-1,74	0,27	-1,38	-0,86	0,42
Y_3	3,28	0,54	0,33	-1,05	1,38

X_4	-1,8	0,4	0,3	1,2	0,2	0,5	-0,6	-0,3	-0,7	0,1
Y_4	3,3	5,4	5,1	6,5	4,9	5,8	4,3	5,0	4,2	5,1

³O livro de Paula (2025) está disponível na Internet pelo endereço eletrônico: https://www.ime.usp.br/~giapaula/texto_2025.pdf.

Exercício 2. Teste, com o nível de significância de 5%, a hipótese $H_0 : \rho = 0$ contra a alternativa $H_a : \rho \neq 0$, para cada conjunto de dados do exercício anterior.

Exercício 3. Suponha que um instituto de pesquisa esteja interessado em saber qual a relação entre a escolaridade do chefe de família (X) e a renda familiar mensal (Y). Para isso, coletou-se uma amostra de 30 famílias e registrou-se o tempo de estudo (em anos) da pessoa de referência e a renda familiar mensal (em reais) de cada uma delas. Os resultados encontram-se na tabela abaixo.

Família	1	2	3	4	5	6	7	8	9	10
X	7	8	10	14	6	14	15	11	11	4
Y	3.949	5.535	5.742	6.454	4.147	7.162	9.424	5.472	4.512	1.946
Família	11	12	13	14	15	16	17	18	19	20
X	6	6	12	8	13	9	12	15	8	13
Y	3.228	2.974	6.562	4.205	6.889	5.628	5.636	9.060	4.797	7.262
Família	21	22	23	24	25	26	27	28	29	30
X	15	6	11	5	7	8	4	8	14	8
Y	6.264	3.499	5.744	4.147	5.691	6.031	1.687	4.004	7.710	3.740

- Construa o diagrama de dispersão e interprete-o.
- Obtenha o coeficiente de correlação linear e interprete o seu valor.
- Determine o modelo linear: $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$.
- Represente a reta de regressão no gráfico do item (a).
- Interprete o parâmetro ajustado $\hat{\beta}_0$.
- Interprete o parâmetro ajustado $\hat{\beta}_1$.
- Calcule e interprete o coeficiente de determinação $\bar{R}^2$.

Exercício 4. Analise os resíduos do modelo ajustado no exercício anterior e comente sobre a adequação do modelo.

Exercício 5. A análise do peso (em kg) de 15 homens escolhidos aleatoriamente de uma população, como função linear da sua altura (em cm), forneceu os resultados abaixo com alguns campos faltantes. Preencha os espaços assinalados pelas letras de (a) a (k) e interprete os resultados.

Tabela ANOVA					
Fonte de variação	Graus de liberdade	Soma dos quadrados	Quadrados médios	Estatística F	p-valor
Altura	(a)	1.103,3097	(e)	(g)	7,39e-07
Resíduos	(b)	(d)	(f)		
Total	(c)	1.286,9333			

Modelo					IC 95%	
	Estimativa	Erro-padrão	t	p-valor	2,5%	97,5%
Intercepto	-39,1475	12,8315	(h)	0,0093	(j)	-11,4267
Altura	0,6610	0,0748	(i)	7,39e-07	0,4995	(k)

Exercício 6. Considere os seguintes dados referentes a contagens diárias de microrganismos em uma placa de Petri.

Dia (X)	1	2	3	4	5	6	7	8	9	10
Nº colônias visíveis (Y)	2	5	7	19	31	48	96	164	289	515

a) Ajuste Y em função de X nos três modelos abaixo:

$$\begin{aligned} \text{Modelo linear: } \hat{Y} &= \hat{\beta}_0 + \hat{\beta}_1 X \\ \text{Modelo exponencial: } \hat{Y} &= \hat{\beta}_0 \hat{\beta}_1^X \\ \text{Modelo potência: } \hat{Y} &= \hat{\beta}_0 X^{\hat{\beta}_1} \end{aligned}$$

b) Encontre o coeficiente de determinação $\bar{R}^2$ para cada modelo ajustado.

c) Qual dos três modelos ajustados é o mais eficaz para esse conjunto de dados? Justifique.

d) Usando o modelo melhor ajustado, qual seria o valor esperado de Y se $X = 12$?

Exercício 7. Um professor de História do 8º ano está interessado em investigar a relação entre o tempo de estudo (em horas) e a nota na prova da disciplina (escala de 0 a 1.000). Para tanto, tomou-se uma amostra de 7 alunos, obtendo-se os dados mostrados na tabela abaixo.

Aluno	A	B	C	D	E	G	H
Tempo (X)	2	3	4	5	5	7	10
Nota (Y)	354	382	589	733	590	862	920

Ajustando-se o modelo linear, obteve-se: $\hat{Y} = 239,72 + 76,44x$ e $F = 32,11$. Como você argumentaria com o aluno A para que ele estudasse mais para a prova de História?

Referências bibliográficas

- AGRESTI, A. Categorical Data Analysis. John Wiley & Sons, New York, NY, 1990.
- AGRESTI, A. Foundations of Linear and Generalized Linear Models. John Wiley & Sons, Hoboken, NJ, 2015.
- AITKIN, M.; ANDERSON, D.; FRANCIS, B.; HINDE, J. Statistical Modelling in GLIM. Oxford University Press, New York, NY, 1989.
- ANDERSON, D. R.; SWEENEY, D. J.; WILLIAMS, T. A. Estatística Aplicada à Administração e Economia. 2ª ed., São Paulo: Pioneira Thomson Learning, 2007.
- ANDERSON, T. W. An Introduction to Multivariate Analysis. 2nd ed., John Wiley & Sons, New York, NY, 1984.
- ARA, A.; LOUZADA, F. (2012). Descrição de algumas das dimensões que compõem o perfil do corpo docente dos Departamentos de Estatística do Brasil. *Bolema* 26(42a):23-38.
- ARAUJO, M. E. A História da Estatística. Em: Semana do Estatístico - 93. Departamento de Estatística da UFRN, Natal, 1993.
- ARNOLD, S. F. The Theory of Linear Models and Multivariate Analysis. John Wiley & Sons, New York, NY, 1981.
- ATKINSON, A. C. Plots, Transformations and Regression. Oxford University Press, New York, NY, 1985.
- AZEVEDO, P. R. M. Introdução à Estatística. 3ª ed., Natal: EDUFRN, 2016.
- BANZATO, D. A.; KRONKA, S. N. Experimentação Agrícola. 4ª ed., Jaboticabal: FUNEP, 2006.
- BATES, D. M.; WATTS, D. G. Nonlinear Regression Analysis and Its Applications. John Wiley & Sons, New York, NY, 1988.
- BEARZOTI, E.; FILHO, J. S. S. B. Introdução à Inferência Estatística. Lavras: UFLA/FAEPE, 2000.
- BECKER, R. A.; CHAMBERS, J. M.; WILKS, A. R. The New S Language. Chapman & Hall, London, 1988.
- BELSLEY, D. A.; KUH, E.; WELSCH, R. E. Regression Diagnostics. John Wiley & Sons, New York, NY, 1980.
- BICKEL, P.; DOKSUM, K. Mathematical Statistics. Prentice-Hall, Englewood Cliffs, NJ, 1977.

- BOLFARINE, H.; BUSSAB, W. O. Elementos de Amostragem. São Paulo: Edgard Blücher, 2005.
- BOTTER, D. A.; PAULA, G. A.; LEITE, J. G.; CORDANI, L. K. Noções de Estatística. São Paulo: Edusp, 1996.
- BUSSAB, W. O. Análise de Variância e Regressão: Uma Introdução. São Paulo: Anual, 1986.
- BUSSAB, W. O.; MORETTIN, P. A. Estatística Básica. 5ª ed., São Paulo: Editora Saraiva, 2006.
- CASELLA, G. e BERGER, R. L. Statistical Inference. 2ª ed., Duxbury Press, 2002.
- CHAMBERS, J. M.; HASTIE, T. J. Statistical Models in S. Chapman & Hall, London, 1992.
- CHATTERJEE, S.; HADI, A. S. Sensitivity Analysis in Linear Regression. John Wiley & Sons, New York, NY, 1988.
- CLAYTON, D.; HILLS, M. Statistical Models in Epidemiology. Oxford University Press, Oxford, 1993.
- COLLISCHONN, W. Hidrologia Estatística. 2021. Disponível em: https://github.com/bielenki/Hidrologia-Estatistica/blob/master/apostila_HidroEstat%C3%A9stica_walter_colischon.pdf.
- COLOSIMO, E. A.; GIOLO, S. R. Análise de Sobrevida Aplicada. São Paulo: Edgard Blücher, 2006.
- COOK, R. D.; WEISBERG, S. Residuals and Influence in Regression. Chapman & Hall, New York, NY, 1982.
- CORDEIRO, G. M.; DEMÉTRIO, C. G. B. Modelos Lineares Generalizados e Extensões. 2008.
- CORREA, S. M. B. B. Probabilidade e Estatística. 2ª ed., Belo Horizonte: PUC Minas Virtual, 2003.
- COSTA NETO, P. L. O. Estatística. São Paulo: Edgard Blücher, 1978.
- COX, D. R.; HINKLEY, D. V. Theoretical Statistics. Chapman & Hall, London, 1974.
- CRAWLEY, M. J. Statistics: An Introduction with R. 2ª ed., John Wiley & Sons, Chichester, 2015.
- DALGAARD, P. Introductory Statistics with R. Springer-Verlag, New York, NY, 2002.
- DANTAS, C. A. B. Desenvolvimento da Estatística na Universidade de São Paulo. Em: Associação Brasileira de Estatística, História da Estatística no Brasil. ABE biênio 2000/2002.
- DOBSON, A. J.; BARNETT, A. G. An Introduction to Generalized Linear Models. 4ª ed., CRC Press, Boca Raton, FL, 2018.
- DUNN, P. K.; SMYTH, G. K. Generalized Linear Models with Examples in R. Springer, New York, NY, 2018.

- EVERITT, B. S. A Handbook of Statistical Analyses Using S-PLUS. Chapman & Hall, London, 1994.
- FERREIRA, D. F. Estatística Básica. UFLA, 1996.
- FERREIRA FILHO, P. Intervalos de confiança para os parâmetros de regressão L_1 : pequenas amostras. Dissertação (Mestrado em Estatística) - Instituto de Matemática, Estatística e Ciência da Computação, Universidade de Campinas. Campinas, p.80, 1988.
- FONSECA, J. S.; MARTINS, G. A. Curso de Estatística. 6ª ed., São Paulo: Atlas, 1996.
- FREUND, J. E.; SIMON, G. A. Estatística Aplicada - Economia, Administração e Contabilidade. São Paulo: Bookman, 2000.
- FREUND, J. E.; SIMON, G. A. Estatística Aplicada. 9ª ed., Porto Alegre: Bookman, 2000.
- GOMES, M. S. S. O.; LIMA, C. A. (2012). Ensino de distribuição normal na disciplina de Estatística aplicada a Química utilizando palitos de fósforos. *Educación Química* 23(1):81-84.
- GOMES, S. C.; MONTEIRO, M. N. O. (2003). A Evolução da Teoria da Probabilidade. *Traços* 6(11):115-122.
- JØRGENSEN, B. The Theory of Dispersion Models. Chapman & Hall, London, 1996.
- HALD, A. A History of Mathematical Statistics: From 1750 to 1930. John Wiley & Sons, New York, NY, 1998.
- HALD, A. Statistical Theory with Engineering Applications. John Wiley & Sons, New York, NY, 1952.
- HOGG, R. V. (1979). Statistical Robustness: One View of its use in Applications Today. *The American Statistician* 33(3):108-115.
- IBGE. Fundação Instituto Brasileiro de Geografia e Estatística. Calendário comemorativo dos 50 anos de fundação do IBGE. Rio de Janeiro, 1987.
- JAMES, B. Probabilidade: Um curso em nível intermediário. IMPA. 2002.
- JOHNSON, N.; KOTZ, S.; BALAKRISHNAN, N. Continuous Univariate Distributions. 2ª ed., John Wiley & Sons, New York, NY, 1994.
- JOHNSON, N.; KOTZ, S.; KEMP, A. Univariate Discrete Distributions. 2ª ed., John Wiley & Sons, New York, NY, 1992.
- KRAUSE, A.; OLSON, M. The Basics of S and S-PLUS. Springer-Verlag, New York, NY, 2000.
- LAURENTI, R.; JORGE, M. H. P. M.; LEBRÃO, M. L.; GOTLIEB, S. L. D. Estatísticas de Saúde. São Paulo: Editora Pedagógica e Universitária Ltda, 1985.
- LEVIN, J. Estatística Aplicada a Ciências Humanas. São Paulo: Editora Harper & Row do Brasil, 1978.
- LINDGREN, B. L. Statistical Theory. 4ª ed., Macmillan, New York, NY, 1993.
- LOPES, P. A. Probabilidades e Estatística. Editora R.A., 1999.

- MARION, J. C.; SILVA, L. B. (1986). Contabilometria: novo campo de estudos para a contabilidade. *Revista Brasileira de Contabilidade* 59:34-41.
- McCULLAGH, P.; NELDER, J. A. *Generalized Linear Models*. 2ª ed., Chapman & Hall, London, 1989.
- MEDRONHO, R.; CARVALHO, D. M.; BLOCH, K. V.; LUIZ, R. R.; WERNECK, G. L. (eds.). *Epidemiologia*. São Paulo: Atheneu, 2002.
- MEYER, P. L. *Probabilidade - Aplicações à Estatística*. Tradução de Ruy C. B. Lourenço Filho, (ENCE/IBGE), Rio de Janeiro, RJ, 1984.
- MILLER, R. G. *Beyond ANOVA: Basics of Applied Statistics*. Chapman & Hall, London, 1997.
- MONTGOMERY, D. C. *Design and Analysis of Experiments*. 8ª ed., John Wiley & Sons, Hoboken, NJ, 2013.
- MONTGOMERY, D. C.; PECK, E. A.; VINING, G. G. *Introduction to Linear Regression Analysis*. 4ª ed., John Wiley & Sons, New York, NY, 2006.
- MOOD, A. M.; GRAYBILL, F. A.; BOES, D. C. *Introduction to the Theory of Statistics*. 3ª ed., McGraw-Hill, New York, NY, 1974.
- MORRETIN, L. G. *Estatística Básica: Inferência - Volume 2*. São Paulo: Makron Books, 2000.
- PADOVANI, C. R. *Bioestatística*. São Paulo: Cultura Acadêmica: Universidade Estadual Paulista, Pró-Reitoria de Graduação, 2012.
- PAULA, G. A. *Modelos de regressão com apoio computacional*. São Paulo: IME-USP, 2013.
- PEREIRA, A. R.; ARRUDA, H. V. Ajuste prático de curvas na pesquisa biológica. *Fundação Cargill, Campinas, SP*, p.14-15, 1987.
- PIMENTEL GOMES, F. *Curso de Estatística Experimental*. 11ª ed., Piracicaba: Livraria Nobel, 1985.
- R DEVELOPMENT CORE TEAM. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing, 2010. ISBN 3-900051-07-0. URL: <http://www.R-project.org>
- RAO, C. R. *Linear Statistical Inference and its Applications*. 2ª ed., John Wiley & Sons, New York, NY, 1973.
- RICE, J. R.; WHITE, J. S. (1964). Norms for Smoothing and Estimation. *SIAM Review* 6(3):243-256.
- ROTHMAN, K. J. (1996). Lessons from John Graunt. *The Lancet* 347:37-39.
- SEARLE, S. R. *Linear Models*. John Wiley & Sons, New York, NY, 1971.
- SEARLE, S. R.; CASELLA, G.; MCCULLOCH, C. E. *Variance Components*. John Wiley & Sons, New York, NY, 1992.
- SILVA, E. M.; SILVA, E. M.; GONÇALVES, V.; MUROLO, A. C. *Estatística para os cursos de Economia, Administração e Ciências Contábeis*. 3ª ed., São Paulo: Atlas, 1999.
- SILVA, H. D. *Estatística*. 2003.

- SILVA, L. F. A Fundação Instituto Brasileiro de Geografia e Estatística - IBGE e a produção das estatísticas. Em: Revista Brasileira de Estatística - RBES. Rio de Janeiro, Ano 50, n.193, 1989.
- SILVEY, S. D. Statistical Inference. Chapman & Hall, London, 1970.
- SNEDECOR, G. W.; COCHRAN, W. G. Statistical Methods. The Iowa State University Press, 1967.
- SPECTOR, P. An Introduction to S and S-Plus. Duxbury, Belmont, CA, 1994.
- SPIEGEL, M. R. Estatística. São Paulo: McGraw-Hill, 1972.
- SPIEGEL, M. R. Estatística: Resumo da teoria. São Paulo: McGraw-Hill do Brasil, 1977.
- STEVENSON, W. J. Estatística aplicada à administração. São Paulo: Harbra, 2001.
- SZWARCWALD, C. L.; CASTILHO, E. A. (1992). The paths of statistics and its incursions through epidemiology. Caderno Saúde Pública 8(1):5–21.
- TAVARES, M. Estatística aplicada à administração. 3ª ed., Florianópolis: Universidade Federal de Santa Catarina, 2014.
- TOLEDO, G. L.; OVALLE, I. I. Estatística Básica. 2ª ed., São Paulo: Editora Atlas, 1994.
- TRIOLA, M. F. Introdução à Estatística. 10ª ed., Rio de Janeiro: Editora LTC, 2008.
- TURKMAN, M. A. A.; SILVA, G. L. Modelos Lineares Generalizados: da teoria à prática. Em: VIII Congresso Anual da Sociedade Portuguesa de Estatística. Lisboa, 2000.
- VENABLES, W. N.; RIPLEY, B. D. Modern Applied Statistics with S. 4ª ed., Springer-Verlag, New York, NY, 2002.
- VENABLES, W. N.; RIPLEY, B. D. S Programming. Springer-Verlag, New York, NY, 2000.
- VIEIRA, S. Introdução à Estatística. Rio de Janeiro: Editora Campus Ltda, 1981.
- VIEIRA, S.; HOFFMANN, R. Estatística Experimental. São Paulo: Atlas, 1989.
- WEISBERG, S. Applied Linear Regression. 2ª ed., John Wiley & Sons, New York, NY, 1985.
- WIKIPÉDIA. Método dos mínimos quadrados. Wikipédia, a enciclopédia livre. https://pt.wikipedia.org/w/index.php?title=M%C3%A9todo_dos_m%C3%ADnimos_quadrados&oldid=58264800. Acesso em 18 de junho de 2022.
- YULE, G. U.; KENDALL, M. G. An Introduction to the Theory of Statistics. Charles Griffin, London, 1950.

Tabelas

Tabela A1: Distribuição Normal padrão - $P(Z < z_\alpha) = \alpha$.

Parte inteira e 1 ^a decimal de z_α	2 ^a decimal de z_α										
	0	1	2	3	4	5	6	7	8	9	
0,0	0,5000	0,5040	0,5079	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359	0,0
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753	0,1
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141	0,2
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517	0,3
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879	0,4
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224	0,5
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549	0,6
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852	0,7
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133	0,8
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389	0,9
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621	1,0
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830	1,1
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015	1,2
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177	1,3
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319	1,4
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441	1,5
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545	1,6
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633	1,7
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706	1,8
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767	1,9
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817	2,0
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857	2,1
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890	2,2
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916	2,3
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936	2,4
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952	2,5
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964	2,6
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974	2,7
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981	2,8
2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986	2,9
3,0	0,9987	0,9987	0,9987	0,9988	0,9988	0,9989	0,9989	0,9989	0,9990	0,9990	3,0
3,1	0,9990	0,9991	0,9991	0,9991	0,9992	0,9992	0,9992	0,9992	0,9993	0,9993	3,1
3,2	0,9993	0,9993	0,9994	0,9994	0,9994	0,9994	0,9994	0,9995	0,9995	0,9995	3,2
3,3	0,9995	0,9995	0,9995	0,9996	0,9996	0,9996	0,9996	0,9996	0,9996	0,9997	3,3
3,4	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9998	3,4
3,5	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	3,5
3,6	0,9998	0,9998	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	3,6
3,7	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	3,7
3,8	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	3,8
3,9	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	3,9

Tabela A2: Distribuição t -Student - $P(T > t_\alpha(gl)) = \alpha$.

gl	α									gl
	0,25	0,1	0,05	0,025	0,01	0,005	0,0025	0,001	0,0005	
1	1,0000	3,0777	6,3138	12,7062	31,8205	63,6567	127,3213	318,3088	636,6192	1
2	0,8165	1,8856	2,9200	4,3027	6,9646	9,9248	14,0890	22,3271	31,5991	2
3	0,7649	1,6377	2,3534	3,1824	4,5407	5,8409	7,4533	10,2145	12,9240	3
4	0,7407	1,5332	2,1318	2,7764	3,7469	4,6041	5,5976	7,1732	8,6103	4
5	0,7267	1,4759	2,0150	2,5706	3,3649	4,0321	4,7733	5,8934	6,8688	5
6	0,7176	1,4398	1,9432	2,4469	3,1427	3,7074	4,3168	5,2076	5,9588	6
7	0,7111	1,4149	1,8946	2,3646	2,9980	3,4995	4,0293	4,7853	5,4079	7
8	0,7064	1,3968	1,8595	2,3060	2,8965	3,3554	3,8325	4,5008	5,0413	8
9	0,7027	1,3830	1,8331	2,2622	2,8214	3,2498	3,6897	4,2968	4,7809	9
10	0,6998	1,3722	1,8125	2,2281	2,7638	3,1693	3,5814	4,1437	4,5869	10
11	0,6974	1,3634	1,7959	2,2010	2,7181	3,1058	3,4966	4,0247	4,4370	11
12	0,6955	1,3562	1,7823	2,1788	2,6810	3,0545	3,4284	3,9296	4,3178	12
13	0,6938	1,3502	1,7709	2,1604	2,6503	3,0123	3,3725	3,8520	4,2208	13
14	0,6924	1,3450	1,7613	2,1448	2,6245	2,9768	3,3257	3,7874	4,1405	14
15	0,6912	1,3406	1,7531	2,1314	2,6025	2,9467	3,2860	3,7328	4,0728	15
16	0,6901	1,3368	1,7459	2,1199	2,5835	2,9208	3,2520	3,6862	4,0150	16
17	0,6892	1,3334	1,7396	2,1098	2,5669	2,8982	3,2224	3,6458	3,9651	17
18	0,6884	1,3304	1,7341	2,1009	2,5524	2,8784	3,1966	3,6105	3,9216	18
19	0,6876	1,3277	1,7291	2,0930	2,5395	2,8609	3,1737	3,5794	3,8834	19
20	0,6870	1,3253	1,7247	2,0860	2,5280	2,8453	3,1534	3,5518	3,8495	20
21	0,6864	1,3232	1,7207	2,0796	2,5176	2,8314	3,1352	3,5272	3,8193	21
22	0,6858	1,3212	1,7171	2,0739	2,5083	2,8188	3,1188	3,5050	3,7921	22
23	0,6853	1,3195	1,7139	2,0687	2,4999	2,8073	3,1040	3,4850	3,7676	23
24	0,6848	1,3178	1,7109	2,0639	2,4922	2,7969	3,0905	3,4668	3,7454	24
25	0,6844	1,3163	1,7081	2,0595	2,4851	2,7874	3,0782	3,4502	3,7251	25
26	0,6840	1,3150	1,7056	2,0555	2,4786	2,7787	3,0669	3,4350	3,7066	26
27	0,6837	1,3137	1,7033	2,0518	2,4727	2,7707	3,0565	3,4210	3,6896	27
28	0,6834	1,3125	1,7011	2,0484	2,4671	2,7633	3,0469	3,4082	3,6739	28
29	0,6830	1,3114	1,6991	2,0452	2,4620	2,7564	3,0380	3,3962	3,6594	29
30	0,6828	1,3104	1,6973	2,0423	2,4573	2,7500	3,0298	3,3852	3,6460	30
35	0,6816	1,3062	1,6896	2,0301	2,4377	2,7238	2,9960	3,3400	3,5911	35
40	0,6807	1,3031	1,6839	2,0211	2,4233	2,7045	2,9712	3,3069	3,5510	40
45	0,6800	1,3006	1,6794	2,0141	2,4121	2,6896	2,9521	3,2815	3,5203	45
50	0,6794	1,2987	1,6759	2,0086	2,4033	2,6778	2,9370	3,2614	3,4960	50

Tabela A3: Distribuição Qui-quadrado - $P(\chi^2 > \chi^2_\alpha(gl)) = \alpha$.

gl	α										gl
	0,995	0,99	0,975	0,95	0,9	0,1	0,05	0,025	0,01	0,005	
1	4e-05	0,0002	0,0010	0,0039	0,0158	2,7055	3,8415	5,0239	6,6349	7,8794	1
2	0,0100	0,0201	0,0506	0,1026	0,2107	4,6052	5,9915	7,3778	9,2103	10,5966	2
3	0,0717	0,1148	0,2158	0,3518	0,5844	6,2514	7,8147	9,3484	11,3449	12,8382	3
4	0,2070	0,2971	0,4844	0,7107	1,0636	7,7794	9,4877	11,1433	13,2767	14,8603	4
5	0,4117	0,5543	0,8312	1,1455	1,6103	9,2364	11,0705	12,8325	15,0863	16,7496	5
6	0,6757	0,8721	1,2373	1,6354	2,2041	10,6446	12,5916	14,4494	16,8119	18,5476	6
7	0,9893	1,2390	1,6899	2,1673	2,8331	12,0170	14,0671	16,0128	18,4753	20,2777	7
8	1,3444	1,6465	2,1797	2,7326	3,4895	13,3616	15,5073	17,5345	20,0902	21,9550	8
9	1,7349	2,0879	2,7004	3,3251	4,1682	14,6837	16,9190	19,0228	21,6660	23,5894	9
10	2,1559	2,5582	3,2470	3,9403	4,8652	15,9872	18,3070	20,4832	23,2093	25,1882	10
11	2,6032	3,0535	3,8157	4,5748	5,5778	17,2750	19,6751	21,9200	24,7250	26,7568	11
12	3,0738	3,5706	4,4038	5,2260	6,3038	18,5493	21,0261	23,3367	26,2170	28,2995	12
13	3,5650	4,1069	5,0088	5,8919	7,0415	19,8119	22,3620	24,7356	27,6882	29,8195	13
14	4,0747	4,6604	5,6287	6,5706	7,7895	21,0641	23,6848	26,1189	29,1412	31,3193	14
15	4,6009	5,2293	6,2621	7,2609	8,5468	22,3071	24,9958	27,4884	30,5779	32,8013	15
16	5,1422	5,8122	6,9077	7,9616	9,3122	23,5418	26,2962	28,8454	31,9999	34,2672	16
17	5,6972	6,4078	7,5642	8,6718	10,0852	24,7690	27,5871	30,1910	33,4087	35,7185	17
18	6,2648	7,0149	8,2307	9,3905	10,8649	25,9894	28,8693	31,5264	34,8053	37,1565	18
19	6,8440	7,6327	8,9065	10,1170	11,6509	27,2036	30,1435	32,8523	36,1909	38,5823	19
20	7,4338	8,2604	9,5908	10,8508	12,4426	28,4120	31,4104	34,1696	37,5662	39,9968	20
21	8,0337	8,8972	10,2829	11,5913	13,2396	29,6151	32,6706	35,4789	38,9322	41,4011	21
22	8,6427	9,5425	10,9823	12,3380	14,0415	30,8133	33,9244	36,7807	40,2894	42,7957	22
23	9,2604	10,1957	11,6886	13,0905	14,8480	32,0069	35,1725	38,0756	41,6384	44,1813	23
24	9,8862	10,8564	12,4012	13,8484	15,6587	33,1962	36,4150	39,3641	42,9798	45,5585	24
25	10,5197	11,5240	13,1197	14,6114	16,4734	34,3816	37,6525	40,6465	44,3141	46,9279	25
26	11,1602	12,1981	13,8439	15,3792	17,2919	35,5632	38,8851	41,9232	45,6417	48,2899	26
27	11,8076	12,8785	14,5734	16,1514	18,1139	36,7412	40,1133	43,1945	46,9629	49,6449	27
28	12,4613	13,5647	15,3079	16,9279	18,9392	37,9159	41,3371	44,4608	48,2782	50,9934	28
29	13,1211	14,2565	16,0471	17,7084	19,7677	39,0875	42,5570	45,7223	49,5879	52,3356	29
30	13,7867	14,9535	16,7908	18,4927	20,5992	40,2560	43,7730	46,9792	50,8922	53,6720	30
31	14,4578	15,6555	17,5387	19,2806	21,4336	41,4217	44,9853	48,2319	52,1914	55,0027	31
32	15,1340	16,3622	18,2908	20,0719	22,2706	42,5847	46,1943	49,4804	53,4858	56,3281	32
33	15,8153	17,0735	19,0467	20,8665	23,1102	43,7452	47,3999	50,7251	54,7755	57,6484	33
34	16,5013	17,7891	19,8063	21,6643	23,9523	44,9032	48,6024	51,9660	56,0609	58,9639	34
35	17,1918	18,5089	20,5694	22,4650	24,7967	46,0588	49,8018	53,2033	57,3421	60,2748	35
36	17,8867	19,2327	21,3359	23,2686	25,6433	47,2122	50,9985	54,4373	58,6192	61,5812	36
37	18,5858	19,9602	22,1056	24,0749	26,4921	48,3634	52,1923	55,6680	59,8925	62,8833	37
38	19,2889	20,6914	22,8785	24,8839	27,3430	49,5126	53,3835	56,8955	61,1621	64,1814	38
39	19,9959	21,4262	23,6543	25,6954	28,1958	50,6598	54,5722	58,1201	62,4281	65,4756	39
40	20,7065	22,1643	24,4330	26,5093	29,0505	51,8051	55,7585	59,3417	63,6907	66,7660	40
41	21,4208	22,9056	25,2145	27,3256	29,9071	52,9485	56,9424	60,5606	64,9501	68,0527	41
42	22,1385	23,6501	25,9987	28,1440	30,7654	54,0902	58,1240	61,7768	66,2062	69,3360	42
43	22,8595	24,3976	26,7854	28,9647	31,6255	55,2302	59,3035	62,9904	67,4593	70,6159	43
44	23,5837	25,1480	27,5746	29,7875	32,4871	56,3685	60,4809	64,2015	68,7095	71,8926	44
45	24,3110	25,9013	28,3662	30,6123	33,3504	57,5053	61,6562	65,4102	69,9568	73,1661	45
46	25,0413	26,6572	29,1601	31,4390	34,2152	58,6405	62,8296	66,6165	71,2014	74,4365	46
47	25,7746	27,4158	29,9562	32,2676	35,0814	59,7743	64,0011	67,8206	72,4433	75,7041	47
48	26,5106	28,1770	30,7545	33,0981	35,9491	60,9066	65,1708	69,0226	73,6826	76,9688	48
49	27,2493	28,9406	31,5549	33,9303	36,8182	62,0375	66,3386	70,2224	74,9195	78,2307	49

Tabela A4: Distribuição F de Fisher-Snedecor - $P(F > F_{0,01}(gl\ num, gl\ denom)) = 0,01$.

<i>gl denom</i>	<i>gl num</i>										
	1	2	3	4	5	6	7	8	9	10	
1	4.052,2	4.999,5	5.403,4	5.624,6	5.763,6	5.859,0	5.928,4	5.981,1	6.022,5	6.055,8	1
2	98,503	99,000	99,166	99,249	99,299	99,333	99,356	99,374	99,388	99,399	2
3	34,116	30,817	29,457	28,710	28,237	27,911	27,672	27,489	27,345	27,229	3
4	21,198	18,000	16,694	15,977	15,522	15,207	14,976	14,799	14,659	14,546	4
5	16,258	13,274	12,060	11,392	10,967	10,672	10,455	10,289	10,158	10,051	5
6	13,745	10,926	9,7795	9,1483	8,7459	8,4661	8,2600	8,1017	7,9761	7,8741	6
7	12,246	9,5466	8,4513	7,8466	7,4604	7,1914	6,9928	6,8400	6,7188	6,6201	7
8	11,259	8,6491	7,5910	7,0061	6,6318	6,3707	6,1776	6,0289	5,9106	5,8143	8
9	10,561	8,0215	6,9919	6,4221	6,0569	5,8018	5,6129	5,4671	5,3511	5,2565	9
10	10,044	7,5594	6,5523	5,9943	5,6363	5,3858	5,2001	5,0567	4,9424	4,8491	10
11	9,6460	7,2057	6,2167	5,6683	5,3160	5,0692	4,8861	4,7445	4,6315	4,5393	11
12	9,3302	6,9266	5,9525	5,4120	5,0643	4,8206	4,6395	4,4994	4,3875	4,2961	12
13	9,0738	6,7010	5,7394	5,2053	4,8616	4,6204	4,4410	4,3021	4,1911	4,1003	13
14	8,8616	6,5149	5,5639	5,0354	4,6950	4,4558	4,2779	4,1399	4,0297	3,9394	14
15	8,6831	6,3589	5,4170	4,8932	4,5556	4,3183	4,1415	4,0045	3,8948	3,8049	15
16	8,5310	6,2262	5,2922	4,7726	4,4374	4,2016	4,0259	3,8896	3,7804	3,6909	16
17	8,3997	6,1121	5,1850	4,6690	4,3359	4,1015	3,9267	3,7910	3,6822	3,5931	17
18	8,2854	6,0129	5,0919	4,5790	4,2479	4,0146	3,8406	3,7054	3,5971	3,5082	18
19	8,1849	5,9259	5,0103	4,5003	4,1708	3,9386	3,7653	3,6305	3,5225	3,4338	19
20	8,0960	5,8489	4,9382	4,4307	4,1027	3,8714	3,6987	3,5644	3,4567	3,3682	20
21	8,0166	5,7804	4,8740	4,3688	4,0421	3,8117	3,6396	3,5056	3,3981	3,3098	21
22	7,9454	5,7190	4,8166	4,3134	3,9880	3,7583	3,5867	3,4530	3,3458	3,2576	22
23	7,8811	5,6637	4,7649	4,2636	3,9392	3,7102	3,5390	3,4057	3,2986	3,2106	23
24	7,8229	5,6136	4,7181	4,2184	3,8951	3,6667	3,4959	3,3629	3,2560	3,1681	24
25	7,7698	5,5680	4,6755	4,1774	3,8550	3,6272	3,4568	3,3239	3,2172	3,1294	25
26	7,7213	5,5263	4,6366	4,1400	3,8183	3,5911	3,4210	3,2884	3,1818	3,0941	26
27	7,6767	5,4881	4,6009	4,1056	3,7848	3,5580	3,3882	3,2558	3,1494	3,0618	27
28	7,6356	5,4529	4,5681	4,0740	3,7539	3,5276	3,3581	3,2259	3,1195	3,0320	28
29	7,5977	5,4204	4,5378	4,0449	3,7254	3,4995	3,3303	3,1982	3,0920	3,0045	29
30	7,5625	5,3903	4,5097	4,0179	3,6990	3,4735	3,3045	3,1726	3,0665	2,9791	30
35	7,4191	5,2679	4,3957	3,9082	3,5919	3,3679	3,2000	3,0687	2,9630	2,8758	35
40	7,3141	5,1785	4,3126	3,8283	3,5138	3,2910	3,1238	2,9930	2,8876	2,8005	40
45	7,2339	5,1103	4,2492	3,7674	3,4544	3,2325	3,0658	2,9353	2,8301	2,7432	45
50	7,1706	5,0566	4,1993	3,7195	3,4077	3,1864	3,0202	2,8900	2,7850	2,6981	50
100	6,8953	4,8239	3,9837	3,5127	3,2059	2,9877	2,8233	2,6943	2,5898	2,5033	100

Tabela A5: Distribuição F de Fisher-Snedecor - $P(F > F_{0,01}(gl\ num, gl\ denom)) = 0,01$. (Continuação)

<i>gl denom</i>	<i>gl num</i>										
	11	12	13	14	15	16	17	18	19	20	
1	6.083,3	6.106,3	6.125,9	6.142,7	6.157,3	6.170,1	6.181,4	6.191,5	6.200,6	6.208,7	1
2	99,408	99,416	99,422	99,428	99,433	99,437	99,440	99,444	99,447	99,449	2
3	27,133	27,052	26,983	26,924	26,872	26,827	26,787	26,751	26,719	26,690	3
4	14,452	14,374	14,306	14,249	14,198	14,154	14,115	14,079	14,048	14,020	4
5	9,9626	9,8883	9,8248	9,7700	9,7222	9,6802	9,6429	9,6096	9,5797	9,5526	5
6	7,7896	7,7183	7,6575	7,6049	7,5590	7,5186	7,4827	7,4507	7,4219	7,3958	6
7	6,5382	6,4691	6,4100	6,3590	6,3143	6,2750	6,2401	6,2089	6,1808	6,1554	7
8	5,7343	5,6667	5,6089	5,5589	5,5151	5,4766	5,4423	5,4116	5,3840	5,3591	8
9	5,1779	5,1114	5,0545	5,0052	4,9621	4,9240	4,8902	4,8599	4,8327	4,8080	9
10	4,7715	4,7059	4,6496	4,6008	4,5581	4,5204	4,4869	4,4569	4,4299	4,4054	10
11	4,4624	4,3974	4,3416	4,2932	4,2509	4,2134	4,1801	4,1503	4,1234	4,0990	11
12	4,2198	4,1553	4,0999	4,0518	4,0096	3,9724	3,9392	3,9095	3,8827	3,8584	12
13	4,0245	3,9603	3,9052	3,8573	3,8154	3,7783	3,7452	3,7156	3,6888	3,6646	13
14	3,8640	3,8001	3,7452	3,6975	3,6557	3,6187	3,5857	3,5561	3,5294	3,5052	14
15	3,7299	3,6662	3,6115	3,5639	3,5222	3,4852	3,4523	3,4228	3,3961	3,3719	15
16	3,6162	3,5527	3,4981	3,4506	3,4089	3,3720	3,3391	3,3096	3,2829	3,2587	16
17	3,5185	3,4552	3,4007	3,3533	3,3117	3,2748	3,2419	3,2124	3,1857	3,1615	17
18	3,4338	3,3706	3,3162	3,2689	3,2273	3,1904	3,1575	3,1280	3,1013	3,0771	18
19	3,3596	3,2965	3,2422	3,1949	3,1533	3,1165	3,0836	3,0541	3,0274	3,0031	19
20	3,2941	3,2311	3,1769	3,1296	3,0880	3,0512	3,0183	2,9887	2,9620	2,9377	20
21	3,2359	3,1730	3,1187	3,0715	3,0300	2,9931	2,9602	2,9306	2,9039	2,8796	21
22	3,1837	3,1209	3,0667	3,0195	2,9779	2,9411	2,9082	2,8786	2,8518	2,8274	22
23	3,1368	3,0740	3,0199	2,9727	2,9311	2,8943	2,8613	2,8317	2,8049	2,7805	23
24	3,0944	3,0316	2,9775	2,9303	2,8887	2,8519	2,8189	2,7892	2,7624	2,7380	24
25	3,0558	2,9931	2,9389	2,8917	2,8502	2,8133	2,7803	2,7506	2,7238	2,6993	25
26	3,0205	2,9578	2,9038	2,8566	2,8150	2,7781	2,7451	2,7153	2,6885	2,6640	26
27	2,9882	2,9256	2,8715	2,8243	2,7827	2,7458	2,7127	2,6830	2,6561	2,6316	27
28	2,9585	2,8959	2,8418	2,7946	2,7530	2,7160	2,6830	2,6532	2,6263	2,6017	28
29	2,9311	2,8685	2,8144	2,7672	2,7256	2,6886	2,6555	2,6257	2,5987	2,5742	29
30	2,9057	2,8431	2,7890	2,7418	2,7002	2,6632	2,6301	2,6003	2,5732	2,5487	30
35	2,8026	2,7400	2,6859	2,6387	2,5970	2,5599	2,5266	2,4967	2,4695	2,4448	35
40	2,7274	2,6648	2,6107	2,5634	2,5216	2,4844	2,4511	2,4210	2,3937	2,3689	40
45	2,6701	2,6076	2,5534	2,5060	2,4642	2,4269	2,3935	2,3633	2,3359	2,3109	45
50	2,6250	2,5625	2,5083	2,4609	2,4190	2,3816	2,3481	2,3178	2,2903	2,2652	50
100	2,4302	2,3676	2,3132	2,2654	2,2230	2,1852	2,1511	2,1203	2,0923	2,0666	100

Tabela A6: Distribuição F de Fisher-Snedecor - $P(F > F_{0,05}(gl\ num, gl\ denom)) = 0,05$.

<i>gl denom</i>	<i>gl num</i>										
	1	2	3	4	5	6	7	8	9	10	
1	161,45	199,50	215,71	224,58	230,16	233,99	236,77	238,88	240,54	241,88	1
2	18,513	19,000	19,164	19,247	19,296	19,330	19,353	19,371	19,385	19,396	2
3	10,128	9,5521	9,2766	9,1172	9,0135	8,9406	8,8867	8,8452	8,8123	8,7855	3
4	7,7086	6,9443	6,5914	6,3882	6,2561	6,1631	6,0942	6,0410	5,9988	5,9644	4
5	6,6079	5,7861	5,4095	5,1922	5,0503	4,9503	4,8759	4,8183	4,7725	4,7351	5
6	5,9874	5,1433	4,7571	4,5337	4,3874	4,2839	4,2067	4,1468	4,0990	4,0600	6
7	5,5914	4,7374	4,3468	4,1203	3,9715	3,8660	3,7870	3,7257	3,6767	3,6365	7
8	5,3177	4,4590	4,0662	3,8379	3,6875	3,5806	3,5005	3,4381	3,3881	3,3472	8
9	5,1174	4,2565	3,8625	3,6331	3,4817	3,3738	3,2927	3,2296	3,1789	3,1373	9
10	4,9646	4,1028	3,7083	3,4780	3,3258	3,2172	3,1355	3,0717	3,0204	2,9782	10
11	4,8443	3,9823	3,5874	3,3567	3,2039	3,0946	3,0123	2,9480	2,8962	2,8536	11
12	4,7472	3,8853	3,4903	3,2592	3,1059	2,9961	2,9134	2,8486	2,7964	2,7534	12
13	4,6672	3,8056	3,4105	3,1791	3,0254	2,9153	2,8321	2,7669	2,7144	2,6710	13
14	4,6001	3,7389	3,3439	3,1122	2,9582	2,8477	2,7642	2,6987	2,6458	2,6022	14
15	4,5431	3,6823	3,2874	3,0556	2,9013	2,7905	2,7066	2,6408	2,5876	2,5437	15
16	4,4940	3,6337	3,2389	3,0069	2,8524	2,7413	2,6572	2,5911	2,5377	2,4935	16
17	4,4513	3,5915	3,1968	2,9647	2,8100	2,6987	2,6143	2,5480	2,4943	2,4499	17
18	4,4139	3,5546	3,1599	2,9277	2,7729	2,6613	2,5767	2,5102	2,4563	2,4117	18
19	4,3807	3,5219	3,1274	2,8951	2,7401	2,6283	2,5435	2,4768	2,4227	2,3779	19
20	4,3512	3,4928	3,0984	2,8661	2,7109	2,5990	2,5140	2,4471	2,3928	2,3479	20
21	4,3248	3,4668	3,0725	2,8401	2,6848	2,5727	2,4876	2,4205	2,3660	2,3210	21
22	4,3009	3,4434	3,0491	2,8167	2,6613	2,5491	2,4638	2,3965	2,3419	2,2967	22
23	4,2793	3,4221	3,0280	2,7955	2,6400	2,5277	2,4422	2,3748	2,3201	2,2747	23
24	4,2597	3,4028	3,0088	2,7763	2,6207	2,5082	2,4226	2,3551	2,3002	2,2547	24
25	4,2417	3,3852	2,9912	2,7587	2,6030	2,4904	2,4047	2,3371	2,2821	2,2365	25
26	4,2252	3,3690	2,9752	2,7426	2,5868	2,4741	2,3883	2,3205	2,2655	2,2197	26
27	4,2100	3,3541	2,9604	2,7278	2,5719	2,4591	2,3732	2,3053	2,2501	2,2043	27
28	4,1960	3,3404	2,9467	2,7141	2,5581	2,4453	2,3593	2,2913	2,2360	2,1900	28
29	4,1830	3,3277	2,9340	2,7014	2,5454	2,4324	2,3463	2,2783	2,2229	2,1768	29
30	4,1709	3,3158	2,9223	2,6896	2,5336	2,4205	2,3343	2,2662	2,2107	2,1646	30
35	4,1213	3,2674	2,8742	2,6415	2,4851	2,3718	2,2852	2,2167	2,1608	2,1143	35
40	4,0847	3,2317	2,8387	2,6060	2,4495	2,3359	2,2490	2,1802	2,1240	2,0772	40
45	4,0566	3,2043	2,8115	2,5787	2,4221	2,3083	2,2212	2,1521	2,0958	2,0487	45
50	4,0343	3,1826	2,7900	2,5572	2,4004	2,2864	2,1992	2,1299	2,0734	2,0261	50
100	3,9361	3,0873	2,6955	2,4626	2,3053	2,1906	2,1025	2,0323	1,9748	1,9267	100

Tabela A7: Distribuição F de Fisher-Snedecor - $P(F > F_{0,05}(gl\ num, gl\ denom)) = 0,05$. (Continuação)

<i>gl denom</i>	<i>gl num</i>										
	11	12	13	14	15	16	17	18	19	20	
1	242,98	243,91	244,69	245,36	245,95	246,46	246,92	247,32	247,69	248,01	1
2	19,405	19,413	19,419	19,424	19,429	19,433	19,437	19,440	19,443	19,446	2
3	8,7633	8,7446	8,7287	8,7149	8,7029	8,6923	8,6829	8,6745	8,6670	8,6602	3
4	5,9358	5,9117	5,8911	5,8733	5,8578	5,8441	5,8320	5,8211	5,8114	5,8025	4
5	4,7040	4,6777	4,6552	4,6358	4,6188	4,6038	4,5904	4,5785	4,5678	4,5581	5
6	4,0274	3,9999	3,9764	3,9559	3,9381	3,9223	3,9083	3,8957	3,8844	3,8742	6
7	3,6030	3,5747	3,5503	3,5292	3,5107	3,4944	3,4799	3,4669	3,4551	3,4445	7
8	3,3130	3,2839	3,2590	3,2374	3,2184	3,2016	3,1867	3,1733	3,1613	3,1503	8
9	3,1025	3,0729	3,0475	3,0255	3,0061	2,9890	2,9737	2,9600	2,9477	2,9365	9
10	2,9430	2,9130	2,8872	2,8647	2,8450	2,8276	2,8120	2,7980	2,7854	2,7740	10
11	2,8179	2,7876	2,7614	2,7386	2,7186	2,7009	2,6851	2,6709	2,6581	2,6464	11
12	2,7173	2,6866	2,6602	2,6371	2,6169	2,5989	2,5828	2,5684	2,5554	2,5436	12
13	2,6347	2,6037	2,5769	2,5536	2,5331	2,5149	2,4987	2,4841	2,4709	2,4589	13
14	2,5655	2,5342	2,5073	2,4837	2,4630	2,4446	2,4282	2,4134	2,4000	2,3879	14
15	2,5068	2,4753	2,4481	2,4244	2,4034	2,3849	2,3683	2,3533	2,3398	2,3275	15
16	2,4564	2,4247	2,3973	2,3733	2,3522	2,3335	2,3167	2,3016	2,2880	2,2756	16
17	2,4126	2,3807	2,3531	2,3290	2,3077	2,2888	2,2719	2,2567	2,2429	2,2304	17
18	2,3742	2,3421	2,3143	2,2900	2,2686	2,2496	2,2325	2,2172	2,2033	2,1906	18
19	2,3402	2,3080	2,2800	2,2556	2,2341	2,2149	2,1977	2,1823	2,1683	2,1555	19
20	2,3100	2,2776	2,2495	2,2250	2,2033	2,1840	2,1667	2,1511	2,1370	2,1242	20
21	2,2829	2,2504	2,2222	2,1975	2,1757	2,1563	2,1389	2,1232	2,1090	2,0960	21
22	2,2585	2,2258	2,1975	2,1727	2,1508	2,1313	2,1138	2,0980	2,0837	2,0707	22
23	2,2364	2,2036	2,1752	2,1502	2,1282	2,1086	2,0910	2,0751	2,0608	2,0476	23
24	2,2163	2,1834	2,1548	2,1298	2,1077	2,0880	2,0703	2,0543	2,0399	2,0267	24
25	2,1979	2,1649	2,1362	2,1111	2,0889	2,0691	2,0513	2,0353	2,0207	2,0075	25
26	2,1811	2,1479	2,1192	2,0939	2,0716	2,0518	2,0339	2,0178	2,0032	1,9898	26
27	2,1655	2,1323	2,1035	2,0781	2,0558	2,0358	2,0179	2,0017	1,9870	1,9736	27
28	2,1512	2,1179	2,0889	2,0635	2,0411	2,0210	2,0030	1,9868	1,9720	1,9586	28
29	2,1379	2,1045	2,0755	2,0500	2,0275	2,0073	1,9893	1,9730	1,9581	1,9446	29
30	2,1256	2,0921	2,0630	2,0374	2,0148	1,9946	1,9765	1,9601	1,9452	1,9317	30
35	2,0750	2,0411	2,0117	1,9858	1,9629	1,9424	1,9240	1,9073	1,8922	1,8784	35
40	2,0376	2,0035	1,9738	1,9476	1,9245	1,9037	1,8851	1,8682	1,8529	1,8389	40
45	2,0088	1,9745	1,9446	1,9182	1,8949	1,8740	1,8551	1,8381	1,8226	1,8084	45
50	1,9861	1,9515	1,9214	1,8949	1,8714	1,8503	1,8313	1,8141	1,7985	1,7841	50
100	1,8857	1,8503	1,8193	1,7919	1,7675	1,7456	1,7259	1,7079	1,6915	1,6764	100

Tabela A8: Distribuição F de Fisher-Snedecor - $P(F > F_{0,10}(gl\ num, gl\ denom)) = 0,10$.

<i>gl denom</i>	<i>gl num</i>										
	1	2	3	4	5	6	7	8	9	10	
1	39,863	49,500	53,593	55,833	57,240	58,204	58,906	59,439	59,858	60,195	1
2	8,5263	9,0000	9,1618	9,2434	9,2926	9,3255	9,3491	9,3668	9,3805	9,3916	2
3	5,5383	5,4624	5,3908	5,3426	5,3092	5,2847	5,2662	5,2517	5,2400	5,2304	3
4	4,5448	4,3246	4,1909	4,1072	4,0506	4,0097	3,9790	3,9549	3,9357	3,9199	4
5	4,0604	3,7797	3,6195	3,5202	3,4530	3,4045	3,3679	3,3393	3,3163	3,2974	5
6	3,7759	3,4633	3,2888	3,1808	3,1075	3,0546	3,0145	2,9830	2,9577	2,9369	6
7	3,5894	3,2574	3,0741	2,9605	2,8833	2,8274	2,7849	2,7516	2,7247	2,7025	7
8	3,4579	3,1131	2,9238	2,8064	2,7264	2,6683	2,6241	2,5893	2,5612	2,5380	8
9	3,3603	3,0065	2,8129	2,6927	2,6106	2,5509	2,5053	2,4694	2,4403	2,4163	9
10	3,2850	2,9245	2,7277	2,6053	2,5216	2,4606	2,4140	2,3772	2,3473	2,3226	10
11	3,2252	2,8595	2,6602	2,5362	2,4512	2,3891	2,3416	2,3040	2,2735	2,2482	11
12	3,1765	2,8068	2,6055	2,4801	2,3940	2,3310	2,2828	2,2446	2,2135	2,1878	12
13	3,1362	2,7632	2,5603	2,4337	2,3467	2,2830	2,2341	2,1953	2,1638	2,1376	13
14	3,1022	2,7265	2,5222	2,3947	2,3069	2,2426	2,1931	2,1539	2,1220	2,0954	14
15	3,0732	2,6952	2,4898	2,3614	2,2730	2,2081	2,1582	2,1185	2,0862	2,0593	15
16	3,0481	2,6682	2,4618	2,3327	2,2438	2,1783	2,1280	2,0880	2,0553	2,0281	16
17	3,0262	2,6446	2,4374	2,3077	2,2183	2,1524	2,1017	2,0613	2,0284	2,0009	17
18	3,0070	2,6239	2,4160	2,2858	2,1958	2,1296	2,0785	2,0379	2,0047	1,9770	18
19	2,9899	2,6056	2,3970	2,2663	2,1760	2,1094	2,0580	2,0171	1,9836	1,9557	19
20	2,9747	2,5893	2,3801	2,2489	2,1582	2,0913	2,0397	1,9985	1,9649	1,9367	20
21	2,9610	2,5746	2,3649	2,2333	2,1423	2,0751	2,0233	1,9819	1,9480	1,9197	21
22	2,9486	2,5613	2,3512	2,2193	2,1279	2,0605	2,0084	1,9668	1,9327	1,9043	22
23	2,9374	2,5493	2,3387	2,2065	2,1149	2,0472	1,9949	1,9531	1,9189	1,8903	23
24	2,9271	2,5383	2,3274	2,1949	2,1030	2,0351	1,9826	1,9407	1,9063	1,8775	24
25	2,9177	2,5283	2,3170	2,1842	2,0922	2,0241	1,9714	1,9292	1,8947	1,8658	25
26	2,9091	2,5191	2,3075	2,1745	2,0822	2,0139	1,9610	1,9188	1,8841	1,8550	26
27	2,9012	2,5106	2,2987	2,1655	2,0730	2,0045	1,9515	1,9091	1,8743	1,8451	27
28	2,8938	2,5028	2,2906	2,1571	2,0645	1,9959	1,9427	1,9001	1,8652	1,8359	28
29	2,8870	2,4955	2,2831	2,1494	2,0566	1,9878	1,9345	1,8918	1,8568	1,8274	29
30	2,8807	2,4887	2,2761	2,1422	2,0492	1,9803	1,9269	1,8841	1,8490	1,8195	30
35	2,8547	2,4609	2,2474	2,1128	2,0191	1,9496	1,8957	1,8524	1,8168	1,7869	35
40	2,8354	2,4404	2,2261	2,0909	1,9968	1,9269	1,8725	1,8289	1,7929	1,7627	40
45	2,8205	2,4245	2,2097	2,0742	1,9796	1,9094	1,8547	1,8107	1,7745	1,7440	45
50	2,8087	2,4120	2,1967	2,0608	1,9660	1,8954	1,8405	1,7963	1,7598	1,7291	50
100	2,7564	2,3564	2,1394	2,0019	1,9057	1,8339	1,7778	1,7324	1,6949	1,6632	100

Tabela A9: Distribuição F de Fisher-Snedecor - $P(F > F_{0,10}(gl\ num, gl\ denom)) = 0,10$. (Continuação)

<i>gl denom</i>	<i>gl num</i>										
	11	12	13	14	15	16	17	18	19	20	
1	60,4727	60,7052	60,9028	61,0727	61,2203	61,3499	61,4644	61,5664	61,6579	61,7403	1
2	9,4006	9,4081	9,4145	9,4200	9,4247	9,4289	9,4325	9,4358	9,4387	9,4413	2
3	5,2224	5,2156	5,2098	5,2047	5,2003	5,1964	5,1929	5,1898	5,1870	5,1845	3
4	3,9067	3,8955	3,8859	3,8776	3,8704	3,8639	3,8582	3,8531	3,8485	3,8443	4
5	3,2816	3,2682	3,2567	3,2468	3,2380	3,2303	3,2234	3,2172	3,2117	3,2067	5
6	2,9195	2,9047	2,8920	2,8809	2,8712	2,8626	2,8550	2,8481	2,8419	2,8363	6
7	2,6839	2,6681	2,6545	2,6426	2,6322	2,6230	2,6148	2,6074	2,6008	2,5947	7
8	2,5186	2,5020	2,4876	2,4752	2,4642	2,4545	2,4458	2,4380	2,4310	2,4246	8
9	2,3961	2,3789	2,3640	2,3510	2,3396	2,3295	2,3205	2,3123	2,3050	2,2983	9
10	2,3018	2,2841	2,2687	2,2553	2,2435	2,2330	2,2237	2,2153	2,2077	2,2007	10
11	2,2269	2,2087	2,1930	2,1792	2,1671	2,1563	2,1467	2,1380	2,1302	2,1230	11
12	2,1660	2,1474	2,1313	2,1173	2,1049	2,0938	2,0839	2,0750	2,0670	2,0597	12
13	2,1155	2,0966	2,0802	2,0658	2,0532	2,0419	2,0318	2,0227	2,0145	2,0070	13
14	2,0729	2,0537	2,0370	2,0224	2,0095	1,9981	1,9878	1,9785	1,9701	1,9625	14
15	2,0366	2,0171	2,0001	1,9853	1,9722	1,9605	1,9501	1,9407	1,9321	1,9243	15
16	2,0051	1,9854	1,9682	1,9532	1,9399	1,9281	1,9175	1,9079	1,8992	1,8913	16
17	1,9777	1,9577	1,9404	1,9252	1,9117	1,8997	1,8889	1,8792	1,8704	1,8624	17
18	1,9535	1,9333	1,9158	1,9004	1,8868	1,8747	1,8638	1,8539	1,8450	1,8368	18
19	1,9321	1,9117	1,8940	1,8785	1,8647	1,8524	1,8414	1,8314	1,8224	1,8142	19
20	1,9129	1,8924	1,8745	1,8588	1,8449	1,8325	1,8214	1,8113	1,8022	1,7938	20
21	1,8956	1,8750	1,8570	1,8412	1,8271	1,8146	1,8034	1,7932	1,7840	1,7756	21
22	1,8801	1,8593	1,8411	1,8252	1,8111	1,7984	1,7871	1,7768	1,7675	1,7590	22
23	1,8659	1,8450	1,8267	1,8107	1,7964	1,7837	1,7723	1,7619	1,7525	1,7439	23
24	1,8530	1,8319	1,8136	1,7974	1,7831	1,7703	1,7587	1,7483	1,7388	1,7302	24
25	1,8412	1,8200	1,8015	1,7853	1,7708	1,7579	1,7463	1,7358	1,7263	1,7175	25
26	1,8303	1,8090	1,7904	1,7741	1,7596	1,7466	1,7349	1,7243	1,7147	1,7059	26
27	1,8203	1,7989	1,7802	1,7638	1,7492	1,7361	1,7243	1,7137	1,7040	1,6951	27
28	1,8110	1,7895	1,7708	1,7542	1,7395	1,7264	1,7146	1,7039	1,6941	1,6852	28
29	1,8024	1,7808	1,7620	1,7454	1,7306	1,7174	1,7055	1,6947	1,6849	1,6759	29
30	1,7944	1,7727	1,7538	1,7371	1,7223	1,7090	1,6970	1,6862	1,6763	1,6673	30
35	1,7614	1,7394	1,7201	1,7031	1,6880	1,6744	1,6622	1,6511	1,6410	1,6317	35
40	1,7369	1,7146	1,6950	1,6778	1,6624	1,6486	1,6362	1,6249	1,6146	1,6052	40
45	1,7180	1,6954	1,6757	1,6582	1,6426	1,6287	1,6161	1,6046	1,5941	1,5846	45
50	1,7029	1,6802	1,6602	1,6426	1,6269	1,6128	1,6000	1,5884	1,5778	1,5681	50
100	1,6360	1,6124	1,5916	1,5731	1,5566	1,5418	1,5283	1,5160	1,5047	1,4943	100

Respostas dos exercícios propostos

Capítulo 2

1.
 - a) 0,75
 - b) 0,65
 - c) 0,40
 - d) 0,4875
 - e) 0,90
 - f) 0,2352941
2. Como $P(A | B) = 1/2 = P(A)$, então A e B são dois eventos independentes.
3.
 - a) 0,3413447

```
> # Código em R:  
> pnorm(104, mean=100, sd=4) - pnorm(100, mean=100, sd=4)  
[1] 0.3413447  
> # ou de forma equivalente:  
> pnorm(1, mean=0, sd=1) - pnorm(0, mean=0, sd=1)  
[1] 0.3413447
```

- b) 0,5328072

```
> # Código em R:  
> pnorm(102, mean=100, sd=4) - pnorm(96, mean=100, sd=4)  
[1] 0.5328072  
> # ou de forma equivalente:  
> pnorm(0.5, mean=0, sd=1) - pnorm(-1, mean=0, sd=1)  
[1] 0.5328072
```

- c) 0,1586553

```
> # Código em R:  
> 1 - pnorm(104, mean=100, sd=4)  
[1] 0.1586553  
> # ou de forma equivalente:  
> 1 - pnorm(1, mean=0, sd=1)  
[1] 0.1586553
```

- d) 6,579415

```
> # Código em R:
> qnorm(0.95, mean=100, sd=4) - 100
[1] 6.579415
> # ou de forma equivalente:
> qnorm(0.95, mean=0, sd=1) * 4
[1] 6.579415
```

e) 0,3852826

```
> # Código em R:
> pnorm(96, mean=100, sd=4) + (1 - pnorm(103, mean=100, sd=4))
[1] 0.3852826
> # ou de forma equivalente:
> pnorm(-1, mean=0, sd=1) + (1 - pnorm(0.75, mean=0, sd=1))
[1] 0.3852826
```

f) 0,04550026


```
> # Código em R:
> (1 - pnorm(108, mean=100, sd=4)) + pnorm(92, mean=100, sd=4)
[1] 0.04550026
> # ou de forma equivalente:
> (1 - pnorm(2, mean=0, sd=1)) + pnorm(-2, mean=0, sd=1)
[1] 0.04550026
```

g) 0,5

```
> # Código em R:
> pnorm(100, mean=100, sd=4)
[1] 0.5
> # ou de forma equivalente:
> pnorm(0, mean=0, sd=1)
[1] 0.5
```

4. a) $c = 0,15$


b)



```
> # Código em R:
> require(RcmdrMisc) # carregar pacote
> x <- 0:5
> plotDistr(x, p=c(0.30,0.40,0.15,0.10,0.04,0.01), xlab="x", ylab="P(X
=x)", discrete=TRUE)
```

c)

$$F(x) = \begin{cases} 0, & \text{se } x < 0 \\ 0,30, & \text{se } 0 \leq x < 1 \\ 0,70, & \text{se } 1 \leq x < 2 \\ 0,85, & \text{se } 2 \leq x < 3 \\ 0,95, & \text{se } 3 \leq x < 4 \\ 0,99, & \text{se } 4 \leq x < 5 \\ 1, & \text{se } x \geq 5 \end{cases}$$



```
> # Código em R:
> require(RcmdrMisc) # carregar pacote
> x <- 0:5
> plotDistr(x, p=c(0.30,0.70,0.85,0.90,0.99,1.00), xlab="x", ylab="F(x
)", ylim=c(0,1), discrete=TRUE, cdf=TRUE)
```

d) $P(X \leq 2) = 0,85$; $P(1 \leq X < 4) = 0,65$ e $P(1 \leq X \leq 3 \mid X > 0) = 13/14$

e) $E(X) = 1,21$ e $Var(X) = 1,3259$

```
> # Código em R:
> x <- 0:5
> p <- c(0.30,0.40,0.15,0.10,0.04,0.01)
> sum(x*p) # E(X)
[1] 1.21
> sum(x^2*p) - sum(x*p)^2 # Var(X)
[1] 1.3259
```

f) $E(2 + X) = 3,21$ e $Var(5X) = 33,1475$.

5. Basta mostrar, por exemplo, que $P(X > x + k \mid X > x) = P(X > k) = e^{-\lambda k}$.

6. a) 0,03097408

```
> # Código em R:  
> pnorm(270, mean=550, sd=150)  
[1] 0.03097408  
> # ou de forma equivalente:  
> pnorm((270-550)/150, mean=0, sd=1)  
[1] 0.03097408
```

- b) 242 dias

```
> # Código em R:  
> qnorm(0.02, mean=550, sd=150)  
[1] 241.9377  
> # ou de forma equivalente:  
> qnorm(0.02, mean=0, sd=1) * 150 + 550  
[1] 241.9377
```

- c) Cerca de 31 baterias

7. a) 0,8646647

```
> # Código em R:  
> 1 - dpois(0, lambda=2)  
[1] 0.8646647
```

- b) 0,9992103

```
> # Código em R:  
> 1 - pbinom(4, size=10, prob=0.8646647)  
[1] 0.9992103
```


- c) Binomial

Capítulo 3

1.
 - a) Qualitativa nominal
 - b) Qualitativa ordinal
 - c) Quantitativa discreta
 - d) Qualitativa nominal
 - e) Quantitativa contínua
 - f) Quantitativa discreta
 - g) Qualitativa ordinal
 - h) Quantitativa contínua

- 2.


```
> # Código em R:  
> fatias<-c(32,63,5)  
> nomes<-c("Favoráveis","Contrários","Indiferentes")  
> pct<-round(fatias/sum(fatias)*100,1)  
> nomes<-paste(nomes,pct); nomes<-paste(nomes,"%",sep="")  
> pie(fatias, col=c("blue","red","yellow"), labels=nomes, main="Opinião")
```



3. a) $\bar{X} = 862,375$; $Me = 849,5$; $A = 789$; $s = 200,3091$.


```
> # Código em R:
> x<-c(961,773,604,987,660,961,733,926,627,802,814,1093,682,885,
      897,1393)
> mean(x)      # função predefinida do R
[1] 862.375
> mediana(x)
[1] 849.5
> amplitude(x)
[1] 789
> sd(x)        # função predefinida do R
[1] 200.3091
```

b)



```
> boxplot(x, main="", ylab="Peso (g)")
```

4. Observa-se, por exemplo, que a maioria das mulheres entrevistadas não torce para nenhum time, enquanto que a maioria dos homens entrevistados torce para o Corinthians. Além disso, nota-se que a maioria dos torcedores de Corinthians e São Paulo é do sexo feminino.



```
> # Código em R:
> torcida<-matrix(c(130,160,93,54,54,76,54,29,19,16,16,2,105,215)/1023,
  nrow=2, ncol=7)
> barplot(torcida, col=c("blue","green"), ylim=c(0,0.3), names=c("
  Corinthians","Palmeiras","São Paulo","Santos","Flamengo","Outros","
  Nenhum"), ylab="Frequência relativa", legend=c("Masculino","Feminino"),
  beside=TRUE, cex.names=1.1)
```

5. Existe maior variabilidade na distribuição dos pesos desses indivíduos ($CV_{peso} = 18,36328\%$ e $CV_{altura} = 6,991695\%$).

```
> # Código em R:
> peso<-c(59,80,56,67,70,47,84,86,69,64)
> cvamo(peso)
[1] 18.36328
> altura<-c(170,177,196,175,195,173,174,158,171,162)
> cvamo(altura)
[1] 6.991695
```

6. a) **Escola A:** $\bar{X} = 19,2$; $Me = 16,5$; $Mo = 14$; $A = 27$; $Q_1 = 14$; $Q_3 = 23,25$; $s^2 = 72,62222$; $s = 8,521867$; $CV = 44,38473\%$.
Escola B: $\bar{X} = 17,2$; $Me = 14$; $Mo = 10$; $A = 33$; $Q_1 = 11,25$; $Q_3 = 17,75$; $s^2 = 99,06667$; $s = 9,953224$; $CV = 57,86758\%$.
Escola C: $\bar{X} = 18,7$; $Me = 15,5$; $Mo = \text{"Amodal"}$; $A = 31$; $Q_1 = 10,50$; $Q_3 = 25,25$; $s^2 = 117,3444$; $s = 10,83256$; $CV = 57,92815\%$.

```
> # Código em R:
> A<-c(16,10,12,17,14,18,25,37,29,14)
> B<-c(13,12,17,43,18,10,23,15,10,11)
> C<-c(12,17,15,16,10,28,39,33,8,9)
> summary(A)      # função predefinida do R
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
```

```

10.00  14.00  16.50  19.20  23.25  37.00
> moda(A); amplitude(A); var(A); sd(A); cvamo(A)
$moda
[1] 14


[1] 27
[1] 72.62222
[1] 8.521867
[1] 44.38473
> summary(B)      # função predefinida do R
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  10.00  11.25   14.00   17.20  17.75   43.00
> moda(B); amplitude(B); var(B); sd(B); cvamo(B)
$moda
[1] 10

[1] 33
[1] 99.06667
[1] 9.953224
[1] 57.86758
> summary(C)      # função predefinida do R
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   8.00  10.50   15.50   18.70  25.25   39.00
> moda(C); amplitude(C); var(C); sd(C); cvamo(C)
[[1]]
[1] "Amodal"

[1] 31
[1] 117.3444
[1] 10.83256
[1] 57.92815

```


- b) Observa-se, por exemplo, que as distribuições são todas assimétricas à direita (as medianas estão mais próximas de Q_1 do que de Q_3). A escola C apresenta variabilidade (tamanho da caixa) maior do que as demais. Existe um *outlier* superior (ou positivo) na amostra da escola B.



```
> escola<-c(rep("A",10),rep("B",10),rep("C",10))
> numero<-c(A,B,C)
>
> boxplot(numero ~ escola, col=c("blue","green","red"), main="", xlab="
  Escola", ylab="Número de alunos evadidos", names=c("A","B","C"))
```

- c) O número médio (e mediano) de alunos evadidos é ligeiramente maior para a escola A.

7. a)



```
> # Código em R:
> barplot(c(18,42,78,115,178,107,88,52,30,12), xlab="Idade (anos)",
  ylab="Frequência", names.arg=c("15 | 20","20 | 25","25 | 30","
  30 | 35","35 | 40","40 | 45","45 | 50","50 | 55","55 | 60","
  60 | 65"), beside=T, space=0, ylim=c(0,200))
```

- b) $\mu = 38,54167$; $Me = 38,00562$; $Mo_b = 37,5$; $Mo = 37,35075$; $Q_1 = 31,82609$; $Q_3 = 45,11364$; $D_2 = 30,26087$; $D_6 = 40,04673$; $P_{35} = 34,95652$; $P_{83} = 48,38636$; $\sigma^2 = 96,13715$; $\sigma = 9,804956$.

```
> m<-seq(17.5,62.5,5)
> f<-c(18,42,78,115,178,107,88,52,30,12)
> mediafreq(m,f)
[1] 38.54167
> medianafreq(m,f)
[1] 38.00562
> modafreq(m,f)
[1] 37.5
> modaCzuber(m,f)
[1] 37.35075
> varfreqpop(m,f)
[1] 96.13715
> sqrt(varfreqpop(m,f))
[1] 9.804956
> quartilfreq(m,f)
[1] 31.82609 38.00562 45.11364 65.00000
> decilfreq(m,f)
[1] 25.76923 30.26087 33.39130 35.98315 38.00562 40.04673
[7] 43.41121 47.15909 52.11538 65.00000
> percentilfreq(m,f,35)
[1] 34.95652
> percentilfreq(m,f,83)
[1] 48.38636
```

Capítulo 4

1. a) $k = \binom{5}{3} = 10$ amostras possíveis

```
> # Código em R:
> choose(5,3)
[1] 10
```

- b) Resultados das $k = 10$ amostras possíveis de tamanho $n = 3$ (sem reposição):

Amostra	Dados			$\bar{X}_i$
1	10	12	14	12
2	10	12	16	38/3
3	10	12	18	40/3
4	10	14	16	40/3
5	10	14	18	14
6	10	16	18	44/3
7	12	14	16	14
8	12	14	18	44/3
9	12	16	18	46/3
10	14	16	18	16

- c) $\mu = \bar{\bar{X}} = 14$

- d) $\sigma^2 = 8$ e $\sigma_{\bar{X}}^2 = 4/3$ ($= 8/3 \times (5-3)/(5-1) = \sigma^2/n \times (N-n)/(N-1)$)

2. Resultados das $k = 5^3 = 125$ amostras possíveis de tamanho $n = 3$ (com reposição):

Amostra	Dados			$\bar{X}_i$	Amostra	Dados			$\bar{X}_i$	Amostra	Dados			$\bar{X}_i$
1	10	10	10	10	46	12	18	10	40/3	91	16	16	10	14
2	10	10	12	32/3	47	12	18	12	14	92	16	16	12	44/3
3	10	10	14	34/3	48	12	18	14	44/3	93	16	16	14	46/3
4	10	10	16	12	49	12	18	16	46/3	94	16	16	16	16
5	10	10	18	38/3	50	12	18	18	16	95	16	16	18	50/3
6	10	12	10	32/3	51	14	10	10	34/3	96	16	18	10	44/3
7	10	12	12	34/3	52	14	10	12	12	97	16	18	12	46/3
8	10	12	14	12	53	14	10	14	38/3	98	16	18	14	16
9	10	12	16	38/3	54	14	10	16	40/3	99	16	18	16	50/3
10	10	12	18	40/3	55	14	10	18	14	100	16	18	18	52/3
11	10	14	10	34/3	56	14	12	10	12	101	18	10	10	38/3
12	10	14	12	12	57	14	12	12	38/3	102	18	10	12	40/3
13	10	14	14	38/3	58	14	12	14	40/3	103	18	10	14	14
14	10	14	16	40/3	59	14	12	16	14	104	18	10	16	44/3
15	10	14	18	14	60	14	12	18	44/3	105	18	10	18	46/3
16	10	16	10	12	61	14	14	10	38/3	106	18	12	10	40/3
17	10	16	12	38/3	62	14	14	12	40/3	107	18	12	12	14
18	10	16	14	40/3	63	14	14	14	14	108	18	12	14	44/3
19	10	16	16	14	64	14	14	16	44/3	109	18	12	16	46/3
20	10	16	18	44/3	65	14	14	18	46/3	110	18	12	18	16
21	10	18	10	38/3	66	14	16	10	40/3	111	18	14	10	14
22	10	18	12	40/3	67	14	16	12	14	112	18	14	12	44/3
23	10	18	14	14	68	14	16	14	44/3	113	18	14	14	46/3
24	10	18	16	44/3	69	14	16	16	46/3	114	18	14	16	16
25	10	18	18	46/3	70	14	16	18	16	115	18	14	18	50/3
26	12	10	10	32/3	71	14	18	10	14	116	18	16	10	44/3
27	12	10	12	34/3	72	14	18	12	44/3	117	18	16	12	46/3
28	12	10	14	12	73	14	18	14	46/3	118	18	16	14	16
29	12	10	16	38/3	74	14	18	16	16	119	18	16	16	50/3
30	12	10	18	40/3	75	14	18	18	50/3	120	18	16	18	52/3
31	12	12	10	34/3	76	16	10	10	12	121	18	18	10	46/3
32	12	12	12	12	77	16	10	12	38/3	122	18	18	12	16
33	12	12	14	38/3	78	16	10	14	40/3	123	18	18	14	50/3
34	12	12	16	40/3	79	16	10	16	14	124	18	18	16	52/3
35	12	12	18	14	80	16	10	18	44/3	125	18	18	18	18
36	12	14	10	12	81	16	12	10	38/3					
37	12	14	12	38/3	82	16	12	12	40/3					
38	12	14	14	40/3	83	16	12	14	14					
39	12	14	16	14	84	16	12	16	44/3					
40	12	14	18	44/3	85	16	12	18	46/3					
41	12	16	10	38/3	86	16	14	10	40/3					
42	12	16	12	40/3	87	16	14	12	14					
43	12	16	14	14	88	16	14	14	44/3					
44	12	16	16	44/3	89	16	14	16	46/3					
45	12	16	18	46/3	90	16	14	18	16					

Tem-se que: $\bar{\bar{X}} = 14 = \mu$ e $\sigma_{\bar{X}}^2 = 8/3 = \sigma^2/n$.

3. 0,05112421

```
> # Código em R:
> pnorm(9, mean=9.95, sd=3.90/sqrt(45))
[1] 0.05112421
> # ou de forma equivalente:
> pnorm((9-9.95)/(3.90/sqrt(45)), mean=0, sd=1)
[1] 0.05112421
```

4. a) 0,02198004

```
> # Código em R:
> x <- c(27.56,27.04,28.64,26.14,27.25,27.85,28,27.75,29.3)
> x.barra <- mean(x)
> s <- sd(x)
> n <- length(x)
> pt((27-x.barra)/(s/sqrt(n)), df=n-1)
[1] 0.02198004
```

b) 0,01710283

```
> # Código em R:
> 1 - pt((28.5-x.barra)/(s/sqrt(n)), df=n-1)
[1] 0.01710283
```

5. a) 0,2304974

```
> # Código em R:
> 1 - pnorm(0.10, mean=0.08, sd=sqrt(0.08*0.92/100))
[1] 0.2304974
> # ou de forma equivalente:
> 1 - pnorm((0.10-0.08)/sqrt(0.08*0.92/100), mean=0, sd=1)
[1] 0.2304974
```

b) 0,2875778

```
> # Código em R:
> pnorm(0.09, mean=0.08, sd=sqrt(0.08*0.92/100)) - pnorm(0.07, mean=0.08, sd=sqrt(0.08*0.92/100))
[1] 0.2875778
> # ou de forma equivalente:
> pnorm((0.09-0.08)/sqrt(0.08*0.92/100), mean=0, sd=1) - pnorm((0.07-0.08)/sqrt(0.08*0.92/100), mean=0, sd=1)
[1] 0.2875778
```

c) 0,07018433

```
> # Código em R:
> pnorm(0.04, mean=0.08, sd=sqrt(0.08*0.92/100))
[1] 0.07018433
> # ou de forma equivalente:
> pnorm((0.04-0.08)/sqrt(0.08*0.92/100), mean=0, sd=1)
[1] 0.07018433
```

6. 0,8904014

```
> # Código em R:
> pnorm(160, mean=150, sd=6.25) - pnorm(140, mean=150, sd=6.25)
[1] 0.8904014
> # ou de forma equivalente:
> pnorm(1.6, mean=0, sd=1) - pnorm(-1.6, mean=0, sd=1)
[1] 0.8904014
```

7. 2,266956e-06

```
> # Código em R:
> n.A <- 16
> n.B <- 16
> s2.A <- 49
> s2.B <- 25
> s2.barra <- ((n.A-1)*s2.A+(n.B-1)*s2.B)/(n.A+n.B-2)
> 1 - pt(12/sqrt(s2.barra*(1/n.A+1/n.B)), df=n.A+n.B-2)
[1] 2.266956e-06
```

Capítulo 5

1. a) $IC[\mu, 97,5\%] = (2,08793; 2,31207)$ e $IC[\mu, 99\%] = (2,071209; 2,328791)$

```
> # Código em R:  
> n <- 16  
> x.barra <- 2.2  
> sigma <- 0.2  
> alpha <- 0.025  
> LI <- x.barra - qnorm(alpha/2, lower.tail=FALSE)*sigma/sqrt(n)  
> LS <- x.barra + qnorm(alpha/2, lower.tail=FALSE)*sigma/sqrt(n)  
> LI; LS  
[1] 2.08793  
[1] 2.31207  
>  
> alpha <- 0.01  
> LI <- x.barra - qnorm(alpha/2, lower.tail=FALSE)*sigma/sqrt(n)  
> LS <- x.barra + qnorm(alpha/2, lower.tail=FALSE)*sigma/sqrt(n)  
> LI; LS  
[1] 2.071209  
[1] 2.328791
```

- b) $IC[\mu, 97,5\%] = (2,013259; 2,386741)$ e $IC[\mu, 99\%] = (1,978997; 2,421003)$

```
> # Código em R:  
> n <- 16  
> x.barra <- 2.2  
> s <- 0.3  
> alpha <- 0.025  
> LI <- x.barra - qt(alpha/2, df=n-1, lower.tail=FALSE)*s/sqrt(n)  
> LS <- x.barra + qt(alpha/2, df=n-1, lower.tail=FALSE)*s/sqrt(n)  
> LI; LS  
[1] 2.013259  
[1] 2.386741  
>  
> alpha <- 0.01  
> LI <- x.barra - qt(alpha/2, df=n-1, lower.tail=FALSE)*s/sqrt(n)  
> LS <- x.barra + qt(alpha/2, df=n-1, lower.tail=FALSE)*s/sqrt(n)  
> LI; LS  
[1] 1.978997  
[1] 2.421003
```

- c) Os intervalos de confiança obtidos no item (b) têm maior amplitude (ou comprimento) do que os intervalos de confiança encontrados no item (a).

2. $IC[p, 90\%] = (0,2603026; 0,3066574)$

```
> # Código em R:  
> ICprop(290,1023,0.10)  
[1] 0.2603026 0.3066574
```

3. a) p-valor = 0,656; logo, não rejeitamos a hipótese de normalidade da variável peso.

```
> # Código em R:
> x <- c(107,95,85,108,89,107,93,105,87,97,98,115,90,102,103,103,108,
      84,97,80,103,109,108,112,93,95,84,100,124,85)
> shapiro.test(x)

      Shapiro-Wilk normality test

data:  x
W = 0.97409, p-value = 0.656
```

b) b.1) $IC[\sigma, 95\%] = (8,438061; 14,243238)$

```
> ICdesvio(x,0.05)
[1] 8.438061 14.243238
```

b.2) $IC[\sigma^2, 95\%] = (8,438061^2; 14,243238^2) = (71,20087; 202,86983)$

```
> ICdesvio(x,0.05)^2
[1] 71.20087 202.86983
```

4. a) $H_0 : \mu = 0,03$, $H_a : \mu > 0,03$; não rejeitamos H_0 ao nível de significância de 1%.

```
> # Código em R:
> x <- c(0.018,0.012,0.020,0.021,0.029,0.019,0.030,0.024)
> testeHipmedia(x,0.03,0.01,"maior",0.005)
[1] "Nao Rejeito H0"
```

b) $H_0 : \mu = 0,03$, $H_a : \mu > 0,03$; não rejeitamos H_0 ao nível de significância de 1%.

```
> testeHipmedia(x,0.03,0.01,"maior")
[1] "Nao Rejeito H0"
```

5. Rejeitamos $H_0 : p = 0,15$ ao nível de significância de 10%.

```
> # Código em R:
> testeHipprop(130,1023,0.15,0.10,"diferente")
[1] "Rejeito H0"
```

6. a) $H_0 : \sigma = 0,01$, $H_a : \sigma > 0,01$

b) Erro Tipo I: rejeitar H_0 quando H_0 é verdadeira, ou seja, concluir que o produto está fora da norma, quando na realidade está dentro dela. Erro Tipo II: não rejeitar H_0 quando H_0 é falsa, isto é, concluir que o produto está dentro da norma, quando na realidade está fora dela.

c) Não rejeitamos H_0 ao nível de significância de 2,5%.

```
> # Código em R:
> testeHipvar(x,0.01^2,0.025,"maior")
[1] "Nao Rejeito H0"
```

7. a) p-valor = 0,04550026; logo, rejeitamos $H_0 : \mu = 30$ ao nível de significância de 5%.

```
> # Código em R:
> pnorm(33, mean=30, sd=sqrt(225/100), lower.tail=FALSE)*2
[1] 0.04550026
```

```
> # ou de forma equivalente:
> pnorm((33-30)/sqrt(225/100), mean=0, sd=1, lower.tail=FALSE)*2
[1] 0.04550026
```

- b) p-valor = 0,427077; logo, não rejeitamos $H_0 : \mu = 50$ ao nível de significância de 5%.

```
> # Código em R:
> pt((60-50)/sqrt(144/20), df=19, lower.tail=FALSE)
[1] 0.427077
```

- c) p-valor = 0,01943355; logo, rejeitamos $H_0 : p = 0,25$ ao nível de significância de 5%.

```
> # Código em R:
> pnorm(0.21, mean=0.25, sd=sqrt(0.25*0.75/500))
[1] 0.01943355
> # ou de forma equivalente:
> pnorm((0.21-0.25)/sqrt(0.25*0.75/500), mean=0, sd=1)
[1] 0.01943355
```

- d) p-valor = 0,5886633; logo, não rejeitamos $H_0 : \sigma^2 = 100$ ao nível de significância de 5%.

```
> # Código em R:
> pchisq(44*87.5/100, df=44)*2
[1] 0.5886633
```

Capítulo 6

1. Sim.

```
> # Código em R:
> x <- c(6.00,5.98,6.00,6.00,6.02,6.00,6.02,6.01,5.99,6.01)
> y <- c(5.96,5.98,5.97,5.99,6.00,6.00,5.95,6.00,5.98,6.01)
> testeHipdifvar(x,y,0.02,"diferente")
[1] "Não Rejeito H0"
> # ou alternativamente:
> var.test(x, y, alternative="two.sided", conf.level=0.98)

F test to compare two variances

data:  x and y
F = 0.40988, num df = 9, denom df = 9, p-value = 0.2001
alternative hypothesis: true ratio of variances is not equal to 1
98 percent confidence interval:
 0.07659762 2.19334061
sample estimates:
ratio of variances
 0.4098837
```

2. a) p-valor = 0,01855227; logo, rejeitamos H_0 ao nível de significância de 2%.

```

> # Código em R:
> testemediasnp(x,y,0.02,"diferente")
[[1]]
[1] "Rejeito H0"

$statistic
      t
2.588237

$parameter
df
18

$p.value
[1] 0.01855227

$conf.int
[1] 0.0002632231 0.0377367769
attr(,"conf.level")
[1] 0.98

$estimate
mean of x mean of y
      6.003      5.984

$null.value
difference in means
              0

$stderr
[1] 0.007340905

$alternative
[1] "two.sided"

$method
[1] " Two Sample t-test"

$data.name
[1] "x and y

```

- b) p-valor = 0,9907239; logo, não rejeitamos H_0 ao nível de significância de 2%.

```

> testemediasnp(x,y,0.02,"menor")
[[1]]
[1] "Não Rejeito H0"

$statistic
      t
2.588237

```

```

$parameter
df
18

$p.value
[1] 0.9907239

$conf.int
[1]      -Inf 0.03525059
attr(,"conf.level")
[1] 0.98

$estimate
mean of x mean of y
      6.003      5.984

$null.value
difference in means
              0

$stderr
[1] 0.007340905

$alternative
[1] "less"

$method
[1] " Two Sample t-test"

$data.name
[1] "x and y"

```

- c) p-valor = 0,009276136; logo, rejeitamos H_0 ao nível de significância de 2%.

```

> testemediasnp(x,y,0.02,"maior")
[[1]]
[1] "Rejeito H0"

$statistic
      t
2.588237

$parameter
df
18

$p.value
[1] 0.009276136

$conf.int
[1] 0.002749414      Inf

```

```

attr(,"conf.level")
[1] 0.98

$estimate
mean of x mean of y
      6.003      5.984

$null.value
difference in means
              0

$stderr
[1] 0.007340905

$alternative
[1] "greater"

$method
[1] " Two Sample t-test"

$data.name
[1] "x and y"

```

3. Considerando variâncias iguais, tem-se: $|T| = 3,088203 > t_{0,05}(18) = 1,734064$. Supondo variâncias diferentes, tem-se: $|T| = 3,2897 > t_{0,05}(15,26343) = 1,751066$. Logo, a 10% de significância, rejeita-se $H_0 : \mu_1 = \mu_2$ em ambos os testes.

```

> # Código em R:
> n1<-9; n2<-11; s1<-9; s2<-36; x1<-7.3; x2<-14.1; delta<-0
> alpha<-0.10
> # Considerando variâncias iguais:
> S<-sqrt(((n1-1)*s1+(n2-1)*s2)/(n1+n2-2))
> T<-(x2-x1-delta)/(S*sqrt((1/n1)+(1/n2)))
> gl<-n1+n2-2
> tcritico<-qt(alpha/2, gl, lower.tail=FALSE)
> abs(T); tcritico
[1] 3.088203
[1] 1.734064
> # Considerando variâncias diferentes:
> T<-(x2-x1-delta)/sqrt(s1/n1+s2/n2)
> w1<-s1/n1
> w2<-s2/n2
> gl<-((w1+w2)^2)/(((w1^2)/(n1-1))+((w2^2)/(n2-1)))
> tcritico<-qt(alpha/2, gl, lower.tail=FALSE)
> abs(T); tcritico
[1] 3.2897
[1] 1.751066

```

4. Como $F_{calc} = 3,24 > F_{(15,24)}(0,975) = 2,437429$, então rejeitamos $H_0 : \sigma_A^2 = \sigma_B^2$ ao nível de significância de 5%, isto é, há evidências de que as variâncias das alturas dos homens das duas localidades sejam diferentes. Como $|T| = 2,680575 > t_{0,025}(11,94136) = 2,18$, então há

indícios de que os homens das duas localidades tenham alturas médias diferentes, ao nível de significância de 5%.

```
> # Código em R:
> alpha=0.05
> # Testando igualdade x diferença entre as variâncias:
> dx<-15
> dy<-24
> varx<-81
> vary<-25
> Fcalc<-varx/vary # estatística Fcalc.
> critico1<-qf(1-alpha/2, dx, dy) # quantil da F(1-alpha/2)
> critico2<-qf(alpha/2, dx, dy) # quantil da F(alpha/2)
> Fcalc
[1] 3.24
> critico1
[1] 2.437429
> critico2
[1] 0.3702826
> # Testando igualdade x diferença entre as médias:
> x1<-167; x2<-176; delta<-0
> s1<-varx; s2<-vary
> T<-(x2-x1-delta)/sqrt(s1/n1+s2/n2)
> w1<-s1/n1
> w2<-s2/n2
> gl<-((w1+w2)^2)/(((w1^2)/(n1-1))+((w2^2)/(n2-1)))
> tcritico<-qt(alpha/2, gl, lower.tail=FALSE)
> abs(T); tcritico
[1] 2.680575
[1] 2.18
```

5. Como $p\text{-valor} = 5,119\text{e-}15 < 0,06$, concluímos que a campanha regional surtiu efeito.

```
> # Código em R:
> x <- c(267.2,293.7,250,310.8,315.2,191.8,290.6,279.5,330.6,227.3,273.8,
  226.7,251.7,239.7,296.3,266.1,194.8,227.7,211.6,232.1,256.8,262.3,
  262.1,266.8)
> y <- c(175.4,196.9,184.9,218.9,239.5,124.8,197.5,201.2,237.5,140.7,196.3,
  177.4,163.6,173.4,166.7,233.4,124.1,126.7,180.3,175.9,186.2,190.3,
  192.9,186.5)
> t.test(x, y, alternative="greater", paired=TRUE, conf.level=0.94)

Paired t-test

data: x and y
t = 17.367, df = 23, p-value = 5.119e-15
alternative hypothesis: true difference in means is greater than 0
94 percent confidence interval:
 69.31907      Inf
sample estimates:
mean of the differences
```

6. a) Sim (p-valor = $1,359e-05 < 0,01$).

```
> # Código em R:
> x <- c(217,230,227,245,206,230,229)
> y <- c(184,199,190,215,183,182,198)
>
> t.test(x, y, alternative="greater", paired=TRUE, conf.level=0.99)

Paired t-test

data:  x and y
t = 11.41, df = 6, p-value = 1.359e-05
alternative hypothesis: true difference in means is greater than 0
99 percent confidence interval:
 24.11784      Inf
sample estimates:
mean of the differences
      33.28571
```

- b) Não (p-valor = $0,1515 > 0,01$).

```
> t.test(x, y, alternative="greater", mu=30, paired=TRUE, conf.level=0.99)

Paired t-test

data:  x and y
t = 1.1263, df = 6, p-value = 0.1515
alternative hypothesis: true difference in means is greater than 30
99 percent confidence interval:
 24.11784      Inf
sample estimates:
mean of the differences
      33.28571
```

- c) Sim, pois no 1º caso ($\Delta = 0$), p-valor $< 0,05$; e no 2º caso ($\Delta = 30$), p-valor $> 0,05$.

7. a) p-valor = 0,00817176; logo, rejeitamos $H_0 : \mu_1 - \mu_2 = 10$ ao nível 5% de significância.

```
> # Código em R:
> n<-20
> d_barra<-13.5
> s2d<-28.1
> sd<-sqrt(s2d/n)
> t<-(d_barra-10)/sd
> t
[1] 2.952772
> pvalor<-pt(t, df=n-1,lower.tail=FALSE)*2
> pvalor
[1] 0.00817176
```

- b) p-valor = 0,1712394; logo, não rejeitamos $H_0 : \sigma_1^2 = \sigma_2^2$ ao nível 5% de significância.

```
> # Código em R:  
> dx<-11  
> dy<-14  
> varx<-144  
> vary<-256  
> Fcalc<-varx/vary # estatística Fcalc.  
> Fcalc  
[1] 0.5625  
> pvalor<-pf(Fcalc, dx, dy, lower.tail=TRUE)  
> pvalor  
[1] 0.1712394
```


- c) p-valor = 0,3305299; logo, não rejeitamos $H_0 : \sigma_1^2 = \sigma_2^2$ ao nível 5% de significância.
p-valor = 0,352015; logo, não rejeitamos $H_0 : \mu_1 - \mu_2 = 5$ ao nível 5% de significância.

```
> # Código em R:  
> n1<-10; n2<-10; s1<-100; s2<-196; x1<-27.5; x2<-20.4; delta<-5  
> # Testando igualdade x diferença entre as variâncias:  
> Fcalc<-s1/s2 # estatística Fcalc.  
> pvalor<-pf(Fcalc, n1-1, n2-1, lower.tail=TRUE)*2  
> Fcalc; pvalor  
[1] 0.5102041  
[1] 0.3305299  
> # Testando igualdade x diferença entre as médias:  
> S<-sqrt(((n1-1)*s1+(n2-1)*s2)/(n1+n2-2))  
> T<-(x1-x2-delta)/(S*sqrt((1/n1)+(1/n2)))  
> pvalor<-pt(T, n1+n2-2, lower.tail=FALSE)  
> T; pvalor  
[1] 0.3859877  
[1] 0.352015
```

Capítulo 7

1. a)

```
> # Código em R:  
> A<-c(51,56,69,77,69,48,41,81)  
> B<-c(80,86,101,111,101,76,67,115)  
> C<-c(57,62,73,81,73,54,48,84)  
> D<-c(68,72,82,89,82,66,59,92)  
> E<-c(50,56,71,81,71,46,37,85)  
> dados<-c(A,B,C,D,E)  
> boxplot(A,B,C,D,E, names=c("A","B","C","D","E"), ylab="Preço (  
  milhares de reais)", col=c("darkblue","green","red","yellow","grey"  
  ))
```



A partir dos *box plots* apresentados na figura acima, observa-se que a variabilidade dos preços é praticamente a mesma para as cinco cidades consideradas. Além disso, nota-se que, em geral, os maiores preços foram observados para a cidade B.

- b) $p\text{-valor} = 0,001006 < 0,10$; logo, rejeitamos $H_0 : E_i = 0$ para todo $i, i = A, B, C, D, E$. Ou seja, os dados apresentam evidências, a 10% de significância, de que existe diferença real entre os preços médios dos terrenos das cinco cidades.

```
> dados<-c(A,B,C,D,E)
> cidade<-c(rep("A",length(A)),rep("B",length(B)),rep("C",length(C)),
  rep("D",length(D)),rep("E",length(E)))
> mydata<-data.frame(cidade, dados)
> anova(lm(dados ~ cidade, mydata))    # ANOVA
Analysis of Variance Table

Response: dados
          Df Sum Sq Mean Sq F value    Pr(>F)
cidade      4 5285.1  1321.29   5.8707 0.001006 **
Residuals  35 7877.2    225.06
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

2. a) Sim, pois $p\text{-valor} = 0,02439 < 0,05$.

```
> # Código em R:
> A<-c(2.8,5.1,3.9,5.0,5.9,5.8)
> B<-c(2.2,5.4,4.1,2.3,2.5,1.2)
> C<-c(5.5,5.2,4.7,4.5,4.6)
> dados<-c(A,B,C)
> tratamento<-c(rep("A",length(A)),rep("B",length(B)),rep("C",length(C)
  )))
> mydata<-data.frame(tratamento, dados)
> anova(lm(dados ~ tratamento, mydata))    # ANOVA
Analysis of Variance Table
```

```

Response: dados
      Df Sum Sq Mean Sq F value    Pr(>F)
tratamento  2 13.611   6.8056   4.8986 0.02439 *
Residuals  14 19.450   1.3893
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

b) Não, pois $p\text{-valor} = 0,02439 > 0,01$. Logo, a 1% de significância, não rejeitamos a hipótese de igualdade entre as médias dos tratamentos comparados.

3. (a) = 16; (b) = 65,3895; (c) = 45,88; (d) = 2,8675; (e) = 7,601221.

4. $p\text{-valor} = 0,06581 > 0,02$; logo, não rejeitamos $H_0 : E_i = 0$ para todo i , $i = \text{I, II, III, IV}$. Ou seja, não há evidências, a 2% de significância, de que os pesos médios diferem de um bando para outro.

```


> # Código em R:
> I<-c(385,369,394,399,373,380,359,346,347,393)
> II<-c(365,349,374,379,353,360,339,326,327,373)
> III<-c(374,359,383,388,363,370,350,337,338,382)
> IV<-c(364,349,373,378,353,360,340,327,328,372)
> dados<-c(I,II,III,IV)
> bando<-c(rep("I",length(I)),rep("II",length(II)),rep("III",length(III)),
  rep("IV",length(IV)))
> mydata<-data.frame(bando, dados)
> anova(lm(dados ~ bando, mydata))    # ANOVA
Analysis of Variance Table

Response: dados
      Df  Sum Sq Mean Sq F value    Pr(>F)
bando    3  2760.1   920.03   2.6175 0.06581 .
Residuals 36 12653.8   351.49
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

5. Apesar do pequeno desvio nas caudas (Normal Q-Q *plot*), não rejeitamos a hipótese de normalidade dos resíduos, ao nível 5% de significância ($p\text{-valor}$ do teste de Lilliefors = 0,0612). Também não rejeitamos a hipótese de homocedasticidade dos resíduos ($p\text{-valor}$ do teste de Levene = 0,9968).

6. a)



Os *box plots* acima indicam que pode haver diferenças entre os níveis dos fatores, isto é, entre fornecedor e máquina.

```
> # Código em R:
> f1<-c(6.01,6.00,6.02,6.02,6.00,6.01,5.99,5.98,5.98,6.02,5.99,5.99,
        6.03,5.98,6.02,6.00,6.01,6.01,6.02,6.00)
> f2<-c(5.89,5.91,5.89,5.90,5.88,5.90,5.91,5.90,5.89,5.89,6.02,6.01,
        6.02,6.03,6.01,6.02,6.03,6.02,6.02,6.03)
> dados<-c(f1,f2)
> fornecedor<-c(rep("Fornecedor 1",length(f1)),rep("Fornecedor 2",
        length(f2)))
> maquina<-c(rep("Máquina 1", 10),rep("Máquina 2",10),rep("Máquina 1"
        ,10),rep("Máquina 2",10))
> mydata<-data.frame(fornecedor, maquina, dados) # Cria o data frame
> par(mfrow=c(1,2))
> boxplot(dados ~ fornecedor, names=c("Fornecedor 1","Fornecedor 2"),
        ylab="Diâmetro (mm)", xlab="", col=c("darkblue","green"))
> boxplot(dados ~ maquina, names=c("Máquina 1","Máquina 2"), ylab="Diâ
        metro (mm)", xlab="", col=c("red","yellow"))
```

- b) b.1) Sim (p-valor < 2,2e-16).
 b.2) Sim (p-valor = 1,919e-13).
 b.3) Sim (p-valor < 2,2e-16).


```
> anova(lm(dados ~ fornecedor*maquina, mydata)) # ANOVA
Analysis of Variance Table

Response: dados
          Df    Sum Sq  Mean Sq F value    Pr(>F)
fornecedor  1  0.020703  0.020703   128.72 1.919e-13 ***
maquina     1  0.040322  0.040322   250.71 < 2.2e-16 ***
fornecedor:maquina 1  0.037823  0.037823   235.17 < 2.2e-16 ***
Residuals   36  0.005790  0.000161
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

7. (a) = 2; (b) = 4; (c) = 10.683,72; (d) = 5.341,86; (e) = 19.559,36; (f) = 28,96782; (g) = 3,559544. A partir dos p-valores apresentados na tabela, considerando o nível 1% de significância, concluímos que: (i) existe influência do fator A no resultado obtido (p-valor = 0,0020); (ii) existe influência do fator B no resultado obtido (p-valor = 1,91e-07); (iii) não há evidências de interação entre o fator A e o fator B (p-valor = 0,0186).

Capítulo 8

1. (X_1, Y_1) : $r = -0,9782253$
 (X_2, Y_2) : $r = 0,04677649$
 (X_3, Y_3) : $r = -0,2569002$
 (X_4, Y_4) : $r = 0,9707028$



A partir dos resultados dos coeficientes de correlação linear e dos diagramas de dispersão construídos, temos indicativos de que: (i) existe alta correlação linear negativa (ou inversa) entre X_1 e Y_1 ; (ii) a correlação linear entre X_2 e Y_2 é muito fraca ou inexistente (valor de r próximo de zero); (iii) a relação entre X_3 e Y_3 é não linear (quadrática); (iv) existe alta correlação linear positiva (ou direta) entre X_4 e Y_4 .

```
> # Código em R:
> X1<-c(20,21,14,18,19,26)
> Y1<-c(5,4,10,8,7,1)
> X2<-c(1.5,1.2,-1.1,-0.6,1.6,1.0,-1.4,0.0,-0.1)
> Y2<-c(11.2,6.3,16.3,17.1,11.8,14.7,1.8,13.6,10.5)
> X3<-c(-1.74,0.27,-1.38,-0.86,0.42)
```

```

> Y3<-c(3.28,0.54,0.33,-1.05,1.38)
> X4<-c(-1.8,0.4,0.3,1.2,0.2,0.5,-0.6,-0.3,-0.7,0.1)
> Y4<-c(3.3,5.4,5.1,6.5,4.9,5.8,4.3,5.0,4.2,5.1)
> # diagramas de dispersão:
> par(mfrow=c(2,2))
> plot(X1,Y1); plot(X2,Y2); plot(X3,Y3); plot(X4,Y4)
> # coeficientes de correlação linear de Pearson:
> cor(X1,Y1); cor(X2,Y2); cor(X3,Y3); cor(X4,Y4)
[1] -0.9782253
[1] 0.04677649
[1] -0.2569002
[1] 0.9707028

```

2. (X_1, Y_1) : p-valor = 0,000706; logo, rejeitamos $H_0 : \rho = 0$ ao nível 5% de significância.
 (X_2, Y_2) : p-valor = 0,9049; logo, não rejeitamos $H_0 : \rho = 0$ ao nível 5% de significância.
 (X_3, Y_3) : p-valor = 0,6765; logo, não rejeitamos $H_0 : \rho = 0$ ao nível 5% de significância.
 (X_4, Y_4) : p-valor = 3,111e-06; logo, rejeitamos $H_0 : \rho = 0$ ao nível 5% de significância.

```

> cor.test(X1,Y1)

Pearson's product-moment correlation

data:  X1 and Y1
t = -9.4266, df = 4, p-value = 0.000706
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.9977127 -0.8086163
sample estimates:
      cor
-0.9782253

> cor.test(X2,Y2)

Pearson's product-moment correlation

data:  X2 and Y2
t = 0.12389, df = 7, p-value = 0.9049
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.6371381  0.6894793
sample estimates:
      cor
0.04677649

> cor.test(X3,Y3)

Pearson's product-moment correlation

data:  X3 and Y3
t = -0.46042, df = 3, p-value = 0.6765
alternative hypothesis: true correlation is not equal to 0

```

```

95 percent confidence interval:
-0.9286777 0.8086504
sample estimates:
      cor
-0.2569002


> cor.test(X4,Y4)

Pearson's product-moment correlation

data:  X4 and Y4
t = 11.426, df = 8, p-value = 3.111e-06
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.8772094 0.9932652
sample estimates:
      cor
0.9707028

```

3. a) O diagrama de dispersão, logo abaixo, indica que há uma relação linear e positiva (ou direta) entre as variáveis X (escolaridade do chefe de família) e Y (renda familiar mensal).



```

> # Código em R:
> X<-c(7,8,10,14,6,14,15,11,11,4,6,6,12,8,13,9,12,15,8,13,15,6,11,5,
      7,8,4,8,14,8)
> Y<-c(3949,5535,5742,6454,4147,7162,9424,5472,4512,1946,3228,2974,
      6562,4205,6889,5628,5636,9060,4797,7262,6264,3499,5744,4147,5691,
      6031,1687,4004,7710,3740)
> # diagrama de dispersão:
> plot(X,Y, xlab="Tempo de estudo (anos)", ylab="Renda familiar mensal
      (reais)")

```

b) $r = 0,886875 \rightarrow$ correlação linear positiva e forte entre X e Y

```
> # coeficiente de correlação linear de Pearson:  
> cor(X,Y)  
[1] 0.886875
```

c) $\hat{Y} = 761,3 + 473,1X$

```
> # ajuste do modelo:  
> ajuste<-lm(Y~X)  
> ajuste
```


Call:

```
lm(formula = Y ~ X)
```

Coefficients:

(Intercept)	X
761.3	473.1

d)



```
> abline(ajuste) # traça o modelo no gráfico
```

e) $\hat{\beta}_0 = 761,3$ reais : é a renda familiar mensal esperada (ou média) de uma família cuja pessoa de referência (chefe de família) não possui escolaridade (isto é, zero anos de estudo).

f) $\hat{\beta}_1 = 473,1$ reais : a cada ano de escolaridade do chefe de família, a renda familiar mensal aumenta, em média, 473,1 reais.

g) $\overline{R}^2 = 0,7789$, o que indica que 77,89% da variação da renda familiar mensal é explicada pela escolaridade do chefe de família.

```
> summary(ajuste)
```

```

Call:
lm(formula = Y ~ X)


Residuals:
    Min       1Q   Median       3Q      Max
-1594.3  -605.1  -112.7   497.7  1617.8

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   761.29     474.71   1.604   0.12
X             473.13      46.58  10.158 6.81e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 872.9 on 28 degrees of freedom
Multiple R-squared:  0.7865, Adjusted R-squared:  0.7789
F-statistic: 103.2 on 1 and 28 DF, p-value: 6.808e-11

```

4. A partir do gráfico de resíduos *versus* valores preditos (ou ajustados) e do resultado do teste de comparação de variâncias (p-valor = 0,3871), não há evidências contra a homocedasticidade dos resíduos. A partir do Q-Q *plot* e do resultado do teste de Shapiro-Wilk (p-valor = 0,5564), não há evidências contra a normalidade dos resíduos. Logo, o modelo ajustado é adequado.



```

> # Código em R para realizar a análise de resíduos:
> plot(fitted(ajuste), residuals(ajuste), xlab="Valores ajustados", ylab="
  Resíduos")
> abline(h=0)
> # Teste de homogeneidade de variâncias:
> var.test(residuals(ajuste)[1:15], residuals(ajuste)[16:30])

F test to compare two variances

```

```

data: residuals(ajuste)[1:15] and residuals(ajuste)[16:30]
F = 0.62327, num df = 14, denom df = 14, p-value =
0.3871
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.2092509 1.8564709
sample estimates:
ratio of variances
      0.6232722

> # Gráfico Q-Q Normal dos resíduos:
> qqnorm(residuals(ajuste), xlab="Quantis teóricos", ylab="Quantis
  amostrais", main="Normal Q-Q plot")
> qqline(residuals(ajuste))
> # Teste de normalidade:
> shapiro.test(residuals(ajuste))

      Shapiro-Wilk normality test

data: residuals(ajuste)
W = 0.97063, p-value = 0.5564

```

5. (a) = 1; (b) = 13; (c) = 14; (d) = 183,6236; (e) = 1.103,3097; (f) = 14,12489; (g) = 78,11103; (h) = -3,05089; (i) = 8,836898; (j) $\approx$ 66,86827; (k) $\approx$ 0,8225956. Com base nos resultados obtidos, temos evidências de que a altura do indivíduo explica a variação do peso.

6. a) Modelo linear: $\hat{Y} = -137,00 + 46,29X$
 Modelo exponencial: $\hat{Y} = 1,34062 \times 1,826816^X$
 Modelo potência: $\hat{Y} = 0,9760081X^{2,404316}$

```

> # Código em R:
> X<-c(1,2,3,4,5,6,7,8,9,10)
> Y<-c(2,5,7,19,31,48,96,164,289,515)
> ajuste.L<-lm(Y~X)      # ajuste do modelo linear
> ajuste.L

Call:
lm(formula = Y ~ X)

Coefficients:
(Intercept)          X
      -137.00         46.29

> ajuste.E<-lm(log(Y)~X)  # ajuste do modelo exponencial
> ajuste.E

Call:
lm(formula = log(Y) ~ X)

Coefficients:
(Intercept)          X

```

```

0.2931      0.6026

> ajuste.P<-lm(log(Y)~log(X))    # ajuste do modelo potencia
> ajuste.P

Call:
lm(formula = log(Y) ~ log(X))

Coefficients:
(Intercept)      log(X)
    -0.02428      2.40432

```

- b) Modelo linear: $\overline{R}^2 = 0,6697$
 Modelo exponencial: $\overline{R}^2 = 0,9939$
 Modelo potência: $\overline{R}^2 = 0,9191$

```

> summary(ajuste.L)

Call:
lm(formula = Y ~ X)

Residuals:
    Min       1Q   Median       3Q      Max
-92.75 -67.86 -12.02   39.41 189.09

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -137.00      65.47  -2.093  0.06974 .
X              46.29      10.55   4.387  0.00233 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 95.84 on 8 degrees of freedom
Multiple R-squared:  0.7064, Adjusted R-squared:  0.6697
F-statistic: 19.25 on 1 and 8 DF, p-value: 0.002326

> summary(ajuste.E)

Call:
lm(formula = log(Y) ~ X)

Residuals:
    Min       1Q   Median       3Q      Max
-0.20256 -0.06850 -0.02562   0.09667   0.24101

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.29313     0.09791   2.994   0.0172 *
X            0.60257     0.01578  38.186 2.43e-10 ***
---

```

```

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1433 on 8 degrees of freedom
Multiple R-squared:  0.9945, Adjusted R-squared:  0.9939
F-statistic: 1458 on 1 and 8 DF, p-value: 2.429e-10

> summary(ajuste.P)

Call:
lm(formula = log(Y) ~ log(X))

Residuals:
    Min       1Q   Median       3Q      Max
-0.67122 -0.39959 -0.06139  0.33705  0.73231

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.02428    0.39333  -0.062   0.952
log(X)       2.40432    0.23654  10.164 7.51e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5202 on 8 degrees of freedom
Multiple R-squared:  0.9281, Adjusted R-squared:  0.9191
F-statistic: 103.3 on 1 and 8 DF, p-value: 7.514e-06

```

- c) O modelo exponencial (maior $\overline{R}^2$).
- d) $\hat{Y} = 1.852,01$ colônias visíveis
7. Como $F = 32,11 > F_{tab} = F_{(1,5)}(0,95) = 6,607891$, então temos evidências, ao nível 5% de significância, de que o tempo de estudo explica a nota na prova da disciplina. Além disso, $\hat{\beta}_1 = 76,44$ indica que a cada hora a mais de estudo, a nota na prova da disciplina aumenta, em média, 76,44.

```

> # Código em R:
> qf(0.95, 1, 5)
[1] 6.607891

```

